Министерство образования и науки Российской Федерации
федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет «Московский институт электронной техники»

Архитектура вычислительных систем (организация ЭВМ) и Ассемблер

с приложением методических указаний к лабораторным работам

Гагарина Л. Г., Кононова А. И.

Актуальную версию можно найти на `https://gitlab.com/illinc/gnu-asm`

2024

Аннотация

«Архитектура вычислительных систем (организация ЭВМ) и Ассемблер» (учебное пособие).

В пособии представлен систематизированный курс одной из основных дисциплин специализированной подготовки бакалавров по направлениям 09.03.04 «Программная инженерия» и 01.03.04 «Прикладная математика» с точки зрения прикладного программирования и парадигмы кроссплатформенности.

Рассмотрены основы архитектуры вычислительных систем как системной дисциплины. Представлен обзор архитектуры популярных процессоров семейства x86, в том числе шестидесятичетырёхбитных, представление основных типов данных в памяти компьютера, основные команды набора x86 и синтаксис AT&T. Обозначена проблематика прикладного кроссплатформенного программирования, объединяющего язык высокого уровня и язык Ассемблера.

Строгий стиль изложения сопровождается доступными для понимания пояснениями и многочисленными примерами, а также контрольными вопросами к каждой главе, необходимыми для глубокого усвоения материала. Книга адресована студентам технических специальностей, соискателям степени бакалавра по указанным направлениям, слушателям институтов повышения квалификации, может быть использована для самообразования.

Приложение Б содержит методические указания к лабораторным работам.

Введение

Красота — это страшная сила
И нет слов, чтобы это сказать.
Красота — это страшная сила,
Но мне больше не страшно, я хочу знать.

Б. Б. Гребенщиков. Красота (это страшная сила)

Программирование на языке Ассемблера в этой книге описано на примере наиболее известной и доступной для экспериментов архитектуры — линейки x86. Исторически сложилось так, что разработчик данной архитектуры — компания Intel — использует один синтаксис языка Ассемблера (он так и называется — синтаксис Intel), а большая часть операционных систем, происходя от больших Unix'ов, предпочитает другой, так называемый синтаксис AT&T.

Синтаксис AT&T по умолчанию использует GNU Assembler (GAS) — неотъемлемая часть коллекции компиляторов GCC, используемая в процессе компиляции с различных языков высокого уровня, в частности, C, C++ и Фортран. GAS вместе с коллекцией GCC портирован более чем на 45 платформ, в том числе — на операционную систему Microsoft Windows для x86-совместимых процессоров (исторически этот порт носит название MinGW), так что распространённое мнение «AT&T — это только под Linux» в корне неверно. Напротив, использование GCC и AT&T позволяет сделать программу с ассемблерными вставками в код C++ столь же переносимой между операционными системами, как и чистый C++, а также облегчает переход на неинтеловские архитектуры.

Существующая на сегодняшний день литература по Ассемблеру x86 на русском языке в основном описывает синтаксис Intel, при этом практически отсутствует русскоязычная литература по синтаксису AT&T. Данное пособие призвано заполнить этот пробел.

В результате изучения курса «Архитектура вычислительных систем» студент будет:

- знать и понимать особенности архитектуры и принципы построения вычислительных систем;
- уметь применять язык низкого уровня Assembler, а также ассемблировать и отлаживать готовые программы на языке ассемблера IBM PC;
- владеть разработкой процедур и ассемблерных модулей в программах на языках высокого уровня.

Учебное пособие адресовано студентам бакалавриата по направлениям подготовки 09.03.04 «Программная инженерия» и 01.03.04 «Прикладная математика».

Особая благодарность группам «Аквариум» (Б. Б. Гребенщиков)
и «Оргия праведников» (С. А. Калугин),
а также писателям А. В. Жвалевскому и И. Е. Мытько
за разрешение использовать цитаты из их произведений в эпиграфах.
Вы делаете этот мир ещё прекраснее!

Глава 1. Понятие вычислительной системы (ВС)

Это требует, чтобы о нём написать. И напишу.

В. В. Маяковский. Я сам

Вычислительная система описывается как компонентами этой системы, так и языком программирования, предназначенным для взаимодействия с вычислительной машиной. В данной главе обе точки зрения рассматриваются на примере семейства x86, а также в разрезе истории развития вычислительной техники.

1.1. Терминология

— ...Дамы и господа! Вашему вниманию предлагается магический компьютер, сокращённо «магокомпьютер». Это новое слово в технологиях.
Сен напряг память, но был вынужден согласиться, что слово «магокомпьютер» — действительно новое.

А. В. Жвалевский, И. Е. Мытько.
Девять подвигов Сена Аесли. Подвиги 5-9

Перед тем, как рассматривать архитектуру вычислительных систем, приведём определения из основных стандартов и справочной литературы.

Архитектура системы в стандарте ANSI/IEEE Std 1471-2000 (IEEE Recommended Practice for Architectural Description of Software-Intensive Systems) определяется как фундаментальная организация системы, реализованная в её компонентах, их взаимоотношениях друг с другом и средой, а также в принципах, определяющих её конструкцию (проектирование, дизайн) и развитие [71].

Таким образом, архитектура вычислительной системы реализована в компонентах этой системы и их взаимоотношениях. Что же такое вычислительная система?

Вычислительная система (ВС), согласно Воройскому [30], определяется как:

1. Совокупность ЭВМ и средств программного обеспечения, предназначенная для выполнения вычислительных процессов.
2. Любая автоматизированная система, основанная на использовании ЭВМ.

Термин «автоматизированная система» (АС), в свою очередь, словарь Воройского также определяет двумя способами:

1. Совокупность управляемого объекта и автоматических управляющих устройств, в которых часть функций управления выполняет человек-оператор.
2. Комплекс технических, программных, др. средств и персонала, предназначенный для автоматизации различных процессов.

В отличие от автоматической системы не может функционировать без участия человека.

Если же обратиться к комплексу стандартов на автоматизированные системы [32], получим третье определение: автоматизированная система — система, состоящая из персонала и комплекса средств автоматизации его деятельности, реализующая информационную технологию выполнения установленных функций.

Таким образом, вычислительная система глобально может быть представлена как совокупность человека (оператора или программиста), технических средств (вычислительной машины, или компьютера) и связывающих их программных средств.

Соответственно, архитектура вычислительной системы может быть описана двояко:

– **структурная декомпозиция** рассматривает ВС с точки зрения её аппаратных составляющих и физических связей между ними и позволяет выделить её функциональные компоненты, в том числе компоненты, предназначенные для хранения и обработки программ, и компоненты, взаимодействующие с пользователем;

– **иерархическая декомпозиция** рассматривает ВС с точки зрения её логическо-информационной структуры и описывает языки взаимодействия программиста с программными и техническими средствами системы.

1.2. Структурная декомпозиция вычислительной системы

Кура
дура
процедура состоит из трёх частей:
карбюратор
вентилятор и коробка скоростей!

Надпись на парте

Структурная декомпозиция применяется к аппаратной части ВС — вычислительной машине, то есть компьютеру.

Если посмотреть на персональный компьютер, то он, как правило, состоит из **системного блока** и **внешних устройств,** среди которых обязательно присутствуют **устройства ввода-вывода,** предназначенные для взаимодействия с пользователем — экран, клавиатура, мышь и т. д.

Внутри системного блока находятся **внутренние устройства,** из которых основными являются:

– системная, или материнская плата;
– центральный процессор;

– оперативная память (оперативное запоминающее устройство — ОЗУ);
– внешняя, или долговременная память (жёсткие диски, SSD и т. д.);
– видеокарта;
– звуковая карта и т. д.

Внутренние устройства защищены корпусом системного блока и получают постоянный ток через блок питания.

Все компоненты компьютера связывает воедино системная плата (рис. 1.1). Важную роль играют входящие в её состав два мощных контроллера-концентратора — северный мост и южный мост, обеспечивающие согласование и передачу информационных потоков между различными компонентами системного блока и внешними устройствами.

Северный мост определяет частоту системной шины, тем самым — вид и объём ОЗУ, тип шины видеоадаптера (обычно это PCI Express или AGP), осуществляет обмен между центральным процессором и скоростными устройствами, это:

– оперативная память (ОЗУ);
– видеокарта;
– южный мост.

Южный мост осуществляет обмен с устройствами по низкоскоростным интерфейсам, это:

– часы;
– энергозависимая память (ПЗУ);
– контроллер SATA;
– контроллер IDE;
– контроллер прерываний;
– контроллер USB;
– контроллер прямого доступа.

Внутренняя шина, связывающая северный мост и южный мост, обеспечивает непрерывность потоков информации.

Взаимосвязь различных элементов системной платы и устройств обеспечивают различные системные шины (магистрали). Иногда **системной шиной** называют только шину, связывающую процессор и северный мост.

Совокупность проводов системной магистрали можно разбить на четыре группы (рис. 1.2):

– шина питания (так как по этой шине не передаётся никакой информации, её часто опускают на схемах);
– шина управления, используемая для организации обмена самой магистрали;
– шина данных;
– шина адреса.

Шины питания и управления связывают все устройства, в том числе **тактовый генератор,** предназначенный для синхронизации работы различных устройств системной платы. Тактовый генератор задаёт частоту работы процессора как самого

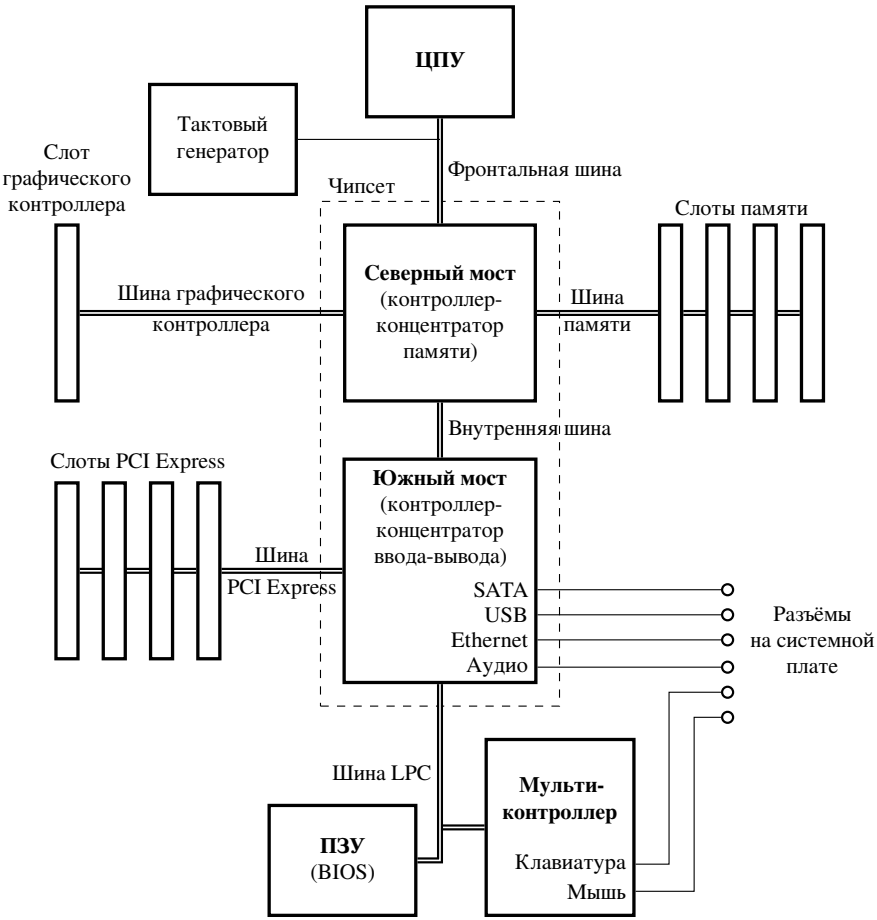

Рис. 1.1. Схема системной платы

быстрого устройства; частоты более медленных устройств являются делителями частоты процессора.

Кроме оперативной памяти в ВС имеется **постоянное запоминающее устройство (ПЗУ)** — энергонезависимая память, в которой записана неизменяемая информация, она сохраняется после отключения питания. Там хранится микропрограмма управления вычислительной машиной. Она обязательно включает программы начальной загрузки и самотестирования.

В постоянном запоминающем устройстве персонального компьютера записывается BIOS (Basic Input/Output System — базовая система ввода/вывода), вклю-

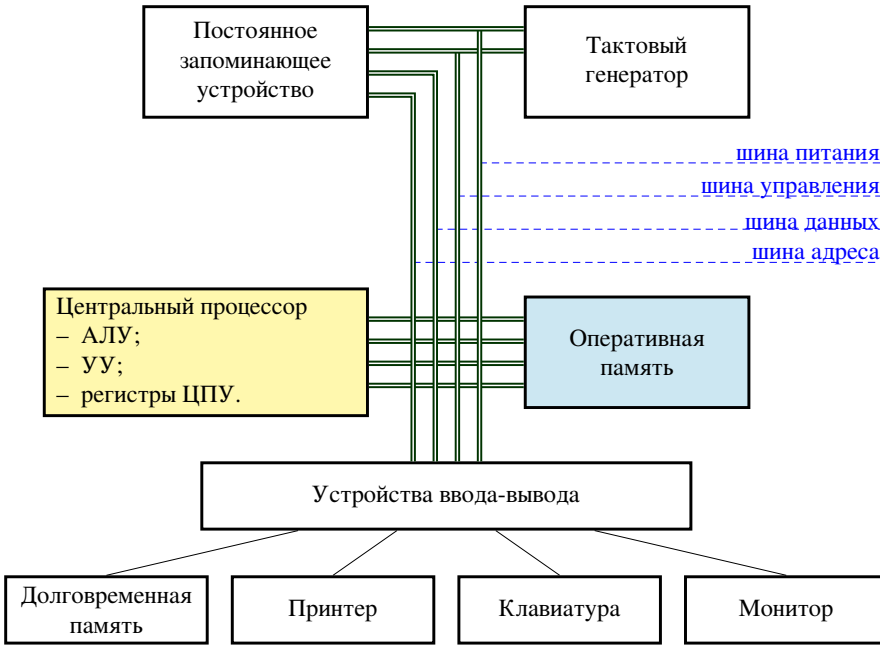

Рис. 1.2. Структура системной шины

чающая, кроме загрузчика, также настройки и функции ввода/вывода с помощью программных прерываний. Ввод-вывод при помощи BIOS доступен только в реальном режиме работы компьютера. Современные операционные системы сразу после загрузки переводят компьютер в защищённый режим и не используют BIOS.

Сама операционная система, как и загружаемые ею программы, располагается в **оперативной** (энергозависимой) памяти.

Центральный процессор (центральное процессорное устройство, ЦПУ) является «мозгом» ВС. Он исполняет код программ. ЦПУ часто называют просто процессором, иногда — микропроцессором (МП). Исторически микропроцессор — это процессор, выполненный на одной микросхеме; сейчас другие варианты исполнения нерентабельны и эти два термина стали синонимами. Ранее для специализированных процессоров, расширяющих функциональность ЦПУ, использовался термин «сопроцессор», но в настоящее время сопроцессоры либо вошли в состав ЦПУ (в частности, математический сопроцессор x87 входит в ядро современных ЦПУ семейства x86), либо получили иные названия (так, графический сопроцессор обычно называется видеокартой или графическим ускорителем).

Центральный процессор включает:

– арифметико-логическое устройство (АЛУ), выполняющее обработку данных;

– управляющее устройство (УУ), декодирующее поступающие в процессор команды и формирующее на их основе сигналы для АЛУ;
– регистры — сверхбыструю память особой структуры и малого объёма, предназначенную для временного хранения данных. Часть регистров может быть использована программистом по своему усмотрению (регистры общего назначения), часть используется для специальных целей.

Также современные процессоры содержат кеш-память (сверхоперативную память), предназначенную для прозрачного временного хранения фрагментов оперативной памяти. Время обращения к кеш-памяти больше, чем к регистрам, но меньше, чем к ОЗУ.

1.2.1. Единицы измерения

Нам в школе выдали линейку,
Чтобы мерить объём головы.

Б. Б. Гребенщиков. Растаманы из глубинки

Базовой единицей измерения информации в современных ЭВМ является **бит** — двоичный разряд.

В соответствии с характеристиками магистрали и регистров вводятся дополнительные платформозависимые единицы измерения:

– машинное **слово** — разрядность регистров процессора и/или шины данных;
– **байт** — минимальный независимо адресуемый набор данных.

Понятие машинного слова возникло раньше понятия байта. Вначале минимально адресуемый блок памяти (байт) и блок, загружаемый или обрабатываемый за один раз (слово) всегда совпадали. В настоящее время машинное слово может быть как равно, так и кратно байту.

В настоящее время байт обычно составляет восемь бит, но существуют DSP-процессоры, для которых байт состоит из шестнадцати или двенадцати бит. На начальных этапах развития вычислительной техники размер байта вообще не был стандартизирован. Впервые термин «байт» был употреблён для совокупности шести битов.

Если необходимо описать именно восемь двоичных разрядов, используется термин **октет.** В частности, эта единица измерения используется при описании сетевых протоколов.

В семействе процессоров x86 используется восьмибитный байт. Длина машинного слова менялась от шестнадцати бит у первых моделей до шестидесяти четырёх у современных. При этом для совместимости документации термин «слово» остался за шестнадцатью битами. Тридцать два бита называют двойным словом, шестьдесят четыре — четверным и так далее.

Далее по тексту везде подразумевается, что байт состоит из восьми бит.

1.2.2. Порядок следования байтов

Вот в руке письмо, но вижу только буквы
И мне не вспомнить, как они собирались в слова.

Б. Б. Гребенщиков. Voulez-Vous Coucher Avec Moi?

Для начала уточним: в современных ВС память адресуется побайтово, при этом начальный адрес равен нулю, и адрес каждого следующего байта возрастает на единицу. То есть в качестве модели памяти можно рассматривать непрерывную ленту из последовательно расположенных байтов с непрерывно возрастающими на единицу номерами — адресами. Подобные последовательности принято записывать, следуя обычному направлению письма, то есть адреса возрастают слева направо. Адресом слова считается адрес его самого левого байта (далее будем обозначать его ζ).

Кроме того, число в вычислительных системах представляется в двоичной позиционной системе счисления, то есть в виде совокупности двоичных разрядов — битов. Каждый бит имеет свой вес, соответственно которому разряды также можно упорядочить — от младшего к старшему.

$$X = x_0 + x_1 \cdot 2 + \ldots + x_k \cdot 2^k, \;\; x_i \in \{0,1\} \tag{1.1}$$

Если число включает восемь бит (занимает один байт), то никакой неоднозначности нет — число имеет адрес, равный адресу единственного байта. Биты внутри байта не имеют адресов, но ранжируются по весу.

Если число включает шестнадцать бит, оно записывается двумя байтами. Каждый байт включает восемь смежных по старшинству разрядов числа (рис. 1.3, а).

$$X = \chi_0 + \chi_1 \cdot 256, \;\; \chi_i \in \{0,1,\ldots 255\} \tag{1.2}$$

При этом каждому байту числа можно сопоставить и его вес (старшинство его битов в числе), и адрес (расположение в памяти). На любой платформе байты двухбайтового числа (младший χ_0 и старший χ_1) расположены в памяти рядом, но друг относительно друга они могут располагаться по-разному.

Для двухбайтового числа возможны только два варианта:

- прямой порядок (также называемый little-endian, Intel или VAX) — младший байт слова расположен по младшему адресу (рис. 1.3, б);
- обратный (big-endian, Motorola или сетевой порядок) — младший байт слова расположен по старшему адресу (рис. 1.3, в).

Числа в любой позиционной системе счисления принято записывать в арабской традиции — младший разряд справа, старший слева. Содержимое памяти (дамп памяти), напротив, записывается, следуя европейскому направлению письма — младшие адреса слева, старшие справа. Из-за этого на рис. 1.3 именно прямой

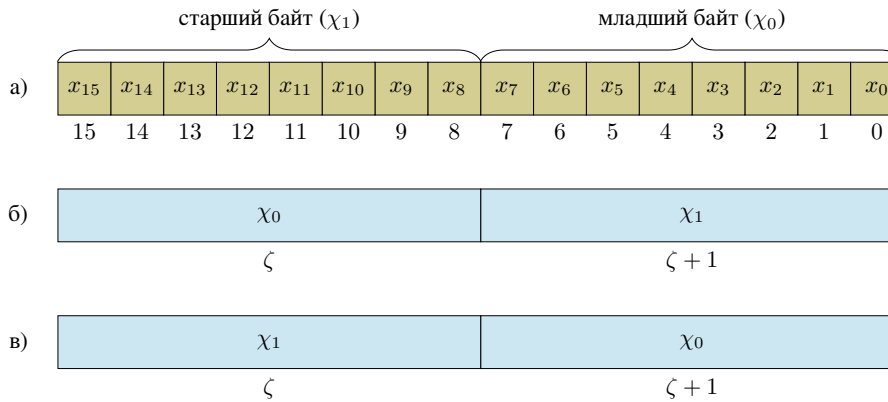

Рис. 1.3. Двухбайтовое число: а) биты старшего и младшего байтов, б) прямой порядок байтов в памяти, в) обратный порядок байтов в памяти

порядок выглядит «перевёрнутым», а обратный — соответствует привычной позиционной записи числа.

Значение каждого байта в дампе записывается двумя шестнадцатеричными цифрами в арабской традиции (как число, которое уже не может быть разделено на части с разными адресами). Соответственно, конкретные числа в дампе памяти выглядят ещё экзотичнее. Пусть необходимо записать в память вычислительной машины с восьмибитным байтом шестнадцатибитное число $x = \texttt{0x0A 0B}$. Оно содержит два байта: старший $\chi_1 = \texttt{0A}$, младший $\chi_0 = \texttt{0B}$. Дамп памяти с прямым порядком байтов, соответственно, будет выглядеть как $\chi_0\chi_1 = \texttt{0B 0A}$ (то есть разряды числа несколько «перетасованы»), с обратным порядком — как $\chi_1\chi_0 = \texttt{0A 0B}$.

Если число состоит из нескольких байтов, эти байты в памяти ВС также могут быть расположены друг относительно друга по-разному. Чаще всего используется прямой или обратный порядок (рис. 1.4).

Пусть необходимо записать в память вычислительной машины с восьмибитным байтом тридцатидвухбитное число $x = \texttt{0x0A 0B 0C 0D}$. Оно займёт четыре смежных байта с адресами $\zeta, \zeta+1, \zeta+2$ и $\zeta+3$. Наименьший из них (младший) адрес ζ будет адресом числа x. Рассмотрим, как оно будет расположено в памяти при разных порядках размещения.

При записи с обратным порядком байтов это число при просмотре дампа памяти будет выглядеть как 0A 0B 0C 0D, то есть старший байт 0A будет записан по младшему адресу ζ и, соответственно, напечатан первым (левее всего), байт 0B — по адресу $\zeta+1$, 0C— по адресу $\zeta+2$, младший байт 0D окажется записанным по

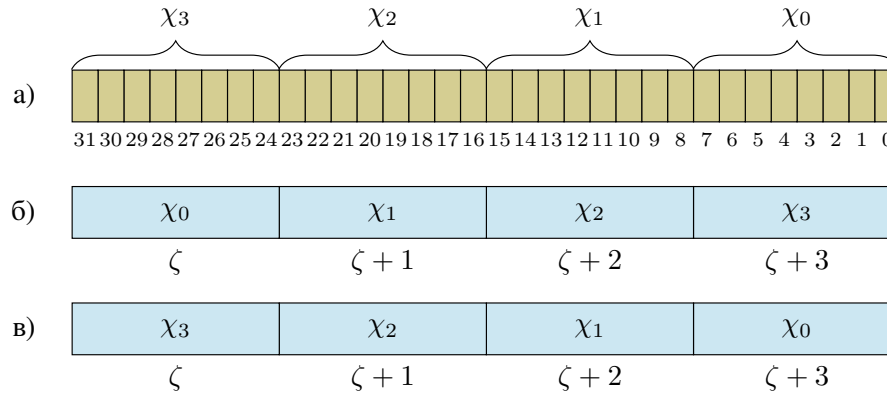

Рис. 1.4. Четырёхбайтовое число: а) байты и биты числа,
б) прямой порядок байтов в памяти,
в) обратный порядок байтов в памяти

самому старшему адресу $\zeta + 3$ и при просмотре или печати дампа памяти окажется правее остальных.

При записи с прямым порядком байтов это число будет выглядеть как `0D 0C 0B 0A`: младший байт `0D` записан по младшему адресу ζ, `0C` — по адресу $\zeta + 1$, `0D` — по адресу $\zeta + 2$, старший байт `0A` — по старшему адресу $\zeta + 3$.

Очевидно, что обратный порядок байтов позволяет легко читать числа, записанные в памяти. Обратный порядок принят в протоколе TCP/IP.

Прямой порядок байтов удобен при обработке чисел большой разрядности с помощью процессора малой разрядности, так как позволяет при сложении таких чисел обращаться к памяти последовательно в порядке возрастания адресов, а такие запросы выполняются быстрее (это учитывается в схемной реализации алгоритмов обработки).

Некоторые системы позволяют переключать используемый порядок байтов при помощи перемычки на материнской плате или программно (bi-endian, bytesexual).

Также иногда используется смешанный (middle-endian, mixed-endian) порядок байтов: байты в словах расположены в одном порядке, но, если число состоит из нескольких слов, слова располагаются наоборот. В частности, в PDP-11 младший байт слова расположен по младшему адресу, но младшее слово числа — по старшему (PDP-endian), так что наше число `0x0A 0B 0C 0D` имеет в памяти вид `0B 0A 0D 0C`. Другой вариант смешанного порядка — младший байт слова по старшему адресу, а младшее слово числа — по младшему, — даст `0C 0D 0A 0B`.

В процессорах семейства x86 используется прямой порядок байтов (порядок Intel). Он применяется даже к вещественным числам, которые не имеет смысла об-

рабатывать по частям: число `3F F0 00 00 00 00 00 00` (1.0, то есть единица с плавающей запятой двойной точности) будет записано в памяти как `00 00 00 00 00 00 F0 3F`.

1.2.3. Цикл выполнения команды

А ну,
раз взмахнул,
и ещё взмахну.

В. В. Маяковский. Мистерия-буфф

Проходящие через ВС потоки информации можно разделить на две основные группы: команды и данные.

Данные представляют собой информацию, подлежащую обработке и, как правило, размещаются в памяти ВС.

Команды предназначены организовать и выполнить обработку данных процессором ВС. Последовательность команд называется программой и также расположена в памяти ВС.

Выполнение команды процессором можно разбить на ряд этапов. Эту последовательность называют циклом выполнения команды, или рабочим циклом процессора.

1. Выборка (загрузка) команды из памяти. Адрес загружаемой команды хранится в специальном регистре — указателе команды (instruction pointer, ip). На рис. 1.5 указатель команд хранит адрес команды К-1.
   Двоичный код выбранной команды К-1 попадает в другой специальный регистр — регистр команд.
2. Декодирование команды. На этом этапе определяется, выбрана ли команда целиком или необходима дозагрузка (разные команды могут иметь различную длину). Когда команда загружена полностью, определяется наличие у неё операндов и их расположение, наличие числового результата и его расположение, а также формируется сигнал для АЛУ в соответствии с типом команды.
3. Выборка операндов. На следующем этапе из памяти загружаются операнды команды, которые затем помещаются в специальные регистры. Если операнды располагаются в регистрах общего назначения, они поступают в АЛУ на этапе выполнения [40].
4. Выполнение инструкции. Этап выполнения команды протекает различным образом для различных команд. В случае арифметических команд операнды поступают из регистров на вход АЛУ, АЛУ выполняет операцию, соответствующую команде, результат записывается в специальный регистр результата, формируются признаки результата (нулевое значение, некорректный результат и так далее).

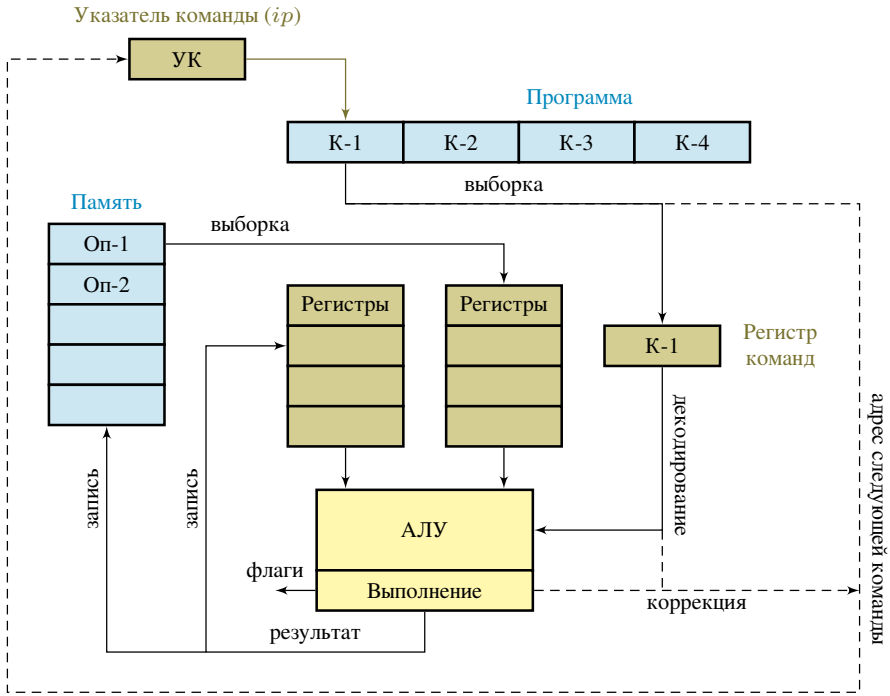

Рис. 1.5. Цикл выполнения команды

5. Запись результатов и установка флагов. На этом этапе результат загружается из регистра результата в расположение, определённое при декодировании (это может быть как ячейка памяти, так и регистр общего назначения). Признаки результата записываются в регистр флагов, доступный для анализа дальнейшими командами.
6. Формирование адреса следующей команды. В регистр указателя команд помещается адрес следующей команды. Если К-1 была командой условного или безусловного перехода, вызова или возврата из функции и т. п., адрес следующей команды можно узнать только после выполнения К-1.

Конвейер

Обработка разных команд при этом может вестись параллельно. Для этого цикл выполнения команды разбивают на несколько стадий — от двух для ранних ЭВМ, в частности, для ЭЦВМ Урал, до нескольких десятков в настоящее время. Выполнение каждой из этих стадий реализуется независимо от других.

При подобной реализации обработка следующей команды может выполняться, не дожидаясь конца текущей; такой способ организации вычислений называется **конвейером.**

Так, в большинстве случаев после команды К-1 будет выполняться команда, непосредственно следующая за ней в программе (К-2) — подобная последовательность называется естественным ходом выполнения. Таким образом, уже после полной выборки К-1 можно обновить указатель команд. Соответственно, если конвейер включает шесть стадий, описанных выше, то:

– пока К-1 будет декодироваться, можно выполнить выборку К-2;
– во время выборки операндов К-1 освободится блок декодирования, так что можно декодировать К-2;
– во время выполнения К-1 можно выбрать из памяти операнды К-2 и так далее.

Если нет сбоев или задержек, время выполнения команды будет определяться временем выполнения самой длинной стадии.

Сбои конвейерной обработки возможны в нескольких случаях:

1. Различные времена выполнения стадий для разных команд. Для решения этой проблемы перед блоками, исполняющими каждую стадию, вставляются блоки-диспетчеры, организующие очередь.
2. Конфликты по данным (в частности, операндом К-2 может быть результат К-1). Подобные зависимости отслеживаются на этапе декодирования и учитываются планировщиком на этапе выполнения. В некоторых процессорах планировщик может изменить порядок выполнения команд так, чтобы избежать зависимостей по данным между соседними командами.
3. Выполняемая команда нарушает естественный ход выполнения программы (например, К-1 может быть командой перехода к К-4). Это приводит к очистке и повторной загрузке конвейера, что существенно снижает быстродействие. Для предотвращения постоянной очистки конвейера в циклах современные процессоры используют различные алгоритмы прогнозирования переходов.

В линейке x86 конвейер впервые появился в процессоре i486 и включал пять стадий, что позволило более чем вдвое увеличить производительность.

Если процессор включает несколько конвейеров, возможна полностью одновременная обработка нескольких команд. Подобные процессоры называются **суперскалярными**. При этом параллельно могут выполняться только команды, не связанные зависимостями по данным. Отслеживание зависимостей и планирование исполнения реализуется внутри суперскалярных процессоров.

Перед выполнением программы её код должен быть загружен в память. Выполнение программы начинается с помещения в указатель команд ip адреса той команды, которая должна быть выполнена первой (точки входа).

Классификация по набору команд

По количеству и структуре команд архитектуры делятся на два основных типа.

1. CISC (complex instruction set computer — компьютер с набором сложных команд) — набор команд огромен и разнообразен, сами команды имеют переменную длину и сложную структуру, а также используют сложные режимы адресации; регистров мало и функции многих из них предопределены.
   Это было сделано для упрощения программирования в машинных кодах, компактности программ и удешевления самого процессора.
2. RISC (reduced instruction set computer — компьютер с набором упрощённых команд, архитектуры load/store) — набор команд включает команды простой постоянной структуры и фиксированной длины; при этом процессор содержит множество регистров, так что обращение к памяти производится только для загрузки (load) данных в регистры и выгрузки (store) их оттуда.
   Такая архитектура позволяет поднять частоту и параллельность и хорошо подходит для компиляции с языка высокого уровня.

Естественным продолжением идеологии RISC являются архитектуры типа VLIW (very long instruction word — сверхдлинное командное слово). Команда VLIW объединяет несколько команд RISC по числу конвейеров процессора; эти команды выполняются параллельно на соответствующих конвейерах.

В отличие от суперскалярных процессоров, где распределение команд по конвейерам происходит во время выполнения специальным устройством в составе процессора, командные слова VLIW формируются компилятором на этапе сборки программы. Это позволяет упростить и удешевить процессор, но усложняет разработку компиляторов и увеличивает длину программы.

1.2.4. Расположение программ и данных

Аксиома:
Все люди имеют шею.
Задача:
Как поэту пользоваться ею?

В. В. Маяковский. Пятый Интернационал

Данные и команды поступают в процессор по системной шине из памяти. Соответственно, память может быть общей для команд и данных — в этом случае для связи с процессором достаточно одной общей шины (рис. 1.6, а). Такая архитектура требует меньшего количества элементов и дорожек, поэтому она дешевле и компактнее.

Идея общей памяти и общей шины для программ и данных впервые была реализована Конрадом Цузе в Германии. В США подобная архитектура разрабатывалась в школе Мура при Пенсильванском университете научным коллективом, куда вхо-

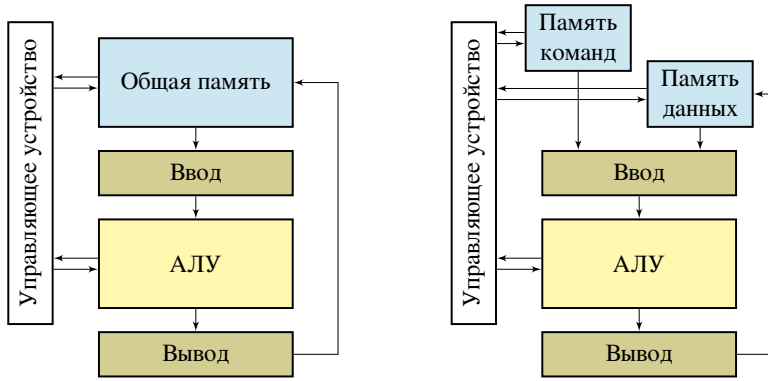

Рис. 1.6. Расположение программ и данных
в фон-неймановской (а) и гарвардской (б) архитектурах

дили, в частности, Джон Мокли и Джон Преспер Экерт. Незадолго до окончания работ результаты были описаны одним из участников проекта, Джоном фон Нейманом, без указания соавторов, а затем и опубликованы в таком виде куратором со стороны армии, Германом Голдштейном [22]. Так как фон Нейман к тому времени уже был известным математиком, архитектуру с общей шиной обычно называют фон-неймановской (или принстонской, по основному месту работы фон Неймана).

Общая шина для памяти программ и данных — узкое место фон-неймановской архитектуры.

Ускорить обмен с памятью можно, введя раздельные шины и, соответственно, физически раздельные запоминающие устройства для программ и для данных (рис. 1.6, б). Это дороже и сложнее в реализации, поэтому, хотя сама идея раздельных шин использовалась в позднем проекте Бэббиджа, а практический проект подобной архитектуры разрабатывался в Гарвардском университете США одновременно с проектом школы Мура, широко использоваться на практике этот подход стал относительно недавно. Архитектура с раздельными шинами программ и данных обычно называется гарвардской.

В персональных компьютерах используется фон-неймановская архитектура. В первых процессорах линейки x86 и соответствующих системных платах такое решение было использовано для удешевления, в последующих из соображений совместимости также используется единое пространство памяти. При этом современные процессоры имеют раздельную кеш-память для программ и данных.

1.2.5. Память

> На каждого с именем приходится тысяча, имеющих только фамилию.
> На каждого с фамилией приходятся тысячи — ни имя, ни фамилия
> которых никого не интересуют, кроме консьержки.
>
> *В. В. Маяковский. Семидневный смотр французской живописи*

Память в вычислительных системах образуют запоминающие устройства различной природы, имеющие разные характеристики по объёму памяти, по скорости обмена и по времени создания контакта (рис. 1.7).

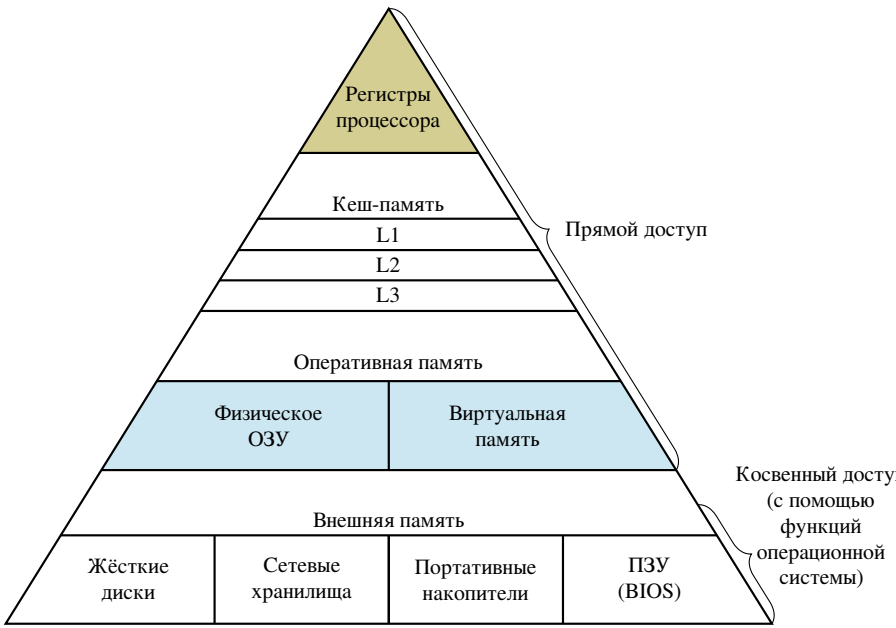

Рис. 1.7. Иерархия запоминающих устройств. Сверху вниз увеличивается объём и уменьшается скорость обмена

Самыми быстрыми — но при этом и самыми дорогими — являются регистры. Поэтому объём регистровой памяти очень ограничен.

Оперативное запоминающее устройство — ОЗУ — характеризуется оптимальным соотношением цена-быстродействие. ОЗУ в современных вычислительных системах имеют довольно большие объёмы памяти, но и они не беспредельны.

Внешние запоминающие устройства — ВЗУ — характеризуются большим временем создания контакта и низкой скоростью обмена. Но при этом они, во-первых,

могут иметь очень большие объёмы, и, во-вторых, несколько ВЗУ могут быть поочерёдно подключены и либо считаны, либо записаны. На заре компьютерной эры программист вручную организовывал обмен с нужными устройствами, учитывая их особенности и протоколы обмена.

Сейчас программисту не надо заботиться об этом. Операционные системы предоставляют ему необходимый объём памяти — в виртуальном адресном пространстве — и программист пользуется им, не заботясь о физических протоколах обмена. Операционная система сама организует и поддерживает соответствие между физическими адресами реальной памяти и адресами виртуальной памяти.

Плоская модель памяти

Современные операционные системы используют так называемую **плоскую модель памяти**. Каждой исполняющейся программе (процессу) предоставляется диапазон виртуальных адресов от 0 до 2^N, где N — разрядность системы (32 или 64). Каждому адресу соответствует один байт памяти.

При обращении к определённому виртуальному адресу он транслируется в физический аппаратным механизмом трансляции адресов, контролируемым операционной системой [2]. Виртуальный адрес может быть некорректным либо соответствовать байту в оперативной памяти или специализированной области жёсткого диска (в разделе подкачки; некоторые операционные системы также могут использовать файл подкачки). Операционная система может перемещать данные в оперативной памяти или из памяти на диск и обратно. Виртуальные адреса и, соответственно, указатели в программе при этом не изменяются.

Диапазон доступных физических адресов зависит от объёма установленных ОЗУ и возможностей системной платы. Разрядность физического адреса может составлять как 32, так и 40 или 52 бита [2].

Процесс не может обратиться к физическому адресу, принадлежащему другому процессу, без специальных средств межпроцессного взаимодействия.

Страничная организация памяти

Виртуальное адресное пространство плоской модели памяти делится на части определённого размера $pagesize$ — страницы.

Каждая страница включает непрерывный последовательный диапазон виртуальных адресов $[\zeta, \zeta + pagesize)$ и соответствует последовательному фрагменту ОЗУ или раздела подкачки на жёстком диске. Страница может быть вытеснена из ОЗУ на диск или загружена с диска в ОЗУ только целиком, то есть страница — минимальный квант памяти при её распределении между процессами.

Страницы в принципе могут иметь различные атрибуты защиты (разрешения чтения, записи, исполнения и т. д.).

1.2.6. Регистры

> Позволь нам пройти землею твоею: мы не пойдем по полям
> и по виноградникам и не будем пить воды из колодезей твоих;
> но пойдем дорогою царскою, не своротим ни направо,
> ни налево, доколе не перейдем пределов твоих.
>
> *Чс. 20:17*

Чем более объёмно запоминающее устройство, тем, как правило, медленнее оно работает. Оперативная память обладает меньшей скоростью, чем процессор; хотя частоты работы как оперативной памяти, так и процессора непрерывно растут, это соотношение сохраняется. В настоящее время частоты процессоров измеряются в гигагерцах, памяти — в сотнях мегагерц.

Соответственно, использование только данных, расположенных в оперативной памяти, сильно замедлило бы работу. Частично обмен данными ускоряется при помощи кеширования, но оно не уравнивает скорости процессора и памяти.

Кроме того, АЛУ процессора не может обрабатывать данные, расположенные непосредственно в оперативной памяти, так что, в частности, оператор $++i$ (или соответствующая ему команда ассемблера `inc i`) будет выполняться в несколько приёмов (раздел 1.2.3):

- загрузка значения переменной i из оперативной памяти в специальную ячейку внутри процессора — регистр;
- расчёт значения $i + 1$;
- выгрузка значения $i + 1$ из регистра в память по адресу переменной i,

причём загрузка-выгрузка в ОЗУ занимает больше времени, чем расчёт значения. Для ускорения работы часто используемые переменные логично хранить прямо в процессоре, выделив для этого некоторое количество регистров, не используемых в цикле обработки команд. Они называются регистрами общего назначения.

В отличие от специальных регистров, недоступных программисту, их можно указать в команде как источник или приёмник значения, то есть использовать как сверхбыстрые ячейки памяти. На уровне машинных команд регистры общего назначения обозначаются короткими номерами, на уровне ассемблера — именами. Регистры — часть процессора и работают с ним на одной частоте.

Специальные регистры процессора также имеют имена, но они используются только в документации [19]. Значение специальных регистров программист может узнать или модифицировать только косвенно, с помощью специальных команд. В частности, указатель команд ip изменяется командами условного или безусловного перехода.

Регистры процессоров семейства x86 подробнее описаны в разделе 3.3.

1.3. Иерархическая декомпозиция ВС

> Государь мой, прости, но для этой песни — я заимствую твой язык
> Ибо жизнь заставляет заняться работой, к которой я не привык.
>
> *С. А. Калугин. Открытое письмо ефрейтору Расчёскину*

Согласно Таненбауму [45], вычислительную систему можно представить в виде ряда уровней абстракции. Каждому уровню соответствует свой язык, программы на котором путём компиляции или интерпретации переводятся на язык нижележащего уровня.

Большинство современных систем включает шесть уровней [45]:

- уровень языка прикладных программистов;
- уровень ассемблера;
- уровень операционной системы;
- уровень архитектуры команд;
- микроархитектурный уровень;
- цифровой логический уровень.

Над этой иерархией языков находится прикладной программист и воплощаемый им алгоритм; под цифровым логическим уровнем — физическая элементная база.

Современная шестиуровневая структура сформировалась далеко не сразу и не является пределом развития. Примитивные счётные устройства (абак, суанпан, русские счёты) рассчитаны на взаимодействие человека напрямую с элементной базой. Развитие вычислительной техники и программной инженерии ведёт к постепенному наращиванию уровней абстракции.

Иногда между уровнем языка прикладных программистов и уровнем операционной системы находится уровень байт-кода или p-кода, интерпретируемого виртуальной машиной. Он не эквивалентен уровню ассемблера, так как не отражает специфику аппаратной части вычислительной системы.

1.3.1. Цифровой логический уровень

> Он лежит и ждёт, когда придёт сигнал. После этого нужно быстро — очень быстро — изменить ноль на единицу или единицу на ноль. Но сигнала всё нет.
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Порри Гаттер и Каменный Философ*

На цифровом логическом уровне существуют цифровые **сигналы**, которые могут принимать ограниченный набор значений. Для современных ЭВМ эти значения — 0 и 1.

Соответственно количеству состояний сигнала определяется базовая единица измерения информации. Так как современные ЭВМ двоичны, единицей информации считается бит — один двоичный разряд, который может находиться в двух состояниях — 0 и 1. Для троичных ЭВМ, таких как Сетунь, информация измеряется в тритах.

Сигналы обрабатываются базовыми элементами схем — **логическими вентилями,** преобразующими множество входных сигналов в выходной в соответствии с какой-либо из логических операций (в частности, «и», «или», «не», «и-не»).

Существует множество стандартов изображения логических вентилей. В отечественной литературе чаще всего используются либо обозначения, описанные в стандарте IEC 60617-12 (1997) , либо похожие обозначения ГОСТ 2.743-91 из единой системы конструкторской документации (ЕСКД).

Из-за особенностей элементной базы основными для построения схем являются вентили «и-не» и «или-не» (NOR и NAND), реализующие соответственно операции $\neg(x \vee y)$ и $\neg(x \wedge y)$ для входных сигналов x и y.

Из вентилей конструируются более сложные элементы, в частности, двоичный полусумматор, рассчитывающий сумму двух входов, формируя два выходных сигнала: сумму входов по модулю 2 и разряд переноса, или полный одноразрядный сумматор, рассчитывающий сумму трёх входов (на один из них при построении многоразрядного сумматора подаётся перенос из предыдущего разряда).

Цифровой логический уровень — хронологически первый уровень абстракции. Впервые он появился ещё в непрограммируемых счётных машинах, в том числе вавилонских и греческих астрономических калькуляторах, но при этом отсутствует в простых устройствах наподобие счётов, где перенос между разрядами осуществляется вручную.

1.3.2. Микроархитектурный уровень

> ...Антагонизмы в области материального производства делают необходимой надстройку из идеологических сословий, деятельность которых, — хороша ли она или дурна, — хороша потому, что необходима...
>
> *К. Маркс. Капитал*

Микроархитектура процессора — это аппаратная организация и логическая структура микропроцессора:

- регистры — сверхбыстрые ячейки памяти внутри процессора;
- набор микрокоманд;
- управляющие схемы;
- арифметико-логические устройства (АЛУ);
- запоминающие устройства;

– связывающие их информационные магистрали (шины).

В частности, к микроархитектуре относятся все решения, касающиеся цикла выполнения команды: декодирование команды вышележащего уровня в последовательность микрокоманд, конвейер, кеширование команд и данных, прогнозирование переходов и т. п.

Микроархитектурный уровень впервые начал отделяться от уровня архитектуры команд в ЭВМ EDSAC-2 в 1957 г., когда впервые было применено микропрограммирование для реализации команды как последовательности микрокоманд.

В настоящее время микроархитектура процессора качественно отличается от архитектуры уровня команд. Так, на уровне микроархитектуры все современные процессоры семейства x86 (то есть процессоры с CISC-набором команд) организованы по принципу RISC. Они имеют набор микрокоманд простой структуры и множество регистров, которые поочерёдно играют роль восьми регистров общего назначения за счёт механизма переименования. Это позволяет ускорить выполнение программ, сохраняя при этом совместимость на уровне архитектуры команд.

1.3.3. Уровень архитектуры команд

Это полотно, где одна только краска — число.

В. Хлебников. В. Э. Мейерхольду

Уровень архитектуры команд включает:
– архитектуру памяти;
– взаимодействие с внешними устройствами ввода/вывода;
– режимы адресации;
– регистры;
– набор машинных команд;
– различные типы внутренних данных (целочисленные, с плавающей запятой и т. д.);
– обработчики прерываний и исключений.

Эти пункты во многом повторяют компоненты микроархитектуры. Различие состоит в том, что уровень архитектуры команд доступен программисту и, как всякий интерфейс, должен соответствовать документации и относительно редко меняется. Микроархитектура скрыта от программиста и может различаться даже у разных партий процессоров одной и той же модели.

В соответствии со структурой памяти, разрядностью шины и регистров определяются платформозависимые единицы измерения — байт и машинное слово.

Программа уровня архитектуры команд — последовательность двоичных машинных кодов. Программы ранних поколений записывались непосредственно в двоичном коде в виде отверстий на перфокартах и перфолентах (отверстие соответствовало единице, нетронутая позиция — нулю). Позже для хранения программ

стали использоваться различные виды долговременной памяти (обычно магнитные ленты и диски), а запись — сокращать с помощью восьмеричного и шестнадцатеричного представления двоичных чисел.

Каждому процессору соответствует свой набор машинных кодов.

В частности, для процессоров семейства x86 опкод пересылки непосредственного тридцатидвухбитного значения в тридцатидвухбитный регистр общего назначения имеет вид B8, после этого кода записывается трёхбитный код регистра, после чего идёт само значение. Соответственно, запись значения CC CC CC CC в регистр с кодом 1 выполняется командой B9 CC CC CC CC. Часто одно и то же действие можно выполнить с помощью различных машинных команд.

Уровень архитектуры команд, отличающий программируемую вычислительную машину (компьютер) от калькулятора или арифмометра, появился в проекте аналитической машины Чарльза Бэббиджа, а впервые реализован был в механическом компьютере Z1 Конрадом Цузе в 1938 г. При этом сама идея цифровых программ появилась задолго до её применения для вычислительных машин. Двоичные программы, записанные на перфолентах, использовались в механических орга́нах — шарманках в XV–XIX вв., на перфокартах — в автоматизированном ткацком станке Жозефа Жаккара (1802 г.).

Программирование в машинных кодах использовалось в течение долгого времени параллельно с ассемблером и языками высокого уровня. Даже в настоящее время бывает необходимо использовать вставки на машинном языке. Это может понадобиться либо в случае, когда ассемблер устарел и не распознаёт мнемоническое обозначение необходимой команды, либо при разработке защитных механизмов — для затруднения дизассемблирования и обратной разработки алгоритма защиты.

1.3.4. Уровень операционной системы

Дыхание этого спутника я всегда слышал.

В. Хлебников. Слово о числе и наоборот

На уровне операционной системы осуществляется:

- управление памятью (распределение между процессами, организация виртуальной памяти);
- загрузка программ в оперативную память и их выполнение;
- исполнение запросов программ (системные вызовы);
- стандартизованный доступ к периферийным устройствам (устройства ввода-вывода);
- управление доступом к данным на энергонезависимых носителях (таких как жёсткий диск, оптические диски и др.), организованным в той или иной файловой системе;
- обеспечение пользовательского интерфейса;

– сохранение информации об ошибках системы.

Данный уровень является гибридным — большая часть команд его языка совпадает с командами нижележащего уровня (машинного языка), и только некоторые интерпретируются непосредственно операционной системой.

При этом операционная система работает с этим языком и как компилятор (преобразуя исполняемый файл в готовую к выполнению программу в оперативной памяти, что для современных форматов исполняемых файлов не сводится к простому копированию), и как интерпретатор (исполняя так называемые системные вызовы).

Именно различие в системных вызовах и формате исполняемых файлов не позволяет выполнять в Microsoft Windows программы, собранные для того же процессора под GNU/Linux и наоборот.

В частности, системные вызовы используются для получения параметров командной строки (открытие документа двойным щелчком в Microsoft Windows — тоже вызов программы с параметром!) и для завершения работы. Непосредственное обращение к системным вызовам обычно скрыты от прикладного программиста библиотечными функциями-обёртками.

Первой операционной системой можно считать аппаратный супервизор релейного многоядерного компьютера Bell Model V (1946 г.), обеспечивавший загрузку следующей программы из очереди на освободившееся ядро без участия оператора и переключение между перфолентами по команде условного перехода. Позже появилась пакетная операционная система GM-NAA I/O (General Motors & North American Aviation Input/Output system) для IBM 704 (1956 г.) [60].

В конце 1950-х гг. были разработаны первые широко используемые операционные системы FMS (Fortran Monitor System) [45, 60] и SOS (Share 709 System) [12, 60] для IBM 709, которые включали компиляторы (Фортран для FMS и ассемблер для SOS) и обрабатывали системные вызовы, представленные перфокартами со специальным содержимым.

1.3.5. Уровень ассемблера

И язык — звукомые числа <нашего бытия>.

В. Хлебников. И, всенея, ховун...

Программировать в машинных кодах не слишком удобно, даже если записывать их в компактном восьмеричном или шестнадцатеричном виде. Намного удобнее создавать программы, используя понятное человеку символическое представление машинных команд — мнемоники, а также символические имена регистров и адресов в памяти (переменных, меток).

Перевод программы из подобного символического представления в машинные команды реализуется путем трансляции (сборки, ассемблирования), а не интер-

претации. Программа-транслятор для такого перевода соответственно называется ассемблером, а язык программирования — языком ассемблера. Язык ассемблера часто сокращённо называют просто ассемблером, как и транслятор.

Так как набор мнемоник — символическое представление набора команд процессора, процессорам с различным набором команд соответствуют разные языки ассемблера.

Синтаксис языка асемблера также зависит от используемого транслятора, так что для одного и того же процессора могут быть разработаны несколько ассемблеров.

В частности, команда `B9 CC CC CC CC`, то есть команда записи значения `CC CC CC CC` в регистр с кодом 1 для x86 (этому коду для тридцатидвухбитного регистра в тексте программы соответствует имя ecx), на уровне ассемблера будет иметь вид `movl $0xCCCCCCCC, %ecx`. Строка `mov` называется мнемоническим обозначением, или мнемоникой команды пересылки. Одной мнемонике может соответствовать несколько машинных команд (в частности, обозначение `mov` объединяет множество команд пересылки данных); кроме того, одна машинная команда может на уровне ассемблера обозначаться несколькими мнемониками (так, `jge` — переход, если больше или равно и `jnl` — переход, если не меньше, — это одна и та же команда)

Считается, что первый ассемблер появился в 1949 г. По разным источникам, он был разработан Дэвидом Джоном Уилером для ЭВМ EDSAC [56] или Джоном Мокли и Джоном Преспером Экертом для ЭВМ BINAC [44].

Иногда ассемблер называют самым старым языком программирования после машинного кода, хотя первый язык высокого уровня появился ещё раньше. Тем не менее, ассемблер заслуженно считается вторым поколением языков программирования.

1.3.6. Языки высокого уровня

> Язык Заменгофа очень строен, лёгок и красив, но беден звуками и не разнообразен: избыток омонимии и скудень синонимии.
>
> *В. Хлебников. Мысли и заметки*

Третьим поколением считаются языки высокого уровня (ЯВУ), позволяющие программисту описывать алгоритм, а не его реализацию на данной конкретной машине.

Для языка высокого уровня возможна как компиляция до уровней ассемблера или операционной системы (или, иногда, до другого ЯВУ), так и пошаговая интерпретация. При этом программы на некоторых языках традиционно только компилируются (в частности, Паскаль/Delphi, C/C++), на некоторых — только интерпретируются (в частности, это языки командной оболочки, наиболее известным из которых является семейство sh/bash), для большинства есть и компиляторы,

и интерпретаторы (Python, PHP и т. д.). В некоторых современных языках высокого уровня (в частности, C#, Java) вводится дополнительный уровень абстракции — программа на ЯВУ компилируется до байт-кода, который затем интерпретируется.

Идея символического языка для прикладного программирования, который не был бы связан с архитектурой конкретной вычислительной машины, почти так же стара, как и само программирование.

Первый язык высокого уровня — Планкалкюль — был разработан Конрадом Цузе в 1943-45 гг., но для него в то время не был разработан компилятор.

Первый компилятор, переводивший программу в алгебраической форме на машинный язык, A-0, был разработан в 1952 г. Грейс Хоппер.

Первый отечественный компилятор с языка высокого уровня ПП-1 (программирующая программа) был разработан в 1954 г. В некоторых источниках считается первым компилятором с языка высокого уровня [46]. Язык ПП-1 (и его позднейшие потомки) был основан на математической нотации [33].

Первым языком высокого уровня, дожившим до настоящего времени под оригинальным именем (но при этом породивший другой известный язык — Бейсик), является Фортран. Он был создан в 1954-1957 гг. группой программистов под руководством Джона Бэкуса в IBM. Также в 1957 г. был создан первый язык функционального программирования APL.

Как конкурент языку от IBM, в 1958 г. группой под руководством Питера Наура был разработан язык Алгол — родоначальник большинства современных языков общего назначения, в частности, семейства, включающего линейки Паскаль/Delphi/C# и B/C/C++. В это же время появился язык обработки списков Lisp, существующий до сих пор под этим именем.

В 1959 г. под руководством Грейс Хоппер был создан язык Кобол, максимально приближённый к английскому языку. Сейчас аналогичную нишу в нашей стране занимает 1С.

В настоящее время иногда выделяются также сверхвысокоуровневые языки программирования, позволяющие описывать даже не алгоритм решения задачи, а саму задачу, в частности, Python, Ruby, AWK/Perl.

Иногда объектно-ориентированные, а также языки запросов и другие сверхвысокоуровневые языки выделяются в следующее — четвёртое поколение языков программирования. При этом естественные языки объединяются с языками экспертных систем и баз знаний в пятое поколение.

В данном пособии уровень языка прикладных программистов будет рассматриваться в основном на примере компилируемого языка высокого уровня C++.

1.4. История

> ...В самом деле, так как возникновение по направлению вверх не беспредельно, то необходимо, чтобы не было вечным то, из чего как из первого возникло что-то через его уничтожение.
>
> *Аристотель. Метафизика*

Термин «компьютер» (вычислитель) в разное время обозначал различные понятия — и клерка-вычислителя, проводившего расчёты вручную или с использованием простых (счёты и подобные им устройства — абак, суанпан) или сложных (арифмометр, механический калькулятор) вспомогательных устройств; и сами эти устройства. При этом в настоящее время даже инженерные калькуляторы представляют собой миникомпьютеры, превосходящие многие ранние ЭВМ. Таким образом, многие аспекты архитектуры вычислительных систем необходимо рассматривать в контексте развития вычислительной техники и программного обеспечения.

Договоримся называть компьютером, или вычислительной машиной, устройство, которое может исполнять заданную изменяемую последовательность вычислительных операций — программу. Таким образом, компьютер содержит как минимум два уровня абстракции — цифровой логический и архитектуры команд.

Непрограммируемые вычислительные устройства назовём калькуляторами или арифмометрами. Калькулятор содержит цифровой логический уровень, но не включает уровня архитектуры команд.

Исторически можно выделить такой вид калькуляторов, как табуляторы, выполняющие единообразную обработку больших массивов данных, представленных на перфокартах. Табуляторы можно назвать также промежуточным звеном между калькуляторами и компьютерами.

1.4.1. Развитие вычислительной техники

> И с тех пор у нас в округе гении пропали,
> А без них кусты сирени все перезавяли.
>
> *С. А. Калугин. Небритый гений*

Вычислительные машины, как правило, разделяют на четыре поколения в соответствии с используемой элементной базой.

1. Электронные лампы.
2. Транзисторы.
3. Интегральные схемы малой и средней плотности.
4. Интегральные схемы большой и сверхбольшой плотности.

Это деление достаточно условно. Вычислительные машины разных поколений достаточно долгое время существовали параллельно. Часто различные компоненты

одного и того же компьютера строились на различных элементных базах. Кроме того, такое деление не отражает развития архитектуры.

В некоторых источниках вводится понятие пятого поколения, но нет единого его определения. Часть источников выделяет пятое поколение не по элементной базе, а по решаемым задачам. Одноимённый японский проект называет ЭВМ пятого поколения искусственный интеллект, направленный на обработку знаний. Также пятым поколением называют компактные персональные ЭВМ. Таненбаум считает пятым поколением встраиваемые системы (микроконтроллеры, системы на одном кристалле) [45], что естественным образом продолжает устоявшееся деление.

Любое из приведённых определений пятого поколения ЭВМ подразумевает, что в настоящее время оно успешно сосуществует с четвёртым. Также многие источники относят все современные компьютеры к четвёртому поколению.

Часто также выделяют нулевое поколение — электромеханические вычислительные машины. По аналогии с этим чисто механические вычислительные машины можно назвать минус первым поколением.

Большинство поколений делится на три периода: вначале выпускается прототип, основанный на новой элементной базе (или несколько независимо разработанных прототипов). Такие проекты часто остаются неизвестными из-за секретности или стечения обстоятельств. Через какое-то время множество стран и/или корпораций одновременно выпускают более совершенные компьютеры (одиночные или серийные). Соответственно, для каждого поколения указывается три даты: выпуск первого устройства, начало массового использования и выход из употребления.

Минус первое поколение (античность–XVIII в.–конец XX в.) — зубчатые колёса и рейки

К этому поколению можно отнести всего два полноценных компьютера — проект Бэббиджа конца XIX в., реализованный только в 1985-1991 гг., и Z1 Конрада Цузе (1938 г.).

При этом, если заменить в определении компьютера «последовательность вычислительных операций» на просто «последовательность операций», как это сделано в некоторых источниках, к минус первому поколению компьютеров также можно отнести цифровые мультимедийные механические устройства, серийно выпускавшиеся в XV–XIX вв. (шарманки и музыкальные шкатулки), а также механические станки с ЧПУ — первый известный такой станок был разработан в 1802 г. Жозефом Жаккаром.

Цифровые механические калькуляторы существенно более разнообразны. Сохранились упоминания об античных и вавилонских вычислительных устройствах, предназначенных для моделирования астрономических событий. Были найдены остатки подобного устройства — механизма из Антикитеры, собранного, по разным оценкам, в 140-80 гг. до н. э.

В современной европейской истории цифровой логический уровень присутствует в проекте тринадцатиразрядной машины Леонардо да Винчи, впервые реализован в 1623 г. в счётной машине Вильгельма Шиккарда, позже — в суммирующей машине Паскаля (1642 г.).

Позже были разработаны механические калькуляторы, выполняющие как сложение и вычитание, так и умножение и даже деление в десятичной системе — арифмометры Лейбница (1672 г.), Тома де Кольмара (1820 г.), Однера (1890 г.) и другие. В СССР наиболее популярен был «Феликс» (усовершенствованный арифмометр Однера), производившийся до 1978 г. Компактные, надёжные и энергонезависимые арифмометры повсеместно использовались до 1970-х гг. (а счёты — ещё дольше).

Около 1840 г. Томасом Фаулером был разработан механический калькулятор, работавший в сбалансированной троичной системе.

Дальнейшим развитием стал калькулятор, вычисляющий значение многочлена в десятичной системе — малая разностная машина, успешно построенная Чарльзом Бэббиджем в 1822 г. На её основе Георг Шутц и Мартин Виберг создали другие разностные калькуляторы.

Наиболее известная сейчас работа Чарльза Бэббиджа — постоянно дорабатывавшийся им проект механической десятичной аналитической машины, включающий управляющий барабан (УУ), хранилище (регистровую память), мельницу (арифметическое устройство — АУ).

На вход машины в последнем варианте проекта подавались два потока перфокарт: операционные карты (команды) и карты переменных (данные), что в современной классификации соответствует гарвардской архитектуре [65].

В 1930-х гг. над своим проектом вычислительной машины независимо от Бэббиджа начал работать Конрад Цузе, в это время — студент Берлинского политехнического. Компьютер Цузе был двоичным, для ввода-вывода данные преобразовывались в десятичный вид.

Цузе сформулировал основные принципы построения вычислительных машин:

- двоичная система счисления;
- использование устройств, работающих по принципу «да/нет» (логические 1 и 0);
- полностью автоматизированный процесс работы вычислителя;
- программное управление процессом вычислений;
- поддержка арифметики с плавающей запятой;
- использование памяти большой ёмкости.

Цузе впервые ввёл понятие «да/нет-статуса», аналогичное современному биту, термин «машинное слово», объединил в вычислителе арифметические и логические операции.

Первая демонстрационная модель Z1 была механической с электроприводом. Вместо использованных Бэббиджем шестерёнок логические и арифметические операции были реализованы на скользящих металлических рейках. Z1 обрабатывал

22-битные числа с плавающей запятой, включал не только регистры, но и механическую память (очень малого объёма, так что программа загружалась непосредственно с бумажной перфоленты). Поддерживались команды сложения и вычитания, умножения и деления, ввода и вывода, загрузки и сохранения в память. В системе команд Z1 не было условных переходов, так как их затруднительно выполнять на перфоленте. Цикл реализовывался склейкой перфоленты в кольцо [23, 66].

В отличие от проекта аналитической машины Бэббиджа, который так и остался проектом, Z1 был реализован в 1938 г. и является первым в истории компьютером.

Серийно выпускаться механические компьютеры общего назначения так и не стали; но выпуск специализированных устройств (мультимедийных проигрывателей, калькуляторов, цифровых сигнальных процессоров) был налажен достаточно широко.

К электромеханическим цифровым сигнальным процессорам (DSP) можно отнести, в частности, знаменитую Энигму (1923-1945 гг.) и более совершенную шифровальную машину Lorenz SZ. Так как механическую часть представляли не реле, а зубчатые роторы, их можно условно отнести к минус первому поколению.

Нулевое поколение (1890–1941–1960) — реле

Устройства нулевого поколения построены на основе телеграфных реле, идея которых была предложена ещё в 1830 г. Реле состоит из металлического переключателя, который, в зависимости от положения, может либо замыкать, либо размыкать электрическую цепь, и электромагнита, управляющего положением переключателя.

Таким образом, реле — электромеханическая ячейка, которая, в отличие как от более ранней механической памяти, так и от более поздних разновидностей, может принимать два и только два состояния.

В начале XX в. на основе реле были разработаны первые автоматические телефонные станции. Для этого был разработан и запатентован релейный регистр.

Первым счётным устройством, основанным на электромеханических реле, был табулятор Германа Холлерита (1890 г.). Для его разработки была создана компания, которая позже будет переименована в IBM.

В Германии на основе реле в 1939 г. Цузе разработал компьютер Z2 с механической памятью, по архитектуре практически полностью повторяющий Z1. В 1941 г. — Z3 с полностью релейной памятью, к системе команд которого было добавлено вычисление квадратного корня [23, 66]. Перфоленты для программ Z2 и Z3 делались уже не из бумаги, а из более прочной киноплёнки.

В США независимо от Цузе, но на основе проекта Бэббиджа, разрабатывались две линейки релейных вычислительных устройств — в фирме Bell (Джордж Штибитц) и в Гарвардском университете совместно с IBM (Говард Айкен).

Первый релейный калькулятор линейки Bell, «вычислитель комплексных чисел» был построен в 1940 г., последним (Bell Model V в 1946 г.) был полноценный многоядерный компьютер, где распределение заданий по ядрам выполнял аппаратный супервизор, который можно назвать ранней операционной системой. Система команд Bell Model V включала условные переходы, реализующиеся как переключение между различными перфолентами.

Первым из линейки Гарвардского университета и IBM первоначально также был калькулятор Harvard Mark I, или ASCC (1941 г.) с релейным процессором и механической памятью, который в 1944 г. был доработан до компьютера, загружающего инструкции с бумажной перфоленты.

Позже были разработаны полностью релейный Harvard Mark II (1947 г.) и релейно-ламповый Mark III/ADEC (1949 г.). Именно в электромеханическом реле Harvard Mark II, согласно легенде, был обнаружен первый баг.

В системе команд Mark I и Mark II, так же как и в ранних компьютерах Цузе, не было условных переходов, а циклы выполнялись закольцовыванием перфоленты. Программы Harvard Mark I и Mark II (аналогично позднему проекту Бэббиджа) хранились на перфолентах отдельно от данных, что позже получило название гарвардской архитектуры.

Из-за механического элемента в реле быстродействие таких машин было ограничено. Кроме того, у реле ограниченный ресурс срабатывания, поэтому релейные компьютеры были не слишком надёжны (хотя иногда надёжнее ламповых). Релейные компьютеры устойчивы к радиации и потребляют мало мощности.

Первое поколение (1943–1949–1965) — электронные лампы

В 1918 г. М. А. Бонч-Бруевичем было изобретено электронное реле — триггер, состоящее из двух электронных ламп — триодов. Триггер может менять своё состояние быстрее электромеханического реле, что позволило ускорить быстродействие вычислительных устройств.

Первым счётным устройством на электронных лампах считаются, согласно различным источникам, британский калькулятор Colossus Mark I и американский табулятор ENIAC. Оба этих калькулятора были построены в 1943 г.

Проект Colossus был рассекречен только в конце 1970-х гг., поэтому большая часть источников приписывает первенство ENIAC. В рамках этого проекта был разработан также Colossus Mark II (1944 г.), который не только работал в пять раз быстрее предшественника, но и был программируемым, так что Colossus Mark II может быть назван первым электронным компьютером (но не первым цифровым). В Colossus не было памяти, так что данные хранились на замкнутой перфоленте.

Табулятор ENIAC был разработан в школе Мура Пенсильванского Университета, США и обрабатывал десятичные числа. Каждый десятичный разряд представлялся десятью двоичными, при этом включён был только один из них — соответ-

ствующий нужной десятичной цифре. ENIAC иногда называют первой ЭВМ, но он не являлся вычислительной машиной (компьютером) в современном понимании, так как не имел уровня архитектуры команд. «Программирование» ENIAC выполнялось перекоммутацией связей, то есть фактически как перестройка машины.

В 1948-1950-х гг. началась повсеместная разработка ламповых компьютеров: EDVAC, BINAC и Harvard Mark III/ADEC в США, EDSAC в Британии, МЭСМ и М-1 в СССР, CSIRAC в Австралии.

Почти сразу, в 1951-1956 гг. был начат выпуск серийных компьютеров: UNIVAC, Ferranti, Минск-1, БЭСМ-1 и БЭСМ-2, серия «Стрела», Z22. В целом поколение электронно-ламповых компьютеров было многочисленным и разнообразным. В это время сложилось большинство архитектурных решений.

Кроме больших ЭВМ, занимавших иногда несколько этажей здания, стали появляться и малые. Так, первый мобильный компьютер общего назначения — Урал-1 (1955 г., СССР) — мог перевозиться на двух грузовиках.

Ненадёжность ламп приводила в том числе и к частым перестройкам и усовершенствованиям компьютеров, так что второе поколение включало множество моделей, большинство из которых существовали в единственном экземпляре. При этом программное обеспечение уже было достаточно сложным и функциональным, так что его было нерентабельно переписывать заново под язык каждой новой машины. Соответственно, в 1954–1960 гг. началось формирование двух новых уровней абстракции, обеспечивающих переносимость программ:

- декодирование машинной команды на набор микрокоманд, что позволяет нескольким различным компьютерам выполнять один и тот же набор команд (EDSAC-2);
- компиляция с языков высокого уровня (Фортран, Алгол, APL, Кобол).

Второе поколение (1955–1960–1970) — дискретные транзисторы

В 1947 г. Уолтер Браттейн и Джон Бардин создали первый твердотельный аналог лампы-триода — полупроводниковый транзистор.

Транзисторы оказались компактнее, быстрее и надёжнее, чем триоды. Первым транзисторным компьютером считается экспериментальный TX-0 (1955 г., США, МТИ), на основе которого позже разработали TX-2, а затем PDP-1 (1961 г., США, DEC).

Первые частично транзисторные компьютеры общего назначения появились в 1958 г. Сразу же началось их серийное производство: Elliot-803 в Британии, Simens-2002 в Германии, Н-1 в Японии, Раздан-2, Минск-2 (а также его модификации Минск-22 и Минск 22М) и Минск-32, М-220 и М-222, Урал-14, Наири-1 и Наири-2, МИР, БЭСМ-4 и БЭСМ-6в СССР, PDP-1, IBM 7030 (Stretch) и CDC 6600 в США и т. д.

Новая элементная база позволила уменьшить не только габариты больших ЭВМ (до нескольких десятков шкафов), но и мобильные компьютеры общего назначения (один-два шкафа). Такими были Раздан-2 и двоично-десятичный Проминь в СССР, PDP-4, PDP-5 и PDP-8 в США. Активно разрабатывались специализированные (обычно военные) мобильные компьютеры: бортовой компьютер самолёта TRADIC в США, Гранит, Клён, Диана, Радон и т. д. в СССР.

Также ко второму поколению относится агрегатная система средств вычислительной техники (набор устройств с унифицированными внешними связями, из которых можно компоновать различные вычислительные модели, начиная от простейших вычислительных машин сбора информации до сложных многопроцессорных систем обработки данных, систем массового обслуживания и т. д.) АСВТ-Д [49]. На основе АСВТ-Д собирались такие компьютеры, как М-1000, М-1010 (Ангара-2, 40 м^2), М-2000 (144 м^2) и М-3000 (170-220 м^2). Для сравнения — площадь, занимаемая IBM 7030, составляет около 250 м^2.

Появляется механизм трансляции адресов и страничная организация оперативной памяти.

Активно развиваются компьютеры на нестандартной элементной базе: Senac-1 на параметронах в Японии, троичная Сетунь в СССР, CAB-500 на магнитных элементах во Франции.

В процессе проектирования IBM 7030 (Stretch) возникло понятие байта как совокупности шести битов. В компьютерах других производителей байт мог быть равен семи или девяти битам.

Начиная со второго поколения, практически все компьютеры выпускаются сериями различного объёма. Кроме того, большинство описанных названий — не одна модель, а семейство компьютеров схожей архитектуры и, как правило, с совместимыми наборами команд. Разные семейства (даже разрабатываемые на основе друг друга, как PDP-1 и PDP-4 или IBM 7030 и IBM 360) часто были несовместимы между собой. Тем не менее, в некоторых компьютерах, в частности, Минск-32 в СССР, поддерживались режимы программной совместимости с более ранними моделями [37].

Третье поколение (1961–1966–1980) — малые и средние интегральные схемы

Первые интегральные схемы (отдельные триггеры в США и логические вентили в СССР) были созданы в 1961–1962 гг. параллельно Джеком Килби из Texas Instruments, Робертом Нойсом из Fairchild и Ю. В. Осокиным из КБ Рижского завода полупроводниковых приборов.

Первые компьютеры, построенные с использованием подобных схем, мало отличались от компьютеров, построенных только из отдельных транзисторов, то есть граница между вторым и третьим поколением достаточно условна. Некото-

рые модели компьютеров собирались вначале из дискретных элементов, затем из интегральных схем.

С увеличением степени интеграции появилась возможность выполнить на одном кристалле целый блок ЭВМ — регистр, дешифратор, счётчик и т. д. Примерно в это же время появляется понятие процессора, объединяющего в себе АЛУ (возможно, несколько специализированных АЛУ) и УУ.

К третьему поколению больших ЭВМ относятся, в частности, Днепр-2 и МИР-2, Урал-11М и Урал-25, Наири-3 и Наири-4 в СССР, серии IBM 360 и IBM 370 в США. Часто к третьему поколению по особенностям архитектуры относят и БЭСМ-6, хотя этот компьютер собирался из дискретных элементов.

Выросло количество мобильных компьютеров. Наиболее известны двенадцатиразрядная линейка компьютеров общего назначения PDP-8 и шестнадцатиразрядная — PDP-11 фирмы DEC. Для PDP-8 ввели термин «миникомпьютер», и, согласно легенде, это был первый компьютер, украденный частными лицами (он занимал всего один шкаф и весил менее 50 кг).

Также выпускались специализированные мобильные компьютеры. В СССР это были, в частности, Карат, Алмаз на основе модулярной арифметики и ряд программно-совместимых компьютеров Атака, Арка и Арфа, а также управляющий миникомпьютер Параметр. Параметр, в свою очередь, послужил основой для агрегатной системы средств вычислительной техники АСВТ-М, на основе которой собирались М-4000, М-6000.

Как было сказано ранее, в период создания машин из отдельных транзисторов или малых интегральных схем каждая компания устанавливала свои стандарты на аппаратные интерфейсы. К концу 1960-х гг. не было практически никаких общих стандартов. Проблема переносимости программного обеспечения, актуальная ещё в начале 1960 гг., встала крайне остро.

В капиталистических странах большая часть избыточных стандартов исчезла вместе с создавшими их фирмами, так как компьютеры без программного обеспечения были непопулярны. Остались несколько несовместимых между собой серий компьютеров разных фирм, в основном IBM и DEC.

В СССР был поставлен вопрос о создании единственного ряда компьютеров, совместимых на уровне команд друг с другом и основанных на системе команд наиболее известной западной линейки — IBM 360. Для IBM 360 к тому времени было написано много программ, но сами эти компьютеры, разработанные в начале 1960-х, устарели. Официальное сотрудничество с IBM было невозможно как из-за холодной войны, так и из-за политики самой IBM. Изначально выдвигался проект переориентации на сходные с IBM 360 архитектуры английской фирмы ICL или немецкой Siemens. Обе они были готовы официально поделиться существующими технологиями и немедленно начать совместную разработку компьютеров четвёртого поколения.

Тем не менее, в 1970 г. появился административный приказ о копировании устаревшей системы IBM 360. При этом предполагалось копировать не архитектуру команд, а микроархитектуру по нелегально полученным снимкам интегральных схем и фрагментам документации [42, 79].

Чуть позже в 1970 г. IBM анонсировала линейку IBM 370. А в 1971 г. в СССР был выпущен морально устаревший к этому времени клон IBM 360 — первый представитель линейки ЕС ЭВМ. Большая часть оригинальных разработок была прекращена и забыта; многие архитектурные решения, воплощённые в МИР и БЭСМ, были переоткрыты в Intel и AMD в 1990-2000 гг.

В описываемое время окончательно сформировались уровни архитектуры команд и языка высокого уровня.

Появляется ещё один уровень абстракции — промежуточные универсальные языки, облегчающие компиляцию (такие, как Алмо, Эпсилон, внутренний язык системы Бета в СССР). При компиляции с m языков высокого уровня для n машин через промежуточный язык достаточно разработать всего $m + n$ трансляторов, при компиляции напрямую в машинные или ассемблерные коды $m \cdot n$. Этот уровень не прижился в 1970-е гг., но в настоящее время он активно используется для языков, подобных Java или C#, как уровень байт-кода.

Четвёртое поколение (1971–1980–настоящее время) — большие и сверхбольшие интегральные схемы

Граница между третьим и четвёртым поколением ещё более условна, чем между вторым и третьим. Часто считается, что переход к четвёртому поколению — размещение процессора на одной микросхеме (микропроцессоре).

Первой подобной микросхемой был процессор Intel 4004 (1971 г.).

Естественно, что первые микропроцессоры были относительно простыми, а сложные и высокопроизводительные процессоры четвёртого поколения по-прежнему были модульными.

В это время выпускались как большие ЭВМ, в основном уменьшившиеся до одного шкафа, наиболее производительные из которых стали называть суперкомпьютерами (Cray-1 в США, серия Эльбрус на основе БЭСМ-6 в СССР), так и миникомпьютеры на основе микропроцессоров, габариты и стоимость которых также уменьшались со временем. Это DEC VAX в США, различные линии СМ ЭВМ в СССР (среди них были и продолжения АСВТ-М, и клоны PDP-11, и оригинальные разработки, совместимые на уровне архитектуры команд с VAX или, позже, с Intel x86). Из специализированных мобильных компьютеров 1980-1990 гг. в СССР можно отметить Карат-КМ-Е, Акация, Лада-2.

В 1973 г. появился прототип Xerox Alto — недорогой миникомпьютер с экраном, клавиатурой, мышью и сетевой картой Ethernet, операционная система кото-

рого, как и Unix, поддерживала графический интерфейс пользователя. Подобный миникомпьютер позже получил название персонального компьютера.

В 1975 г. поступил в продажуперсональный компьютер MITS Altair 8800 на основе процессора Intel 8080 и специально разработанной системной шины S-100. В базовой комплектации он не имел ни экрана, ни алфавитной клавиатуры, но поддерживал карты расширения. Благодаря низкой цене, гибкой и открыто опубликованной архитектуре, а также качественной рекламе Альтаир стал популярен, а энтузиасты разработали для него как полноценные периферийные устройства, так и качественное программное обеспечение.

Позже, начиная с 1977 г. были выпущены несколько недорогих персональных компьютеров: Apple II, IBM 5100, Tandy TRS-80, Commodore PET, Электроника НЦ-8010 и т. д. При разработке базового программного обеспечения для них отказались от графического интерфейса.

В 1981 г. появился персональный компьютер IBM 5150, или IBM PC. В отличие от более ранних моделей IBM, в IBM PC использовались сторонние компоненты, в частности, процессор Intel 8088. Архитектура IBM PC, вопреки обычной политике IBM, была открытой, что привело к популярности и огромному количеству клонов (IBM PC-совместимых компьютеров).

В 1983 г. появился первый процессор с архитектурой ARM, предназначенной для встраиваемых систем.

Сейчас под словом «компьютер» чаще всего понимают «IBM PC-совместимый компьютер», хотя эта архитектура (и, соответственно, процессоры семейства x86) в настоящее время не является самой распространённой.

Наиболее популярными персональными компьютерами сейчас являются смартфоны и планшеты, где применяются процессоры семейства ARM. Ещё более распространены цифровые сигнальные процессоры и специализированные компьютеры. Часто специализированный компьютер реализуется в виде одной интегральной схемы — микроконтроллера.

Также в настоящее время продолжается выпуск суперкомпьютеров, таких как Cray-X1E. С ними успешно соперничают кластеры, объединяющие множество компьютеров общего назначения.

1.4.2. Операционные системы

> Мы не претендуем на монополизацию революционности в искусстве.
> Выясним соревнованием.
>
> *В. В. Маяковский. За что борется Леф?*

Уровень операционной системы, облегчающий взаимодействие прикладных программ с аппаратной частью ВС, возник достаточно рано. При этом первые операционные системы были неотделимы от соответствующих компьютеров и со-

здавались той же компанией, что и сам компьютер. В них использовалось множество прогрессивных архитектурных решений и приёмов человеко-машинного взаимодействия, в частности, в 1972 г. в системе PLATO появился графический интерфейс пользователя; но при смене компьютера приходилось менять и систему.

Позже появились операционные системы, разработанные сторонними организациями. Так как при смене компьютера нерационально полностью отказываться от старой операционной системы и, соответственно, от написанного для неё ПО, появились порты таких систем на архитектуры, отличные от первоначальной, а также семейства схожих систем.

В настоящее время наиболее известным семейством являются Unix-подобные операционные системы. Для архитектуры x86 наиболее распространены такие представители этого семейства, как GNU/Linux и разнообразные ветки BSD; для ARM — основанная на ядре Linux система Android. Именно Android сейчас является наиболее распространённой операционной системой.

История семейства Unix

Наиболее известным семейством операционных систем является семейство Unix. Первоначально операционная система Unics (Uniplexed Information and Computing System) была разработана Кеном Томпсоном, Денисом Ритчи и Брайаном Кернига́ном как порт системы Multics (Multiplexed Information and Computing Service) на миникомпьютер DEC PDP-7. Первая версия Unics была написана на ассемблере [73].

Первая версия Unix (V1) появилась в 1971 г. Начиная с версии V6 (1975 г.) операционная система Unix распространилась в университетах, что привело к появлению множества различных веток.

В настоящее время потомки операционной системы Unix называются Unix-подобными операционными системами. Для архитектуры x86 наиболее распространены такие представители этого семейства, как GNU/Linux и разнообразные ветки BSD; для ARM — основанная на ядре Linux система Android. Именно Android сейчас является наиболее распространённой операционной системой.

Понятие Unix-системы описывается семейством стандартов Single UNIX Specification (SUS). Зарегистрированными Unix-системами являются коммерческие операционные системы.

Кроме того, существует стандарт POSIX, описывающий взаимодействие операционной системы с прикладной программой, служащий для обеспечения совместимости Unix-подобных систем на уровне исходного кода. При этом операционная система может поддерживать POSIX и не являясь Unix-подобной.

Операционные системы IBM PC

Оригинальный компьютер IBM PC (1981 г), использовавший восьмиразрядный процессор Intel 8088, из-за множества аппаратных ограничений не мог использовать существовавшие в то время многозадачные и многопользовательские операционные системы.

Разработка специализированной системы, вопреки обычной политике IBM (но в соответствии с положенными в основу IBM PC принципами модульности и открытости), была поручена сторонней фирме — Microsoft, которой и была куплена и доработана простая однозадачная операционная система DOS, обладающая текстовым интерфейсом. Позже была разработана графическая надстройка над DOS — Windows. Дальнейшее развитие связки DOS и Windows привело к линейке операционных систем Microsoft Windows 95/98/Me для IBM PC, которая так и не стала полностью многозадачной и была закрыта.

Практически сразу были предприняты попытки разработки для IBM PC альтернативных операционных систем (в частности, OS/2), а также портирования Unix. Начиная с процессора 80386, на платформе x86 возможна работа полноценных многозадачных операционных систем, наиболее известной из которых стала Unix-подобная GNU/Linux.

В настоящее время для процессоров семейства x86, кроме множества вариантов Unix-подобных систем, доступны также специфические операционные системы: линейка операционных систем с закрытым исходным кодом Microsoft Windows NT (в настоящее время NT является единственной поддерживаемой линейкой Microsoft Windows, поэтому обозначение NT часто опускают), семейство MenuetOS и так далее. Эти операционные системы не поддерживают стандарт POSIX, хотя для Microsoft Windows периодически заявляется частичная поддержка (часть POSIX, причём не для всех версий и не для всех типов Microsoft Windows).

Контрольные вопросы

1. Что включает архитектура системы?
2. Что такое вычислительная система?
3. Какие вы знаете единицы измерения информации?
4. Какие вы знаете типы наборов команд?
5. Какие вы знаете виды архитектуры, различающиеся расположением программ и данных?
6. Какие уровни абстракции включает современная вычислительная система?

Глава 2. Представление данных

Проволока мира — число.

В. Хлебников. Зангези

Пифагорейцы в VI–IV веках до н. э. считали числа первоосновой мира. В настоящее время этот принцип воплощается на практике — всё больше информации переходит в цифровой формат, то есть описывается при помощи чисел. Числа же в свою очередь представляются в вычислительных системах при помощи специальных кодов в виде набора нулей и единиц.

2.1. Качественные и количественные данные

Всё познаваемое имеет число, потому что без числа невозможно что-либо понять или распознать.

Филолай. Антология Стобея, I, 21

Данные делятся на две основные группы — количественные и качественные. К **количественным** данным относятся в основном либо сведения о числе объектов, удовлетворяющих тем или иным условиям, либо числовые результаты измерений. Для таких данных имеют смысл базовые арифметические действия — сложение, вычитание, умножение на число или другую величину подходящей размерности. Именно для описания количественных данных изначально и появилось само понятие числа.

Для подсчёта количества объектов (яблок, землекопов и т. д.) используются **натуральные числа:** $1, 2, 3, \ldots$ Множество натуральных чисел $\{1, 2, 3, \ldots\}$ обычно обозначается как $\mathbb{N}$.

Ноль не используется при счёте, поэтому не считается натуральным числом. Тем не менее, часто удобно рассматривать множество $\mathbb{N} \cup \{0\} = \{0, 1, 2, 3, \ldots\}$. Оно обозначается $\mathbb{N}_0$. В некоторых зарубежных источниках именно $\mathbb{N}_0$ называется множеством натуральных чисел, но в отечественной литературе, как и в значительной части зарубежной, принято определение из предыдущего абзаца, не включающее ноль. Универсальное название элементов $\mathbb{N}_0$ — неотрицательные целые числа, также их часто называют **беззнаковыми** целыми числами.

Для описания некоторых величин требуются отрицательные числа (-1, -2, $-3, \ldots$). Множество, включающее натуральные числа, противоположные им отрицательные и ноль, называется множеством целых чисел $\mathbb{Z}$. В противоположность беззнаковым (неотрицательным) величинам те, которые могут принимать как положительные, так и отрицательные значения, называются **знаковыми.**

Результаты измерений большей части величин (длина, путь, масса, время и т. д.) невозможно представить в виде целых чисел, знаковых или беззнаковых. Соответствующие им **вещественные** числа (в частности, $\frac{1}{3}, \sqrt{2}, \pi, e$) образуют множество $\mathbb{R}$.

Числа и, соответственно, количественные данные лучше всего подходят для обработки с помощью вычислительных систем. Таким образом, чтобы ввести и использовать какую-то информацию в вычислительной системе, эту информацию необходимо представить в виде числа или набора чисел.

Качественные данные представляют собой, как правило, элементы (символы), несравнимые между собой или цепочки (строки) подобных символов. В частности, к качественным данным относятся цвет, буквы, цифры, ноты, символы шахматных фигур, карточных мастей и т. д. Множество всех возможных символов называется алфавитом.

Для обработки с помощью вычислительных систем качественные данные также необходимо представить в виде чисел. Чтобы сделать это, символы качественных данных упорядочиваются, затем каждому символу сопоставляется его порядковый номер в списке — код символа, беззнаковое целое число. Полученное соответствие называется **кодовой таблицей**.

Наиболее известны кодовые таблицы, сопоставляющие коды знакам письменных языков — цифрам, буквам кириллицы, латиницы, знакам препинания и т. д. (чаще всего под термином «символ» подразумевается именно знак письменности). В частности, старейшая из принятых в настоящее время кодовая таблица ASCII (American Standard Code for Interchange of Information) описывает цифры, строчные и заглавные буквы латиницы, некоторое количество знаков препинания и специальных символов (так называемые ASCII-символы) и сопоставляет им коды в диапазоне от 0 до 127 [57]. Все более современные кодовые таблицы, включающие кириллицу и другие национальные знаки, описывает ASCII-символы этими же кодами.

Кодовая таблица ASCII настолько прочно закрепилась в информационных технологиях, что такие языки, как C/C++, вообще не делают различия между ASCII-символом и его кодом: тип $char$ является одновременно и символьным, и коротким целым. При этом представление символов не из таблицы ASCII, в частности, кириллицы, может быть различным в разных реализациях.

Сейчас для представления различных национальных алфавитов чаще всего используется кодовая таблица Unicode, сопоставляющая кириллице коды от 1024 до 1279 (обычно коды Unicode записывают в шестнадцатеричном виде — от `0400` до `04FF`). Для того, чтобы представление буквы кириллицы в памяти компьютера не могло совпасть с представлением последовательности из нескольких ASCII-символов, используются различные **кодировки** Unicode. Наиболее распространённая из них — UTF-8 — записывает символ в виде цепочки байтов, включающих, кроме собственно кода, ещё и служебную информацию. Соответственно,

кириллица, представленная в UTF-8, занимает диапазон от `D080` до `D19F`, так что кириллические буквы занимают два байта.

2.2. История чисел

> Всякое начало трудно, — эта истина
> справедлива для каждой науки.
>
> *К. Маркс. Капитал*

Система счисления — это представление чисел с помощью специальных письменных знаков — цифр.

Старейшая система представления чисел — единичная, когда при счёте каждому объекту сопоставляют один счётный предмет или символ — загибают палец, передвигают бусину чёток, ставят галочку на бумаге или зарубку на доске. Таким образом, чтобы записать число N, нужно поставить N галочек или зарубок. Значение счётного предмета или знака при этом не зависит от его положения и всегда равно единице. Этот громоздкий способ записи подходит только для небольших натуральных чисел.

Для подсчёта большого количества объектов естественно разбивать их на группы одного размера и подсчитывать уже эти группы. Размер такой группы называется **основанием** системы счисления.

Даже в единичной системе обычно используется группировка по какому-либо основанию. В чётках через определённое количество бусин вставляется отличная размером или цветом; пальцы рук естественным путём сгруппированы по 5 и 10, фаланги — по 12 (на всех пальцах одной руки, исключая большой), 15 (включая большой), 24 (на двух руках, исключая большие пальцы) и 30.

Исторически чаще всего использовались основания, равные 10 (по числу пальцев на руках) или 12 (по числу фаланг пальцев одной руки, кроме большого — он используется для указания на текущую фалангу-цифру). Системы счисления с такими основаниями называются соответственно десятичной и двенадцатеричной. Некоторыми народами использовались также восьмеричная система счисления (по суставам пальцев одной руки, кроме большого) и даже девятеричная. Сейчас общепринятой в быту является десятичная система счисления.

Группировка счётных знаков позволяет нагляднее представить относительно большие числа, но единичная запись всё равно будет громоздкой. Для сокращения длины логично записывать число не объектов, а групп и при этом как-то различать записи «N объектов» и «N групп объектов». Простейшее решение — ввести для группы, например, десятка, специальный счётный знак.

Подобная запись использовалась, в частности, в Древнем Египте. Там была принята десятичная система, при этом использовались различные знаки для записи

единиц (|), десятков (∩), сотен и так далее. Например, для записи числа $29 = 2 \cdot 10 + 9 \cdot 1$ были необходимы два знака десятков и девять знаков единицы: ∩ |||| ∩ ||||| . Порядок записи этих знаков не был чётко определён.

Таким образом, значение счётного знака зависело только от его формы, но не от его положения относительно других знаков. Такие системы счисления называются непозиционными.

В Древнем Риме применялась смешанная система счисления — пятично-десятичная. Специальные знаки существовали для единиц (I, схематичное изображение пальца), пятёрок (V, напоминающая руку с отставленным большим пальцем), десяток (X, две руки), 50, 100 и т. д.

Значение цифры зависело от того, находилась ли она справа от более крупной цифры (в этом случае их значения складывались) или слева (в этом случае меньшее значение вычиталось из большего). В частности, $29 = 2 \cdot 10 + 9 = 2 \cdot 10 + 10 - 1 =$ XXIX, $31 = 3 \cdot 10 + 1 =$ XXXI. Таким образом, значение счётного знака зависит и от его формы, и от его положения относительно других знаков, но при этом, например, единица и десяток обозначаются при помощи принципиально разных символов. Такая система счисления называется смешанной.

Римская запись сложна, почти так же громоздка, как египетская и, кроме, того, неоднозначна — например, число 4 записывалось и как IIII $(4 \cdot 1)$, и как IV $(5 - 1)$. Существуют различные виды римской записи, позволяющие либо сократить длину числа, либо убрать неоднозначность, но не то и другое сразу.

В Индии была придумана более удобная запись, в которой использовались различные счётные знаки для всех чисел от единицы до девяти, а также впервые возникло специальное обозначение для нуля. Для подобной записи числа, как и в египетской системе, разбивается на сумму некоторого числа единиц, десятков и т. д., причём для записи количества единиц и десятков будет использован один и тот же набор цифр. Значение цифры определяется её положением в записи; такая система счисления называется **позиционной.** Десятичная позиционная запись была перенята у индийцев арабами, а затем распространилась повсеместно. Начертание счётных знаков со временем превратилось в так называемые арабские цифры, которые сейчас привычны нам с детства, как и позиционная система записи: $2 \cdot 10 + 9 \cdot 1 = 29$.

В настоящее в быту повсеместно используется именно десятичная позиционная запись. На десятичной позиционной системе основано наиболее совершенное из простых счётных устройств — русские счёты. Ряд спиц в них соответствует позициям, десять костяшек на каждой спице — цифрам.

Одна из первых механическая суммирующая машина — Паскалина — также была построена на основе десятичной позиционной записи, несмотря на то, что использовалась для финансовых расчётов в принятой тогда недесятичной денежной системе. Каждому десятичному разряду соответствовало одно зубчатое колесо, на

которое были нанесены цифры от 0 до 9. Поворачиваясь от 9 к 0, колесо сдвигало следующее за ним, формируя перенос.

Десятичная позиционная система счисления использовалась в механических калькуляторах, арифмометрах, разностной машине Бэббиджа, весившей более трёх тонн, а также в его же проекте аналитической машины, не реализованном из-за из-за своих габаритов и высокой стоимости. Даже много позже в самом известном из первых электронных (то есть построенных на вакуумных лампах) калькуляторов — ЭНИАК — использовалась десятичная система, из-за чего размеры ЭНИАК превысили размеры более поздних ламповых вычислительных машин.

При этом, как уже было сказано, основание системы счисления, равное десяти, было популярным, но не единственным. В XVI–XVII вв. различные учёные рассматривали двоичную, троичную и т. д. системы счисления и их свойства [11, 21]. Лейбниц видел в двоичной системе мистическое отражение реальности, но не рекомендовал использовать её на практике для вычислений (знаменитый арифмометр Лейбница был основан на десятичной системе).

Первая реально построенная вычислительная машина Z1 была механической и была создана в Германии Конрадом Цузе. Идеи Цузе были поразительно схожи с планами Бэббиджа (несмотря на независимую работу) и теми, что позже будут реализованы фон Нейманом. При этом Z1 помещалась в гостиной Цузе, а её масса составила всего 500 кг. Такая компактность была достигнута за счёт использования другой позиционной системы счисления — **двоичной.** Для ввода-вывода в Z1 было реализовано двоично-десятичное преобразование. Усовершенствованный вариант вычислителя Цузе, электромеханический Z2 на основе телеграфных реле, закрепил использование двоичной логики — реле может находиться только в двух состояниях — оно либо открыто, либо закрыто. Используемые в последующих вычислительных машинах вакуумные лампы, а затем транзисторы также могли находиться в двух состояниях. Таким образом, в настоящее время двоичная позиционная система применяется в электронике повсеместно.

Но двоичная система не является самой экономичной. Теоретически оптимальной является система счисления по основанию e, а из натуральных оснований наиболее экономичным является 3 [47]. Троичная ЭВМ — Сетунь была разработана в МГУ, выпускалась серийно и оказалась весьма эффективной. Но, так как для построения троичных логических элементов использовалась двоичная элементная база (транзисторы), существенно уменьшить габариты и стоимость за счёт экономичности основания системы счисления не удалось, так что в дальнейшем от троичной логики надолго отказались. Тем не менее, недавно о ней снова пришлось вспомнить: элементы квантовых компьютеров могут принимать как раз три значения.

Кроме позиционных систем счисления, в вычислительной технике использовались и другие, более оригинальные системы представления чисел. Наиболее интересной представляется система остаточных классов, или модулярная арифме-

тика — представление числа x в виде последовательности остатков от деления x на набор взаимно простых чисел $p_1, p_2, \dots p_n$.

$$x = (x \bmod p_1, x \bmod p_2, \dots\ x \bmod p_n)$$

Такое представление позволяет выполнять умножение с той же скоростью, что и сложение.

Первым модулярным компьютером была чехословацкая ЭВМ Эпос, позже в СССР разрабатывалась серия модулярных ЭВМ. Наиболее известная советская модулярная ЭВМ, К-340А, используется до сих пор из-за своей поразительной надёжности и быстродействия [38, 39]. В настоящее время на модулярной арифметике основаны многие специализированные процессоры, предназначенные для обработки сигналов в режиме реального времени.

Программная реализация модулярной арифметики в настоящее время используется для ускорения вычислений в криптографии.

2.3. Позиционные системы счисления

> Человек, который дружит с тиранами, подобен камешку при вычислении, значение которого бывает иногда большое, а иногда малое.
>
> *Приписывается Солону.*
> *Диоген Лаэртский. О жизни, учениях и изречениях знаменитых философов*

Все позиционные системы счисления строятся по одному общему принципу. Выбирается некоторое натуральное число $N > 1$ — основание системы счисления, и каждое число $X \in \mathbb{N}_0$ представляется в виде комбинации его степеней с коэффициентами, принимающими значения от 0 до $N - 1$, т. е. в виде

$$X = x_0 + x_1 \cdot N + \ldots + x_k \cdot N^k \tag{2.1}$$

где $0 \leqslant x_i < N$ — целые. Такое разложение существует и единственно для каждого $X \in \mathbb{N}_0$.

Далее число X сокращённо записывается в виде $x_k \ldots x_1 x_0$. Для того, чтобы отличать это представление от сокращённой записи умножения $x_k \cdot \ldots \cdot x_1 \cdot x_0$, над позиционной записью может быть проведена горизонтальная черта; основание системы счисления N может быть указано в виде нижнего индекса, таким образом:

$$X = x_k \cdot N^k + \ldots + x_1 \cdot N + x_0 = \overline{x_k \ldots x_1 x_0}_N \tag{2.2}$$

Если позиционность представления и основание системы очевидны из контекста, эти обозначения могут опускаться. Так, запись 13 для позиционного десятичного

представления числа «тринадцать» будет, скорее всего, прочитана правильно, как и 0400 – 04FF для позиционного шестнадцатеричного представления диапазона кодов Unicode.

Каждому возможному значению x_i, от 0 до $N-1$, соответствует специальный знак — цифра. Для записи значений, не превышающих девяти, используются привычные нам знаки $0 \ldots 9$. Если необходимо записать одной цифрой значение «десять», для этого обычно используется знак A, одиннадцать записывается как B и так далее.

Таким образом, в часто используемой в информационных технологиях шестнадцатеричной системе счисления числа записываются с помощью шестнадцати цифр: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F. Знаки A ... F в этом контексте называются именно цифрами, а не буквами, и качественно ничем не отличаются от знаков 0 ... 9. В двенадцатеричной системе используется двенадцать цифр: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B.

$$13_{10} = 11_{12} = \mathtt{D}_{16}$$

Величина, обозначаемая цифрой в записи числа, зависит от её позиции (разряда). Разряды числа, в отличие от текста, записываются по-арабски — справа налево. Цифра, записываемая крайней справа, обозначает количество единиц (младший радряд), вторая справа в десятичной системе обозначает количество десятков, в двенадцатеричной — количество дюжин и т. д. Крайний слева разряд называется старшим.

$$12345_{10} = 5 \cdot 10^0 + 4 \cdot 10^1 + 3 \cdot 10^2 + 2 \cdot 10^3 + 1 \cdot 10^4$$

Иногда разряды числа нумеруются, но порядок нумерации в различных источниках не совпадает. Младший разряд обозначается иногда как первый (так сложилось исторически), иногда как нулевой (так как $1 = N^0$). В некоторых источниках разряды чисел фиксированной ширины (например, регистров) вообще нумеруются от старшего к младшему, по направлению текста.

В любой позиционной системе счисления ноль записывается как 0, единица — как 1. Основание этой системы счисления всегда записывается в виде 10.

2.3.1. Перевод натуральных чисел между позиционными системами счисления

— Что общего между Хэллоуином и Рождеством?
— Каждый программист знает: 31 oct = 25 dec.

Программистский фольклор

В общем случае для перевода натуральных чисел между системами счисления используется деление с остатком. Действительно, сгруппируем в (2.1) все члены,

куда входит N в степени, большей 1:

$$X = x_0 + \left(x_1 \cdot N + \ldots + x_k \cdot N^k\right) \tag{2.3}$$

вынесем за скобки N и обозначим оставшееся значение как X_1:

$$X = x_0 + \underbrace{\left(x_1 + \ldots + x_k \cdot N^{k-1}\right)}_{X_1} \cdot N = x_0 + X_1 \cdot N, \tag{2.4}$$

где x_0 и X_1 — целые неотрицательные числа, причём $0 \leqslant x_0 < N$. Таким образом, младшая цифра x_0 числа X в N-ичной системе счисления — остаток от целочисленного деления X на N, также в процессе этого деления мы получим частное, равное X_1. Так как в соответствии с (2.4)

$$X_1 = x_1 + x_2 \cdot N + \ldots + x_k \cdot N^{k-1}, \tag{2.5}$$

следующую цифру x_1 можно найти как остаток от деления X_1 на N и так далее:

$$\left.\begin{array}{rcrcr} 266 & = & 22 \cdot 12 & + & 2 \\ 22 & = & 1 \cdot 12 & + & 10 \\ 1 & = & 0 \cdot 12 & + & 1 \end{array}\right\} \quad 266_{10} = 1\mathtt{A}2_{12}. \tag{2.6}$$

Если необходимо перевести число из системы счисления по произвольному основанию N в ту систему счисления, которая используется в расчётах (при расчётах вручную это обычно десятичная система), это можно сделать, используя определение (2.2):

$$12345_{12} = 5 \cdot 12^0 + 4 \cdot 12^1 + 3 \cdot 12^2 + 2 \cdot 12^3 + 1 \cdot 12^4 = 24677_{10}$$
$$101_2 = 1 \cdot 2^0 + 0 \cdot 2^1 + 1 \cdot 2^2 = 5_{10}$$
$$\mathtt{1A}_{16} = 10 \cdot 16^0 + 1 \cdot 16^1 = 26_{10}$$

Компьютер оперирует с данными, представленными в двоичной системе, таким образом, при вводе десятичных данных необходимое преобразование также можно выполнить по (2.2):

$$13_{10} = 11 \cdot 1010^0 + 1 \cdot 1010^1 = 11 + 1010 = 1101$$

Впрочем, десятично-двоичное преобразование уже реализовано в библиотеке ввода-вывода любого языка высокого уровня и выполняется неявно для программиста и тем более для пользователя.

Если число необходимо перевести из системы счисления по основанию N в систему по основанию $N^k, k \in \mathbb{N}$ или наоборот, то также нет необходимости в сложных вычислениях. В этом случае существует взаимно однозначное соответствие между группой из k разрядов в системе по основанию N и одним разрядом в системе по основанию N^k, что будет подробнее рассмотрено ниже на примере двоичной, восьмеричной и шестнадцатеричной систем.

2.3.2. Экономичность системы счисления

> *Ка* — взаимное сближение двух точек до неподвижного предела, остановки многих точек у одной неподвижной. Звезда движений, обратная *Эс*.
>
> *В. Хлебников. Царапина по небу*

С точки зрения математики, все позиционные системы счисления равнозначны. Но, как показывает практика, вычислительные системы, обрабатывающие данные в двоичной системе, более просто устроены и, соответственно, имеют меньшие габариты, чем десятичные (при сопоставимых возможностях). Это связано с таким свойством, как экономичность, или компактность системы счисления. Считается, что понятие экономичности введено фон Нейманом.

Рассмотрим сравнительную экономичность двоичной и десятичной систем на следующем примере [47]. В десятичной системе для представления 10^3 чисел от 0 до 999 используется три разряда, каждый из которых помещает одну из десяти различных цифр, то есть всего используется 30 цифр. В двоичной системе из тех же 30 цифр можно составить 15 разрядов, каждый из которых хранит ноль или единицу. Таким образом, всего можно представить $2^{15} = 32\,768$ различных чисел — более чем на порядок больше, чем в десятичной.

Обобщая эти рассуждения, можно оценить количество $E_n(N)$ различных чисел, представимых в системе счисления по основанию N с помощью n цифр:

$$E_n(N) = N^{\frac{n}{N}} \tag{2.7}$$

Хотя на практике используются только натуральные основания систем счисления, (2.7) можно распространить и на вещественные положительные N. На рис. 2.1 представлена зависимость $E_n(N)$ для трёх значений количества цифр n.

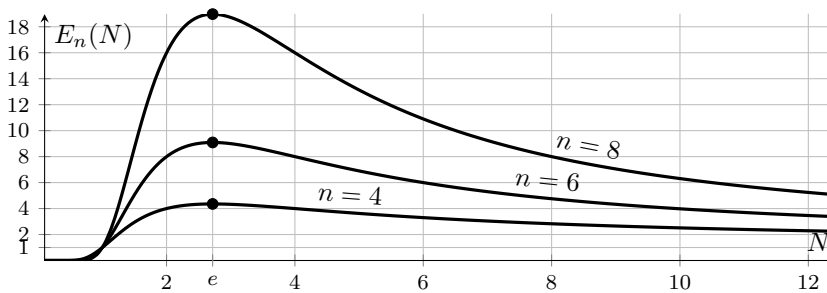

Рис. 2.1. Эффективность систем счисления

Как видно из рис. 2.1, количество используемых цифр n не влияет на то, какая из систем счисления более экономична, от него зависит только выраженность пика:

чем большее количество цифр используется, тем больше разрыв между различными системами. Для всех значений n двоичная система существенно превосходит десятичную, но отнюдь не является самой эффективной. Максимум $E_n(N)$ находится в точке $N = e = 2{,}71828\ldots$, что можно доказать дифференцированием (2.7). Из натуральных N наибольшее значение достигается при $N = 3$, то есть троичная система ещё экономичнее двоичной. Далее эффективность снижается с ростом N: четверичная система так же экономична, как и двоичная; при $N > 4$ экономичность плавно снижается и асимптотически стремится к единице.

Также можно заметить, что для всех n получаем $E_n(1) = 1$. Действительно (хотя единичная система не является в полной мере позиционной и, соответственно, не может однозначно рассматриваться как частный случай (2.7)): в единичной системе с помощью n цифр можно записать только одно число — оно равно n.

Таким образом, наиболее эффективной должна быть вычислительная машина, построенная с использованием троичной системы счисления. Двоичная система, использование которой связано с тем, что большинство существующих электронных компонентов может находиться только в двух состояниях, также относительно эффективна.

2.3.3. Нецифровые символы в представлении чисел

Как рассказать володение чисел,
Поведать их полдням и ночам?

В. Хлебников. Дети Выдры

В позиционной системе счисления по основанию N с помощью цифр можно записать любое число из $\mathbb{N}_0$. Но, как было сказано выше, для представления некоторых данных недостаточно неотрицательных целых чисел. В этих случаях используются формы записи, включающие дополнительные символы, не являющиеся цифрами.

Знак

В частности, отрицательные числа маркируются нецифровым символом «$-$» (минус), после которого записывается абсолютная величина (модуль) числа в используемой системой счисления. Соответственно, перед значением положительного числа может быть поставлен символ $+$ (плюс), но он часто опускается:

$$\begin{array}{rcrcrcl} -1_{10} & = & -1_2 & = & -1_{12} & & \\ +2_{10} & = & +10_2 & = & +2_{12} & = & 2_{12} \\ -11_{10} & = & -1011_2 & = & -\mathrm{A}_{12} & & \end{array} \tag{2.8}$$

Дробная черта

Простые дроби $\frac{m}{n}$ представляются своими числителем и знаменателем, разделёнными горизонтальной чертой:

$$\begin{aligned}\left(\frac{3}{4}\right)_{10} &= \left(\frac{11}{100}\right)_2 = \left(\frac{3}{4}\right)_{12}\\ \left(\frac{12}{5}\right)_{10} &= \left(\frac{1100}{101}\right)_2 = \left(\frac{10}{5}\right)_{12}\\ \left(\frac{100}{49}\right)_{10} &= \left(\frac{1100100}{110001}\right)_2 = \left(\frac{84}{41}\right)_{12}\end{aligned} \tag{2.9}$$

Но не все вещественные числа можно представить в виде отношения двух натуральных; кроме того, работать с таким представлением не всегда удобно.

Разделитель дробной части

Более универсальным является расширение позиционного представления на случай вещественных чисел. Для разделения целой и дробной частей такого представления также используется нецифровой символ. В российской традиции это запятая, в западной — точка:

$$\begin{aligned}11{,}5_{10} &= 1011{,}1_2 = \text{B}{,}6_{12}\\ 0{,}25_{10} &= 0{,}01_2 = 0{,}3_{12}\end{aligned} \tag{2.10}$$

Рассмотрим это представление подробнее.

2.3.4. Позиционное представление вещественных чисел

Прелестная бездна.
Бездна — восторг!

В. В. Маяковский. Человек

Хотя определение позиционного представления по основанию N (2.2) изначально давалось для натуральных чисел, его можно расширить, введя отрицательные степени $\frac{1}{N}$, $\frac{1}{N^2}$, и так далее:

$$\begin{aligned}X &= x_k \cdot N^k + \ldots + x_1 \cdot N^1 + x_0 \cdot N^0 + x_{-1} \cdot N^{-1} + \ldots + x_{-\ell} \cdot N^{-\ell} + \ldots =\\ &= x_k \cdot N^k + \ldots + x_1 \cdot N + x_0 + \frac{x_{-1}}{N} + \ldots + \frac{x_{-\ell}}{N^\ell} + \ldots =\\ &= \overline{x_k \ldots x_1 x_0{,}x_{-1} \ldots x_{-\ell} \ldots}_N,\ \ 0 \leqslant x_i < N \text{ — целые}\end{aligned} \tag{2.11}$$

Коэффициенты x_i (цифры) записываются в порядке убывания степени N; между коэффициентами при N^0 и при N^{-1} ставится запятая. В форме (2.11) (N-ичной

дроби) можно представить любое неотрицательное вещественное число X, но не всегда это можно сделать с помощью конечного количества знаков (количество отрицательных степеней N с ненулевыми коэффициентами может быть бесконечным даже для конечных рациональных чисел).

Если для какого-либо s все коэффициенты $x_{-\ell}$ для $\ell > s$ нулевые, позиционная дробь называется конечной (или, что то же самое, числом с конечной дробной частью):

$$\begin{gathered} X = x_k \cdot N^k + \ldots + x_1 \cdot N^1 + x_0 \cdot N^0 + x_{-1} \cdot N^{-1} + \ldots + x_{-s} \cdot N^{-s} = \\ = x_k \cdot N^k + \ldots + x_1 \cdot N + x_0 + \frac{x_{-1}}{N} + \ldots + \frac{x_{-s}}{N^s} = \\ = \overline{x_k \ldots x_1 x_0, x_{-1} \ldots x_{-s}}_N, \quad 0 \leqslant x_i < N \text{ — целые} \end{gathered} \tag{2.12}$$

Число X, представимое в одной системе счисления как конечная дробь, в другой может оказаться бесконечным.

В случае $N = 10$ получаем привычные **десятичные дроби,** а запятая (или, в западной традиции, точка), отделяющая целую часть от дробной, называется **десятичным разделителем.**

Сгруппируем члены (2.11):

$$\begin{gathered} X = \underbrace{\left(x_k \cdot N^k + \ldots + x_1 \cdot N + x_0\right)}_{\lfloor X \rfloor} + \underbrace{\left(x_{-1} \cdot N^{-1} + \ldots + x_{-\ell} \cdot N^{-\ell} + \ldots\right)}_{\{X\}} = \\ = \lfloor X \rfloor + \{X\} \end{gathered} \tag{2.13}$$

получаем разделение числа X на целую и дробную часть: $\lfloor X \rfloor$ — целое неотрицательное число (сумма целых неотрицательных слагаемых), $\{X\} \in [0,1]$ — дробная часть:

$$\begin{gathered} 0 = 0 \cdot N^{-1} + \ldots + 0 \cdot N^{-\ell} + \ldots \leqslant \{X\} \leqslant \\ \leqslant (N-1) \cdot N^{-1} + \ldots + (N-1) \cdot N^{-\ell} + \ldots = 1 \end{gathered} \tag{2.14}$$

если рассматривать только конечные дроби, то $\{X\} \in [0,1)$.

Для нуля и неотрицательных нецелых чисел представление (2.11) единственно, натуральные могут быть представлены в двух формах — с нулевой дробной частью или с бесконечной дробной частью $\sum_{\ell=1}^{\infty} \frac{N-1}{N^\ell} = 1$, например:

$$\begin{gathered} 2_{10} = 2{,}000\ldots_{10} = 1{,}999\ldots_{10} = \\ = 10_2 = 10{,}000\ldots_2 = 1{,}111\ldots_2 = \\ = 2_{12} = 2{,}000\ldots_{12} = 1{,}\mathrm{BBB}\ldots_{12} \end{gathered} \tag{2.15}$$

канонической (а если есть какие-то ограничения на длину дробной части — единственной) формой записи натуральных чисел является запись с нулевой дробной частью.

Таким образом, для представления числа $X \in [0,+\infty)$ в каноническом виде (2.11) необходимо разделить его на целую часть $\lfloor X \rfloor \in \mathbb{N}_0$, которая затем записывается в позиционной форме (2.2) уже описанным способом, и дробную часть $\{X\} \in [0,1)$, которую надо представить в виде:

$$\{X\} = x_{-1} \cdot N^{-1} + \ldots + x_{-\ell} \cdot N^{-\ell} + \ldots \tag{2.16}$$

после чего представления целой и дробной частей записываются рядом. Для их разделения используется соответствующий нецифровой символ — запятая или (в западной традиции) точка.

Геометрическая интерпретация

Рассмотрим геометрическую интерпретацию позиционной записи дробной части в виде (2.16). Представим диапазон $[0,1)$ как полуинтервал на числовой оси (рис. 2.2). Края этого полуинтервала, показанные двумя вертикальными линиями — 0 и 1 — одинаково записываются в любой позиционной системе счисления.

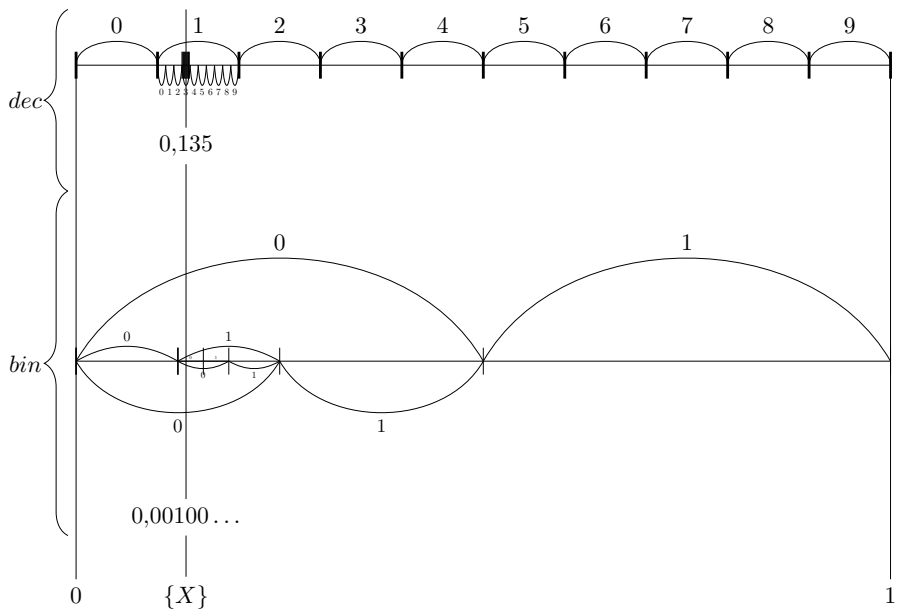

Рис. 2.2. Геометрическая интерпретация позиционного представления дробной части в различных системах счисления

Каждому значению из диапазона $[0,1)$ соответствует одна точка полуинтервала, причём её положение не зависит от используемой системы счисления. Значе-

ние $\{X\}$, которое требуется представить в форме (2.16), показано вертикальной линией внутри полуинтервала.

Первое слагаемое (2.16), то есть $\frac{x_{-1}}{N}$, можно проиллюстрировать разбиением полуинтервала на N равных полуинтервалов $[\frac{n}{N}, \frac{n+1}{N})$, где n принимает значения от 0 до $N-1$. На рис. 2.2 показано такое разбиение для $N=10$ (вверху) и $N=2$ (внизу). Значение n для каждого полуинтервала записано на дуге, проведённой над этим полуинтервалом. Соответственно, первая цифра в позиционной записи $\{X\}$ соответствует тому полуинтервалу, которому принадлежит точка $\{X\}$. Для значения, показанного на рис. 2.2, это 1 в десятичной системе счисления и 0 — в двоичной.

Вторая цифра получается делением полученного полуинтервала на N ещё меньших (показаны дугами и цифрами под осью). Для показанного на рисунке значения получаем 3 в десятичной системе счисления и 0 — в двоичной.

Дальнейшее разбиение полуинтервалов (на рисунке показано только для двоичной системы) приводит к десятичной записи $0{,}135$ и двоичной $0{,}00100\ldots$

Перевод простых дробей в позиционные

Перевод простой дроби в вид (2.11) можно выполнить делением в столбик. Рассмотрим представление одной третьей в различных позиционных системах счисления.

В двоичной системе потребуется разделить 1_2 на 11_2:

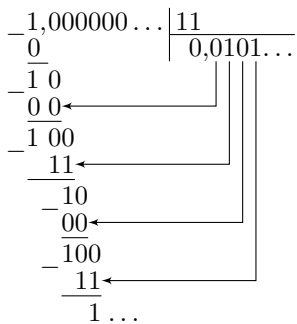

$$\frac{1}{11} = 0{,}0101\ldots = 0{,}(01) \tag{2.17}$$

деление будет бесконечным, причём после первого повторения частичного остатка процесс будет циклически повторяться. Таким образом, одна треть в двоичной системе представляется как бесконечная двоичная дробь $0{,}(01)$.

В двенадцатеричной системе делим 1_{12} на 3_{12}:

$$\begin{array}{l} \underline{-1,00\ldots}\,\big|\,\underline{3} \\ \underline{\;\;0\;\;}\quad\;\big|\,0{,}4 \\ \underline{-1\;0\;\;} \\ \underline{\;\;1\;0\;\;} \\ \;\;\;0 \end{array} \qquad \frac{1}{3} = 0{,}4 \tag{2.18}$$

так как $\frac{1}{3} = \frac{4}{12}$, получаем конечную двенадцатеричную дробь $0{,}4_{12}$.

Вообще, дробь конечна, если простые делители знаменателя простой дроби входят в число делителей основания системы счисления. Таким образом, чтобы число представлялось конечной двенадцатеричной дробью, знаменатель должен быть произведением произвольного количества двоек и троек; чтобы дробь была конечной в десятичной системе — двоек и пятёрок; а в двоичной системе конечными будут только те дроби, знаменатель которых является степенью двойки.

Перевод вещественных чисел между позиционными системами счисления

Процесс перевода вещественного числа $X \in \mathbb{R}$ в систему счисления по основанию N включает шесть стадий:

1. Знак числа отделяется от абсолютной величины:

$$X = \pm|X| \tag{2.19}$$

2. Абсолютная величина разделяется на целую и дробную части:

$$|X| = \Big\lfloor |X| \Big\rfloor + \Big\{ |X| \Big\}, \tag{2.20}$$

где $\Big\lfloor |X| \Big\rfloor \in \mathbb{N}_0, \Big\{ |X| \Big\} \in [0;1)$.

3. Целая часть абсолютной величины числа раскладывается на сумму неотрицательных степеней основания N:

$$\Big\lfloor |X| \Big\rfloor = a_0 + a_1 N + a_2 N^2 + \ldots + a_k N^k, \;\; a_i \in \{0, 1, \ldots, N-1\}. \tag{2.21}$$

Для нахождение коэффициентов a_i используется деление с остатком, как говорилось ранее.

4. Дробная часть раскладывается на сумму отрицательных степеней N (возможно, бесконечную — на практике в этом случае дробная часть округляется в соответствии с погрешностью числа X):

$$\Big\{ |X| \Big\} = \frac{b_1}{N} + \frac{b_2}{N^2} + \frac{b_3}{N^3} + \ldots, \;\; b_i \in \{0, 1, \ldots, N-1\}. \tag{2.22}$$

5. Абсолютная величина числа записывается как последовательность коэффициентов a_i и b_i, расположенных по убыванию степени (коэффициенты при отрицательных степенях отделяются запятой):

$$|X| = \overline{a_k \dots a_2 a_1 a_0{,}b_1 b_2 b_3 \dots} \tag{2.23}$$

6. Перед записью (2.23) ставится знак «+» или «−», определённый на первой стадии (знак «+» может быть опущен).

Рассмотрим процесс перевода дробной части $\left\{|X|\right\} \in [0,1)$ в вид (2.22) подробнее. Если цифры целой части получались путём последовательного деления её с остатком на основание системы, то очередную цифру дробной части можно определить *умножением* на N:

$$\begin{gathered}\left\{|X|\right\} \cdot N = \overline{0{,}b_1 b_2 b_3 \dots} \cdot N = \\ = \left(\frac{b_1}{N} + \frac{b_2}{N^2} + \frac{b_3}{N^3} + \dots\right) \cdot N = b_1 + \frac{b_2}{N} + \frac{b_3}{N^2} + \dots = \\ = \overline{b_1{,}b_2 b_3 \dots} = b_1 + \overline{0{,}b_2 b_3 \dots}\end{gathered} \tag{2.24}$$

Таким образом, после умножения $\left\{|X|\right\} \in [0,1)$ на N получаем значение в диапазоне $[0,N)$. Его целая часть — b_1, первая цифра $\left\{|X|\right\}$ после запятой. Дробная часть $\overline{0{,}b_2 b_3 \dots}$ лежит в диапазоне $[0,1)$. Умножая её на N, можно найти вторую цифру после запятой b_2 и так далее.

Таким образом, последовательность цифр b_i можно получить по следующей итерационной схеме:

$$\begin{cases} b_i = \left\lfloor X_{i-i} \cdot N \right\rfloor \\ X_i = \left\{X_{i-i} \cdot N\right\} \end{cases}, \tag{2.25}$$

где $X_0 = \left\{|X|\right\}$.

В таблице 2.1 показан процесс перевода значения $X_0 = 0{,}135_{10}$ в двоичную систему счисления. Порядковый номер действия i соответствует позиции полученной цифры после запятой. Сама полученная цифра b_i (целая часть результата действия) показана жирным шрифтом.

На двадцать четвёртом шаге результат совпал с полученным на четвёртом шаге. Так как следующий шаг полностью определяется результатом предыдущего, далее процесс повторится, и получится бесконечная периодическая дробь:

$$0{,}135_{10} = 0{,}001(0001010001111010111 0)_2 \tag{2.26}$$

Перевод $0{,}135_{10}$ в двоичную систему счисления

Таблица 2.1

i	Действие	i	Действие	i	Действие
1	$0{,}135 \cdot 2 = \mathbf{0}{,}270$	9	$0{,}560 \cdot 2 = \mathbf{1}{,}120$	17	$0{,}360 \cdot 2 = \mathbf{0}{,}720$
2	$0{,}270 \cdot 2 = \mathbf{0}{,}540$	10	$0{,}120 \cdot 2 = \mathbf{0}{,}240$	18	$0{,}720 \cdot 2 = \mathbf{1}{,}440$
3	$0{,}540 \cdot 2 = \mathbf{1}{,}080$	11	$0{,}240 \cdot 2 = \mathbf{0}{,}480$	19	$0{,}440 \cdot 2 = \mathbf{0}{,}880$
4	$0{,}080 \cdot 2 = \mathbf{0}{,}160$	12	$0{,}480 \cdot 2 = \mathbf{0}{,}960$	20	$0{,}880 \cdot 2 = \mathbf{1}{,}760$
5	$0{,}160 \cdot 2 = \mathbf{0}{,}320$	13	$0{,}960 \cdot 2 = \mathbf{1}{,}920$	21	$0{,}760 \cdot 2 = \mathbf{1}{,}520$
6	$0{,}320 \cdot 2 = \mathbf{0}{,}640$	14	$0{,}920 \cdot 2 = \mathbf{1}{,}840$	22	$0{,}520 \cdot 2 = \mathbf{1}{,}040$
7	$0{,}640 \cdot 2 = \mathbf{1}{,}280$	15	$0{,}840 \cdot 2 = \mathbf{1}{,}680$	23	$0{,}040 \cdot 2 = \mathbf{0}{,}080$
8	$0{,}280 \cdot 2 = \mathbf{0}{,}560$	16	$0{,}680 \cdot 2 = \mathbf{1}{,}360$	24	$0{,}080 \cdot 2 = \mathbf{0}{,}160$

Таким образом, $X_0 = 0{,}135_{10}$ невозможно точно представить конечной двоичной дробью. Для практической обработки его необходимо округлить.

Как определить, сколько двоичных разрядов достаточно для представления числа? Если значение $0{,}135_{10}$ точное, то есть равно $0{,}1350000\ldots_{10}$, то любое конечное количество разрядов будет недостаточным, и погрешность округления будет определяться возможностями вычислителя.

Если, как чаще всего бывает для измеряемых величин, достоверно известны только приведённые цифры, то есть $X_0 = (0{,}135 \pm 0{,}0005)_{10}$, можно отбросить все те разряды, вес которых $\frac{1}{2^\ell}$ меньше погрешности. Это разряды, для которых $2^\ell > \frac{1}{0{,}0005} = 2000$, а именно $\ell \geqslant 11$. Так как одиннадцатый разряд нулевой, неоднозначности с округлением не возникает. Таким образом, получаем десять значащих двоичных разрядов:

$$(0{,}135 \pm 0{,}0005)_{10} = (0{,}0010001010 \pm 0{,}00000000001)_2 \qquad (2.27)$$

Последний ноль в двоичной записи также является значащим, так как его вес больше погрешности значения.

Рассмотрим приближённое значение $\widetilde{X_0} = 0{,}0010001010_2$ и переведём его обратно в десятичную систему. Все действия выполняются аналогично приведённым ранее — на каждом шаге выполняется масштабирование в $10_{10} = 1010_2$ раз (таблица 2.2). Полученная на каждом шаге цифра b_i выделена жирным шрифтом и для наглядности продублирована в десятичном виде в последнем столбце.

Технически можно довести вычисления до конца, так как любая конечная двоичная дробь представима конечной десятичной (так как два — делитель десяти).

Перевод $0{,}0010001010_2$ в десятичную систему счисления

Таблица 2.2

i	**Действие**				$(b_i)_{10}$
1	$0{,}0010001010$	$\cdot 1010$	$=$	$\mathbf{1}{,}01011001$	1
2	$0{,}01011001$	$\cdot 1010$	$=$	$\mathbf{11}{,}0111101$	3
3	$0{,}0111101$	$\cdot 1010$	$=$	$\mathbf{100}{,}110001$	4
4	$0{,}110001$	$\cdot 1010$	$=$	$\mathbf{111}{,}10101$	7
5	$0{,}10101$	$\cdot 1010$	$=$	$\mathbf{110}{,}1001$	6
6	$0{,}1001$	$\cdot 1010$	$=$	$\mathbf{101}{,}101$	5
7	$0{,}101$	$\cdot 1010$	$=$	$\mathbf{110}{,}01$	6
8	$0{,}01$	$\cdot 1010$	$=$	$\mathbf{10}{,}1$	2
9	$0{,}1$	$\cdot 1010$	$=$	$\mathbf{101}{,}0$	5

На девятом шаге получаем нулевую дробную часть, то есть $\widetilde{X_0} = 0{,}0010001010_2$ представляется конечной десятичной дробью:

$$\widetilde{X_0} = 0{,}0010001010_2 = 0{,}134765625_{10} \tag{2.28}$$

Но большая часть знаков этой дроби — «мусорные».

Если в двоичной записи числа $\widetilde{X_0}$ достоверны только указанные знаки, то есть $\widetilde{X_0} = 0{,}0010001010 \pm \frac{1}{2^{11}}$, то десятичные разряды с весом $\frac{1}{10^\ell}$, меньшим погрешности, не определены. Это разряды с $10^\ell > 2^{11} = 2048$, то есть $\ell \geqslant 4$. Таким образом, в ответе останутся три значащих десятичных цифры после запятой, а вычисления в таблице 2.2 нужно было прервать после четвёртого шага ($\widetilde{X_0} = 0{,}1347\ldots$) и округлить до трёх десятичных разрядов. После этого получим исходное значение $X_0 = 0{,}135_{10}$.

2.4. Двоичное представление беззнаковых целых чисел

> Но да будет слово ваше: «да, да»; «нет, нет»;
> а что сверх этого, то от лукавого.
>
> *Мф. 5:37*

В настоящее время в вычислительных системах повсеместно используются элементы, которые могут находиться в двух различных состояниях. Соответственно, применяется позиционная система счисления по основанию 2, в которой используется всего две цифры — 0 и 1 (без нецифровых символов, так что отрицательные

и вещественные числа невозможно представить привычным образом; работа с ними будет рассмотрена отдельно).

Таким образом, число $X \in \mathbb{N}_0$ представляется в виде:

$$X = x_0 + x_1 \cdot 2 + \ldots + x_k \cdot 2^k = \overline{(x_k \ldots x_1 x_0)}_2, \;\; x_i \in \{0,1\} \tag{2.29}$$

например,

$$109_{10} = 1 + 0 \cdot 2 + 1 \cdot 4 + 1 \cdot 8 + 0 \cdot 16 + 1 \cdot 32 + 1 \cdot 64 = 1101101_2.$$

Каждому двоичному разряду (биту, от binary digit) числа, соответствует одна элементарная ячейка памяти, которая может находиться в одном из двух состояний. Эти состояния обычно также обозначаются как 0 и 1.

Количество таких ячеек в числе не может быть произвольным — оно определяется особенностями вычислительной системы и всегда кратно определённому числу, называемому размером байта. Число минимально возможного размера, соответственно, называется **байтом**. В настоящее время байт обычно содержит 8 разрядов (битов), иногда — 16, другие значения встречаются реже.

Ячейка памяти не может быть пуста — в ней обязательно содержится либо 0, либо 1. В частности, хотя двоичное представление десятичного числа 109 содержит семь значащих цифр (1101101), записать в восьмибитный байт можно только восемь (01101101).

Такая запись называется натуральным двоичным кодом (binary, сокращённо bin), так как она, с одной стороны, используется для натуральных чисел (и ещё для нуля), а с другой — является наиболее естественным их представлением.

Добавленный нулевой старший бит соответствует в разложении числа слагаемому $0 \cdot 128 = 0$, то есть не влияет на значение числа. Таким образом, ноль в старшем разряде (ведущий ноль) для числа в натуральном двоичном коде является **незначащим** и часто опускается на письме.

Минимальное число, которое можно записать в восьми битах натуральным двоичным кодом — ноль ($0000\,0000$), максимальное — 255 ($1111\,1111$). В общем случае N битами можно записать числа от 0 до $2^N - 1$.

2.4.1. Восьмеричное и шестнадцатеричное представление

> К болтовне поэтической я слишком привык, —
> я ещё говорю стихом, а не напрямик.
>
> *В. В. Маяковский. Пятый Интернационал*

Двоичная запись даже относительно небольших чисел выглядит очень громоздко и трудно читается человеком. Обычно для ввода-вывода используется десятичная запись, но в некоторых случаях это неприемлемо.

Для того, чтобы придать числам компактный вид и при этом сохранить их двоичную структуру, используются восьмеричная (octal, oct) и шестнадцатеричная (hexadecimal, hex) системы счисления. Так как основания этих систем являются степенью двойки (то есть основания исходной системы), нет необходимости в сложных вычислениях.

Восьмеричное представление натуральных чисел

Рассмотрим двоичную запись некоторого числа в форме (2.29), сгруппируем слагаемые по тройкам (если число разрядов не кратно трём, дополним число справа одним или двумя незначащими нулями) и вынесем общий множитель за скобки:

$$\begin{gathered} X = \overline{(x_k \dots x_1 x_0)}_2 = \\ = \underbrace{x_0 + x_1 \cdot 2 + x_2 \cdot 2^2}_{} + \underbrace{x_3 \cdot 2^3 + x_4 \cdot 2^4 + x_5 \cdot 2^5}_{} + \\ + \dots + \underbrace{x_{3i} \cdot 2^{3i} + x_{3i+1} \cdot 2^{3i+1} + x_{3i+2} \cdot 2^{3i+2}}_{} + \dots = \\ = (x_0 + x_1 \cdot 2 + x_2 \cdot 2^2) + (x_3 + x_4 \cdot 2 + x_5 \cdot 2^2) \cdot 2^3 + \\ + \dots + (x_{3i} + x_{3i+1} \cdot 2 + x_{3i+2} \cdot 2^2) \cdot 2^{3i} + \dots \end{gathered} \tag{2.30}$$

Так как двоичные цифры могут принимать только значения 0 и 1, значение внутри каждой скобки целое, неотрицательное и не превышает семи:

$$0 = 0 + 0 \cdot 2 + 0 \cdot 2^2 \leqslant x_{3i} + x_{3i+1} \cdot 2 + x_{3i+2} \cdot 2^2 \leqslant 1 + 1 \cdot 2 + 1 \cdot 2^2 = 7 \tag{2.31}$$

коэффициенты при скобках имеют вид $2^{3i} = \left(2^3\right)^i = 8^i$. Таким образом, получаем позиционную восьмеричную запись:

$$\begin{gathered} X = (x_0 + x_1 \cdot 2 + x_2 \cdot 4) + (x_3 + x_4 \cdot 2 + x_5 \cdot 4) \cdot 8 + \\ + \dots + (x_{3i} + x_{3i+1} \cdot 2 + x_{3i+2} \cdot 4) \cdot 8^i + \dots = \\ = \widetilde{x_0} + \widetilde{x_1} \cdot 8 + \dots + \widetilde{x_i} \cdot 8^i, \;\; \widetilde{x_i} \in \{0, 1, 2, \dots 7\} \end{gathered} \tag{2.32}$$

где $\widetilde{x_i} = x_{3i} + x_{3i+1} \cdot 2 + x_{3i+2} \cdot 4$.

На практике для перевода двоичной записи в восьмеричную достаточно разбить разряды на тройки и затем заменить каждую тройку двоичных цифр одной восьмеричной (таблица 2.3):

$$1101010_2 = 001\,101\,010_2 = 152_8 \tag{2.33}$$

для обратного преобразования каждая восьмеричная цифра заменяется тремя двоичными:

$$234_8 = 010\,011\,100_2 = 10011100_2 \tag{2.34}$$

Восьмеричное представление чисел используется, в частности, для записи прав доступа в Unix.

Соответствие двоичных триад восьмеричным цифрам

Таблица 2.3

bin	000	001	010	011	100	101	110	111
oct	0	1	2	3	4	5	6	7

Шестнадцатеричное представление натуральных чисел

Аналогично предыдущему разделу, для перевода из двоичной системы в шестнадцатеричную двоичные разряды необходимо группировать по четыре, так как $16 = 2^4$:

$$
\begin{aligned}
&X = \overline{(x_k \ldots x_1 x_0)}_2 = \\
&= \underbrace{x_0 + x_1 \cdot 2 + x_2 \cdot 2^2 + x_3 \cdot 2^3} + \underbrace{x_4 \cdot 2^4 + x_5 \cdot 2^5 + x_6 \cdot 2^6 + x_7 \cdot 2^7} + \\
&+ \ldots + \underbrace{x_{4i} \cdot 2^{4i} + x_{4i+1} \cdot 2^{4i+1} + x_{4i+2} \cdot 2^{4i+2} + x_{4i+3} \cdot 2^{4i+3}} + \ldots = \\
&= (x_0 + x_1 \cdot 2 + x_2 \cdot 2^2 + x_3 \cdot 2^3) + (x_4 + x_5 \cdot 2 + x_6 \cdot 2^2 + x_7 \cdot 2^3) \cdot 2^4 + \\
&\quad + \ldots + (x_{4i} + x_{4i+1} \cdot 2 + x_{4i+2} \cdot 2^2 + x_{4i+3} \cdot 2^3) \cdot 2^{4i} + \ldots = \\
&= (x_0 + x_1 \cdot 2 + x_2 \cdot 4 + x_3 \cdot 8) + (x_4 + x_5 \cdot 2 + x_6 \cdot 4 + x_7 \cdot 8) \cdot 16 + \\
&\quad + \ldots + (x_{4i} + x_{4i+1} \cdot 2 + x_{4i+2} \cdot 4 + x_{4i+3} \cdot 8) \cdot 16^i + \ldots = \\
&= \widetilde{x_0} + \widetilde{x_1} \cdot 16 + \ldots + \widetilde{x_i} \cdot 16^i, \;\; \widetilde{x_i} \in \{\mathtt{0}, \mathtt{1}, \mathtt{2}, \ldots \mathtt{F}\}
\end{aligned}
\tag{2.35}
$$

четыре двоичных разряда (тетрада) заменяются одним шестнадцатеричным (таблица 2.4)

$$1101010_2 = 0110\,1010_2 = 6A_{16} \tag{2.36}$$

и наоборот

$$\mathtt{2B3}_{16} = 0010\,1011\,0011_2 = 001010110011_2 \tag{2.37}$$

Соответствие двоичных тетрад шестнадцатеричным цифрам

Таблица 2.4

bin	0000	0001	0010	0011	0100	0101	0110	0111
hex	0	1	2	3	4	5	6	7
bin	1000	1001	1010	1011	1100	1101	1110	1111
hex	8	9	A	B	C	D	E	F

Шестнадцатеричное представление используется чаще, так как типичный байт (восемь бит) представляется двумя шестнадцатеричными цифрами. Часто двоичный код разделяют на тетрады просто для читабельности.

Так как восьмеричная и шестнадцатеричная системы счисления обычно используются для более компактной записи двоичного кода (содержимого памяти, в котором не используются нецифровые символы), а не как самостоятельные позиционные системы, они традиционно применяются только для беззнаковых целых чисел. Для более сложных структур данных под шестнадцатеричным представлением подразумевается шестнадцатеричное представление двоичного содержимого памяти, а не самих данных. Так, запись $-1 = \texttt{FFFF FFFF}$ обозначает, что значение -1 представляется в памяти двоичным кодом 1111 1111 1111 1111 1111 1111 1111 1111, что в шестнадцатеричном виде соответствует `FFFF FFFF`.

В частности, функции форматированного ввода-вывода стандартной библиотеки C++ (семейства $scanf$ и $printf$) предоставляют два спецификатора для десятичного представления — десятичное знаковое `%d` и десятичное беззнаковое `%u`, но шестнадцатеричное представление возможно только беззнаковое.

2.4.2. Беззнаковая арифметика в вычислительных системах

> Митрофан (вычисляя, шепчет).
> Единожды ноль — ноль. Единожды ноль — ноль.
> Нуль да нуль — нуль. Один да один... (Задумался.)
>
> *Д. И. Фонвизин. Недоросль*

Из-за единообразного представления чисел в позиционных системах счисления арифметические действия во всех таких системах выполняется по одному и тому же алгоритму. Соответственно, сложение, вычитание, умножение и деление натуральных чисел, записанных в двоичной системе, выполняется по привычной нам схеме «в столбик», с одним отличием: $1 + 1 = 10$.

Арифметика в вычислительных системах имеет ещё одно отличие от ручных вычислений, кроме основания системы счисления — ограниченность. Производя вычисления вручную, можно потенциально обрабатывать сколь угодно большие числа. Узел ЭВМ, предназначенный для выполнения арифметических действий, имеет фиксированную разрядность. В частности, N-разрядный сумматор — узел, выполняющий сложение — обрабатывает операнды, состоящие из N разрядов и формирует результат также длины N; и возможна ситуация, когда операнды арифметической операции попадают в допустимый диапазон, а её результат — уже нет.

Большинство современных процессоров семейства x86 имеет наборы команд для $N = 8_{10}$, $N = 16_{10}$, $N = 32_{10}$ и $N = 64_{10}$. Для наглядности все арифметические операции будут рассматриваться на примере $N = 8_{10}$.

Сложение и вычитание

Сложение производится поразрядно, начиная с младшего разряда. Если сумма младших разрядов равна или превышает 10, возникает **перенос в старший разряд.**

Рассмотрим сложение двух чисел, представленных в двоичном виде. При сложении младших разрядов получаем $1 + 1 = 10$, то есть младший разряд суммы равен 0, а к более старшему разряду добавляется единица переноса (перенос показан мелким шрифтом над первым слагаемым). Соответственно, для второго разряда получаем уже $1 + 1 + 1 = 11$ — единица в соответствующем разряде суммы и единица переноса — и так далее:

$$\begin{array}{r} {\scriptstyle 1\ 1\ \ \ \ \ \ \ } \\ 1010011 \\ +\ \ \ 1011 \\ \hline 1011110 \end{array} \quad (83_{10} + 11_{10} = 94_{10}) \tag{2.38}$$

В скобках показано десятичное представление слагаемых и суммы.

Как уже было сказано, одной из особенностей арифметики вычислительных систем является ограниченный диапазон представимых чисел. Все операции в ЭВМ выполняется над числами фиксированной длины N (в данном разделе рассматривается случай $N = 8_{10}$).

В этом случае пример (2.38) корректнее было бы записать в виде:

$$\begin{array}{r} {\scriptstyle \ \ 1\ 1\ \ \ \ \ \ \ } \\ 01010011 \\ +\ 00001011 \\ \hline 01011110 \end{array} \quad (83_{10} + 11_{10} = 94_{10}) \tag{2.39}$$

так как ни один из разрядов числа не может быть пуст. Но такая запись тяжело читается, поэтому незначащие нули часто опускают.

Пусть необходимо прибавить к максимальному представимому числу (для восьми разрядов это $1111\,1111 = 255_{10}$) единицу. Сумма младших разрядов слагаемых даст ноль в младшем разряде и единицу переноса ($1 + 1 = 10$); сумма единицы переноса и вторых разрядов слагаемых — ноль во втором разряде и единицу переноса ($1 + 1 + 0 = 10$) и так далее. Сумма старших (восьмых) разрядов тоже также даст ноль в старшем (восьмом) разряде результата и единицу переноса в девятый разряд результата ($1+1+0 = 10$), так что в неограниченной арифметике (в частности, при ручном расчёте) получилось бы:

$$\begin{array}{r} {\scriptstyle 1\ 1\ 1\ 1\ 1\ 1\ 1\ 1\ } \\ 11111111 \\ +\ \ \ \ \ \ \ 1 \\ \hline 100000000 \end{array} \quad (255_{10} + 1_{10} = 256_{10}) \tag{2.40}$$

но у восьмибитного результата нет девятого разряда — поэтому фактический результат будет равен нулю. Такая ситуация называется **беззнаковым переполнением.** Бит переноса в несуществующий разряд результата сохраняется в специальной ячейке, называемой **флагом переноса** (CF — Carry flag).

$$\begin{array}{r} {\scriptstyle 1\,1\,1\,1\,1\,1\,1\,1} \\ +\,11111111 \\ \hline 00000000 \end{array} \quad (255_{10} + 1_{10} = 0_{10}) \quad CF = 1 \tag{2.41}$$

В общем случае в N-битной арифметике $(2^N - 1) + 1 = 0$, при этом $CF = 1$.

Флаг переноса не является частью числа, куда записывается результат. Конструктивно ячейка CF принадлежит сумматору и, если подряд выполняется несколько операций, каждая из них будет перезаписывать CF новым значением.

Если размер суммы не превышает N разрядов, всё делается аналогично неограниченной арифметике и флаг переноса CF равен нулю.

$$\begin{array}{r} {\scriptstyle 1\qquad 1\,1} \\ +\,01010011 \\ \hline 10011110 \end{array} \quad (83_{10} + 75_{10} = 158_{10}) \quad CF = 0 \tag{2.42}$$

Одного разряда для флага переноса достаточно. Даже при сложении двух максимально возможных восьмибитных беззнаковых значений возникает перенос в девятый, но не в десятый разряд:

$$\begin{array}{r} {\scriptstyle 1\,1\,1\,1\,1\,1\,1\,1} \\ +\,11111111 \\ \hline 11111110 \end{array} \quad (255_{10} + 255_{10} = 254_{10}) \quad CF = 1 \tag{2.43}$$

Таким образом, в ЭВМ реализована циклическая двоичная арифметика: при сложении операндов a и b разрядности N результат фактически равен $(a + b) \bmod 2^N$. Программист может определить корректность результата, анализируя флаг переноса из старшего разряда CF.

Вычитание выполняется, как и сложение, поразрядно. При необходимости выполняется заём из старшего разряда:

$$\begin{array}{r} {\scriptstyle \cdot\,\cdot\,\cdot} \\ -\,1000011 \\ \hline 111010 \end{array} \quad (67_{10} - 9_{10} = 58_{10}) \tag{2.44}$$

В случае, когда уменьшаемое меньше вычитаемого, возможен заём из несуществующего девятого разряда. Такая ситуация также отмечается единичным значением флага переноса CF:

$$\begin{array}{r} {\scriptstyle \cdot\,\cdot\qquad\cdot\,\cdot} \\ -\,00001001 \\ \underline{\quad 01000011} \\ \quad 11000110 \end{array} \quad (9_{10} - 67_{10} = 198_{10}) \quad CF = 1 \tag{2.45}$$

Как можно заметить, в неограниченной арифметике $58_{10} + 198_{10} = 256_{10}$.

Таким образом, вычитание, реализованное в ЭВМ, также циклическое: разность a и b разрядности N равна $(a - b) \bmod 2^N$, где под знаком «$-$» подразумевается вычитание в неограниченной арифметике. Здесь остаток $(a - b) \bmod 2^N$ всегда неотрицателен (то есть вычисляется по правилам математики, а не C++). Корректность результата можно определить, анализируя флаг CF, показывающий также заём в старший разряд.

В частности,

$$\begin{array}{r} {\scriptstyle \cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot} \\ -\,00000000 \\ \underline{\qquad\quad 1} \\ \quad 11111111 \end{array} \quad (0_{10} - 1_{10} = 255_{10}) \quad CF = 1 \tag{2.46}$$

Циклическое сложение (сложение по модулю 2^N) коммутативно ($a+b = b+a$) и ассоциативно ($a + (b + c) = (a + b) + c$). Циклическое вычитание связано с ним так же, как и обычное вычитание с обычным (неограниченным) сложением. Таким образом, циклическое вычитание антикоммутативно ($a - b = -(b - a)$) и требует смены знаков при раскрытии скобок ($a - (b - c) = (a - b) + c$). Циклические сложение и вычитание (сложение и вычитание по модулю 2^N) коммутативны и ассоциативны.

Умножение и деление

При умножении двух чисел первый множитель последовательно умножается на каждый разряд второго множителя и сдвигается влево на соответствующее количество разрядов (что соответствует умножению на 10, то есть на два). Затем результаты складываются:

$$\begin{array}{r} \times\,1010011 \\ \underline{\qquad\quad 1011} \\ \quad 1010011 \\ \quad 1010011 \\ \quad 0000000 \\ \underline{1010011\qquad} \\ 1110010001 \end{array} \quad (83_{10} \cdot 11_{10} = 913_{10}) \tag{2.47}$$

Как видно из (2.47), разрядность произведения может превысить разрядность множителей более чем на один бит. Поэтому большинство команд умножения процессоров семейства x86, работающие с операндами размера N, возвращают результат размера $2N$.

Действительно, рассмотрим умножение двух максимально возможных восьмибитных беззнаковых значений.

$$
\begin{array}{r}
\times\ 1111\ 1111 \\
\underline{\quad 1111\ 1111} \\
\scriptstyle 1\,2\,3\,4\ \ 5\,6\,7\,7\ \ 6\,5\,4\,3\ \ 2\,1 \\
1111\ 1111 \\
1\ 1111\ 111 \\
11\ 1111\ 11 \\
111\ 1111\ 1 \\
1111\ 1111 \\
1\ 1111\ 111 \\
11\ 1111\ 11 \\
111\ 1111\ 1 \\
\hline
1111\ 1110\ 0000\ 0001
\end{array}
\qquad (255_{10} \cdot 255_{10} = 65025_{10}) \tag{2.48}
$$

В умножении столбиком, как правило, переносы между разрядами не записываются, а запоминаются, но в данном примере ввиду его громоздкости перенос показан мелким шрифтом в следующей строке после множителей. Для наглядности столбцы, соответствующие тетрадам произведения, отделены пробелами.

Таким образом, для произведения двух восьмибитных множителей достаточно шестнадцати разрядов.

Беззнаковое умножение ассоциативно ($a \cdot (b \cdot c) = (a \cdot b) \cdot c$) и коммутативно ($a \cdot b = b \cdot a$), как и сложение, так что циклическую беззнаковую арифметику в целом можно назвать ассоциативной и коммутативной.

Деление также выполняется по классической схеме:

$$
\begin{array}{l}
\_1010011 \mid 1011 \\
\underline{\ 0000\ \ } \mid 0111 \\
\_10100 \\
\ \ \underline{1011} \\
\_10011 \\
\ \ \underline{1011} \\
\_10001 \\
\ \ \underline{1011} \\
\ \ \ 110
\end{array}
\qquad (83_{10}/11_{10} = 7_{10} \text{ и } 6_{10} \text{ в остатке}) \tag{2.49}
$$

обычно при ручном счёте нулевые вычитаемые опускают:

$$\begin{array}{r|l} 1010011 & 1011 \\ \underline{1011} & \underline{111} \\ 10011 & \\ \underline{1011} & \\ 10001 & \\ \underline{1011} & \\ 110 & \end{array} \qquad (83_{10}/11_{10} = 7_{10} \text{ и } 6_{10} \text{ в остатке}) \tag{2.50}$$

Так как деление обратно умножению, большинство команд деления процессоров семейства x86 для делителя и частного размера N используют делимое размера $2N$.

Деление неассоциативно и некоммутативно не только для беззнаковых целых, но и для вещественных чисел в целом.

2.5. Представление отрицательных чисел

> Если вы уже открываете мне лицевой счёт, то хоть ведите его правильно. Заведите дебет, заведите кредит. В дебет не забудьте внести шестьдесят тысяч рублей, которые вы мне должны, а в кредит — жилет. Сальдо в мою пользу — пятьдесят девять тысяч девятьсот девяносто два рубля. Ещё можно жить.
>
> *Илья Ильф, Евгений Петров. Двенадцать стульев*

Натуральный двоичный код позволяет кодировать только неотрицательные целые числа. При этом в некоторых задачах необходимы целые числа со знаком. В ячейках памяти нельзя непосредственно сохранить знак числа, так что знаковые и, в частности, отрицательные числа необходимо представить в виде комбинации нулей и единиц.

Рассмотрим различные способы кодирования знаковых чисел на восьми разрядах. Всего в восьмиразрядную ячейку можно записать 256 различных комбинаций нулей и единиц. Каждой из этих комбинаций соответствует некоторое неотрицательное число u в натуральном двоичном коде.

Для кодирования знаковых чисел необходимо поставить в соответствие каждой комбинации новое число (декодированное значение x), причём около половины из этих чисел должны быть отрицательными. Это можно сделать различными способами.

К представлению знаковых чисел можно сформулировать следующие пожелания:

– код должен позволять представить с помощью N битов все целые числа некоторого диапазона $x \in [\nu_1, \nu_2]$. Представимый диапазон $[\nu_1, \nu_2]$ должен включать ноль и примерно равное количество положительных и отрицательных чисел;

– представление неотрицательных чисел должно совпадать с их натуральным двоичным кодом;
– должен существовать простой способ различения положительных и отрицательных чисел;
– сложение и вычитание должно выполняться с помощью того же сумматора, что и сложение и вычитание неотрицательных чисел.

Три наиболее известных способа представления знаковых чисел на примере восьми разрядов представлены в таблицах 2.5 и 2.6.

Таблица 2.5 показывает кодирование знаковых чисел x различными способами. Первый столбец содержит десятичное представление знакового числа x, следующая группа из трёх столбцов показывает двоичный код x в виде величины со знаком, шестнадцатеричное представление этого кода, а также десятичное представление кода (так как это представление кода, а не самого числа x, оно беззнаковое). Аналогично, следующая группа из трёх столбцов содержит код с избытком (представлен избыток 128) и его шестнадцатеричное и десятичное представления, третья группа — дополнительный код.

Таблица 2.6 показывает декодирование беззнакового кода u. Первые три столбца содержат код u в десятичном, шестнадцатеричном и двоичном виде, четвёртый — значение, получаемое при декодировании u как величины со знаком, пятый — при декодировании как кода с избытком 128, шестой — как дополнительного кода.

Для кодирования целых знаковых чисел как самостоятельных величин в ЭВМ используется дополнительный код, соответствующих всем перечисленным выше критериям. Представление в виде величины со знаком или кода с избытком используются в кодировании компонент вещественных чисел.

2.5.1. Величина со знаком

Прискульптурив бороду на подбородок,
из Лассаля сделает Калинина.

В. В. Маяковский. Халтурщик

Наиболее очевидный способ кодирования чисел со знаком — выделить один бит (обычно старший) для хранения знака, а в оставшихся хранить абсолютную величину (модуль) числа (столбец «Величина со знаком» таблицы 2.6). Такой код легко читается человеком и для неотрицательных чисел совпадает с натуральным. Код в виде величины со знаком из N разрядов позволяет представить числа в диапазоне $\left[-2^{N-1}+1, 2^{N-1}-1\right]$ — всего 2^N-1 значений, хотя N разрядов вмещают 2^N различных двоичных кодов.

Различные способы представления знаковых чисел (кодирование)

Таблица 2.5

Значение	**Код** u								
x_{10}	**Величина со знаком**			**Код с избытком 128**			**Дополнительный код (дополнение до 2)**		
	u_2	u_{16}	u_{10}	u_2	u_{16}	u_{10}	u_2	u_{16}	u_{10}
-128	отсутствует			0000 0000	00	0	1000 0000	80	128
-127	1111 1111	FF	255	0000 0001	01	1	1000 0001	81	129
-126	1111 1110	FE	254	0000 0010	02	2	1000 0010	82	130
-125	1111 1101	FD	253	0000 0011	03	3	1000 0011	83	131
-124	1111 1100	FC	252	0000 0100	04	4	1000 0100	84	132
-123	1111 1011	FB	251	0000 0101	05	5	1000 0101	85	133
...	...	...	...	...	...	...	...	...	...
-4	1000 0100	84	132	0111 1100	7C	124	1111 1100	FC	252
-3	1000 0011	83	131	0111 1101	7D	125	1111 1101	FD	253
-2	1000 0010	82	130	0111 1110	7E	126	1111 1110	FE	254
-1	1000 0001	81	129	0111 1111	7F	127	1111 1111	FF	255
0	1000 0000 0000 0000	80 00	128 0	1000 0000	80	128	0000 0000	00	0
$+1$	0000 0001	01	1	1000 0001	81	129	0000 0001	01	1
$+2$	0000 0010	02	2	1000 0010	82	130	0000 0010	02	2
$+3$	0000 0011	03	3	1000 0011	83	131	0000 0011	03	3
$+4$	0000 0100	04	4	1000 0100	84	132	0000 0100	04	4
...	...	...	...	...	...	...	...	...	...
$+121$	0111 1001	79	121	1111 1001	F9	249	0111 1001	79	121
$+122$	0111 1010	7A	122	1111 1010	FA	250	0111 1010	7A	122
$+123$	0111 1011	7B	123	1111 1011	FB	251	0111 1011	7B	123
$+124$	0111 1100	7C	124	1111 1100	FC	252	0111 1100	7C	124
$+125$	0111 1101	7D	125	1111 1101	FD	253	0111 1101	7D	125
$+126$	0111 1110	7E	126	1111 1110	FE	254	0111 1110	7E	126
$+127$	0111 1111	7F	127	1111 1111	FF	255	0111 1111	7F	127

Различные способы представления знаковых чисел (декодирование)

Таблица 2.6

Код u			**Декодированное значение** x		
u_{10}	u_{16}	u_2	**Величина со знаком**	**Код с избытком 128**	**Дополнительный код (дополнение до 2)**
0	00	0000 0000	+0	−128	0
1	01	0000 0001	+1	−127	+1
2	02	0000 0010	+2	−126	+2
3	03	0000 0011	+3	−125	+3
4	04	0000 0100	+4	−124	+4
5	05	0000 0101	+5	−123	+5
6	06	0000 0110	+6	−122	+6
...	...	...	...	...	...
123	7B	0111 1011	+123	−5	+123
124	7C	0111 1100	+124	−4	+124
125	7D	0111 1101	+125	−3	+125
126	7E	0111 1110	+126	−2	+126
127	7F	0111 1111	+127	−1	+127
128	80	1000 0000	−0	0	−128
129	81	1000 0001	−1	+1	−127
130	82	1000 0010	−2	+2	−126
131	83	1000 0011	−3	+3	−125
132	84	1000 0100	−4	+4	−124
...	...	...	...	...	...
249	F9	1111 1001	−121	+121	−7
250	FA	1111 1010	−122	+122	−6
251	FB	1111 1011	−123	+123	−5
252	FC	1111 1100	−124	+124	−4
253	FD	1111 1101	−125	+125	−3
254	FE	1111 1110	−126	+126	−2
255	FF	1111 1111	−127	+127	−1

Это связано с тем, что данный код включает два нуля: $+0$, совпадающий с беззнаковым нулём, и -0 — с единичным знаковым битом и нулевым модулем.

Сложение таких чисел с использованием беззнакового сумматора требует большого числа дополнительных действий (в случае слагаемых одного знака модули будут складываться, для разных знаков — вычитаться).

Напротив, умножение и деление отрицательных чисел, представленных в виде величины со знаком, выполняется как беззнаковое умножение или деление величин, дополненное сложением знаков по модулю 2 (xor). Но, так как способ кодирования отрицательных чисел сложился в ранний период развития вычислительной техники, когда аппаратно были реализованы только сложение и вычитание (умножение и деление выполнялись подпрограммами), это достоинство оказалось несущественным.

Соответственно, код в виде величины со знаком не используется для целых чисел. Идея раздельного кодирования знака и абсолютной величины используется при кодировании вещественных чисел с плавающей запятой.

2.5.2. Код с избытком

> Я сразу смазал карту будня,
> плеснувши краску из стакана;
> я показал на блюде студня
> косые скулы океана.
>
> *В. В. Маяковский. А вы могли бы?*

Также для сопоставления знаковых чисел беззнаковым кодам можно задать некоторую константу ξ и поставить в соответствие каждому знаковому числу x беззнаковое значение $u = x + \xi$. После этого к полученному значению u применяется натуральное двоичное кодирование. Подобный код называется кодом с избытком ξ. Значение x по коду u, соответственно, можно найти как $x = u - \xi$.

Беззнаковым значение $u = x + \xi$ будет только для $x \geqslant -\xi$; соответственно, числа $x < -\xi$ невозможно закодировать подобным образом. Верхняя граница определяется не только величиной избытка ξ, но и количеством разрядов N, отведённых для кода u. Таким образом, код с избытком ξ позволяет представить N разрядами числа в диапазоне $\left[-\xi, 2^N - \xi - 1\right]$. В отличие от других описанных способов кодирования знаковых чисел, диапазон представимых чисел, в зависимости от значения ξ, может быть несимметричным и даже может не включать нуля. В частности, запись года двумя цифрами — код с избытком $\xi = -2000$.

В пятом столбце таблицы 2.6 показан код с избытком 128. В данном коде присутствует только один ноль, но его код не равен 0000 0000; кроме того, положительные числа кодируются не натуральным кодом.

Для сложения и вычитания чисел, представленных в коде с избытком, можно воспользоваться беззнаковым сумматором, но понадобится коррекция полученного результата. В частности, сложение двух чисел с избытком ξ даст результат с избытком 2ξ, так что необходимо вычесть ξ. Таким образом, сложение или вычитание таких чисел требует двух операций сложения/вычитания.

Код с избытком используется для представления порядка вещественных чисел с плавающей запятой, а также в специальной аппаратуре или для передачи данных по каналам связи, если диапазон данных невелик, но заведомо несимметричен относительно нуля (в частности, год или температура в помещении в градусах Цельсия).

2.5.3. Дополнительный код

Я знаю путь, который не во вред,
Я знаю средство поборать сомненья,
Я прохожу за поволоку лет
В четвёртый год от моего рожденья...

С. А. Калугин. Когда пронзит пылающий вопрос

Для того, чтобы записывать ноль и положительное число x натуральным двоичным (прямым) кодом и при этом иметь возможность пользоваться для знаковых чисел беззнаковым сумматором без коррекции результата, необходимо записывать отрицательное число $-x$ тем кодом, который получается в результате беззнакового вычитания $0 - x$ (с учётом цикличности сложения и вычитания в ЭВМ беззнаковое представление этого кода $2^N - x$).

Такой код называется дополнительным (или дополнением до двух) и представлен в последнем столбце таблицы 2.6. В таблице видно, что с помощью восьми двоичных разрядов можно представить:

- одно значение нуля ($0 = -0 = 0000\,0000$);
- положительные значения от 1 до 127, представленные в натуральном двоичном коде, которым соответствуют коды от $0000\,0001$ до $0111\,1111$;
- соответствующие им отрицательные значения от -1 до -127 — коды от $1111\,1111$ $(0 - 1)$ до $1000\,0001$ $(0 - 127)$.

Старший бит называется знаковым, так как у нуля и положительных чисел он равен нулю, у отрицательных — единице. Соответственно, код $1000\,0000$, который можно в принципе трактовать и как 128, и как $0 - 128 = -128$, считается кодом отрицательного числа -128.

Таким образом, дополнительный код позволяет представить с помощью N разрядов целые числа в диапазоне $\left[-2^{N-1}, 2^{N-1} - 1\right]$.

Дополнительный код неотрицательных чисел совпадает с прямым (натуральным).

Для перевода отрицательного числа $-x$ на практике используется следующая схема. Преобразуем $0 - x$ с учётом ассоциативности и коммутативности циклического сложения и соответствующих свойств вычитания:

$$-x = 0 - x = (-1 - x) + 1. \tag{2.51}$$

С учётом того, что дополнительный код -1 состоит из единиц во всех разрядах, $-1 - x$ — это инверсия всех битов x. Соответственно, дополнительный код $-x$ может быть рассчитан как $\neg x + 1$, где $\neg x$ — побитовое отрицание (инверсия битов) натурального двоичного представления абсолютной величины числа x.

Именно в дополнительном коде представлены отрицательные числа в современных вычислительных системах. При этом нет способа, анализируя двоичный код, в частности, 1111 1111, понять, кодирует ли он беззнаковое число 255 или знаковое -1 (или и вовсе что-то иное). Программист должен сам помнить, что именно было записано в данную ячейку, и применять соответствующие команды для обработки и вывода. При программировании на языке высокого уровня (в частности, C++) данную информацию хранит компилятор, но при присваивании переменных различного типа значения могут интерпретироваться по-разному.

2.5.4. Знаковая арифметика в вычислительных системах

> Ничего не доводи до крайности: человек, желающий трапезовать слишком поздно, рискует трапезовать на другой день поутру.
>
> *К. П. Прутков. Плоды раздумья. Мысли и афоризмы*

В большинстве вычислительных систем целые знаковые числа представляются дополнительным кодом, чтобы иметь возможность складывать и вычитать их теми же командами, что и беззнаковые. Рассмотрим подробнее действия над такими числами.

Сложение и вычитание

Дополнительный код построен таким образом, что операции с беззнаковым переполнением получают смысл.

В частности, примеры (2.41) и (2.43), демонстрирующие переполнение при беззнаковом сложении, являются корректными операциями сложения, если рас-

сматривать операнды и результат как знаковые:

$$\begin{array}{r} {\scriptstyle 1\,1\,1\,1\,1\,1\,1\,1} \\ +\,11111111 \\ \hline 1 \\ \hline 00000000 \end{array} \qquad -1_{10} + 1_{10} \;=\; 0_{10}$$

$$\begin{array}{r} {\scriptstyle 1\,1\,1\,1\,1\,1\,1\,1} \\ +\,11111111 \\ \hline 11111111 \\ \hline 11111110 \end{array} \qquad -1_{10} + (-1_{10}) \;=\; -2_{10} \tag{2.52}$$

Корректными станут и операции вычитания большего числа из меньшего в (2.45) и (2.46):

$$\begin{array}{r} {\scriptstyle \cdot\;\;\cdot} \\ -\,00001001 \\ \hline 01000011 \\ \hline 11000110 \end{array} \qquad 9_{10} - 67_{10} \;=\; -58_{10}$$

$$\begin{array}{r} {\scriptstyle \cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot} \\ -\,00000000 \\ \hline 1 \\ \hline 11111111 \end{array} \qquad 0_{10} - 1_{10} \;=\; -1_{10} \tag{2.53}$$

Операции (2.38) и (2.44), где и операнды, и результат неотрицательны и не превышают 127_{10}, корректны и при знаковой, и при беззнаковой трактовке.

Если беззнаковая операция корректна (переполнения не было), но результат превышает максимально возможное знаковое положительное число (для восьми бит 127_{10}), то при знаковой интерпретации результат перестаёт быть правильным. Например, в (2.42)

$$\begin{array}{r} {\scriptstyle 1\qquad 1\,1} \\ +\,01010011 \\ \hline 01001011 \\ \hline 10011110 \end{array} \qquad 83_{10} + 75_{10} = -98_{10} \tag{2.54}$$

В (2.54), в отличие от (2.52) и (2.53), есть перенос в старший (знаковый) разряд, но нет переноса из него в несуществующий девятый разряд.

Возможна ситуация, когда, наоборот, сумма двух отрицательных чисел имеет ноль в знаковом разряде, и, соответственно, интерпретируется как положительное число:

$$\begin{array}{r} {\scriptstyle 1\qquad 1\,1} \\ +\,10010011 \\ \hline 11001011 \\ \hline 01011110 \end{array} \qquad -109_{10} + (-53_{10}) = +94_{10} \tag{2.55}$$

Здесь не было переноса в знаковый разряд, но есть перенос из него.

Подобная ситуация называется **знаковым переполнением.**

Классические случаи знакового переполнения — добавление единицы к максимально возможному положительному числу:

$$\begin{array}{r} {\scriptstyle 1\,1\,1\,1\,1\,1\,1} \\ 01111111 \\ +\quad\quad 1 \\ \hline 10000000 \end{array} \qquad 127_{10} + 1_{10} \;=\; -128_{10} \tag{2.56}$$

и вычитание единицы из минимально возможного отрицательного:

$$\begin{array}{r} {\scriptstyle \cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot\,\cdot} \\ 10000000 \\ -\quad\quad 1 \\ \hline 01111111 \end{array} \qquad -128_{10} - 1_{10} \;=\; +127_{10} \tag{2.57}$$

Соответственно, если беззнаковое переполнение — это циклический переход через ноль, то знаковое переполнение для N бит — циклический переход между $+2^{N-1}-1$ и -2^{N-1} (код этого числа соответствует беззнаковому значению 2^{N-1}). Для восьми бит это переход от $+127_{10}$ к $-128_{10} = 128_{10}$ или наоборот. Именно этот переход и демонстрирует перенос/заём в знаковый разряд, который не компенсируется переносом/заёмом из него.

Таким образом, сложение и вычитание знаковых чисел, представленных в дополнительном коде, может выполняться таким же образом, как и беззнаковых чисел. При этом для проверки корректности результата нужно анализировать не перенос/заём в несуществующий разряд (флаг переноса CF), а знаковое переполнение — комбинацию переноса/заёма в знаковый разряд и переноса/заёма из знакового разряда в несуществующий.

Наличие знакового переполнения также отражается специальным флагом — **флагом переполнения** (OF, Overflow flag). Так, для (2.52) и (2.53) $OF = 0$, для (2.54)-(2.57) получим $OF = 1$.

Соответственно, команды сложения и вычитания не разделяются на знаковые и беззнаковые.

По результатам выполнения устанавливается значение как флага переноса (беззнакового переполнения) CF, так и флага знакового переполнения OF. Программист должен помнить, величины какого рода он складывал и вычитал и анализировать соответствующий флаг для проверки корректности. Если оба флага переполнения после сложения или вычитания сброшены, результат корректен и при знаковой, и при беззнаковой интерпретации.

Знаковое N-битное сложение, так же как и беззнаковое, коммутативно и ассоциативно.

Умножение и деление

Умножение отрицательных чисел по беззнаковой схеме, показанное, в частности, в (2.48), явно некорректно — результат получается также отрицательным. Это связано с тем, что при сложении частичных произведений подразумевалось, что пустые ячейки в записи умножения «столбиком» — это пропущенные незначащие нули.

Но ведущий ноль в дополнительном коде обозначает положительное число, поэтому во всех пустых ячейках необходимо разместить единицы.

$$
\begin{array}{l}
\times\ldots111\ 1111\\
\underline{\ldots111\ 1111}\\
\quad\scriptstyle 5\,4\,3\quad\scriptstyle 2\,1\\
\ldots111\ 1111\\
\ldots111\ 111\\
\ldots111\ 11\\
\ldots111\ 1\\
\ldots111\\
\ldots11\\
\underline{\ldots1}\\
\ldots000\ 0001
\end{array}
\qquad (-1_{10})\cdot(-1_{10}) = 1_{10} \tag{2.58}
$$

Для того, чтобы получить все значащие цифры произведения (как и для беззнаковых чисел, максимальное их количество равно $2N$), можно не рассматривать бесконечное количество ведущих единиц — достаточно ограничиться размером произведения.

$$
\begin{array}{l}
\times\ 1111\ 1111\ 1111\ 1111\\
\underline{1111\ 1111\ 1111\ 1111}\\
\scriptstyle E\,D\,C\,B\quad\scriptstyle A\,9\,8\,7\quad\scriptstyle 6\,5\,4\,3\quad\scriptstyle 2\,1\\
1111\ 1111\ 1111\ 1111\\
1111\ 1111\ 1111\ 111\\
\ldots\\
\\
11\\
\underline{1}\\
0000\ 0000\ 0000\ 0001
\end{array}
\qquad (-1_{10})\cdot(-1_{10}) = 1_{10} \tag{2.59}
$$

В общем случае знаковые множители дополняются до $2N$ разрядов знаковым битом (см. раздел 2.7.2). После этого они перемножаются уже без учёта знака и переносов за пределы разрядной сетки, как в (2.59).

Таким образом, если для умножения вычисляются все $2N$ бит (а для деления — делимое имеет размер $2N$), то знаковое и беззнаковое умножение и деление выполняются по различным алгоритмам и, соответственно, для них должны быть предусмотрены разные команды. Младшие N бит произведения двух N-разрядных чисел одинаковы и для беззнакового, и для знакового умножения [78].

Знаковое N-битное умножение также коммутативно и ассоциативно. Таким образом, арифметику целых знаковых чисел в дополнительном коде можно назвать в целом коммутативной и ассоциативной.

2.6. Альтернативная арифметика

Сегодня нам на доукомплектование прибыло 28 танков.
Их нужно распределить по 7 ротам. Я посчитал,
на каждую роту получается по 13 танков.
<...>
Ты получаешь 13 танков. 3 танка отдаёшь в 3 взвода,
а 1 остаётся тебе. Всё.

Фольклор

В предыдущих разделах рассматривались позиционное двоичное представление беззнаковых и знаковых целых чисел ограниченной разрядности и циклическая (по модулю 2^N) арифметика над такими числами. Но для некоторых задач удобнее использовать другое представление или другой способ обработки.

Следует помнить, что как невозможно по представлению в памяти отличить знаковое число от беззнакового, нельзя отличить их и от двоично-десятичных чисел, и от вектора остатков модулярного представления, и т. д. Программист сам должен отслеживать тип данных и применять соответствующие команды.

2.6.1. Двоично-десятичная арифметика

— Сложно со мной, — сообщил он с земли.
— Мне сколько ни дай — или много, или мало.

А. В. Жвалевский, И. Е. Мытько.
Девять подвигов Сена Аесли. Подвиги 5-9

Двоично-десятичное представление (binary-coded decimal, BCD) беззнаковых целых чисел — это десятичное позиционное представление, в котором каждая десятичная цифра записана двоичным кодом. Если для записи используется n десятичных цифр, представимый диапазон чисел — $[0, 10^n - 1]$.

Существует множество вариантов как для размера кода десятичных цифр, так и для сопоставления различных кодовых комбинаций цифрам.

Для записи десятичных цифр, принимающих десять различных значений, недостаточно трёх бит (с их помощью можно задать восемь кодовых комбинаций), а четырёх (шестнадцать комбинаций) хватает с избытком. Таким образом, размер двоичного кода десятичной цифры в принципе может принимать значения от четырёх до бесконечности, но на практике используются всего два размера:

– четыре бита (двоичная тетрада) — для максимальной компактности записи;
– байт используемой системы — для упрощения поразрядных десятичных арифметических действий.

Если размер цифры равен байту, значение обычно записано в младшей тетраде байта, а все остальные (старшие) биты раны нулю. Таким образом, достаточно рассмотреть четырёхбитные двоично-десятичные коды.

Так как десятичных цифр десять, а четырёхбитных кодовых комбинаций шестнадцать, то либо шесть комбинаций будут недопустимыми (не будут обозначать никакую цифру), либо некоторые цифры будут кодироваться неоднозначно — двумя и более комбинациями.

Виды представления десятичных цифр (двоично-десятичные коды) делятся на две основные группы.

1. **Взвешенные** коды, когда значение десятичной цифры d вычисляется по битам b_3, b_2, b_1, b_0 тетрады с использованием постоянных весов:

$$d = \sum_{i=0}^{3} q_i \cdot b_i = q_0 \cdot b_0 + q_1 \cdot b_1 + q_2 \cdot b_2 + q_3 \cdot b_3. \tag{2.60}$$

   Взвешенный код обычно обозначается своими весами $q_3 q_2 q_1 q_0$ (может также использоваться обозначение $q_3{-}q_2{-}q_1{-}q_0$ или q_3, q_2, q_1, q_0).
   Натуральный двоичный код цифр (также называемый кодом прямого замещения или кодом 8421), для которого значение десятичной цифры d равно двоичному значению тетрады $\overline{b_3 b_2 b_1 b_0}$, является частным случаем взвешенного кода. Такой код легко читается человеком и переводится в двоичный, но при выполнении сложения и вычитания при помощи двоичного сумматора сложно выделить десятичный перенос. Тетрады $1010_2{-}1111_2$, соответствующие значениям $10_{10}{-}15_{10}$, не являются корректными двоично-десятичными цифрами в коде прямого замещения.
   Хотя код прямого замещения наиболее популярен в ЭВМ (BCD без уточнения обычно означает именно код прямого замещения), на практике используются и другие взвешенные коды, в частности, код Айкена—Эмери 2421. Веса также могут быть отрицательными.
   Основным недостатком взвешенных кодов является то, что, если при передаче будет искажён один из разрядов с большим по модулю весом (в частности, ± 8 или ± 7), ошибка будет значительно больше, чем при искажении разряда с малым по модулю весом. С этой точки зрения лучше применять невзвешенный код, у которого ошибки, вызванные помехами, были бы одинаковыми для любого разряда.
2. **Невзвешенные** коды — значение десятичной цифры не может быть представлено в виде (2.60). Перечислим некоторые невзвешенные двоично-десятичные коды:

– код с избытком 3 (код $8421 + 3$)

$$d = b_0 + 2 \cdot b_1 + 4 \cdot b_2 + 8 \cdot b_3 + 3 \tag{2.61}$$

позволяет относительно просто осуществлять коррекцию после сложения или вычитания двоичным сумматором, в частности, десятичный перенос равен двоичному переносу из тетрады [41];

– код Грея (двоичный рефлексный, или двоичный отражённый код), для которого инверсия любого одного бита изменяет значение на ± 1 [82].

Процессоры семейства x86 содержат набор команд, облегчающих арифметические действия над цифрами двоично-десятичных чисел в коде прямого замещения. Эти команды доступны при разрядности кода до 32 включительно. В 64-разрядном режиме они исключены, так что коррекцию при операциях с двоично-десятичными цифрами необходимо осуществлять программно [74].

Двоично-десятичные числа, поддерживаемые командами x86, делятся на две разновидности по размеру цифры:

– упакованные — каждый байт содержит две десятичные цифры, представленные в коде прямого замещения; например, 12_{10} кодируется одним байтом $0001\,0010$;

– неупакованные — байт содержит одну цифру в коде прямого замещения, так что 12_{10} кодируется двумя байтами $0000\,0010\;0000\,0001$.

Упакованные числа складываются и вычитаются побайтово (по две десятичные цифры) в два этапа. Сначала выполняется двоичное сложение или вычитание байтов, затем — соответствующая команда коррекции.

Цифры неупакованных чисел можно не только складывать и вычитать, но и умножать и делить. При делении одной цифрой (то есть одним байтом) записываются делитель и частное, делимое состоит из двух десятичных цифр, остаток не вычисляется. Обработка также выполняется в два этапа — сначала двоичная операция над байтом, затем команда коррекции.

Действия над двоично-десятичными числами, содержащими несколько цифр, реализуются программно. Соответственно, длина таких чисел потенциально не ограничена.

В 32-разрядном режиме x86 доступен полный набор команд для обработки неупакованных двоично-десятичных цифр, сложения и вычитания упакованных пар цифр (две четырёхбитных цифры в восьмибитном байте), а также преобразований между упакованной и неупакованной формами. В 64-разрядном режиме многие из этих команд исключены.

Кроме того, математический сопроцессор FPU включает команды для импорта и экспорта 80-битных двоично-десятичных чисел со знаком.

2.6.2. Модулярная арифметика

> Новое отношение к времени выводит на первое место действие деления и говорит, что дальние точки могут быть более тождественны, чем две соседние, и что точки m и n тогда подобны, если $m - n$ делится без остатка на y.
>
> *В. Хлебников. Наша основа*

Модулярная арифметика основана на представлении целого неотрицательного числа X в виде последовательности остатков от деления X на набор взаимно простых чисел $p_1, p_2, \dots p_n$:

$$X = (x_1, x_2, \dots x_n), \tag{2.62}$$

где

$$\begin{array}{lcl} x_1 & = & X \bmod p_1 \\ x_2 & = & X \bmod p_2 \\ \dots & & \\ x_n & = & X \bmod p_n \end{array}, \quad \begin{array}{c} p_1, p_2, \dots p_n \in \mathbb{N}, \\ \forall i \neq j : \text{НОД}(p_i, p_j) = 1. \end{array}$$

Согласно китайской теореме об остатках, такое представление единственно для любого целого $X \in [0, P)$, где $P = p_1 \cdot p_2 \cdot \dots \cdot p_n$.

Для вычисления суммы (или произведения) двух чисел, представленных подобным образом, достаточно сложить (или перемножить) каждую пару соответственных остатков.

Так, пусть

$$\left\{ \begin{array}{lcllll} X & = & (x_1, & x_2, & \dots & x_n) \\ Y & = & (y_1, & y_2, & \dots & y_n) \end{array} \right., \tag{2.63}$$

тогда

$$\begin{array}{rcl} X + Y & = & \Big((x_1 + y_1) \bmod p_1, \quad (x_2 + y_2) \bmod p_2, \quad \dots \quad (x_n + y_n) \bmod p_n\Big) \\ X - Y & = & \Big((x_1 - y_1) \bmod p_1, \quad (x_2 - y_2) \bmod p_2, \quad \dots \quad (x_n - y_n) \bmod p_n\Big) \\ X \cdot Y & = & \Big((x_1 \cdot y_1) \bmod p_1, \quad (x_2 \cdot y_2) \bmod p_2, \quad \dots \quad (x_n \cdot y_n) \bmod p_n\Big) \end{array} \tag{2.64}$$

Здесь остаток от деления (mod) вычисляется по правилам математики, а не C/C++ — он неотрицателен (то есть $(-1) \bmod 7 = 6$).

При этом действия с различными парами остатков можно выполнять параллельно, так как действия выполняются независимо друг от друга. При использовании небольших $p_1, p_2, \dots p_n$ возможно вместо вычисления результата операции воспользоваться предварительно вычисленной таблицей. Таким образом, любая операция при соответствующей конвейеризации будет выполняться за один машинный такт.

Подобная арифметика в целом циклична по модулю P, так что, в частности, $(P-1)+1=0$; ассоциативна и коммутативна.

Некоторые операции выполняются сложнее, чем в позиционных системах счисления. Такие операции называются **немодульными.** Это, прежде всего, **сравнение**, то есть установление порядка (установление равенства — модульная операция), и все операции, в реализации которых оно используется:

– контроль переполнения;
– деление;
– квадратный корень и т. п.

Из-за немодульности сравнения расширение модулярного представления на все целые числа возможно только в виде значения со знаком. При использовании для отрицательных чисел кода со смещением $x \to x+\xi$ или дополнительного кода $(-x) \to P-x$ нет простого способа отличить отрицательное число от положительного. На вещественные числа модулярное представление естественным путём не расширяется.

Модулярная арифметика позволяет реализовать очень быстрые вычисления над неотрицательными целыми числами, а также контролировать корректность результата в процессе вычислений, что позволяет обнаруживать аппаратные ошибки.

2.6.3. Арифметика с насыщением

— Чего? — спросил Дуб.
— Стоять и не выпускать, — перевела Мергиона.

А. В. Жвалевский, И. Е. Мытько.
Личное дело Мергионы или Четыре чёртовы дюжины

В предыдущих разделах рассматривалась циклическая арифметика, то есть, если обрабатываемые числа находятся в диапазоне $[Min, Max]$, то $Max+1=Min$ и $Min-1=Max$. Это основная используемая в ЭВМ схема.

Для некоторых задач в случае выхода за границы допустимого диапазона удобнее схема с насыщением — если «правильный» результат операции превышает наибольшее представимое значение Max, то он считается равным Max, если он меньше Min, то, соответственно, формируется результат Min.

Таким образом, $Max+1=Max$ и $Min-1=Min$.

Арифметика с насыщением коммутативна, но неассоциативна, в частности

$$(Max-1)-(Max-1)=0,$$

но

$$Max-(1+Max)+1=Max-Max+1=1.$$

Процессоры семейства x86 поддерживают арифметику с насыщением в рамках команд расширения MMX.

Арифметика чисел с плавающей запятой (раздел 2.8.2) не является арифметикой с насыщением.

2.7. Битовые операции

— Умная игра, — подтвердил Дубль таким же низким голосом,
— клеточек куда больше, чем в крестиках-ноликах!

А. В. Жвалевский, И. Е. Мытько.
Девять подвигов Сена Аесли. Подвиги 5-9

Битовые операции — операции, производимые над цепочками битов.

Существует три основных класса битовых операций:
- поразрядные операции (not, and, or, xor);
- операции расширения (увеличения разрядности);
- сдвиги.

Все поразрядные операции рассматривают операнды как однородные цепочки битов; операции расширения и сдвиги делятся на два типа — знаковые, особым образом обрабатывающие старший (знаковый) бит цепочки, и беззнаковые.

2.7.1. Поразрядные операции

Почему так? Потому что развитое тело
легче изучать, чем клеточку тела.

К. Маркс. Капитал

Поразрядные операции применяются к каждому разряду операнда (для унарных операций) или к каждой паре соответствующих разрядов операндов (для бинарных операций) независимо от соседних разрядов.

Так как один двоичный разряд может принимать только два значения, которые можно трактовать как «ложь» и «истина», набор поразрядных операций обычно включает все логические операции (таблица 2.7).

Логические операции над разрядами

Таблица 2.7

a	b	$\neg a$ (not, $\sim$)	$a \wedge b$ (and, &)	$a \vee b$ (or, |)	$a \oplus b$ (xor, ^)
0	0	1	0	0	0
0	1		0	1	1
1	0	0	0	1	1
1	1		1	1	0

Для поразрядных операций применяются различные обозначения, наиболее популярные из них показаны в шапке таблицы 2.7. В последующих примерах используются обозначения, принятые в языке C++ для поразрядных операций ($\sim,\ \&, |, \hat{}$). Отметим, что для соответствующих логических операций, рассматривающих переменную не как совокупность разрядов, а как единое целое (любое ненулевое значение — как «истину», а ноль как «ложь») приняты другие обозначения ($!,\ \&\&, ||$, логического аналога $\hat{}$ не существует).

Результат в каждом разряде рассчитывается независимо от соседних (отсутствует перенос между разрядами). Разрядность результата соответствует разрядности операндов, для бинарных операций разрядность обоих операндов должна быть одинаковой. Поразрядные операции не могут быть знаковыми или беззнаковыми: обработка старшего бита не отличается от остальных.

Таким образом, поразрядное отрицание (битовая инверсия, дополнение до единицы) — это унарная операция, где к каждому разряду единственного операнда применяется логическое отрицание:

$$\sim 2_{10} = \sim 0000\,0010 = 1111\,1101 \tag{2.65}$$

Полученное значение можно трактовать как -3_{10}, если интерпретировать результат как знаковый, либо как 253_{10}, если интерпретировать его как беззнаковый. Ни одно из этих двух значений здесь не будет «правильным» или «ошибочным».

Если трактовать операнды как знаковые и представленные в дополнительном коде, $\forall x:\ \sim x = -x - 1$.

При этом необходимо помнить, что если операнд 2_{10} имеет бóльшую разрядность (и, соответственно, включает больше ведущих нулей), то и результат будет содержать больше ведущих единиц. Таким образом, равенство $\sim 2_{10} = \mathtt{FD}_{16} = 253_{10}$ верно только для восьмибитных переменных (так, для 16-битных $\sim 2_{10} = \mathtt{FFFD}_{16} = 65533_{10}$). В общем случае разрядности N значение $\sim 2_{10}$ в знаковой интерпретации всегда будет иметь значение -3_{10}, а в беззнаковой — $(2^N - 3)_{10}$.

Поразрядное «и» (конъюнкция) — бинарная операция, к каждой паре разрядов операндов применяется логическое «и»:

$$3_{10}\ \ \&\ \ 5_{10} = 0000\,0011\ \ \&\ \ 0000\,0101 = 0000\,0001 = 1_{10} \tag{2.66}$$

разряд результата равен нулю, если хотя бы один операнд содержит ноль в соответствующем разряде.

При помощи поразрядного «и» можно получить неотрицательный остаток от деления целого числа x на 2^n. В этом случае второй операнд («маска») состоит из n единиц: $x \bmod 2^n = x\ \ \&\ \ (2^n - 1)$.

$$\begin{gathered} 189_{10} \bmod 8_{10} = 189_{10}\ \ \&\ \ 7_{10} = \\ = 1011\,1101\ \ \&\ \ 0000\,0111 = 0000\,0101 = 5_{10} \end{gathered} \tag{2.67}$$

Поразрядное «или» (дизъюнкция) — бинарная операция, к каждой паре разрядов операндов применяется логическое «или»:

$$3_{10} \,|\, 5_{10} = 0000\,0011 \,|\, 0000\,0101 = 0000\,0111 = 7_{10} \tag{2.68}$$

разряд результата равен единице, если хотя бы один операнд содержит единицу в соответствующем разряде.

Поразрядное исключающее «или» (также называется сложением по модулю два, но, в отличие от арифметической операции сложения, нет переноса между разрядами) — бинарная операция, к каждой паре разрядов операндов применяется исключающее «или»:

$$3_{10} \hat{} 5_{10} = 0000\,0011 \hat{} 0000\,0101 = 0000\,0110 = 6_{10} \tag{2.69}$$

разряд результата равен единице, если один и только один операнд содержит единицу в соответствующем разряде.

Так как для одного разряда $\forall b \in \{0,1\} : \; 1 \oplus b = \neg b$, для чисел любой разрядности верно $\forall x : \; (-1) \hat{} x = \sim x$.

Поразрядные логические операции используются как в алгоритмах криптографии, так и, в некоторых ситуациях, для ускорения арифметических вычислений. Последнее возможно, только если один из операндов является константой специфического вида.

2.7.2. Расширение целых чисел

> ...Даже самые абстрактные категории <...> представляют собой в такой же мере и продукт исторических условий и обладают полной значимостью только для этих условий и в их пределах.
>
> *К. Маркс. Капитал*

Часто необходимо увеличить разрядность числа, сохранив его значение. В C++ подобное происходит, в частности, при присваивании переменных разного размера:

```
1 int i;
2 short int s = -1;
3 i = s;  // расширение short int до int (знаковое)
```

Операция увеличения разрядности называется расширением n-разрядного числа x до m разрядов ($m > n$). Младшие n разрядов результата совпадают с расширяемым значением x, старшие $m - n$ должны быть как-то инициализированы.

Существует две операции расширения, по-разному инициализирующие расширяемую часть:

– беззнаковое расширение — расширяемая часть заполняется нулями (такая операция сохраняет значение беззнаковой интерпретации x);
– знаковое расширение — расширяемая часть заполняется значением знакового бита (сохраняет значение знаковой интерпретации x).

В языках высокого уровня знаковость расширения определяется знаковостью используемых типов (так, в C++ расширение `short int` до `int` — знаковое, `short unsigned` до `unsigned` — беззнаковое). В ассемблере знаковое и беззнаковое расширение выполняются разными командами.

В таблице 2.8 показаны примеры знакового и беззнакового расширения восьмибитных чисел до шестнадцати бит.

Знаковое и беззнаковое расширение

Таблица 2.8

Значение	bin	hex	$dec_{\text{знак}}$	$dec_{\text{беззн}}$
x (8 бит)	0000 0000	`00`	0	0
$x \xrightarrow{\text{беззнаковое}}$ 16 бит	0000 0000 0000 0000	`0000`	0	0
$x \xrightarrow{\text{знаковое}}$ 16 бит	0000 0000 0000 0000	`0000`	0	0
x (8 бит)	0000 0001	`01`	1	1
$x \xrightarrow{\text{беззнаковое}}$ 16 бит	0000 0000 0000 0001	`0001`	1	1
$x \xrightarrow{\text{знаковое}}$ 16 бит	0000 0000 0000 0001	`0001`	1	1
x (8 бит)	0000 1111	`0F`	15	15
$x \xrightarrow{\text{беззнаковое}}$ 16 бит	0000 0000 0000 1111	`000F`	15	15
$x \xrightarrow{\text{знаковое}}$ 16 бит	0000 0000 0000 1111	`000F`	15	15
x (8 бит)	1000 0000	`80`	-128	128
$x \xrightarrow{\text{беззнаковое}}$ 16 бит	0000 0000 1000 0000	`0080`	128	128
$x \xrightarrow{\text{знаковое}}$ 16 бит	1111 1111 1000 0000	`FF80`	-128	65 408
x (8 бит)	1111 1111	`FF`	-1	255
$x \xrightarrow{\text{беззнаковое}}$ 16 бит	0000 0000 1111 1111	`00FF`	255	255
$x \xrightarrow{\text{знаковое}}$ 16 бит	1111 1111 1111 1111	`FFFF`	-1	65 535

Каждая строка таблицы соответствует одному значению (цепочке битов). Во втором столбце показано его двоичное представление, в третьем — шестнадцатеричное, в четвёртом — десятичное представление его знаковой интерпретации, в пятом — десятичное представление беззнаковой интерпретации. Строки сгруппированы по три — восьмибитное значение x, его беззнаковое расширение до шестнадцати бит и знаковое расширение до того же размера.

Видно, что для неотрицательных (в знаковой интерпретации) чисел знаковое и беззнаковое расширение выполняется одинаково.

2.7.3. Битовые сдвиги

Заметьте:
справа налево двигать могу
и слева направо.

В. В. Маяковский. Человек

Битовые сдвиги — семейство бинарных операций с несимметричными операндами. Один из операндов представляет собой цепочку битов, второй — неотрицательное целое число — величину сдвига. Цепочка битов смещается вправо или влево на указанное количество битов. Разрядность результата равна разрядности операнда-цепочки. Кроме явных операндов и результата, в сдвигах используется флаг переноса CF.

Сдвиг на n разрядов эквивалентен повторённому n сдвигу на один разряд, соответственно, для простоты ниже рассматривается только сдвиги на один бит.

Как было сказано выше, сдвиги различаются направлением — вправо (в сторону младших разрядов) или влево (в сторону старших). Кроме того, при сдвиге крайний с одной стороны разряд выдвигается за пределы разрядной сетки (его значение попадает в ячейку флага переноса CF), а крайняя ячейка с другой стороны освобождается.

В зависимости от способа заполнения освободившейся ячейки различаются следующие типы сдвига:

– знаковые (арифметические);
– беззнаковые (логические);
– циклические.

Ниже различные виды сдвигов рассматриваются на примере восьмибитных значений.

Знаковый и беззнаковый сдвиги вправо

В случае беззнакового (логического) сдвига вправо (в сторону младших разрядов) освободившийся старший разряд инициализируется нулём (рис. 2.3, а). В случае знакового (арифметического) сдвига вправо — копией знакового бита (рис. 2.3, б).

Логический сдвиг вправо соответствует беззнаковому делению на 2 с остатком, арифметический — знаковому. Знаковое деление при этом выполняется по правилам математики, подразумевающим неотрицательный остаток даже при отрицательном делимом, то есть при делении минус единицы на 2 частное равно минус единице, а остаток — плюс единице.

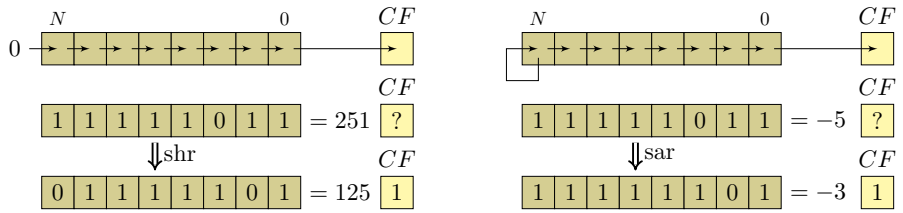

Рис. 2.3. Беззнаковый (а) и знаковый (б) сдвиги вправо

Остаток как для знакового, так и для беззнакового деления на 2 сдвигом на один бит равен биту CF (вышедшему за разрядную сетку младшему биту исходного числа).

Сдвиг вправо на n разрядов соответствует делению на 2^n, причём в случае знакового (арифметического) сдвига отрицательных чисел также выполняется «математическое» деление, подразумевающее неотрицательный остаток.

Во многих языках программирования (в частности, в C/C++) считается, что при делении знаковых чисел остаток может быть отрицательным, то есть при делении минус единицы на 2 частное будет равно нулю, а остаток — минус единице. Команды знакового деления ЭВМ реализуют именно эту схему.

Результат «программистского» деления отрицательного числа x на 2^n в общем случае не равен результату «математического» (подразумевающего неотрицательный остаток и рассчитываемого сдвигом $x \operatorname{sar} n$). Они совпадают только в том случае, когда x делится на 2^n нацело. Для всех остальных $x < 0$ результат «программистского» деления будет на единицу больше.

Таким образом, чтобы получить при помощи арифметического сдвига значение «программистского» частного, необходимо до сдвига прибавить к отрицательному делимому значение $2^n - 1$. Для положительного делимого или нуля коррекция не требуется.

Знаковый и беззнаковый сдвиг влево

В случае сдвига влево (в сторону старших разрядов) освободившийся младший бит инициализируется нулём (рис. 2.4).

Знаковый и беззнаковый (арифметический и логический) сдвиги влево не различаются. Сдвиг влево на один бит эквивалентен умножению на 2 (так как разрядность результата равна разрядности исходной цепочки, неважно — знаковому или нет). Коррекция операндов не требуется.

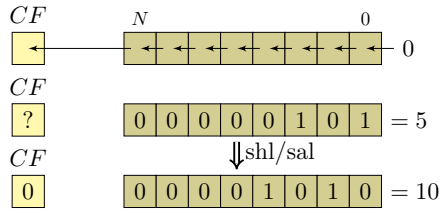

Рис. 2.4. Знаковый (беззнаковый) сдвиг влево

Битовые сдвиги выполняются гораздо быстрее, чем умножение и деление с помощью специализированных команд. Соответственно, умножение и деление на специальные константные значения часто выполняются оптимизирующими компиляторами при помощи сдвигов или комбинации сдвигов и сложения.

Циклические сдвиги

В случае простого циклического сдвига освободившаяся ячейка с одной стороны замещается разрядом, вышедшим с другой стороны за разрядную сетку (рис. 2.5, а) и б).

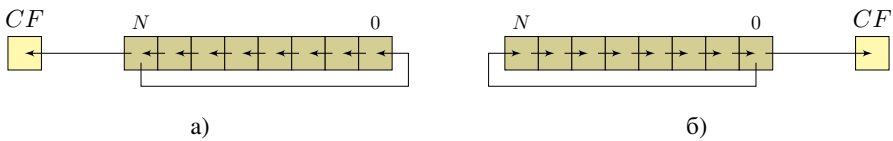

Рис. 2.5. Простой циклический сдвиг: а) влево, б) вправо

В случае циклического сдвига через флаг переноса освободившаяся ячейка инициализируется значением флага переноса CF, а ячейка CF замещается разрядом, вышедшим за разрядную сетку (рис. 2.6, а) и б). Таким образом, результат зависит не только от операндов, но и от текущего значения CF.

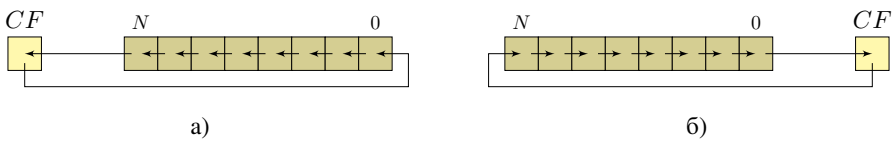

Рис. 2.6. Циклический сдвиг через флаг переноса: а) влево, б) вправо

Если простой циклический сдвиг N-разрядного числа циклически перемещает разряды N-битной цепочки, то сдвиг через флаг переноса — $(N+1)$-битной цепочки (операнд $+ CF$).

Циклические сдвиги не эквивалентны какой-либо арифметической операции. Они широко используются в криптографии.

2.8. Представление вещественных чисел

Опять скажу: никто не обнимет необъятного!

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

Какой бы код ни использовался, с помощью N битов $b_{N-1}\ldots b_1 b_0$ можно получить только 2^N разных кодовых комбинаций и, соответственно, представить не более 2^N значений. При этом, в отличие от целых чисел, вещественных значений в любом диапазоне $[\nu_1, \nu_2] \subseteq \mathbb{R}$ бесконечно много (причём эта бесконечность несчётна, то есть количество вещественных чисел, помещающихся на любом интервале, превышает общее число существующих целых чисел).

Таким образом, для того, чтобы закодировать вещественные числа, необходимо не только ограничить допустимый диапазон, но и проредить его внутреннюю часть. Большую часть вещественных чисел описываемого диапазона $[\nu_1, \nu_2] \subseteq \mathbb{R}$ невозможно точно представить в ЭВМ.

Представление вещественных чисел основано на описанной в разделе 2.3.4 позиционной двоичной записи.

2.8.1. Представление вещественных чисел с фиксированной запятой

Сие редко встречающееся явление
требует двоякого объяснения.

М. В. Ломоносов. Явление Венеры на Солнце

Представим неотрицательное вещественное число X в виде бесконечной двоичной дроби (2.11), округлим до n разряда после запятой, обозначив результат округления $\breve{X}$:

$$\begin{aligned} X \approx \breve{X} &= x_k \cdot 2^k + \ldots + x_1 \cdot 2^1 + x_0 \cdot 2^0 + x_{-1} \cdot 2^{-1} + \ldots + x_{-n} \cdot 2^{-n} = \\ &= x_k \cdot 2^k + \ldots + x_1 \cdot 2 + x_0 + \frac{x_{-1}}{2} + \ldots + \frac{x_{-n}}{2^n} = \\ &= \overline{x_k \ldots x_1 x_0, x_{-1} \ldots x_{-n}}, \quad 0 \leqslant x_i < 2 \text{ — целые} \end{aligned} \tag{2.70}$$

и последовательно запишем цифры $x_{-n}, \dots x_k$в биты кода $b_0, \dots b_{N-1}$, начиная с младшей цифры x_{-n} и младшего бита b_0. После старшей цифры x_k записываются нули. Таким образом, из N битов, отведённых под представление числа, для дробной части используется n, для целой остаётся $N - n$.

$$\breve{X} = b_{N-1} \cdot 2^{N-n-1} + \dots + b_{n+1} \cdot 2 + b_n + \frac{b_{n-1}}{2} + \dots + \frac{b_0}{2^n} = \\ = \overline{b_{N-1} \dots b_n, b_{n-1} \dots b_0} \tag{2.71}$$

Двоичная запятая, отделяющая дробную часть от целой, всегда расположена между разрядами n и $n - 1$. Соответственно, такой способ кодирования называется представлением с фиксированной запятой.

Целая часть числа может принимать значения от 0 до $2^{N-n} - 1$, дробная — от $0 = \overline{0{,}00 \dots 00}$ до $1 - \frac{1}{2^n} = \overline{0{,}11 \dots 11}$ (всего 2^n значений). Таким образом, числа, представимые в формате с фиксированной запятой с помощью N бит, n из которых отведены под дробную часть, заключены в диапазоне $\left[0,\, 2^{N-n} - \frac{1}{2^n}\right]$. На каждом полуинтервале $[\nu, \nu + 1)$ находится 2^n чисел, представимых в виде с фиксированной запятой с n-битной дробной частью.

Точность двоичных чисел с фиксированной запятой

При округлении вещественного числа $X \in \left[0,\, 2^{N-n}\right)$ до n двоичных разрядов после запятой абсолютная погрешность округления не превышает $\frac{1}{2^n}$:

$$\left| X - \breve{X} \right| < \frac{1}{2^n} \tag{2.72}$$

относительная погрешность увеличивается при уменьшении абсолютной величины числа:

$$\left| \frac{X - \breve{X}}{X} \right| < \frac{1}{2^n \cdot |X|} \tag{2.73}$$

Таким образом, абсолютная погрешность округления при сохранении числа X в формат с фиксированной запятой постоянна и зависит только от характеристик формата (от количества n бит, отведённых под дробную часть).

Арифметика чисел с фиксированной запятой

Нетрудно заметить, что при умножении (2.71) на 2^n получим целое число:

$$\begin{gathered}2^n \cdot \breve{X} = 2^n \cdot \overline{b_{N-1} \ldots b_n, b_{n-1} \ldots b_0} = \\ = 2^n \cdot \left(b_{N-1} \cdot 2^{N-n-1} + \ldots + b_{n+1} \cdot 2 + b_n + \frac{b_{n-1}}{2} + \ldots + \frac{b_0}{2^n} \right) = \\ = b_{N-1} \cdot 2^{N-1} + \ldots + b_{n+1} \cdot 2^{n+1} + b_n \cdot 2^n + b_{n-1} \cdot 2^{n-1} + \ldots + b_0 \cdot 2^0 = \\ = \overline{b_{N-1} \ldots b_n b_{n-1} \ldots b_0} = x, \;\; x \in \{0, 1, \ldots 2^N - 1\}\end{gathered} \tag{2.74}$$

то есть существует взаимно однозначное соответствие между числами с фиксированной запятой и целыми числами в диапазоне $\left[0, 2^N - 1\right]$:

$$\breve{X} = \frac{x}{2^n} \tag{2.75}$$

причём $\breve{X}$ и x записываются одной и той же комбинацией бит.

В некоторых вычислительных машинах работа с числами с фиксированной запятой реализована аппаратно. При этом отрицательные числа часто кодируются как значение со знаком.

Если специального набора команд нет, арифметика с фиксированной запятой может быть реализована программно с использованием целочисленных команд. Сложение и вычитание чисел с фиксированной запятой можно выполнять целочисленным сумматором без коррекции результата:

$$\breve{X} + \breve{Y} = \frac{x}{2^n} + \frac{y}{2^n} = \frac{x + y}{2^n} \tag{2.76}$$

После целочисленного умножения требуется коррекция в виде деления результата на 2^n:

$$\breve{X} \cdot \breve{Y} = \frac{x}{2^n} \cdot \frac{y}{2^n} = \frac{x \cdot y}{2^{2n}} = \frac{\frac{x \cdot y}{2^n}}{2^n} \tag{2.77}$$

после целочисленного деления потребовалась бы коррекция в виде умножения результата на 2^n, если бы этот результат был вещественным:

$$\frac{\breve{X}}{\breve{Y}} = \frac{\frac{x}{2^n}}{\frac{y}{2^n}} = \frac{x}{y} = \frac{\frac{x}{y} \cdot 2^n}{2^n} \tag{2.78}$$

но коррекция целочисленного частного умножением даст нулевые значения младших n бит, то есть дробной части числа с фиксированной запятой, что неправильно. Поэтому необходимо проводить коррекцию перед делением:

$$\frac{\breve{X}}{\breve{Y}} = \frac{\frac{x \cdot 2^n}{y}}{2^n} \tag{2.79}$$

В случае, если используемая разрядность не позволяет умножить делимое на 2^n без переполнения, можно воспользоваться тем, что целочисленное деление возвращает результат в виде двух целых чисел — частного q и остатка r:

$$\frac{x}{y} = q + \frac{r}{y} \tag{2.80}$$

Тогда корректное частное чисел в представлении с фиксированной запятой с дробной частью длины n равно:

$$\frac{x}{y} \cdot 2^n = \left(q + \frac{r}{y}\right) \cdot 2^n = q \cdot 2^n + \frac{r \cdot 2^n}{y} \tag{2.81}$$

Умножение и деление на 2^n может быть выполнено при помощи битовых сдвигов, что практически не замедлит работу.

Таким образом, представление с фиксированной запятой позволяет представить числа в малом диапазоне с ограниченной абсолютной погрешностью и позволяет использовать для арифметических действий над вещественными числами быстрые целочисленные и логические операции.

2.8.2. Представление вещественных чисел с плавающей запятой

> И наш Ефрем, не видя дальше носа,
> Упал с откоса
> И вмиг остался без хвоста...
>
> *Б. Б. Гребенщиков. Басня №1*

В основе представления вещественных чисел с плавающей запятой лежит экспоненциальный (научный) формат:

$$X = N^p \cdot \mu \tag{2.82}$$

где N — основание системы счисления (в современных ЭВМ $N = 2$, стандарт арифметики с плавающей точкой IEEE 754 [13, 14, 83] описывает также случай $N = 10$), μ называется мантиссой числа X, целое число p — порядком (иногда из-за английского exponent используется термин «экспонента», но он не принят в отечественной литературе).

В настоящее время чаще всего, кроме порядка и мантиссы, отделяется ещё и знак числа:

$$X = (-1)^s \cdot N^p \cdot \mu, \quad s \in \{0, 1\}, p \in \mathbb{Z}, \mu \geqslant 0 \tag{2.83}$$

В форме (2.83) можно представить любое конечное вещественное число, но не единственным способом:

$$512{,}12 = 512{,}12 \cdot 10^0 = 51212 \cdot 10^{-2} = 51{,}212 \cdot 10^1 = 0{,}051212 \cdot 10^4$$

Представление (2.83) называется нормализованным, если $0{,}1_N \leqslant \mu < 1$:

$$X = (-1)^s \cdot N^p \cdot \mu, \quad s \in \{0,1\}, p \in \mathbb{Z}, \ 0{,}1_N \leqslant \mu < 1 \tag{2.84}$$

В нормализованной форме (2.84) можно представить любое конечное вещественное число, кроме нуля, причём единственным образом. В частности, $512{,}12 = 0{,}51212 \cdot 10^3$. В двоичной системе счисления то же самое число и его нормализованное экспоненциальное представление записываются как $1000000000{,}0001111\ldots = 0{,}1000000000001111\ldots \cdot 2^9$.

Найдём порядок нормализованного представления числа X:

$$\log_N |X| = \log_N (N^p \cdot \mu) = p + \log_N \mu \tag{2.85}$$

так что $p = \log_N |X| - \log_N \mu$. Так как $0{,}1_N \leqslant \mu < 1$, то $-1 \leqslant \log_N \mu < 0$:

$$\log_N |X| < p \leqslant \log_N |X| + 1 \tag{2.86}$$

с учётом того, что $p \in \mathbb{Z}$, получаем

$$p = \left\lfloor \log_N |X| + 1 \right\rfloor \tag{2.87}$$

Если записать мантиссу нормализованного представления числа X в позиционной форме, получим

$$\mu = \overline{0{,}m_1 m_2 m_3 m_4 \ldots}, \quad m_1 \neq 0. \tag{2.88}$$

где $m_i \in \{0, 1, \ldots N-1\}$ — цифры. Если для представления с фиксированной запятой до определённого знака округляется дробная часть числа X (что даёт ограниченную абсолютную погрешность), то для представления с плавающей запятой до определённой длины округляется мантисса (что приводит к ограниченной относительной погрешности округления).

Структура двоичного числа с плавающей запятой согласно IEEE 754

Представим вещественное число $X \neq 0$ в нормализованной двоичной форме (2.83)

$$X = (-1)^s \cdot 2^p \cdot \mu, \quad s \in \{0,1\}, p \in \mathbb{Z}, 0{,}1_2 \leqslant \mu < 1 \tag{2.89}$$

Запишем мантиссу в позиционной двоичной форме $\mu = \overline{0{,}m_1 m_2 m_3 m_4 \ldots}$, где m_i — двоичные цифры, 0 или 1. Так как представление (2.89) нормализовано, $m_1 \neq 0$. В двоичной системе если m_1 не равна нулю, то она равна единице, то есть $\mu = \overline{0{,}1 m_2 m_3 m_4 \ldots}$.

$$X = (-1)^s \cdot 2^p \cdot \overline{0{,}1 m_2 m_3 m_4 \ldots}, \quad s \in \{0,1\}, p \in \mathbb{Z} \tag{2.90}$$

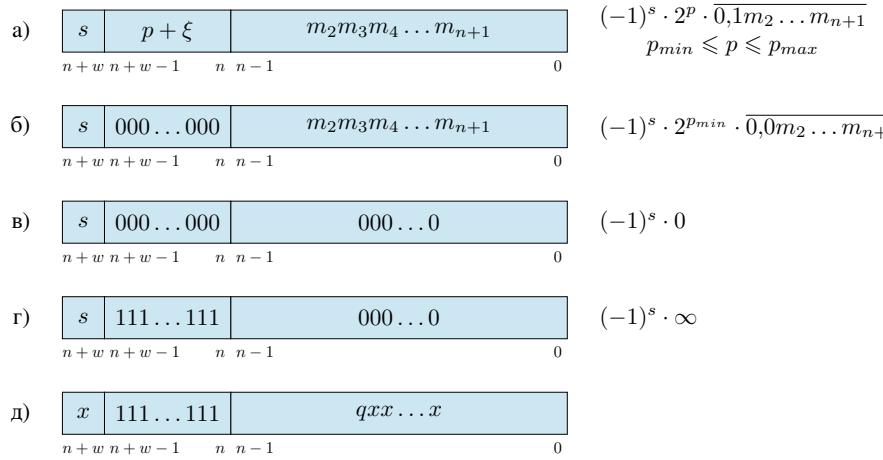

Рис. 2.7. Структура числа с плавающей запятой согласно стандарту IEEE 754: а) нормализованное число, б) денормализованное, в) ноль, г) бесконечность, д) неопределённость или нечисло

Запишем в память компоненты такого представления (рис. 2.7). Знак s занимает старший бит.

Следующие w бит занимает порядок p. Порядок представляется кодом с избытком, то есть после знакового бита следует натуральный код значения $p + \xi$, где $\xi = 2^{w-1} - 2$ постоянно для формата. Значение $p + \xi$ называется смещённым порядком.

Минимально представимое значение смещённого порядка кодируется строкой из одних нулей, максимально представимое — строкой из единиц. Оба они считаются специальными — смещённому порядку $000\ldots000$ соответствуют нули и денормализованные числа, $111\ldots111$ — бесконечности, неопределённость и нечисла.

Таким образом, минимальное допустимое значение смещённого порядка нормализованного числа кодируется как $000\ldots001$, а собственно порядок равен $p_{min} = 1 - \xi = 3 - 2^{w-1}$, максимальное — кодируется как $111\ldots110$, соответственно максимальный порядок числа $p_{max} = 2^w - 2 - \xi = 2^{w-1}$.

Последние n бит числа с плавающей запятой занимает округлённая мантисса.

Так как для нормализованного числа старший бит мантиссы m_1 всегда равен единице, его не имеет смысла хранить. Соответственно, n бит мантиссы хранят разряды от m_2 до m_{n+1}. В поле смещённого порядка нормализованного числа записывается натуральный двоичный код $p + \xi$ (рис. 2.7, а).

Если порядок числа X слишком мал ($p < p_{min}$), число представляют в виде:

$$X = (-1)^s \cdot 2^{p_{min}} \cdot \mu, \quad s \in \{0,1\}, \quad 0 \leqslant \mu < 0{,}1_2 \tag{2.91}$$

и называют денормализованным.

Старший бит m_1 мантиссы денормализованного числа всегда равен нулю ($\mu = \overline{0{,}0m_2m_3m_4\ldots}$), так что его тоже не имеет смысла хранить. В поле мантиссы записываются разряды от m_2 до m_{n+1}. В поле смещённого порядка денормализованного числа записывается специальное значение $000\ldots000$ (рис. 2.7, б).

Если смещённый порядок равен $000\ldots000$ и при этом все биты мантиссы равны нулю, получаем значение ± 0 (рис. 2.7, в):

$$X = (-1)^s \cdot 2^{p_{min}} \cdot \mu, \quad s \in \{0,1\}, \mu = \overline{0{,}0000\ldots0} \tag{2.92}$$

Нули считаются не денормализованными, а специальными значениями, хотя и могут быть декодированы по формуле (2.91).

Если смещённый порядок состоит только из единиц (равен $111\ldots111$), а поле мантиссы — только из нулей, получаем специальное значение бесконечности (рис. 2.7, г).

В зависимости от поля знака, существуют два значения бесконечности и два нуля, так что $\frac{1}{+0} = +\infty$ и $\frac{1}{-0} = -\infty$. На рис. 2.7, в) и г) это показано как $(-1)^s \cdot 0$ и $(-1)^s \cdot \infty$ соответственно.

Если смещённый порядок равен $111\ldots111$, а поле мантиссы содержит не только нули, получаем так называемые нечисла (рис. 2.7, д). Нечисла не имеют знака, бит s игнорируется.

Если при этом старший сохраняемый бит мантиссы (q на рис. 2.7, д) равен единице, это так называемое тихое нечисло, или вещественная неопределённость (получаемая, в частности, как $\frac{0}{0}$). Если $q = 0$, нечисло называется сигнальным и не может быть результатом вещественной операции.

Форматы двоичных чисел с плавающей запятой согласно IEEE 754

Стандарт IEEE 754-1985 описывает два двоичных формата с плавающей запятой — 32-битный формат одинарной точности и 64-битный формат двойной точности. В IEEE 754-2008 были добавлены 16- и 128-битный двоичный форматы (от названий в новой версии формата отказались), а также описана общая формула k-битного двоичного формата для $k \geqslant 128$ (таблица 2.9).

Также IEEE 754-2008 описывает возможность расширения стандартных форматов с увеличением как точности мантиссы, так и диапазона порядка.

Кроме двоичных, IEEE 754-2008 описывает два десятичных формата длины 64 и 128 бит, а также формулы для десятичного формата длины $k = 32\kappa$. Десятичные

Стандартные двоичные форматы с плавающей запятой

Таблица 2.9

Общая длина $n+w+1$, бит	**16**	**32**	**64**	**128**	**k $\geqslant$ 128**
Длина кода знака s, бит	1	1	1	1	1
Длина кода порядка w, бит	5	8	11	15	$round(4 \cdot \log_2 k) - 13$
Длина кода мантиссы n, бит	10	23	52	112	$k - w - 1$

форматы IEEE 754-2008 имеют более сложную структуру, чем двоичные. Для экономии памяти в мантиссе для цифр $m_2, m_3, m_4 \ldots$ используется кодирование троек десятичных цифр группами по десять бит (так как число кодовых комбинаций $2^{10} = 1024 > 10^3$, это возможно), а код порядка соединён с кодом старшей цифры $m_1 \neq 0$.

Структура нестандартного числа FPU x87

В математическом сопроцессоре x87 (FPU), входящем в состав процессоров линейки x86, используется нестандартный формат вещественных чисел (рис. 2.8), так как первый подобный сопроцессор был выпущен задолго до первой редакции стандарта IEEE 754.

Порядок этого формата занимает $w = 15$ бит, мантисса — $n = 64$ бита. Общий размер числа $k = n + w + 1 = 80$ бит.

Формат сопроцессора x87 отличается от стандартных не только разрядностью полей (IEEE 754 предусматривает расширенные форматы с увеличенной разрядностью), но и тем, что мантисса включает старший бит (единицу для нормализованных чисел и ноль для денормализованных). Благодаря этому, кроме тихих и сигнальных нечисел, возможны недопустимые значения, для которых старший бит мантиссы не соответствует порядку.

Также FPU x87 различает несколько видов тихих нечисел (рис. 2.8, е). Только один из них является вещественной неопределённостью (рис. 2.8, д).

Недопустимыми считаются значения, не соответствующие ни одному из шаблонов рис. 2.8, а-ж). Для порядка, состоящего из всех нулей, недопустим единичный старший бит мантиссы (рис. 2.9, а). Для $p_{min} \leqslant p \leqslant p_{max}$ недопустим нулевой старший бит мантиссы (рис. 2.9, б). Для порядка, состоящего из всех единиц, недопустима ненулевая мантисса с нулевым старшим битом (рис. 2.9, в).

Возможен экспорт из описанного нестандартного представления в стандартные форматы одинарной и двойной точности.

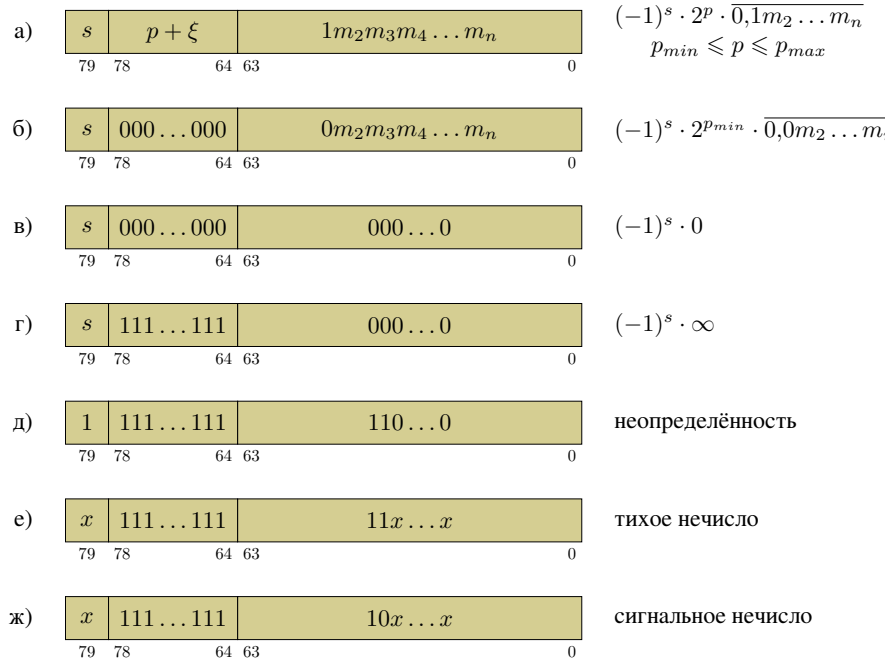

Рис. 2.8. Структура внутреннего представления чисел в FPU x87:
а) нормализованное число, б) денормализованное, в) ноль,
г) бесконечность, д) вещественная неопределённость,
е) тихое нечисло, ж) сигнальное нечисло

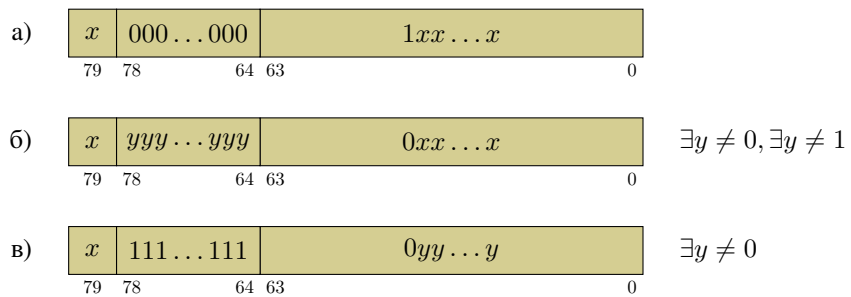

Рис. 2.9. Недопустимые значения в FPU x87:
а) с нулевым порядком, б) с порядком $p_{min} \leqslant p \leqslant p_{max}$,
в) с порядком, состоящим из единиц

Точность двоичных чисел с плавающей запятой

Как и в случае фиксированной запятой, формат с плавающей точкой не может описать все вещественные значения в заданном диапазоне.

При сохранении вещественного числа X в формате с плавающей запятой оно округляется до ближайшего представимого числа $\breve{X}$.

Если $\breve{X} = (-1)^s \cdot 2^p \cdot \mu$ нормализовано, то абсолютная погрешность округления не превышает веса младшего разряда мантиссы:

$$\left| X - \breve{X} \right| < \frac{2^p}{2^{n+1}} = 2^{p-n-1}. \tag{2.93}$$

Эта величина зависит от порядка числа p, а также от количества бит в мантиссе n (n постоянно для формата), и превышает единицу при $p > n + 1$.

Таким образом, с ростом абсолютной величины X (и, соответственно, порядка p) абсолютная погрешность округления катастрофически растёт.

Относительная погрешность округления до нормализованного $\breve{X}$ может быть оценена сверху как $\frac{1}{2^n}$:

$$\begin{aligned} \left| \frac{X - \breve{X}}{X} \right| &< \frac{2^p}{2^{n+1} \cdot |X|} \approx \frac{2^p}{2^{n+1} \cdot |\breve{X}|} = \frac{2^p}{2^{n+1} \cdot 2^p \cdot \mu} = \\ &= \frac{1}{2^{n+1} \cdot \mu} \leqslant \frac{1}{2^{n+1} \cdot 0{,}1_2} = \frac{1}{2^n}. \end{aligned} \tag{2.94}$$

Оценка на самом деле точная, так как хотя настоящая мантисса X не равна μ, она также больше или равна $0{,}1_2$.

Если X невозможно представить в нормализованном виде, абсолютная погрешность округления не превышает $\frac{2^{p_{min}}}{2^{n+1}} = 2^{p_{min}-n-1}$, относительная погрешность будет расти при уменьшении абсолютной величины X, так как мантисса денормализованного числа может быть сколь угодно близка к нулю.

Погрешность округления при сохранении числа X в формате с плавающей запятой одинарной точности составит $2^{-23} \cdot X \approx 1{,}2 \cdot 10^{-7} \cdot X$. Соответственно, такое число сохранит шесть верных десятичных цифр (не после запятой, а всего!) и седьмую — с погрешностью. Остальные будут полностью потеряны. При сохранении в формат двойной точности погрешность составит $2^{-52} \cdot X \approx 2 \cdot 10^{-16} \cdot X$, то есть сохраняется пятнадцать десятичных цифр.

Арифметика чисел с плавающей запятой

Пусть два числа $X_1, X_2 \in \mathbb{R}$ представлены в формате с плавающей запятой:

$$\begin{cases} X_1 = (-1)^{s_1} \cdot N^{p_1} \cdot \mu_1, & 0{,}1_N \leqslant \mu_1 < 1 \\ X_2 = (-1)^{s_2} \cdot N^{p_2} \cdot \mu_2, & 0{,}1_N \leqslant \mu_2 < 1 \end{cases} \tag{2.95}$$

Числа, представленные подобным образом, удобно умножать:

$$X_1 \cdot X_2 = (-1)^{s_1} \cdot N^{p_1} \cdot \mu_1 \cdot (-1)^{s_2} \cdot N^{p_2} \cdot \mu_2 = (-1)^{s_1 \oplus s_2} \cdot N^{p_1+p_2} \cdot \big(\mu_1 \cdot \mu_2\big) \quad (2.96)$$

Здесь $0{,}01_N \leqslant \mu_1 \cdot \mu_2 < 1$. Если $\mu_1 \cdot \mu_2 < 0{,}1_N$, мантисса дополнительно нормализуется; соответственно корректируется порядок результата. Таким образом,

$$X_1 \cdot X_2 = (-1)^{s_1 \oplus s_2} \cdot N^{p_1+p_2+p_\mu} \cdot \mu \quad (2.97)$$

где

$$\mu_1 \cdot \mu_2 = N^{p_\mu} \cdot \mu, \;\; 0{,}1_N \leqslant \mu < 1. \quad (2.98)$$

Умножение чисел с плавающей запятой коммутативно и в большинстве случаев ассоциативно. Ассоциативность может нарушиться, если на каком-то шаге получится денормализованное число или бесконечность. Так, если все вычисления выполняются с одинарной точностью, то $(2^{-64} \cdot 2^{64}) \cdot 2^{64} = 1 \cdot 2^{64} = 2^{64}$, но $2^{-64} \cdot (2^{64} \cdot 2^{64}) = 2^{-64} \cdot (+\infty) = +\infty$.

Аналогично выполняется деление:

$$\frac{X_1}{X_2} = \frac{(-1)^{s_1} \cdot N^{p_1} \cdot \mu_1}{(-1)^{s_2} \cdot N^{p_2} \cdot \mu_2} = (-1)^{s_1 \ominus s_2} \cdot N^{p_1-p_2} \cdot \frac{\mu_1}{\mu_2} = \\ = (-1)^{s_1 \ominus s_2} \cdot N^{p_1-p_2+p_\mu} \cdot \mu \quad (2.99)$$

где

$$\frac{\mu_1}{\mu_2} = N^{p_\mu} \cdot \mu, \;\; 0{,}1_N \leqslant \mu < 1. \quad (2.100)$$

Порядок и нормализованная мантисса записываются в виде, соответствующем формату.

Сложение двух чисел одного порядка $p = p_1 = p_2$ сводится к сложению или вычитанию — с учётом знаков чисел — мантисс (с последующей нормализацией):

$$X_1 + X_2 = (-1)^{s_1} \cdot N^p \cdot \mu_1 + (-1)^{s_2} \cdot N^p \cdot \mu_2 = N^p \cdot \big((-1)^{s_1} \cdot \mu_1 + (-1)^{s_2} \cdot \mu_2\big) \quad (2.101)$$

Для того, чтобы сложить два числа различных порядков, их вначале необходимо привести к одному порядку (наибольшему). Пусть для определённости $p_1 > p_2$. Тогда

$$X_2 = (-1)^{s_2} \cdot N^{p_2} \cdot \mu_2 = (-1)^{s_2} \cdot N^{p_1} \cdot \frac{\mu_2}{N^{p_1-p_2}} \quad (2.102)$$

Приведение к большему порядку соответствует беззнаковому сдвигу мантиссы μ_2 вправо. При этом, так как длина мантиссы ограничена n битами, часть цифр теряется. При достаточно большой разнице порядков ($p_1 - p_2 > n$ для двоичных форматов) приведённая мантисса $\frac{\mu_2}{N^{p_1-p_2}}$ окажется равной нулю, так что в итоге получим $X_1 + X_2 = X_1$.

После приведения выполняется собственно сложение/вычитание:

$$X_1 + X_2 = N^{p_1} \cdot \left((-1)^{s_1} \cdot \mu_1 + (-1)^{s_2} \cdot \frac{\mu_2}{N^{p_1 - p_2}} \right) \tag{2.103}$$

Вычитание чисел с плавающей запятой сводится к сложению сменой знака.

В общем случае $(X_1 + X_2) - X_1 \neq X_2$. Чем больше разница порядков X_1 и X_2, тем сильнее теряется точность. Соответственно, сложение чисел с плавающей запятой не будет ассоциативным практически *ни для каких* слагаемых. Это отличает его от сложения с насыщением, где ассоциативность нарушается только в случае, когда промежуточный результат выходит за границы допустимого диапазона.

Таким образом, арифметика чисел с плавающей запятой не является ни циклической, ни арифметикой с насыщением и в общем случае коммутативна, но неассоциативна. Для того, чтобы уменьшить ошибку вычислений, необходимо выстроить алгоритм так, чтобы избежать вычитания очень близких друг к другу чисел. Сложение множества чисел существенно разного порядка желательно начинать с ближайших к нулю.

Для любого действия возможна ситуация, когда порядок результата непредставим в используемом формате. Если порядок слишком велик для используемого формата, результат будет равен специальному значению — бесконечности с соответствующим знаком, $+\infty$ или $-\infty$. Если порядок слишком мал — результат будет денормализован.

Для специальных значений $+\infty$ и $-\infty$ и любого конечного числа x выполняется $+\infty + x = +\infty$, $-\infty + x = -\infty$. Если при этом $x > 0$, то $(+\infty) \cdot x = +\infty$, $(+\infty) \cdot (-x) = -\infty$, а также $\frac{x}{+\infty} = +0$, $\frac{x}{-\infty} = -0$ и т. п.

Кроме того, арифметика с плавающей запятой включает такое специальное значение, как вещественная неопределённость (обычно обозначаемая nan — not a number). Результат принимается равным nan, в частности, для таких операций, как $\frac{0}{0}$, $\frac{\infty}{\infty}$, $+\infty - \infty$, $0 \cdot \infty$, а также для всех тех, где хотя бы один из операндов равен nan.

Практика показывает, что одинарная точность недостаточна почти всегда (исключение составляют простые одношаговые вычисления и те, погрешность которых не принципиальна, в частности, графика игр). Двойная точность и точность нестандартного формата FPU подходят для большинства приложений. Алгоритмы, требующие предсказуемой погрешности вычислений (в частности, арифметическое сжатие), вообще не могут быть реализованы для чисел с плавающей запятой. В подобных случаях может использоваться представление с фиксированной запятой, но чаще всего алгоритм модифицируется так, чтобы работать с целыми числами.

Нормализованное представление в отечественной и зарубежной традиции

В зарубежных источниках (2.83) называется нормализованным в случае, когда $1 \leqslant \mu < 10_N$ [16]. Там считается, что мантисса нормализованного числа включает целую часть (хотя суть от этого не меняется). Действительно, пусть

$$X = (-1)^s \cdot N^p \cdot \mu, \;\; s \in \{0,1\}, \; p \in \mathbb{Z}, \; 0{,}1_N \leqslant \mu < 1, \tag{2.104}$$

то есть $\mu = \overline{0{,}m_1m_2m_3m_4\ldots}$, $m_1 \neq 0$. Пусть также

$$X = (-1)^{\widetilde{s}} \cdot N^{\widetilde{p}} \cdot \widetilde{\mu}, \;\; \widetilde{s} \in \{0,1\}, \widetilde{p} \in \mathbb{Z}, \; 1 \leqslant \mu < 10_N \tag{2.105}$$

Тогда

$$\left\{ \begin{array}{lcl} \widetilde{s} & = & s \\ \widetilde{p} & = & p-1 \\ \widetilde{\mu} & = & N \cdot \mu \;\; = \;\; 10_N \cdot \mu \;\; = \;\; \overline{m_1{,}m_2m_3m_4\ldots} \end{array} \right. \tag{2.106}$$

Так как двоичная/десятичная запятая является нецифровым символом, она не может быть записана в память, а только *подразумевается* на той или иной позиции, двоичное представление мантиссы в формах (2.104) и (2.105) *полностью совпадает.*

Порядок $\widetilde{p}$ формы (2.105), соответственно, записывается с избытком $\widetilde{\xi} = \xi + 1$. Одна из основных особенностей кода со смещением — невозможность «визуально» определить ноль, так что полученный код (смещённый порядок) также *полностью совпадает* для форм (2.104) и (2.105).

Таким образом, двоичное представление одинаковых чисел (как нормализуемых в формате расширенной точности, так и денормализованных) одинаково и не зависит от формы нормализованного представления.

В отдельных источниках мантисса и вовсе рассматривается как целое беззнаковое число $\overline{m_1m_2m_3m_4\ldots m_n}$ [83]. Такая трактовка также допустима и равносильна (2.104) и (2.105) при соответствующей коррекции порядка и смещения.

Контрольные вопросы

1. Чем различаются качественные и количественные данные?
2. Какие числа называются натуральными?
3. Какие числа называются неотрицательными целыми?
4. Какие нецифровые символы используются в представлении чисел?
5. Какие способы представления беззнаковых целых чисел используются в ЭВМ?
6. Какие способы представления знаковых целых чисел используются в ЭВМ?
7. Какие логические и битовые операции вы знаете?
8. Какие способы представления вещественных чисел используются в ЭВМ?
9. Как выглядит нормализованное представление вещественного числа?

Глава 3. Архитектура команд семейства x86

Знающий сокровенное и явное, силён, мудр.

Коран. 64.18

Обозначением x86 описывают целый класс вычислительных систем, включающий уже практически не используемую 16-битную архитектуру (8086–i286), 32-битную архитектуру IA-32 (i386–i686), 64-битную x86-64 (amd64, Intel 64 или IA-32e).

Все модели этого многочисленного семейства совместимы между собой на уровне архитектуры команд, то есть все современные процессоры в определённом режиме теоретически могут выполнять программы, написанные для более старых (тем не менее из-за особенностей современных операционных систем, а также сильно изменившихся временны́х характеристик процессоров на практике чаще используются эмуляторы).

Несовместимая с набором команд x86 архитектура IA-64 (Itanium) не рассматривается в данной книге.

В данной главе рассматриваются режимы работы x86-совместимых процессоров, доступные регистры, флаги, режимы адресации, а также структура команды и вытекающие из неё ограничения.

3.1. Развитие линейки x86 и режимы работы

В отношении деятельности опыт, по-видимому, ничем
не отличается от искусства; мало того, мы видим,
что имеющие опыт преуспевают больше, нежели те,
кто обладает отвлечённым знанием, но не имеет опыта.

Аристотель. Метафизика

В данном пособии рассматривается 32-битный и 64-битный режимы работы, как более простые для прикладного программирования и более распространённые в настоящее время. Подробное описание качественно отличного от них 16-битного режима можно найти, в частности, у Питера Абеля [26].

Тем не менее, так как многие особенности архитектуры x86 обусловлены исторически и поддерживаются для совместимости, необходимо сделать краткий экскурс в историю данной линейки.

3.1.1. История семейства x86

Я родился в таможне,
Когда я выпал на пол.
Мой отец был торговец,
Другой отец — Интерпол...

Б. Б. Гребенщиков. Таможенный блюз

Архитектура x86 основана на архитектуре четырёхразрядного микропроцессора Intel 4004. Так как микросхема 4004 была разработана для настольного калькулятора, в ней не были реализованы многие механизмы, давно и успешно применявшиеся в более ранних компьютерах, в частности, аппаратная трансляция адресов. Позже была выпущена улучшенная версия 4004 — процессор 4040, а на его основе был разработан восьмиразрядный 8008, включавший семь восьмибитных регистров общего назначения — a, b, c, d, e, h, l; последние объединялись в пару hl и использовались как 16-битный адрес в памяти (то есть можно было адресовать до 2^{16} байт, или 64 килобайта). В улучшенном 8080 возможных 16-битных пар было уже три — bc, de, hl.

16-битные процессоры

Процессор 8086 — родоначальник семейства x86 — был 16-битным, из-за чего 16 бит при программировании для x86 обычно называют **словом.** Он включал четыре 16-битных регистра общего назначения ax, bx, cx, dx, каждый из которых фактически был парой восьмибитных (в частности, $ax = ah : al$), и четыре неделимых 16-битных регистра bp, sp, si, di. У каждого из них было и специальное назначение: A — accumulator (неявный аргумент большинства команд), C — counter (счётчик), D — data (данные), B — base (базовый регистр). В отличие от 32-разрядного режима, невозможно было использовать в косвенной адресации любые регистры. Для задания адреса в памяти использовались только три бита поля R/M и поле смещения (раздел 3.6.2). Базовыми могли быть только bx и bp (base pointer), индексными — только si и di (source index и destination index). Масштабирование индекса не использовалось.

Шина адреса при этом была двадцатиразрядной. Для того, чтобы адресовать 2^{20} байт (один мегабайт) памяти 16-битными адресами, была введена **сегментная модель памяти.** Полный адрес складывался из 16-битного адреса и значения специального сегментного регистра, умноженного на 16.

Область памяти, адресуемая с помощью одного сегментного регистра, называлась сегментом. Сегмент занимал 2^{16} байт, то есть 64 килобайта; разные сегменты могли пересекаться или полностью совпадать. В 8086 было четыре сегментных регистра, соответственно в программе использовалось четыре сегмента:

– cs (code segment) — сегмент кода; значение регистра cs добавлялось к адресам команд;
– ds (data segment) — сегмент данных, его значение добавлялось к адресам статических переменных;
– es (extra segment) — дополнительный сегмент данных, иногда там располагалась куча;
– ss (stack segment) — сегмент стека, добавлялся к адресам в стеке.

Добавляемый сегментный регистр определялся процессором автоматически; для данных при необходимости можно было использовать префикс замены сегмента.

Хотя в настоящее время используется плоская модель памяти (сегментные регистры присутствуют, но содержат другую структуру данных — селектор сегмента) по традиции области адресного пространства, где располагаются код, данные, стек и т. д., часто называются сегментами.

Так как четырёх сегментов по 64 килобайта часто не хватало, программисту приходилось изменять значения сегментных регистров во время работы программы для доступа к различным областям памяти. Управлять сегментами приходилось вручную.

В 8086 всё ещё не было механизма трансляции адресов, так что прикладные программы использовали реальные физические адреса ОЗУ; из-за этого режим совместимости с моделью памяти 8086 в более поздних процессорах называется **реальным режимом.** При этом каждой программе реального режима была доступна вся память компьютера, что не позволяло реализовать полноценную многозадачность.

Для 8086 был разработан математический сопроцессор 8087, предназначенный для вычислений с плавающей запятой. Сопроцессор устанавливался в отдельный сокет на материнской плате. Начиная с этой модели, стали выпускаться урезанные варианты процессоров. Так, 8086 с восьмибитной шиной данных получил название 8088.

На основе 8088 был построен компьютер IBM PC, так что большинство последующих процессоров Intel (и неинтеловских x86-совместимых процессоров) совместимы с 8086 на уровне машинного кода. Теоретически любой современный персональный компьютер можно загрузить в специальном режиме совместимости и выполнить программу, написанную для 8086. Практически с этим возникнут трудности, в частности, из-за несоответствия временны́х характеристик.

Непосредственно следующая модель, 80186, отличалась от 8086 незначительно. В 80286 появилась частичная поддержка **защищённого режима,** когда память разных программ изолирована (защищена) друг от друга за счёт аппаратной трансляции адресов. Шина адреса была увеличена до 24 разрядов.

32-битные и 64-битные процессоры

Полноценная реализация защищённого режима появилась в 32-битном процессоре 80386 (часто называемом просто 386). Так как разрядность процессора сравнялась с разрядностью шины адреса, в защищённом режиме 386 используется плоская модель памяти. Количество сегментных регистров возросло до шести. При этом сегментные регистры защищённого режима содержат не часть адреса, а селектор, кодирующий ссылку на запись в специальной таблице дескрипторов, которая, в свою очередь, задаёт границы сегмента в плоском адресном пространстве и атрибуты защиты.

Современные операционные системы используют именно защищённый режим процессора (либо очень схожий с ним 64-битный режим), в котором прикладной программе недоступны многие функции реального. При этом, так как эти функции прозрачно обеспечиваются операционной системой, прикладное программирование заметно упрощено.

Тем не менее, из-за используемого программного обеспечения даже более поздние модели (до Pentium 4) постоянно или часть времени работали в реальном режиме, так что многие учебники ассемблера описывают его наравне с защищённым.

В целом разработка 386 — наиболее существенный шаг в развитии архитектуры семейства x86. В настоящее время «x86» обозначает, как правило, 386-совместимый процессор (такая архитектура обозначается i386 или IA-32). Дальнейшее развитие в основном сводилось к добавлению новых команд, наращиванию параллелизма и увеличению частоты.

В определённый момент четырёх гигабайт памяти, адресуемых 32-битным указателем в плоской модели, оказалось недостаточно. В первую очередь это проявилось на серверах и специализированных высокопроизводительных рабочих станциях. Разработчики ПО и аппаратного обеспечения не стали возрождать неудобную сегментную модель памяти, вместо этого начали продвигаться решения с 64-битными виртуальными адресами.

Результатом совместной разработки Intel и Hewlett Packard стала архитектура IA-64, схожая с суперкомпьютером Эльбрус и свободная от недостатков, унаследованных от калькулятора 4004 и 16-битного 8086. IA-64 несовместима с набором команд x86. Она не получила популярности в основном из-за недостаточного количества портированного под неё ПО и несовершенства компиляторов, а также дороговизны и некоторых конструктивных недоработок воплощавших её процессоров Itanium. В мае 2017 г. официально объявили о закрытии этой линейки.

Ведущий конкурент Intel, компания AMD, предложила расширение архитектуры IA-32, увеличивающее разрядность адресов до 64 бит и дающее возможность увеличить разрядность данных с помощью специального префикса REX. Именно это расширение, которое в настоящее время поддерживается и процессорами

Intel — наиболее популярный способ увеличить адресуемую память персонального компьютера.

Разработанная компанией AMD 64-битная архитектура x86-64 (также называемая amd64, IA-32e и Intel 64, но не IA-64) не слишком существенно отличается от 32-битной x86.

3.1.2. Режимы работы процессора

У меня есть две фазы, мама,
Я — чистый бухарский эмир.
Когда я трезв, я — Муму и Герасим, мама;
А так я — Война и Мир.

Б. Б. Гребенщиков. Таможенный блюз

Процессоры 32-битной архитектуры x86 (IA-32) поддерживают четыре режима работы (рис. 3.1) [2, 16]:

- 16-битный реальный режим (Real Mode);
- 16-битный режим виртуального 8086 (Virtual-8086 Mode), используемый 32-битными операционными системами для запуска устаревших программ;
- 32-битный защищённый режим (Protected Mode);
- режим системного управления (System Management Mode, SMM) — сверхпривилегированный режим, в котором обрабатываются скрытые от операционной системы события.

Процессоры семейства x86-64 добавляют к ним ещё два режима, в совокупности обозначаемые в документации [2] как Long Mode (на рис. 3.1 эти два режима объединены серым овалом вверху рисунка):

- 32-битный режим совместимости;
- 64-битный режим.

64-битный режим использует по умолчанию 32-битные данные и смещения и концептуально отличается от 32-битного режима гораздо меньше, чем 16-битный. Соответственно, его иногда называют 64-битным расширением защищённого режима, а архитектуру x86-64 обозначают как IA-32e.

Порядок переключения режимов

При загрузке или сбросе процессор переходит в реальный режим. Из реального режима он может переключиться в защищённый, в котором работают все 32-битные операционные системы. При необходимости выполнения 16-битного кода процессор может временно переключаться в режим виртуального 8086.

Из 32-битного защищённого режима процессор может переключиться в 32-битный режим совместимости, а затем в 64-битный режим. Эти два режима используются 64-битными операционными системами. Таким образом, для выполнения

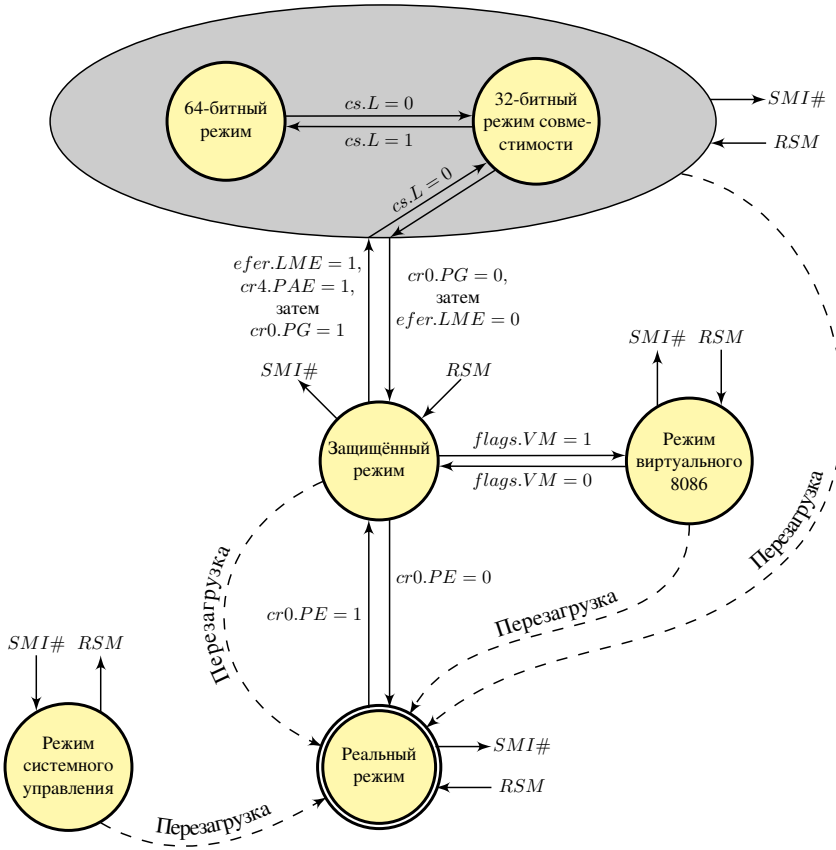

Рис. 3.1. Режимы работы современных процессоров

32-битных приложений процессор может временно переключаться обратно в режим совместимости. Выполнить 16-битное приложение в 64-битной операционной системе невозможно — необходимо использовать эмулятор или перезагрузить компьютер под другой операционной системой.

На рис. 3.1 переключения режимов, возможные в процессе работы, показаны сплошными стрелками, переключения по перезагрузке — пунктиром.

Из любого из этих режимов процессор при возникновении соответствующего события может ненадолго перейти в режим системного управления, а после обработки события — вернуться в исходный режим.

В принципе, возможен переход из 64-битного режима через режим совместимости в защищённый и из защищённого в реальный, но, как правило, подобной

необходимости не возникает и в современных операционных системах она не реализована. Прикладная программа, запущенная в защищённом режиме, не может перевести процессор в реальный (или, соответственно, из 64-битного в защищённый).

3.2. Сегменты памяти

Пара двух точек, разделённая растущим пространством.

В. Хлебников. Царапина по небу

В памяти вычислительной машины фон-неймановской архитектуры хранится как код программы, так и данные.

Данные (переменные) в программе на языке высокого уровня, в частности, C++, делятся на:

- глобальные, время жизни которых равно времени жизни программы, а имя доступно в любой области программы;
- статические локальные, время жизни которых также равно времени жизни программы, но имя доступно только в ограниченной области;
- локальные — каждый вызов функции порождает новую копию переменной, время жизни которой не превышает времени работы функции и которая доступна только в ограниченной области;
- динамические — память выделяется и освобождается с помощью операторов $new/delete$ или функций $malloc()/free()$.

Различные виды переменных и программы находятся в разных областях диапазона доступных виртуальных адресов — адресного пространства процесса, исторически называемых **сегментами** (сейчас иногда используется также термин **«секция»,** чтобы подчеркнуть использование плоской модели памяти и связь областей памяти с секциями исполняемого файла).

На рис. 3.2 представлено возможное распределение виртуальных адресов процесса в 32-битной операционной системе GNU/Linux.

Конкретное расположение сегментов в адресном пространстве процесса может различаться для различных операционных систем. Состав также может различаться, но основные сегменты — кода, данных, кучи и стека — присутствуют всегда.

Хотя все сегменты располагаются в одном адресном пространстве, они могут иметь разные атрибуты защиты. В частности, сегмент кода для предотвращения вредоносных модификаций доступен только для чтения, но не для записи, а для сегментов, доступных программе на запись (данные, стек, куча) запрещено исполнение.

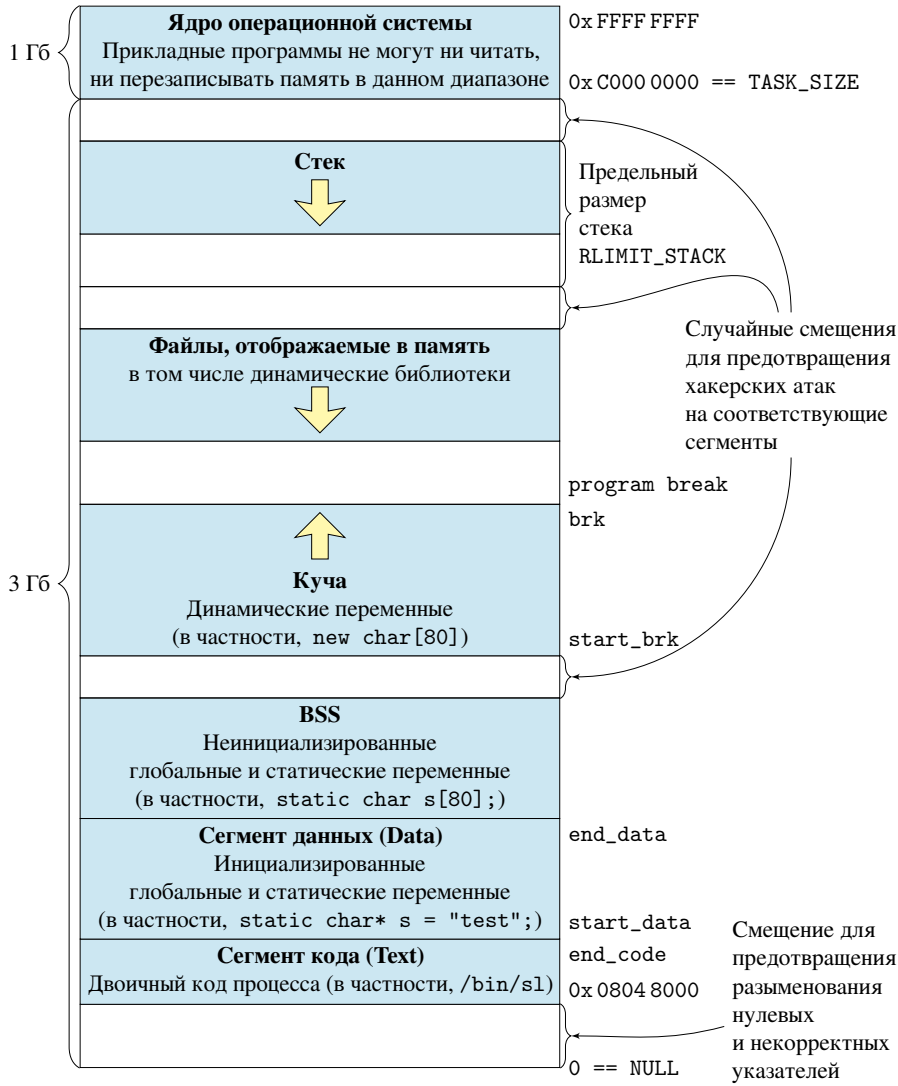

Рис. 3.2. Распределение памяти процесса в 32-битной операционной системе GNU/Linux

Нулевой адрес и ближайшие к нему считаются некорректными для выявления и предотвращения ошибок (разыменования переменных, которые указателями не являются).

Кроме того, между динамически растущими сегментами (данных и кучи, кучи и стека, стека и пространства ядра) добавляются «зазоры» случайного размера для затруднения атак на соответствующие области памяти. Размеры этих смещений определяются при загрузке программы в память.

Часть адресного пространства процесса (в 32-битных системах по умолчанию 1 Гб, в 64-битных — 512 Гб) занимает ядро операционной системы [72].

3.2.1. Код и статические данные

> Центральная станция всех явлений,
> путаница штепселей, рычагов и ручек.
>
> *В. В. Маяковский. Человек*

Код выполняемой программы находится в **сегменте кода.**

Глобальные переменные программы, доступные в любой её точке и статические переменные, отличающиеся от глобальных только областью видимости, расположены в **сегменте данных.** Те глобальные и статические переменные, которые не были инициализированы при объявлении, отделяются в специальный **сегмент BSS.**

Адреса глобальных и статических переменных в программе — неотрицательные целые константы. Для адресов в коде (в частности, функций) возможно задать как фиксированный адрес, так и смещение относительно текущего значения указателя команд ip.

Размеры кода программы и переменных, время жизни которых совпадает со временем жизни программы, могут быть определены ещё на этапе загрузки программы в память, поэтому размеры соответствующих областей памяти постоянны.

При этом адрес, по которому могут быть загружены код и статические данные, в принципе может варьироваться (это особенно актуально для разделяемых библиотек). В этом случае требуется каким-то образом сохранить работоспособность программы и доступность данных.

Для кода программы это достигается использованием для кода относительных адресов (так называемых команд ближнего перехода, содержащих не сам адрес, а его смещение относительно текущего значения указателя команд ip).

Для данных в 32-битном режиме адресация относительно ip невозможна. Соответственно, используются два варианта. Первый — коррекция фиксированных адресов в программе при загрузке исполняемого файла в память (это мешает совместному использованию библиотек, так как, если несколько программ попытаются загрузить библиотеку по разным адресам, получится разный код). Второй — копирование текущего значения ip в регистр общего назначения обходным путём и ручной расчёт смещений относительно полученного значения.

В 64-битном режиме добавлена возможность задавать для данных адрес в виде смещения относительно текущего значения ip. Для Mac OS X адресация глобаль-

ных и статических переменных относительно ip обязательна, для других операционных систем — рекомендуется.

3.2.2. Куча

Главный склад всевозможных лучей.
Место выгоревшие звёзды кидать,
Ветхий чертёж
— неизвестно чей —
первый неудавшийся проект кита.

В. В. Маяковский. Человек

Динамические переменные расположены в **сегменте динамической памяти,** или **куче** (heap). Первоначально программе выделяется определённый объём динамической памяти, из которого средствами языка высокого уровня ($new/new[]/malloc()$ для C++) выделяются области памяти под запросы прикладной программы. Распределённые области помечаются в куче как занятые. Если в свободных областях кучи недостаточно памяти для обработки запроса, $new/new[]/malloc()$ обращается к операционной системе для расширения кучи. Соответственно, количество корректных адресов сегмента кучи увеличивается.

Когда прикладной программе уже не нужна какая-то динамическая переменная, соответствующую область памяти необходимо освободить. Для этого в C++ используются операторы $delete/delete[]$ или функция $free()$, помечающие область как свободную. При этом освобождать область памяти необходимо способом, соответствующим выделению. Таким образом, если память была выделена оператором $new[]$:

```
1 int *p_array = new int[N];
```

освобождать её нужно оператором $delete[]$:

```
1 delete[] p_array;
```

После вызова несоответствующего оператора `delete p_array` будет помечен как свободный только первый элемент массива. В некоторых языках есть механизм автоматического сбора мусора, который освобождает те области памяти, к которым программа уже не обращается, но в C/C++ его нет.

Если память не освобождена, динамические переменные существуют до завершения программы, даже если адрес, по которому можно обратиться к ним, утрачен (подобная ситуация называется утечкой памяти). Таким образом, время жизни динамических переменных фактически определяется программистом.

3.2.3. Стек

Всё в страшном порядке,
в покое,
в чине.

В. В. Маяковский. Человек

Локальные переменные подпрограмм находятся в **сегменте стека,** также оптимизирующие компиляторы могут помещать часть целочисленных переменных в регистры общего назначения.

Стек назван так потому, что организован по принципу LIFO (last in, first out) — последним зашёл, первым вышел. Указателем вершины стека служит специальный регистр sp — stack pointer. Он содержит адрес начала последнего записанного в стек элемента. Соответственно, адреса локальных переменных в программе отсчитываются относительно вершины стека sp.

Команды семейства x86, предназначенные для работы со стеком (`push` и `pop`) могут записывать в стек элементы размером либо в машинное слово (64 бита в шестидесятичетырёхбитном режиме и 32 в тридцатидвухбитных режимах, рис. 3.3),

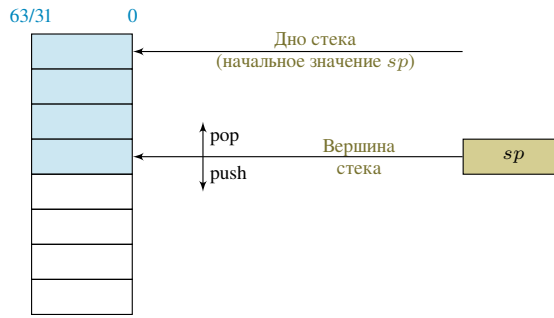

Рис. 3.3. Стек

либо в 16 бит. Вручную изменяя значение sp, можно разместить в стеке элемент любого размера (что используется для компактного размещения локальных переменных). Тем не менее, в 32-битном GNU/Linux стек по соглашению выравнен по $long$, то есть на 32 бита, а в 64-битных системах — на 128 бит, то есть должно выполняться $sp = 16x$ (при этом сразу после входа в функцию $sp = 16x - 8$, так как 64-битный адрес возврата занимает 8 байт).

Стек растёт вниз (в сторону уменьшения адресов). Таким образом, операция помещения элемента в стек (`push`) уменьшает указатель стека sp, операция извлечения (`pop`) — увеличивает. Таким образом, с учётом порядка байт Intel sp указывает на крайний (с наименьшим адресом) занятый байт стека.

В частности, рассмотрим рекурсивное вычисление факториала небольшого целого числа (листинг 3.1). Это крайне неэффективный способ вычисления, но

Листинг 3.1. Рекурсивный вызов функции

```
1  int fact(int n)
2  {
3    int f;
4    if (n <= 2)
5      f = n;
6    else
7      f = n * fact(n-1);
8    return f;
9  }
```

```
10 int main(int argc,
11   char *argv[])
12 {
13   int x;
14   x = fact(3);
15   cout << x;
16   return 0;
17 }
```

в учебниках он традиционно рассматривается как наглядный пример рекурсии.

После запуска программы стартовый код запускает головную функцию $main()$. Соответственно, в стеке находятся данные этой функции (рис. 3.4, а): локаль-

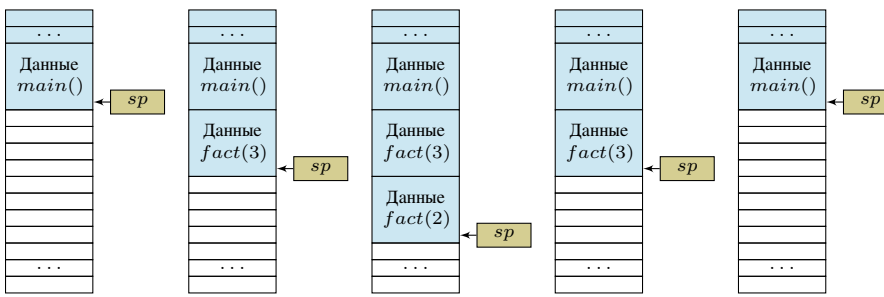

Рис. 3.4. Изменение указателя стека при вызове и возврате из функций

ная переменная x, адрес возврата, показывающий, какой команде будет передано управление после возврата из $main()$, а также аргументы $main()$ — количество параметров командной строки, переданных при запуске программы и указатель на массив этих параметров. В зависимости от используемого соглашения о вызове (подробнее в разделе 6.2.1), часть или все аргументы функции $main()$ могут находиться в регистрах общего назначения; но в 32-битном режиме они все передаются через стек.

Размер каждого из параметров, а также общий размер блока локальных переменных по соглашению о выравнивании должны быть кратны 32 битам.

После вызова функции $fact(3)$ в стек добавляется ещё один слой данных (рис. 3.4, б): параметр $n = 3$, адрес возврата из $fact(3)$ (в данном случае это адрес команды, записывающей результат в переменную x в $main()$) и локальная переменная f. После анализа n следует рекурсивный вызов $fact(2)$, добавляющий в стек новый параметр $n = 2$, новый адрес возврата (адрес команды умножения на n в $fact(3)$) и ещё одна копия локальной переменной f (данные $fact(2)$ на рис. 3.4, в). Таким образом, каждому вызову функции $fact()$ соответствует свой набор параметров и локальных переменных.

После анализа параметра n следует возврат значения n из функции $fact(2)$. При этом управление передаётся команде по адресу возврата, а сам адрес возврата вместе с локальными переменными и параметрами этой функции удаляется из стека (рис. 3.4, г). Удаление выполняется путём изменения указателя sp, содержимое памяти при этом не перезаписывается (рис. 3.5, а) и б). Соответственно,

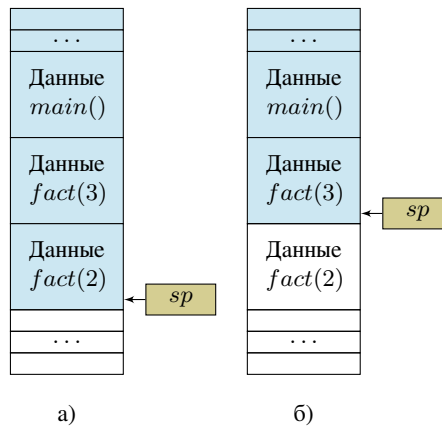

Рис. 3.5. Удаление данных из стека — изменение указателя

в незанятых ячейках стека содержатся «мусорные» данные, поэтому значение неинициализированных локальных переменных непредсказуемо.

После умножения результата $fact(2)$ на n происходит возврат в $main()$ (рис. 3.4, д).

Некоторые модели процессоров, в том числе ранние не-x86 совместимые процессоры Intel, организуют стек вызовов не в памяти, а в специальном наборе регистров. Это ограничивает количество вложенных вызовов функций, зато ускоряет процесс вызова и возврата.

3.3. Регистры

Маленькое усовершенствование — бережёт огромное время.

В. В. Маяковский. О мелочах

Процессоры семейства x86 содержат как множество недоступных и ограниченно доступных программисту специальных регистров, так и определённое количество регистров общего назначения, которые можно адресовать на уровне архитектуры команд по номерам, а в программе на ассемблере — явно указанными в коде именами.

В частности, команда безусловного перехода `jmp label`, аналог оператора C++ $goto\ label$, модифицирует специальный регистр ip (указатель команд), но не содержит его имени. Напротив, команда загрузки значения в регистр общего назначения `mov $13, %eax` содержит его имя (eax) в явном виде, а соответствующий машинный код `B8 00 00 00 0D` содержит номер регистра A (первый байт команды $\mathrm{B8}_{16} = 10111000_2$ включает пятибитный код 10111 загрузки непосредственного значения в регистр, последние три бита 000 задают регистр-приёмник A; завершающие четыре байта 00 00 00 0D — загружаемое 32-битное значение $13_{10} = \mathrm{D}_{16}$, подробнее см. раздел 3.6). Если это имя или номер заменить именем или номером другого регистра общего назначения, получим корректную команду загрузки значения в этот регистр.

Граница между специальными регистрами и регистрами общего назначения в наборе команд x86 достаточно размыта. Так как регистров в оригинальном процессоре 8086 было мало, все адресуемые регистры имели ещё и какое-либо специальное назначение. В частности, регистр A ($rax/eax/ax/al$) — регистр-аккумулятор. Он используется командами знакового расширения, деления и множеством других команд как неявный аргумент.

Со временем специализация адресуемых регистров сглаживается, но многие команды, унаследованные от оригинального набора, обращаются к неявному аргументу в конкретном регистре общего назначения.

Основной набор команд x86 предназначен для обработки целых чисел, так что в регистрах процессора могут находиться целочисленные переменные (адреса, индексы и собственно целые числа).

Регистры, доступные различным расширениям набора команд, в частности, команд обработки вещественных чисел, хранят данные соответствующего типа. Такие регистры, как правило, недоступны командам из основного набора и будут рассматриваться отдельно.

3.3.1. Регистры общего назначения, доступные в 32-битном режиме

Иначе и нельзя. Разделение труда.

В. В. Маяковский. Мелкая философия на глубоких местах

Под номер регистра в команде (её структура более подробно рассматривается в разделе 3.6.2) отведено всего три бита [17, 36], так что регистров общего назначения в 32-битном режиме x86 доступно только восемь (рис. 3.6).

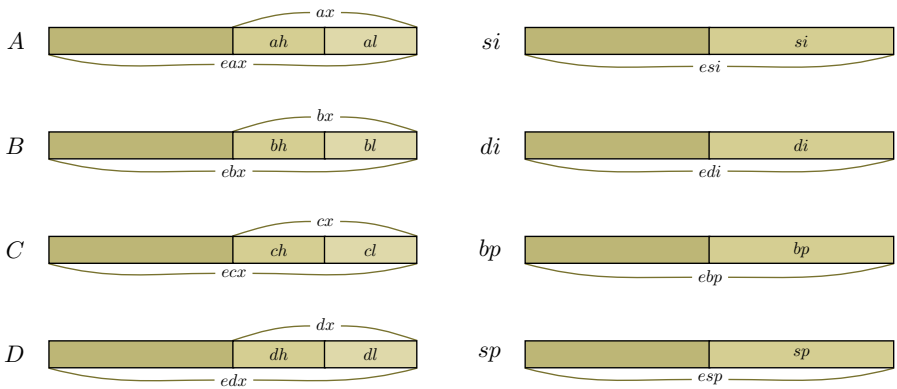

Рис. 3.6. Регистры общего назначения в 32-битном режиме

В некоторых источниках к регистрам общего назначения относят только четыре регистра — A, B, C и D (на рис. 3.6 показаны слева). Каждый из них конструктивно имеет размер машинного слова (сейчас, как правило, 64 бита), но в 32-битном режиме доступны только младшие 32. Разные их части называются разными именами.

В частности, младший байт регистра A обозначается al (low), следующий байт — ah (high). Пара однобайтовых регистров $ah : al$ составляет младшие 16 бит регистра — ax (для 16-битного 8086 это означало eXtended). Младшие 32 бита (максимально доступный в 32-битном режиме размер регистра) обозначаются как eax, доступные только в 64-битном режиме 64 бита — rax. Для краткости будем использовать однобуквенное обозначение регистра, когда его разрядность может быть любой или совпадает с разрядностью системы, в частности, A вместо $rax/eax/ax/al$.

Также имена и номера существуют для регистров si, di, bp и указателя вершины стека sp, которые иногда также причисляют к регистрам общего назначения (на рис. 3.6 справа). Эти имена соответствуют младшим 16 битам регистров. Их

32-битные варианты называются соответственно esi, edi, ebp и esp, 64-битные — rsi, rdi, rbp и rsp. Младшие байты этих регистров не имеют имён в 32-битном режиме.

Для краткости будем использовать оригинальное имя регистра, когда его разрядность совпадает с разрядностью системы, например, sp вместо $rsp/esp/sp$. Это не вызовет путаницы, так как шестнадцатиразрядный код сейчас практически не используется.

Хотя sp можно адресовать как регистр общего назначения, использовать его иначе, чем как указатель вершины стека, категорически не рекомендуется. Кроме того, как будет показано в разделе 3.6.3, возможности адресации sp ограничены. Таким образом, будем считать регистрами общего назначения следующие семь — A, B, C, D, si, di и bp.

3.3.2. Регистры общего назначения, доступные в 64-битном режиме

> Царь потрясающего величия,
> Дарующий спасение тем, кто не отчаялся,
> Спаси меня, источник милосердия.
>
> *День гнева*

В 64-битном режиме доступны все описанные выше регистры. При этом для регистров общего назначения, доступных в 32-битном режиме, используются те же имена. Для 64-битных регистров имена соответствуют 32-битным вариантам, но вместо префикса e используется префикс r (rax, rdi и т. д).

Кроме того, в 64-разрядном режиме может быть использован специальный префикс REX (расширения регистров, подробнее в разделе 3.6.5), который добавляет ещё один бит к номерам регистров в команде, так что можно адресовать ещё восемь регистров общего назначения $r8{-}r15$ (рис. 3.7). В 32-разрядном режиме они недоступны.

Младшие части регистров $r8{-}r15$ имеют имена $r8b{-}r15b$ (размер этих регистров равен одному байту — 8 бит), $r8w{-}r15w$ (размер равен слову — 16 бит), $r8d{-}r15d$ (размер равен двойному слову — 32 бита). Также префикс REX позволяет адресовать младшие байты регистров si, di, bp и sp — они имеют имена sil, dil, bpl и spl [16] и доступны наравне с $al{-}dl$ и $r8b{-}r15b$.

Старшие байты младшего слова (разряды $8{-}15$, аналогично $ah{-}dh$) не имеют собственных имён ни для каких регистров, кроме $A{-}D$. В некоторых источниках сказано, что $ah{-}dh$ в 64-битном режиме недоступны. Это не совсем так. Регистры $ah{-}dh$ доступны, но только в командах без префикса REX.

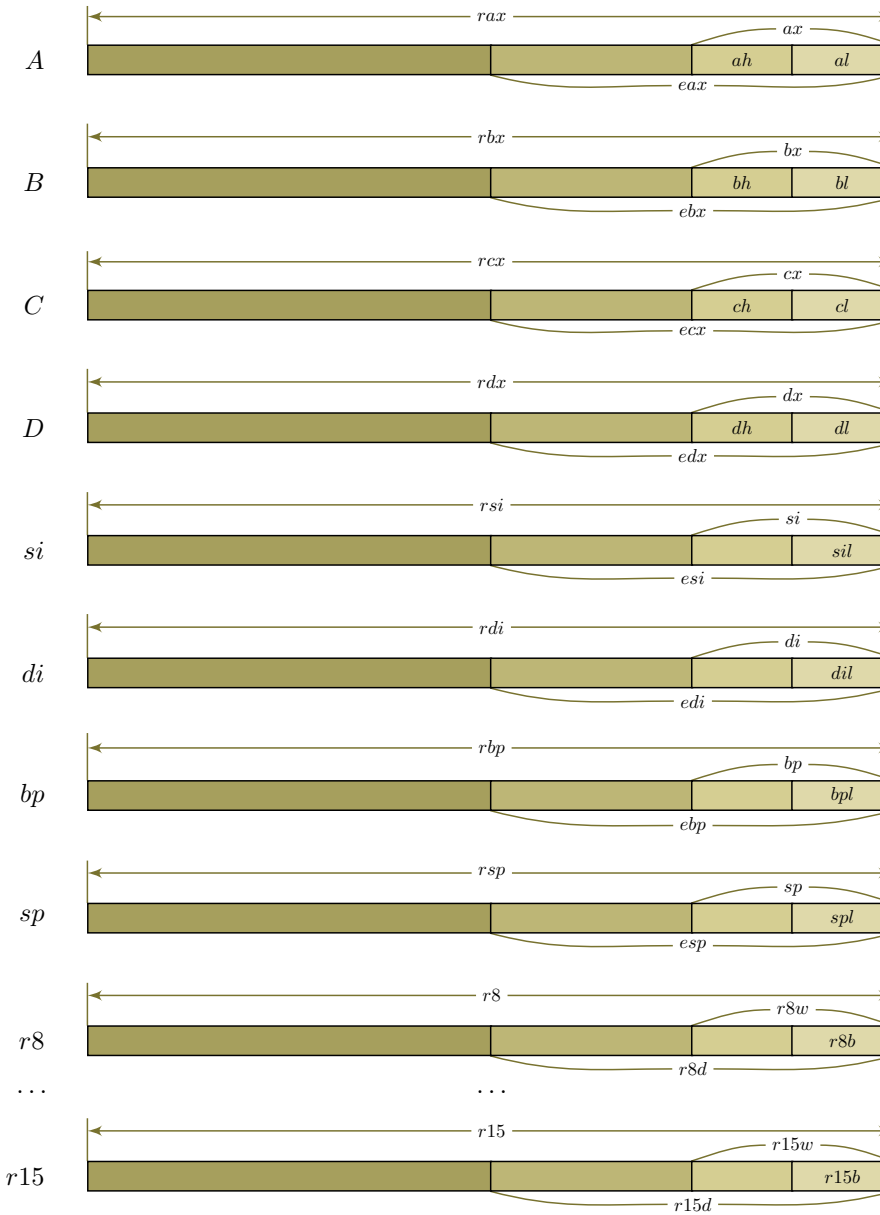

Рис. 3.7. Регистры общего назначения в 64-битном режиме

3.3.3. Специальные регистры и регистры расширений

> В руке подполковника красовалась странная медаль:
> стальной кружок даже без намёка на гравировку
> на колодке ускользающего цвета.
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Сестрички и другие чудовища*

Из специальных регистров следует отметить регистры состояния и управления: уже упоминавшийся указатель команды ip (в 32- и 64-битных системах иногда называется eip и rip соответственно) и регистр флагов $flags$ ($eflags/rflags$). Разряды регистра флагов либо показывают те или иные характеристики последней операции процессора (флаги состояния), либо влияют на выполнение команд (управляющие флаги).

Современные процессоры семейства x86, кроме основного набора команд, поддерживают несколько расширений. Для них реализованы несколько групп регистров общего назначения, доступных в командах соответствующих наборов:

- восемь 80-разрядных регистров FPU x87 ($r_0 - r_7$) могут быть использованы как командами FPU как $st(0) - st(7)$, хранящие числа с плавающей запятой, так и командами расширения MMX как 64-разрядные регистры $mm0 - mm7$, ($mm0 - mm7$ — мантиссы $r_0 - r_7$);
- восемь 128-разрядных регистров расширения SSE, или XMM ($xmm0 - xmm7$). Каждый из них предназначен для хранения вектора вещественных чисел одинарной точности, а не длинного 128-битного числа. В 64-битных системах количество XMM-регистров, как и количество регистров общего назначения, увеличено до шестнадцати ($xmm0 - xmm15$). Расширение AVX (YMM) вдвое увеличило их разрядность — до 256-разрядных $ymm0 - ymm15$, недавно появившееся AVX-512 (ZMM) — до 512-разрядных $ymm0 - ymm31$ (в 32-битных системах доступны только первые восемь). При этом регистры ymm_i — младшие половины регистров zmm_i, а xmm_i, соответственно, — младшие половины ymm_i. Регистры ZMM есть не во всех современных процессорах.

Также расширения могут иметь свои специальные регистры, в частности, регистры флагов. Например, FPU имеет обширный набор специальных регистров, так как изначально команды набора FPU выполнялись отдельным устройством — математическим сопроцессором.

3.4. Математический сопроцессор (FPU x87)

На заборе сидит заяц в алюминиевых клешах,
Сам себе начальник и сам падишах,
Он поставит им мат и он поставит им шах,
И он глядит на них глазами.

Б. Б. Гребенщиков. Иван и Данило

Математический сопроцессор (Floating Point Unit, FPU) — устройство для обработки числовых данных в формате с плавающей точкой. Первый математический сопроцессор для линейки x86 — FPU 8087 — был выпущен в 1980 году. Он представлял собой отдельную микросхему, устанавливаемую в специальный сокет на системной плате. Взаимодействие с основным процессором выполнялось в основном через оперативную память.

Начиная с процессора i486DX математический сопроцессор интегрирован в процессор. При этом сопроцессор долгое время (вплоть до линейки микропроцессоров Atom) имел почти независимое ядро, так что обработка целых чисел CPU и вещественных FPU могла выполняться параллельно. Из-за этого в систему команд была введена команда ожидания завершения работы сопроцессора, а многие команды управления сопроцессором реализованы в двух вариантах — с ожиданием и без. В современных процессорах FPU настолько плотно интегрирован с ядром CPU, что их параллельная работа невозможна и ожидание не требуется.

3.4.1. Регистры FPU

Да, я — разомкнутый круг, обретаю смыкание круга!

С. А. Калугин. Скульптор лепит автопортрет

FPU x87 предоставляет восемь 80-разрядных регистров для хранения данных и шесть вспомогательных регистров [5, 16]. При обращении к ним в GAS надо указывать тот же префикс %, что и для регистров основного процессора (CPU).

Восемь регистров данных, согласно документации Intel [16], носят имена $r_0 - r_7$, но обратиться к ним по этим именам невозможно. Они образуют стек с плавающей вершиной, построенный по принципу кольцевого буфера. К регистру, находящемуся сейчас в вершине стека, можно обратиться как к $st(0)$; если стек содержит более одного элемента, то к более глубоким элементам можно обращаться по именам $st(1)$, $st(2)$ и так далее до $st(7)$ [34]. Регистры данных сопроцессора хранят вещественные числа в 80-битном расширенном формате. Мантисса занимает 64 бита, порядок — 15 бит, под знак отводится один бит.

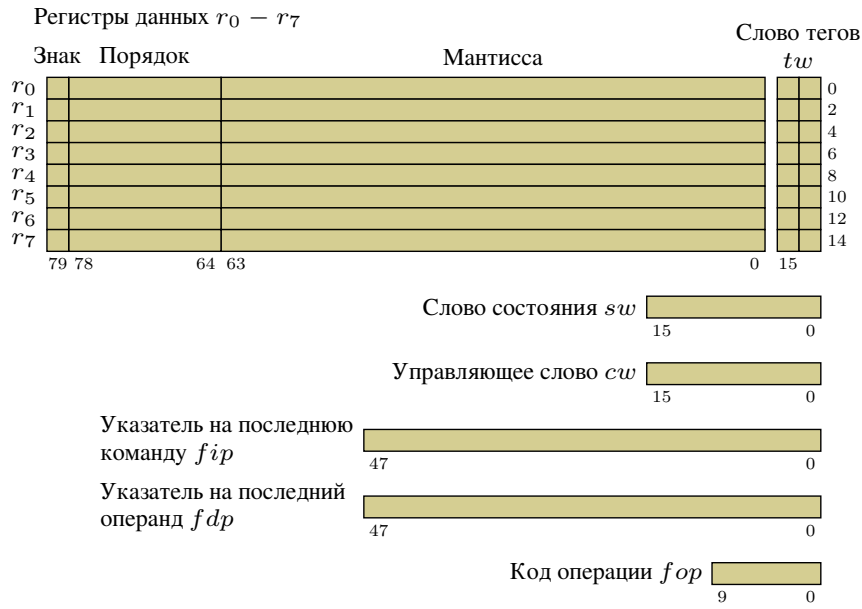

Рис. 3.8. Регистры FPU

Шестнадцатибитный регистр (слово) тегов tw (Tag Word, также используется сокращение twr — Tag Word Register) хранит состояние регистров данных. Каждому регистру $r_0 - r_7$ соответствует два бита слова тегов (рис. 3.9):

а) 00 — в соответствующем регистре корректное ненулевое значение;
б) 01 — в регистре ноль;
в) 10 — в регистре специальное значение: некорректное значение (nan или значение, не соответствующее формату вещественного числа с расширенной точностью), бесконечность или денормализованное число;
г) 11 — регистр пуст.

$tag(7)$		$tag(6)$		$tag(5)$		$tag(4)$		$tag(3)$		$tag(2)$		$tag(1)$		$tag(0)$	
15	14	13	12	11	10	9	8	7	6	5	4	3	2	1	0

Рис. 3.9. Слово тегов FPU

Если регистр r_i помечен в слове тегов как пустой, его значение при этом может быть каким угодно — попытка чтения из него приведёт к ошибке стека.

Флаги математического сопроцессора разбиты на два шестнадцатибитных регистра (рис. 3.10) — управляющие флаги составляют управляющее слово cw (Control

Word, также cwr), флаги состояния сгруппированы в слово состояния — sw (Status Word, также swr).

Рис. 3.10. Слово состояния и управляющее слово FPU

Управляющее слово содержит шесть масок исключений ($IM-PM$), поле управления точностью PC и поле управления округлением RC.

Слово состояния отображает текущее состояние сопроцессора после выполнения последней команды. Младший байт слова состояния включает семь флагов, показывающих корректность операций ($IE-SF$) и флаг ES, показывающий, что сбой не только был, но и привёл к прерыванию. Старший байт включает флаги $C0-C3$, хранящие признаки последней операции FPU (в частности, устаревшие команды сравнения чисел помещают в них результат сравнения), а также трёхбитный текущий номер вершины стека top. Последний бит B в настоящее время не используется.

Таким образом, стек сопроцессора организован с помощью восьми регистров данных $r_0 - r_7$, соответствующих восьми полей слова тегов $tag(0)-tag(7)$ и поля top слова состояния. Вершина стека $st(0)$ находится в регистре r_{top}, обозначение $st(1)$ получает следующий регистр r_{top+1} и так далее. За r_7 по принципу кольцевого буфера следует r_0. На рис. 3.11 показаны соотношения между физическими r_i и логическими $st(i)$ именами регистров данных сопроцессора при различных значениях номера вершины стека top.

Положение дна стека определяется словом тегов tw (первый пустой регистр).

После инициализации стек пуст. После завершения вычислений (перед выходом из функции или ассемблерной вставки) его также необходимо оставить пустым. Если функция возвращает вещественное значение через стек сопроцессора, в стеке не должно остаться ничего, кроме возвращаемого значения.

Для вычислений хотя бы один операнд должен быть загружен в стек сопроцессора.

Два 48-битных регистра указателей (на последнюю команду — FPU Instruction Pointer, fip, в некоторых источниках также ipr [51] и последний загруженный операнд Data (Operand) Pointer, fdp, также dpr), а также десятибитный регистр

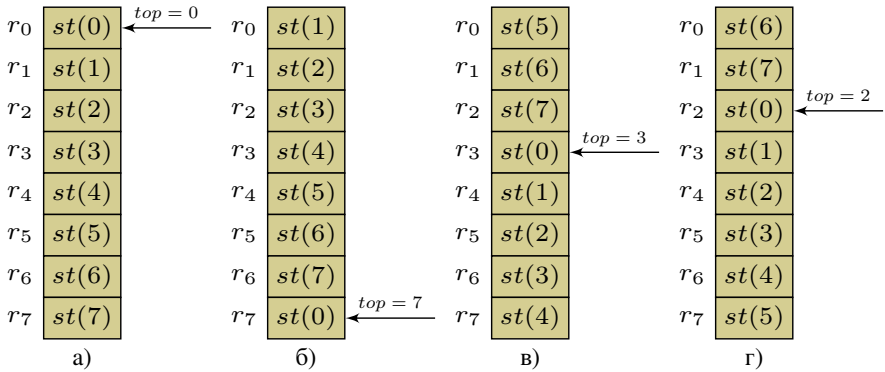

Рис. 3.11. Стек FPU

кода операции последней неуправляющей команды (FPU Opcode Register, fop) используются в обработке исключений для определения места сбоя.

3.4.2. Исключения FPU

> — Не боись! На всякую инструкцию есть своя обструкция!
> Стихи. Сам придумал!
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Порри Гаттер и Каменный Философ*

Во время работы сопроцессора возможны ситуации, когда по какой-то причине невозможно корректно выполнить требуемые вычисления. Подобные ситуации называются исключительными ситуациями, или просто исключениями FPU.

Рассмотрим исключения FPU подробнее. Любое из них приводит к общему исключению недействительной операции (**#I**).

#I — недействительная операция (Invalid operation). Может быть стековой ошибкой **#IS** или недопустимой арифметической операцией **#IA**.

Стековая ошибка

#IS — стековая ошибка (Stack Fault) — попытка записи в полностью заполненный стек или чтения из пустой ячейки стека FPU.

Недопустимые арифметические операции

Недействительной арифметической операцией **(#IA)** считается операция, проводимая над некорректными аргументами. В этом случае может также возникнуть одна из следующих пяти ситуаций.

#D — денормализованный операнд (Denormalized operand) — выполнение арифметической операции над денормализованным числом или загрузка такого числа в стек FPU.

#Z — деление на ноль (Zero Divide) — деление на ноль.

#O — переполнение порядка (Overflow) — порядок результата выходит за максимально допустимое значение.

Для команд выгрузки из стека `f*st` переполнение возможно в том случае, если размер порядка приёмника недостаточен.

#U — антипереполнение, или исчезновение порядка (Underflow) — порядок результата выходит за минимально допустимое значение (денормализованный результат).

Для команд выгрузки из стека `f*st` антипереполнение возможно в том случае, если выгружаемое значение слишком близко к нулю и не может быть корректно представлено в формате приёмника.

#P — неточный результат (Precision) — результат невозможно точно представить в формате назначения (например, $\frac{1}{3}$, $\sqrt{2}$).

Команды вычисления трансцендентных функций (`fsin`, `fcos`, `fsincos`, `fptan`, `fpatan`, `f2xm1`, `fyl2x`, `fyl2xp1`) всегда приводят к неточному результату.

Маски исключений

Если в языках высокого уровня термин «исключение» подразумевает прерывание нормального хода программы и переход к обработчику, то FPU на некоторые (арифметические) исключения может реагировать двояко: помещать на место результата специальное значение (вещественную неопределённость) или инициировать прерывание вычислений.

Поведением FPU управляют шесть масок исключений ($IM-PM$), расположенных в первых шести битах управляющего слова cw. На тех же местах в слове состояния sw располагаются соответствующие флаги $IE-PE$.

Если бит маски установлен в единицу, то соответствующее исключительная ситуация не вызывает прерывания выполнения программы (то есть того, что обычно и называется в языке высокого уровня исключением). Такое исключение называется замаскированным.

Стековую ошибку замаскировать невозможно.

Флаги FPU

Математический сопроцессор имеет собственный регистр флагов — слово состояния sw. Аналогично $flags$, биты слова состояния сопроцессора представляют те или иные характеристики последней операции сопроцессора [16, 75].

На рис. 3.10 показано расположение семи флагов ошибок разных видов, флага суммарной ошибки и флагов $C0-C3$, куда, в частности, помещают результат устаревшие команды сравнения. Команды вещественной арифметики не выставляют флаги $C0-C3$ аналогично командам сравнения, но могут использовать эти биты иначе.

Первые семь битов слова состояния соответствуют исключениям FPU. Каждой исключительной ситуации соответствует свой флаг ошибки, который устанавливается в единицу при возникновении этой исключительной ситуации.

IE (бит 0) — флаг недействительной операции.

Устанавливается в единицу при выполнении недопустимой стековой (в этом случае устанавливается также флаг SF) или арифметической операции. В последнем случае могут быть установлены также флаги DE, ZE, OE, UE или PE.

DE (бит 1) — флаг денормализованного операнда.

ZE (бит 2) — флаг деления на ноль.

OE (бит 3) — флаг переполнения порядка.

UE (бит 4) — флаг антипереполнения, или исчезновения порядка.

PE (бит 5) — флаг неточного результата.

SF (бит 6) — флаг стековой ошибки.

Также по результатам операции выставляется флаг суммарной ошибки, которому не соответствует ни одно из исключений.

ES (бит 7) — флаг суммарной ошибки (Error Summary Status). Он равен единице, если возникает хотя бы одно незамаскированное исключение.

В некоторых источниках говорится, что ES равен единице в том случае, когда в разрядах 0...6 есть хотя бы одна единица [27]. Это в общем случае неверно. Если какое-то исключение замаскировано, ES не дублирует состояние соответствующего флага.

В частности, в C++ деление на ноль не должно приводить к прерыванию работы программы, поэтому соответствующее исключение при настройке сопроцессора стартовым кодом маскируется.

Соответственно, при попытке деления единицы на ноль, как можно убедиться при помощи отладчика, результат принимает специальное значение (inf, то есть $+\infty$, если делителем был $+0$, или $-inf = -\infty$, если единица делилась на -0), устанавливается флаг ZE, но флаг ES не устанавливается.

3.5. Флаги

Мечтой увенчанный язык
Плохой товарищ, где нет чисел,
К числа жезлу наш ум привык.

В. Хлебников. Двух юных слышу разговор...

Во время выполнения многих команд формируется не только результат в виде числа, но и те или иные признаки результата (в частности, корректен ли он) — флаги состояния. Флаг занимает один бит и считается установленным, когда он равен 1, и сброшенным, когда равен 0.

В частности, как было сказано в разделе 2.5, при сложении и вычитании целых беззнаковых чисел ограниченной разрядности может образоваться бит переноса/заёма из старшего разряда, который сохраняется процессором в особой ячейке — флаге переноса CF. При сложении и вычитании знаковых чисел формируется флаг переполнения OF. Как CF, так и OF являются флагами состояния.

Аналогично флагам состояния, однобитовые переменные, не отражающие признаков результата последней операции, но влияющие на выполнение некоторых команд, называются управляющими флагами. Некоторые флаги состояния или управляющие флаги доступны только операционной системе и, соответственно, называются системными.

Флаги и некоторые системные переменные часто объединяются в специальный регистр — регистр флагов. Процессоры семейства x86 исторически имеют два регистра флагов — собственно регистр флагов $flags$, связанный с командами основного набора и слово состояния FPU sw, связанное с командами математического сопроцессора FPU.

3.5.1. Флаги основного процессора

Я посвящён. Я принял взгляд извне.
Так зеркало, уснувшее на дне,
В себя приемлет отблеск ледяной...

С. А. Калугин. Rosarium. Венок сонетов. Сонет 9

Процессоры семейства x86 объединяют ячейку CF и подобные ей биты, показывающие те или иные свойства последней целочисленной арифметической операции — флаги состояния — в специальный регистр флагов $flags$ (таблица 3.1).

Кроме флагов состояния, регистр флагов включает один бит, не отражающий выполнение последней операции, но влияющий на выполнение некоторых команд (управляющий флаг направления DF), а также несколько битов, недоступных прикладным программам (системные флаги) [18, 75, 81]. Часть битов зарезервиро-

вана и не используется сейчас как флаги (зарезервированный бит может иметь как произвольное, так и фиксированное значение).

Доступные прикладным программам флаги состояния в основном сосредоточены в младших восьми разрядах $flags$, поэтому многие команды сохранения/восстановления регистра флагов оперируют только с младшим байтом. Старшие восемь бит содержат один флаг состояния OF, управляющий флаг DF и несколько системных. В 32-битном регистре $eflags$ в старших шестнадцати битах добавлено ещё шесть системных флагов; старшие тридцать два бита 64-битного $rflags$ не используются.

Регистр флагов $flags$

Таблица 3.1

			$flags$	
0	CF	Carry Flag	Флаг переноса (беззнакового переполнения)	Состояние
1	1	—	Зарезервирован	
2	PF	Parity Flag	Флаг чётности	Состояние
3	0	—	Зарезервирован	
4	AF	Auxiliary Carry Flag	Флаг вспомогательного переноса	Состояние
5	0	—	Зарезервирован	
6	ZF	Zero Flag	Флаг нуля	Состояние
7	SF	Sign Flag	Флаг знака	Состояние
8	TF	Trap Flag	Флаг трассировки	Системный
9	IF	Interrupt Enable Flag	Флаг разрешения прерываний	Системный
10	DF	Direction Flag	Флаг направления	Управляющий
11	OF	Overflow Flag	Флаг знакового переполнения	Состояние
12–13	IOPL	I/O Privilege Level	Уровень приоритета ввода-вывода	Системный
14	NT	Nested Task	Флаг вложенности задач	Системный
15	0	—	Зарезервирован	
			$eflags$	
16	RF	Resume Flag	Флаг возобновления	Системный
17	VM	Virtual-8086 Mode	Режим виртуального процессора 8086	Системный
18	AC	Alignment Check	Проверка выравнивания	Системный
19	VIF	Virtual Interrupt Flag	Виртуальный флаг разрешения прерывания	Системный
20	VIP	Virtual Interrupt Pending	Ожидающее виртуальное прерывание	Системный
21	ID	ID Flag	Проверка на доступность инструкции CPUID	Системный
22–31		—	Зарезервированы	

Регистр $flags$ не может быть явно указан как операнд команды, но является неявным результатом большинства арифметических команд и неявным операндом условных команд.

Флаги состояния

Флаги состояния отображают результаты целочисленных арифметических операций (сложения и вычитания; ограниченно умножения и поразрядных логических операций и пр.); этими флагами являются биты 0, 2, 4, 6, 7 и 11 регистра $flags$.

CF (бит 0) Флаг переноса (Carry Flag = CF), также флаг беззнакового переполнения. Устанавливается, если происходит перенос из старшего разряда результата за пределы разрядной сетки при сложении или заём в старший разряд из несуществующего (выходящего за пределы операнда, воображаемого) разряда при вычитании, таким образом, этот флаг показывает переполнение при выполнении беззнаковых арифметических операций.

Флаг CF часто используется и для других целей, тогда его значение не связано с беззнаковым переполнением. Так, этот бит используется командами сдвига — именно в него выдвигается «лишний» бит, командами извлечения бита — для хранения извлечённого значения и многими другими.

PF (бит 2) Флаг чётности (Parity Flag = PF). Устанавливается, если младший байт результата команды содержит чётное число единиц, иначе — сбрасывается.

Флаг чётности использовался для подсчёта контрольных сумм.

AF (бит 4) Флаг вспомогательного переноса (Auxiliary Carry Flag = AF), также используется название «флаг коррекции» (Adjust Flag = AF). Устанавливается, если арифметическая операция производит перенос (заём) из младшей тетрады младшего байта, т. е. из бита 3 в старшую тетраду при сложении (вычитании). Используется только для двоично-десятичной (BCD — Binary-Coded Decimal) арифметики, которая оперирует исключительно младшими байтами.

ZF (бит 6) Флаг нуля (Zero Flag = ZF). Устанавливается, если результат операции — нуль, иначе — сбрасывается.

SF (бит 7) Флаг знака (Sign Flag = SF). Всегда равен значению старшего бита результата. Этот бит интерпретируется как знаковый в некоторых арифметических операциях (0/1 — число положительное/отрицательное).

OF (бит 11) Флаг знакового переполнения (Overflow Flag = OF). Устанавливается, если при знаковой интерпретации результат операции не помещается в операнд (слишком большое положительное или слишком маленькое для отрицательных знаковых чисел); иначе — сбрасывается. При сложении этот флаг устанавливается в 1, если происходит перенос в старший бит и нет переноса из старшего бита (то

есть сумма положительных чисел даёт результат, интерпретируемый как отрицательный), или имеется перенос из старшего бита, но отсутствует перенос в него (сумма отрицательных чисел положительна); в противном случае, флаг OF устанавливается в 0. При вычитании он устанавливается в 1, когда возникает заём из старшего бита, но заём в старший бит отсутствует, либо имеется заём в старший бит, но отсутствует заём из него.

Флаг переполнения сигнализирует о потере старшего бита результата в связи с переполнением разрядной сетки при работе со знаковыми числами. Таким образом, если при вычитании $OF = 1$, то старший (знаковый) бит результата, а также флаг SF, равен не истинному знаку результата, а его инверсии.

Знаковые и беззнаковые команды Флаги состояния используются командами целочисленной арифметики, использующимися для вычислений трёх типов — знаковых, беззнаковых и (в 32-битном режиме) двоично-десятичных BCD, командами битовых сдвигов а также командами условного перехода (ветвления) и условного присваивания.

Устанавливаются флаги состояния по результатам выполнения последней команды. Влияние различных команд на флаги различается, и этот момент желательно уточнять в документации.

В частности, при выполнении операций сложения или вычитания все флаги состояния получают определённые значения. Индикатором переполнения в этом случае является:

- для знаковой арифметики — флаг OF,
- для беззнаковой арифметики — флаг CF.
- для BCD-арифметики — флаг AF.

Так как беззнаковые и представленные в дополнительном коде знаковые числа складываются с помощью одного и того же сумматора и одной командой, этот сумматор на всякий случай формирует при сложении и вычитании и OF, и CF, и остальные флаги состояния. Выбор для анализа того флага, который соответствует реальному типу операндов — ответственность программиста.

3.5.2. Флаги FPU

Я повторяю, говорят иное,
Я странствую, как остаюсь в покое,
Забыта цель и потому права.

С. А. Калугин. Rosarium. Венок сонетов. Сонет 14

Математический сопроцессор FPU включает собственный регистр флагов — слово состояния sw (раздел 3.4.2). Старший байт sw может быть загружен в младший байт флагов основного процессора. Чаще всего для этого используются коман-

ды `fnstsw %ax` (выгрузка sw в ax) и `sahf` (загрузка ah — старшего байта ax — в $flags$).

В таблице 3.2 представлено краткое описание структуры слова состояния FPU sw (слева), а также соответствие старшего байта sw и младшего байта регистра флагов основного процессора $flags$ (справа).

Загрузка состояния FPU в регистр флагов

Таблица 3.2

sw			$flags$, fnstsw + sahf		
0	IE	Недействительная операция			
1	DE	Денормализованный операнд			
2	ZE	Деление на ноль			
3	OE	Переполнение			
4	UE	Антипереполнение			
5	PE	Неточный результат			
6	SF	Стековая ошибка			
7	ES	Бит суммарной ошибки			
8	C0		0	CF	Carry Flag
9	C1		игнорируется		
10	C2		2	PF	Parity Flag
11			игнорируется		
12	TOP	Указатель вершины стека сопроцессора	4	AF	Auxiliary Carry Flag
13			игнорируется		
14	C3		6	ZF	Zero Flag
15	B	Дублирует ES	7	SF	Sign Flag

Некоторые устаревшие команды сравнения вещественных чисел помещают признак отрицательности в бит $C0$ слова состояния sw, признак несравнимости — в $C2$, признак нуля — в $C3$ (более современные команды сравнения помещают результаты напрямую в биты CF, PF, ZF регистра $flags$). При загрузке старшего байта sw во $flags$ $C0$ помещается во флаг беззнакового переполнения CF, признак нуля $C3$ — в аналогичный ему по смыслу ZF, а $C2$ — во флаг чётности PF. Другие флаги младшего байта $flags$ получают фактически неопределённое значение.

Не имеющие аналогов среди флагов CPU признаки исключительных ситуаций FPU (младший байт sw) не загружаются в регистр $flags$.

Биты $C0, C1, C2, C3$ слова состояния sw используются не только командами сравнения, но и арифметическими командами. В отличие от команд основного набора, арифметические команды FPU помещают в эти биты не сведения об отрицательном или нулевом результате, а другие признаки.

3.6. Структура команды и методы адресации

> Тот ли идёт прямо по дороге, кто ходит потупив лице своё?
> Или тот на прямом пути, кто ходит, держа себя прямо?
>
> *Коран. 67.22*

Набор команд процессоров семейства x86 имеет тип CISC. Он создавался в условиях жёсткой экономии памяти, так что команды имеют максимально компактную (и, соответственно, сложную для декодирования и понимания) структуру и используют разнообразные методы адресации операндов.

Необходимость программирования в машинных кодах возникает крайне редко, но знание формата команды помогает лучше представлять себе возможности и ограничения архитектуры.

3.6.1. Методы адресации

> Я, конечно, не в курсе, но знаю одно мурло, которое знает одно чучело, которое знает одного обормота, который может что-то знать...
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Здесь вам не причинят никакого вреда*

Адрес операнда в машинной команде может быть задан одним из следующих способов [53]. Они называются методами адресации операндов.

1. **Неявная** адресация. Местоположение операнда фиксировано и определяется кодом операции.
2. **Непосредственная** адресация. Операнд — константа, которая включается непосредственно в команду.
3. **Прямая абсолютная** (прямая) адресация. Операнд — переменная в памяти по фиксированному адресу (глобальная или статическая). Этот адрес включается непосредственно в команду.
4. **Прямая относительная** адресация. В команде содержится смещение, которое прибавляется к значению указателя команд ip.
   Этот режим используется в командах передачи управления и позволяет загружать код в память по произвольному адресу без нарушения корректности переходов.
   64-битное расширение x86 позволяет использовать прямую относительную адресацию также и для данных.
5. **Регистровая** адресация. Операнд находится в регистре общего назначения. В команду включается номер этого регистра.
6. **Косвенно-регистровая** (косвенная) адресация. Операнд — переменная в памяти и её адрес находится в регистре (регистрах) общего назначения.

Иногда выделяют следующие виды косвенной адресации:

- базовая адресация — адрес операнда в регистре (базовом регистре, базе);
- базовая адресация со смещением — адрес операнда вычисляется как сумма базового регистра и константы (смещения);
- базово-индексная адресация — адрес операнда вычисляется как сумма двух регистров — базового регистра и индексного;
- базово-индексная адресация со смещением — адрес операнда вычисляется как сумма двух регистров и константы.

Косвенная адресация x86 (таблица 3.3) охватывает все перечисленные варианта.

Если необходимо обработать значение, адрес которого получается более сложным образом (в частности, переменная в памяти, указатель на которую также находится в памяти), этот адрес надо вычислить отдельно и поместить в регистр.

3.6.2. Структура команды

Наше знание — сила и оружие.

В. В. Маяковский. Владимир Ильич Ленин

Команды процессоров семейства x86 имеют переменную длину. Структура команды показана на рис. 3.12.

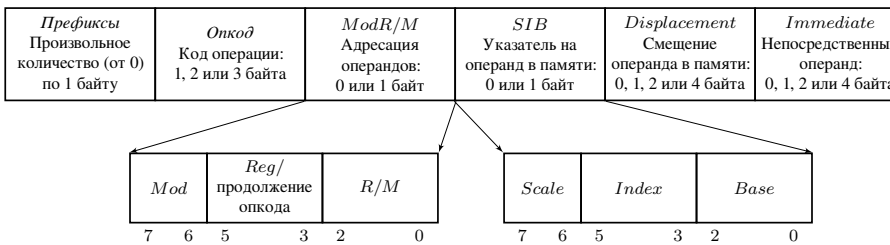

Рис. 3.12. Структура команды в архитектуре x86

Все поля, кроме кода операции, необязательны [17, 36].

Команда может предваряться одним или несколькими префиксами, изменяющими её поведение. Из префиксов x86 следует отметить префикс изменения размера операнда `0x66` и префикс изменения размера адреса `0x67`. Для 32-битного режима (и его 64-битного расширения) они уменьшают разрядность операнда или адреса соответственно до 16 бит, для 16-битного — повышают до 32. Восьмибитные варианты команд, как правило, представлены отдельными опкодами.

Далее идёт код операции (опкод), занимающий один, два или три байта (и, может быть, ещё три бита в байте $Mod\ R/M$). Следующий байт, $Mod\ R/M$, согласно [17], задаёт адресацию операндов. За ним следует необязательный байт SIB, уточняющий расположение операнда в памяти, если такой есть и для него

используется косвенная базово-индексная адресация. Каждый из байтов $Mod\ R/M$ и SIB состоит из трёх полей.

Поле $Displacement$ содержит смещение адреса при косвенной адресации. Оно трактуется как знаковое 32-битное (при использовании понижающего разрядность адреса префикса 0x67 — 16-битное) или восьмибитное число.

Поле $Immediate$ — непосредственное значение («магическое число», включённое непосредственно в команду). Оно присутствует, если опкод соответствует операции с непосредственным операндом.

Опкод присутствует в команде всегда; наличие или отсутствие полей $Mod\ R/M$ и $Immediate$ задаётся опкодом; наличие или отсутствие полей SIB и $Displacement$ задаётся значением полей байта $Mod\ R/M$, как указано в таблице 3.3 (в частности, при отсутствии $Mod\ R/M$ отсутствуют также SIB и $Displacement$).

3.6.3. Адресация операндов команды x86

Это не костыль — это уже экзоскелет.

Программистский фольклор

Количество и адресация операндов в системе команд x86 определяется совокупностью множества полей команды:

- наличие, количество и расположение *неявных* операндов полностью определяется опкодом;
- наличие *непосредственного* операнда (присутствие поля $Immediate$ в команде) определяется опкодом; значение — значением поля $Immediate$;
- наличие ещё одного или двух операндов в регистрах или памяти (присутствие байта $Mod\ R/M$ в команде) определяется опкодом; их конкретное расположение — значениями $Mod\ R/M$, SIB и $Displacement$.

Непосредственный операнд в $Immediate$. Поле $Immediate$ (однобайтовое $Imm8$, двухбайтовое $Imm16$ или четырёхбайтовое $Imm32$) может присутствовать в любой команде. В 32-битном режиме максимальная разрядность $Immediate$ равна 32 для всех команд. В 64-битном — также 32 для всех команд, кроме опкода `B8` (команды пересылки непосредственного операнда в регистр) в сочетании с единичным $REX.W$ (что повышает разрядность регистра-приёмника до 64). В документации Intel эта форма команды обозначается мнемоникой `mov`, как и другие варианты пересылки значения. Синтаксис AT&T выделяет форму с восьмибайтовым $Imm64$ как мнемонику `movabs`.

Некоторые команды расширения AVX трактуют $Imm8$ как номер дополнительного операнда-регистра; но для большинства команд поле $Immediate$ любого размера — это непосредственный операнд (может быть только источником, так как неизменяем).

Единственный операнд-регистр в опкоде. Для самых компактных команд номер единственного операнда-регистра может быть указан внутри опкода (байт $Mod\ R/M$ отсутствует). Так, тот вариант команды `mov`, который записывает непосредственное значение в регистр, состоит из однобайтового опкода и поля $Immediate$; при этом собственно код операции занимает пять старших бит опкода, а последние три бита задают регистр-приёмник.

Два операнда в Reg и R/M. Если опкодом задаётся использование двух операндов в памяти или регистре — эти два операнда адресуются полями Reg и R/M байта $ModR/M$:

- поле Reg содержит трёхбитовый номер (при наличии префикса REX — младшие три бита четырёхбитового номера) операнда-регистра;
- поле R/M в зависимости от поля Mod может как содержать номер второго операнда-регистра, так и определять адрес операнда в памяти, как показано ниже в таблице 3.3.

При этом, если один из операндов команды — регистр (поле Reg) а другой в памяти (поле R/M), то для некоторых команд операнд R/M может быть как источником, так и приёмником, что определяет специальный бит опкода — бит направления (direction bit). Бит направления присутствует не во всех опкодах, и часто в памяти может располагаться только операнд-источник.

Единственный операнд в R/M. Если опкодом задаётся использование только одного операнда в памяти или регистре (при этом у команды может быть и второй операнд — непосредственный) — он адресуется полями Mod и R/M в соответствии с таблицей 3.3, а в освободившееся поле Reg байта $Mod\ R/M$ может быть записана часть опкода.

В частности, однобайтовый опкод `FF`, требующий байта $ModR/M$ (в зависимости от значений Mod и R/M также возможны SIB и $Displacement$) соответствует, в зависимости от поля Reg, четырём различным однооперандным командам: `inc`, `dec`, `call` и `push`. Таким образом, полный код операции в этом случае занимает не восемь, а одиннадцать бит и записывается в двух полях.

Соответственно, у команды описанной выше структуры может быть **от нуля до трёх явных операндов:**

- в поле $Immediate$ — непосредственный;
- в поле Reg байта $ModR/M$ — регистр;
- в поле R/M байта $ModR/M$ (в сочетании с полем Mod и, при необходимости, SIB и $Displacement$) — *регистр или адрес в памяти.*

Все команды, кроме `lea`, получив адрес в памяти в поле R/M, обращаются к *значению* в памяти по этому адресу (разыменовывают его). Команда `lea` — вычисляет адрес, не разыменовывая, и записывает в регистр-приёмник.

Адресация операнда в памяти (R/M, SIB и $Displacement$)

При $Mod = 11$ поле R/M — номер операнда-регистра. Остальные три возможных значения двухбитового поля Mod соответствуют косвенной адресации, то есть операнд находится в памяти по некоторому адресу (таблица 3.3).

Адресация операнда при помощи полей Mod и R/M

Таблица 3.3

Внимание! В столбце «Операнд» под $Base$ и $Index$ понимаются *значения,* хранящиеся в базовом и индексном регистрах; в столбцах R/M и SIB — *номера* соответствующих регистров

№ п/п	Операнд	Mod	R/M	SIB	$Displacement$
1	$Reg2$	11	$Reg2$	—	—
2	$*\left(Base + Disp8\right)$	01	$Base \neq 100$	—	$Disp8$
3	$*\left(Base + Disp8\right)$		100	$(Scale,\ 100,\ Base)$	
4	$*\left(Base + 2^{Scale} \cdot Index + Disp8\right)$		100	$(Scale, Index, Base)$ $\not\in 100$	
5	$*\left(Base + Disp32\right)$	10	$Base \neq 100$	—	$Disp32$
6	$*\left(Base + Disp32\right)$		100	$(Scale,\ 100,\ Base)$	
7	$*\left(Base + 2^{Scale} \cdot Index + Disp32\right)$		100	$(Scale, Index, Base)$ $\not\in 100$	
8	$*\left(Base\right)$	00	$Base \notin \{100, 101\}$	—	—
9	$*\left(Base\right)$		100	$(Scale,\ 100,\ Base)$ $\not\in 101$	
10	$*\left(Base + 2^{Scale} \cdot Index\right)$		100	$(Scale, Index, Base)$ $\not\in 100$ $\not\in 101$	
11	$*\left(2^{Scale} \cdot Index + Disp32\right)$		100	$(Scale, Index,\ 101)$ $\not\in 100$	$Disp32$
12	$*\left(Disp32\right)$		100	$(Scale,\ 100,\ 101)$	
13	зависит от разрядности режима 32-битный: $*\left(Disp32\right)$ 64-битный: $*\left(rip + Disp32\right)$		101	—	

Этот адрес в общем случае может включать до четырёх компонент:

$$\text{Адрес} = Base + 2^{Scale} \cdot Index + Displacement \tag{3.1}$$

где масштаб $Scale \in [0, 3]$ — константа, $Base$ и $Index$ — регистры, $Displacement$ — 8-битное ($Disp8$, строки 2–4) или 32-битное ($Disp32$, строки 5–7 и 11–13) знаковое число.

При этом, как видно из таблицы 3.3, в формуле (3.1) могут отсутствовать:
- слагаемое $2^{Scale} \cdot Index$ — при отсутствии байта SIB вообще (строки 2, 5, 8) или если $SIB.Index = 100$ (строки 3, 6, 10);
- слагаемое $Base$ — строка 11;
- слагаемое $Displacement$ — как вместе с полем $Displacement$ (строки 8 и 10), так и при наличии поля $Displacement$ ($Disp8$ или $Disp32$), равного нулю (обычно для экономии памяти это $Disp8$).

Также при $SIB.Scale = 0$ можно считать отсутствующим множитель $2^{Scale} = 1$. Таким образом, каждая из компонент формулы (3.1) может быть опущена.

В качестве базовых можно использовать любые регистры A, B, C, D, si, di, bp (а в 64-битном режиме и $r8{-}r15$) необходимой разрядности, включая регистры с номерами 100 и 101.

Индексным регистром может быть регистр, кроме регистра с номером 100, то есть указателя стека sp (а в 64-битном режиме — ещё кроме $r12$ с номером 1100, который тоже соответствует $SIB.Index = 100$).

При вычислении адреса значение $Displacement$ расширяется до размера адреса (64 или 32 бита) как знаковое.

Разрядность поля $Displacement$ в 64-битном режиме не повышается до 64 бит.

Прямая адресация и обращение к статическим переменным в памяти)

Прямая абсолютная адресация в x86 является частным случаем косвенной (включается только $Displacement$) и в 32-битном режиме ей соответствуют строки 12 и 13 таблицы 3.3, в 64-битном режиме — только строка 12.

В 32-битном режиме прямая абсолютная адресация — единственно возможный способ обращения к статическим (имеющим постоянный адрес) переменным в памяти.

Прямая относительная адресация (относительно указателя команды ip) в 32-битном режиме недоступна в явном виде. В 64-битном режиме ей соответствует строка 13 таблицы 3.3.

В 64-битном режиме к фиксированному адресу можно обратиться, только указав специальные значения байта SIB, а при $R/M = 101$ используется адресация относительно счётчика команд ip (в 64-битном режиме — rip) [3]:

$$\text{Адрес} = \begin{cases} ip + Displacement, & R/M = 101 \\ Displacement, & R/M = 100, Base = 101, Index = 100 \end{cases} \tag{3.2}$$

Таким образом, хотя 64-битный указатель команд rip по-прежнему не является регистром общего назначения и не имеет собственного номера, он может быть базовым при $Mod = 00$ без байта SIB.

Адресация относительно ip используется для решения двух задач:

– получение кода библиотек, работоспособность которого не зависит от адреса библиотеки в памяти (в 32-битном режиме эта задача решалась либо вручную, либо корректировкой фиксированных адресов при загрузке [50]);
– обращение к переменным по произвольному шестидесятичетырёхразрядному адресу (поле смещения в 64-битном режиме осталось 32-битным [61], так что прямая адресация позволяет обратиться только к адресам в пределах младших четырёх гигабайт).

Хотя в 64-битном режиме всё ещё возможна и прямая абсолютная адресация (строка 12 таблицы 3.3), рекомендуемым способом обращения к статическим переменным в памяти является прямая относительная адресация — **адресация относительно указателя команды (rip-relative).**

Неявно прямая относительная адресация реализуется так называемыми командами ближнего перехода, которые трактуют операнд как смещение относительно ip, но само это смещение адресуется описанными выше средствами. Также для адресов команд доступна и прямая абсолютная адресация (дальние переходы). Ближние и дальние переходы соответствуют разным опкодам.

3.6.4. Разрядность операндов

> В ней есть одна странная черта — снаружи, внешне эта техника производит недоделанное, временное впечатление.
>
> *В. В. Маяковский. Моё открытие Америки*

Разрядность операндов в регистрах и памяти

В 32-битном режиме размер операнда по умолчанию — 32 бита. Исключением являются восьмибитные команды, размер операнда-данного которых — 8 бит независимо от режима (16-, 32- или 64-битного) и не изменяется префиксами.

Для большинства команд в 64-битном режиме размер операнда по умолчанию — также 32 бита. Исключением являются восьмибитные команды, а также операнды-адреса и стековое слово, используемые перечисленными ниже группами команд. Разрядность операндов может быть понижена до 16 бит соответствующим префиксом или повышена до 64 префиксом REX с единичным третьим битом $REX.W$ [1, 17].

В 64-битном режиме есть две группы команд, которые по умолчанию (без указания префикса REX) используют 64-битные операнды: это команды, работающие с указателями (условные и безусловные переходы) и команды, неявно использующие указатель стека (по умолчанию это rsp). Команды вызова и возврата из функций относятся к обеим группам, так что они по умолчанию используют 64-битные адреса и 64-битный указатель стека rsp. Разрядность операндов этих ко-

манд может быть понижена с 64 бит до 16 указанием соответствующего префикса, но способа понизить её до 32 бит не существует [3].

Разрядность непосредственных операндов и смещения

Размер полей $Immediate$ (кроме команды пересылки непосредственного значения в регистр) и $Displacement$ в 64-битном режиме не повышается до 64 бит даже при использовании префикса REX.

Таким образом, непосредственные операнды занимают 1, 2 или 4 байта. Если непосредственный операнд (обычно 32-битный) присутствует в 64-битной команде, он расширяется до 64 бит во время исполнения команды.

Единственная команда, включающая непосредственный операнд размером 8 байт — команда пересылки непосредственного операнда в регистр в сочетании с единичным $REX.W$ (что повышает разрядность регистра-приёмника до 64). В документации Intel эта форма команды обозначается мнемоникой `mov`, как и другие варианты пересылки значения. Синтаксис AT&T выделяет форму с 64-битным непосредственным операндом как мнемонику `movabs`.

3.6.5. Регистры в 32-битном и 64-битном режимах

> В последний момент Мари отдавала команду «Двоись!»,
> и близняшки разбегались в разные стороны.
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Здесь вам не причинят никакого вреда*

Все поля в команде, содержащие номер регистра, трёхбитовые. Соответственно, без дополнения формата команды (в 32-битном режиме) адресуемы не более восьми регистров. В 64-битном режиме к номеру регистра добавляется ещё один бит, хранящийся вне команды (в префиксе REX), за счёт чего количество адресуемых регистров удваивается.

Номера регистров в 32-битном режиме

В 32-битном режиме номера операндов-регистров задаются только трёхбитовыми полями байтов $Mod\ R/M$ и SIB. Каждому трёхбитному номеру соответствует определённый регистр общего назначения с учётом типа и разрядности команды (таблица 3.4).

В зависимости от разрядности команды и от того, входит ли команда в основной набор инструкций или в какое-либо из расширений, один и тот же номер адресует разные регистры. Из таблицы 3.4 видно, что в 32-битном режиме младшие байты регистров sp, bp, si, di не могут иметь имён, потому что соответствующие номера уже заняты $ah{-}dh$.

Номера (коды) регистров в 32-битном режиме

Таблица 3.4

Регистр					Код
32 бита	**16 бит**	**8 бит**	**Команда MMX**	**Команда XMM**	
eax	ax	al	$mm0$	$xmm0$	000
ecx	cx	cl	$mm1$	$xmm1$	001
edx	dx	dl	$mm2$	$xmm2$	010
ebx	bx	bl	$mm3$	$xmm3$	011
esp	sp	ah	$mm4$	$xmm4$	100
ebp	bp	ch	$mm5$	$xmm5$	101
esi	si	dh	$mm6$	$xmm6$	110
edi	di	bh	$mm7$	$xmm7$	111

Расширение регистров в 64-битном режиме

В 64-битном режиме между историческими префиксами и опкодом может находиться специальный однобайтовый префикс расширения регистров REX (рис. 3.13). Его младшие три бита (биты 0-2, обозначаемые в документации как B, X, R) используются для увеличения разрядности номеров регистров, следующий (третий) бит W определяет, используются ли 64-битные операнды ($REX.W = 1$) или разрядность операндов не изменяется ($REX.W = 0$). Старшие четыре бита равны 0100 и служат для идентификации. Таким образом, префиксы REX — байты в диапазоне `40` $-$ `4F`. Соответственно, команды с опкодами `40` $-$ `4F` (это однобайтовые формы команд `inc` и `dec`) в 64-битном режиме недоступны (при этом доступны двухбайтовые формы `inc` и `dec` с полем $ModR/M$, так что изменения в программы, написанные на ассемблере, вносить не нужно).

Бит 2 префикса REX ($REX.R$) добавляется к полю Reg байта $Mod\ R/M$, бит 1 ($REX.X$) — к полю $Index$ байта SIB, младший бит 0 ($REX.B$), в зависимости от используемой адресации — к полю R/M байта $Mod\ R/M$, полю $Base$ байта SIB или номеру регистра внутри опкода.

Таким образом, количество адресуемых регистров общего назначения возрастает до шестнадцати. Номера регистров $A-di$, указанные в таблице 3.4, соответствуют отсутствию префикса REX или нулю в соответствующем бите REX (в последнем случае с учётом REX получаем четырёхбитовые коды $0100-0111$). Единица в REX в сочетании с трёхбитовым полем в команде даёт номера регистров $1000-1111$, то есть $r8-r15$ (таблица 3.5).

Изменяя бит 3 префикса REX ($REX.W$), можно получить разрядность от 8 до 64 как для $r8-r15$, так и для $A-di$. При использовании восьмибитной команды

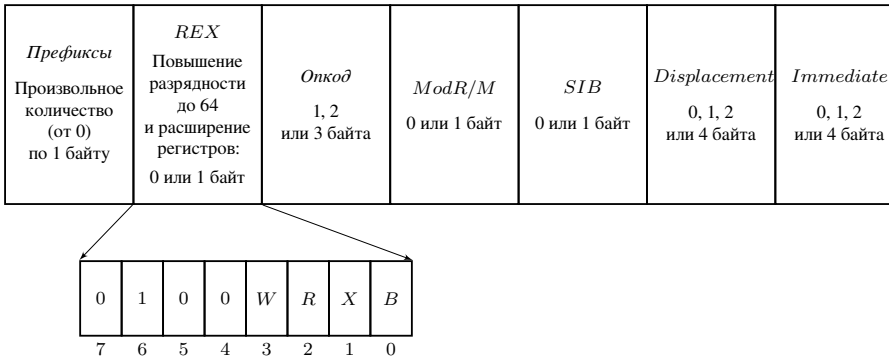

Рис. 3.13. Префикс расширения регистров REX в структуре команды x86-64

Номера (коды) регистров общего назначения при использовании REX

Таблица 3.5

Регистр				**Код**	**Регистр**				**Код**
64 бита	**32 бита**	**16 бит**	**8 бит**		**64 бита**	**32 бита**	**16 бит**	**8 бит**	
rax	eax	ax	al	0000	$r8$	$r8d$	$r8w$	$r8b$	1000
rcx	ecx	cx	cl	0001	$r9$	$r9d$	$r9w$	$r9b$	1001
rdx	edx	dx	dl	0010	$r10$	$r10d$	$r10w$	$r10b$	1010
rbx	ebx	bx	bl	0011	$r11$	$r11d$	$r11w$	$r11b$	1011
rsp	esp	sp	spl	0100	$r12$	$r12d$	$r12w$	$r12b$	1100
rbp	ebp	bp	bpl	0101	$r13$	$r13d$	$r13w$	$r13b$	1101
rsi	esi	si	sil	0110	$r14$	$r14d$	$r14w$	$r14b$	1110
rdi	edi	di	dil	0111	$r15$	$r15d$	$r15w$	$r15b$	1111

в сочетании с REX с нулевым третьим битом (то есть разрядность не изменяется и операнды занимают 8 бит) коды регистров $0100-0111$ описывают младшие байты регистров $sp-di$ — в документации и коде программы они обозначаются $spl-dil$. Таким образом, в 64-битном режиме доступны как $ah-dh$, так и $spl-dil$. При этом в одной и той же команде нельзя адресовать, например, ah и sil, так как для первого требуется обязательное отсутствие у команды префикса REX, а для второго — наличие REX с нулевым третьим битом.

REX — не единственный префикс расширения регистров. В частности, команды расширения AVX (YMM) Intel используют двух- или трёхбайтовый префикс VEX, одной из функций которого также является расширение номеров регистров ymm; расширение AVX512 (ZMM) — префикс $EVEX$. В расширении SSE5 (XOP) AMD также используется похожий, но при этом несовместимый с VEX префикс [4].

Контрольные вопросы

1. Какие вы знаете режимы работы процессора?
2. Какие вы знаете сегменты памяти?
3. Чем различается размещение в памяти локальных, глобальных и статических переменных?
4. Какие вы знаете регистры общего назначения x86?
5. Какие регистры используются в FPU для хранения вещественных данных?
6. Какие вы знаете флаги?
7. Какие методы адресации вы знаете?

Глава 4. Связь уровней абстракции

Мы выходим по приборам на великую глушь
Назад в Архангельск.

Б. Б. Гребенщиков. Назад в Архангельск

Современная вычислительная система включает шесть уровней абстракции, но только нижние четыре из них интерпретируются вычислительной машиной или операционной системой. Для трансляции программы с языка высокого уровня, в частности, C++, или даже с языка ассемблера в исполняемый файл, пригодный для запуска операционной системой, необходимы специализированные программные средства.

Более того, подобные средства должны обеспечивать не только прямую вертикальную связь соседних уровней, то есть компиляцию с языка на язык, но и «диагональные» связи — сборку исполняемого файла из множества фрагментов (модулей, функций), возможно, написанных на различных языках.

Универсальный способ объединения функций, написанных на различных языках — использование промежуточного (так называемого объектного) представления с последующей компоновкой модулей, содержащих эти функции, в единое целое. Так, в частности, из программы, написанной на языке Паскаль, можно вызвать функцию, описанную на C++, если они будут следовать одному соглашению о вызове.

Для соединения языка высокого уровня и языка ассемблера также используется механизм ассемблерных вставок в код. С помощью специальной конструкции ЯВУ можно вставить в код несколько команд ассемблера, не используя вызова и возврата из функции.

4.1. Компиляция

Если это дело наших рук,
то какая дверь перед нами не отворится?

В. В. Маяковский. Мистерия-буфф

В простейшем случае вертикальная связь уровней абстракции осуществляется через компиляцию — перевод программы с языка более высокого уровня на язык следующего уровня абстракции.

4.1.1. Инструменты разработки

> Средство труда есть вещь или комплекс вещей, которые человек помещает между собой и предметом труда, и которые служат для него в качестве проводника его воздействий на этот предмет.
>
> *К. Маркс. Капитал*

В настоящее время разработка программного обеспечения невозможна без вспомогательных программ — инструментов разработчика. Для перевода программы с языка высокого уровня, в частности, C++, или даже с языка ассемблера, в машинный код, необходима программа-компилятор, для получения исполняемого файла — компоновщик и т. д.

Компиляторы C++

Для платформы x86 разработано множество компиляторов C++. Большинство из них входит в состав той или иной коллекции. В подобные коллекции входят компиляторы с языков C и C++, часто ассемблер, а также компилятор с Фортрана и других ЯВУ. Некоторые коллекции включают, кроме компиляторов, и другие средства разработки, иногда даже специализированные отладчик и IDE.

Перечислим наиболее известные коллекции.

- **GNU Compiler Collection (GCC)** реализована более чем для 45 платформ, поддерживает большинство ОС (порт под Microsoft Windows исторически носит название **MinGW**), семь языков (в том числе C и C++, со строгим соблюдением стандартов) и распространяется под лицензией GNU GPL 3+, позволяющей как образовательную, так и коммерческую разработку (в том числе разработку приложений с закрытым исходным кодом).
- **TenDRA/Ten15** — первоначально британская оборонная разработка, сейчас поддерживает архитектуры x86, x86-64, IA-64 (Itanium), DEC Alpha; POSIX-совместимые ОС и распространяется под лицензией BSD, позволяющей любые виды разработки.
- **Portable C Compiler (PCC)** — ранний компилятор C, какое-то время поддерживавшийся в OpenBSD, в настоящее время x86, x86-64, Unix-подобные ОС, в том числе GNU/Linux, Microsoft Windows; лицензия BSD.
- **Intel C++ compiler** — x86, x86-64, IA-64, GNU/Linux, MacOS X, Microsoft Windows, коммерческая собственническая лицензия.
- **Oracle Solaris Studio** — x86, x86-64, SPARC; Solaris, OpenSolaris, GNU/Linux; собственническая лицензия. В настоящее время распространяется бесплатно.
- **Open Watcom** — DOS, OS/2 и Microsoft Windows; лицензия Sybase Open Watcom Public License version 1.0, неполная поддержка стандарта.

– **Microsoft Visual Studio** — x86, x86-64, IA-64 и .NET, только Microsoft Windows, коммерческая собственническая лицензия, грубые нарушения стандарта.

Коллекция GCC портирована на наибольшее количество платформ. В её состав входят, в частности, **gcc** — компилятор C и **g++** — компилятор C++, а также ассемблер **gas.**

Ассемблеры x86

Если синтаксис языка высокого уровня описан соответствующим стандартом, то синтаксис ассемблера не стандартизирован. Хотя набор мнемонических обозначения ассемблера определяется набором команд процессора, их символьное представление может существенно различаться. Кроме того, практически у каждого ассемблера уникальный набор директив и других синтаксических элементов, которые не транслируются непосредственно в машинные команды, но необходимы для корректной сборки программы.

Таким образом, фактически каждый ассемблер, предназначенный для архитектуры x86, обладает уникальным синтаксисом, несовместимым с остальными. При этом их можно разбить на две большие группы: синтаксис AT&T, традиционно используемый в Unix, но реализованный и для других операционных систем, и множество диалектов синтаксиса Intel.

– **GNU Assembler (GAS)** из коллекции GCC (лицензия GNU GPL 3+) используется на одном из этапов компиляции, поэтому реализован для всех поддерживаемых платформ. GAS использует для всех процессоров единообразный синтаксис (так называемый синтаксис AT&T).

Другие трансляторы поддерживают только архитектуру x86 и её шестидесятичетырёхбитный вариант x86-64.

– **Flat Assembler (FASM)** реализован для Unix-подобных операционных систем (GNU/Linux, OpenBSD и др.), FreeDOS и Microsoft Windows, распространяется по лицензии BSD. Несколько операционных систем написаны полностью на FASM — MenuetOS и KolibriOS.
– **NASM/Yasm** также реализован для Unix-подобных систем, FreeDOS и Microsoft Windows под лицензией BSD.
– **Turbo Assembler (TASM)/Lazy Assembler** — поддерживает FreeDOS и Microsoft Windows. Оригинальный Turbo Assembler имел два режима — режим совместимости с MASM и более удобный режим Ideal. Lazy Assembler использует синтаксис режима Ideal и при этом поддерживает современные наборы команд.
– **MASM** от Microsoft также поддерживает только FreeDOS и Microsoft Windows.

Они используют различные варианты (диалекты) синтаксиса Intel, предложенного разработчиком x86 и не используемого на неинтеловских процессорах.

Хотя все эти диалекты обычно объединяются термином «синтаксис Intel», они несовместимы между собой как из-за различных директив, так и из-за неоднозначности трактовки операндов. В частности, команда пересылки (её мнемоническое обозначение `mov` происходит от move — перемещать) `mov ecx, dword ptr [0xCCCCCCCC]` записана в соответствии с синтаксисом Intel (очевидный приёмник — регистр общего назначения ecx — указан первым, размер операнда-константы задан с помощью конструкции `dword ptr`, то есть равен 32 битам), но по-разному трактуется различными ассемблерами.

Так, MASM преобразует её в код `B9 CC CC CC CC`, который запишет в регистр ecx значение указателя, то есть константу `0xCCCCCCCC` (что в синтаксисе Intel также может быть записано как `mov ecx, 0xCCCCCCCC`). Для синтаксиса AT&T это действие записывается как `movl $0xCCCCCCCC, %ecx`, где суффикс `l` после имени команды означает разрядность операндов 32 бита ($long$), префикс `$` — непосредственное значение, а префикс `%` — имя регистра.

Другой популярный ассемблер с синтаксисом Intel, NASM, преобразует `mov ecx, dword ptr [0xCCCCCCCC]` в код `8B 0D CC CC CC CC`, который записывает в ecx значение из памяти по заданному указателю (для синтаксиса AT&T это соответствует команде `movl 0xCCCCCCCC, %ecx` — отсутствие префикса перед константой означает разыменование её как указателя).

GAS также поддерживает синтаксис Intel для архитектуры x86, но в данном пособии будет рассматриваться синтаксис AT&T как более наглядный и универсальный.

Интегрированные среды разработки

Интегрированные среды разработки (integrated development environment, IDE) включают редактор кода и множество инструментов, облегчающих разработку, в том числе интерфейс для запуска компилятора.

Набор файлов исходного кода, настроек и сценариев сборки объединяется в **проект.** Формат проекта различается для разных IDE. Один и тот же проект может быть собран с различными комплектами настроек. Такой комплект может называться целью или конфигурацией. Для каждого проекта IDE по умолчанию создаёт как минимум две цели сборки: отладочную (Debug) и лишённую отладочной информации (Release). Интерактивная отладка на уровне инструкций языка высокого уровня (в частности, точка останова на конкретном операторе ЯВУ) возможна только для отладочной сборки.

Большинство интегрированных сред может работать с различными компиляторами и отладчиками. Если на компьютере разработчика установлено несколько коллекций компиляторов, в настройках потребуется выбрать необходимый вариант. Многие среды могут поставляться как отдельно, так и комплекте с какой-либо коллекцией компиляторов и отладчиком. Некоторые среды, в частности, IDE

Visual Studio от Microsoft, поставляющаяся только с соответствующей коллекцией компиляторов, ограничены в функциональности и полностью поддерживают только одну коллекцию (хотя в последних версиях появилась частичная поддержка GCC). Соответственно, IDE Visual Studio непригодна для разработки на ассемблере с синтаксисом AT&T. Наиболее распространена IDE Qt Creator. Также для разработки с помощью GCC можно использовать IDE Code::Blocks или TheIDE.

Дизассемблер

Так как язык ассемблера близок к машинному коду, возможно преобразовать машинные команды в инструкции ассемблера. Такое преобразование не всегда однозначно. Соответствующие инструменты — дизассемблеры — широко применяются в Microsoft Windows для исследования программного обеспечения с закрытым исходным кодом.

В GNU/Linux дизассемблер используется в основном как компонент интерактивного отладчика, позволяющий работать с программой, собранной без отладочной информации.

4.1.2. Этапы компиляции

> Являясь уже продуктом, сам первоначальный сырой материал должен, однако, пройти ещё целый ряд различных процессов, в которых он в постоянно изменяющемся виде каждый раз снова функционирует как сырой материал вплоть до последнего процесса труда, из которого он выходит уже как готовое жизненное средство или готовое средство труда.
>
> *К. Маркс. Капитал*

Компиляция программы на языке C++ в исполняемый файл включает четыре этапа (рис. 4.1): препроцессинг, собственно компиляция (с C++ в ассемблерный код), ассемблирование и компоновка [55].

Некоторые компиляторы объединяют этапы компиляции и ассемблирования, преобразуя исходный код на языке высокого уровня, обработанный препроцессором, напрямую в объектный файл.

Компиляторы коллекции GCC позволяют выделить все четыре описанных выше этапа. Выполнить их все по порядку и получить исполняемый файл, соответствующий программе `main.cpp`, можно командой:

```
1 $ g++ main.cpp
```

Здесь и далее, знак доллара (`$`) обозначает стандартное приглашение к вводу команды в консоли (приглашение, оканчивающееся знаком `$`, традиционно используется в командных интерпретаторах Unix-подобных систем). Писать знак доллара не требуется. Регистр важен.

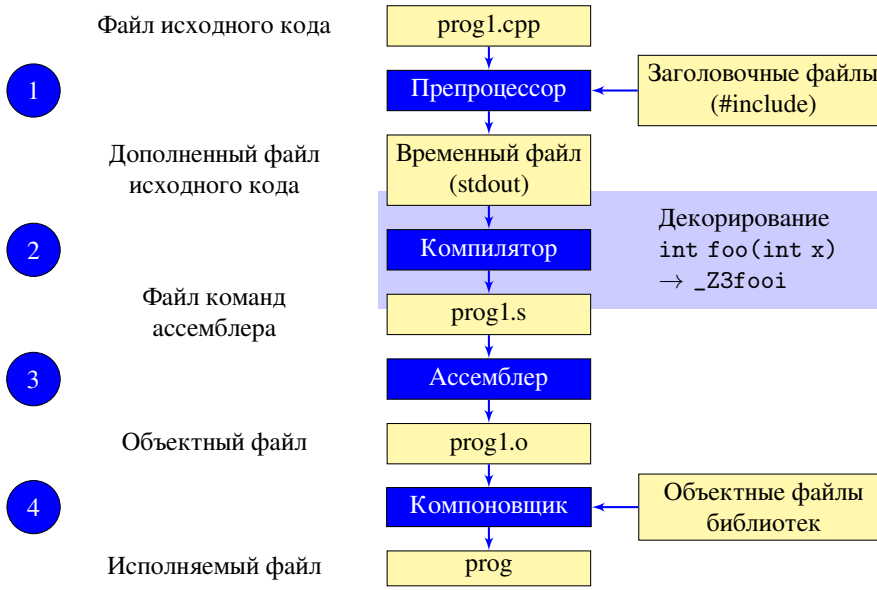

Рис. 4.1. Этапы компиляции программы на C++

Задавая дополнительные ключи, можно остановить компиляцию после какого-либо этапа. Рассмотрим их подробнее.

1. **Препроцессинг** (предобработка). Препроцессор копирует содержимое включённых директивой `#include` заголовочных файлов в исходный код модуля, раскрывает макросы и, в том числе, выполняет текстовые замены «констант», определённых с помощью директивы `#define`, на их значения, а также отрабатывает директивы условной компиляции, выбрасывая из кода те или иные фрагменты.

При использовании компилятора из коллекции GCC увидеть результат препроцессинга можно, воспользовавшись ключом `-E`. Результат будет выведен в стандартный поток вывода (в представленном примере перенаправлен в файл main.E).

```
1 $ g++ -E main.cpp > main.E
```

2. **Компиляция.** Код, обработанный препроцессором, транслируется компилятором в ассемблерный код для соответствующей платформы.

Для остановки компиляции после этого этапа для компилятора g++ следует воспользоваться ключом `-S`:

```
1 $ g++ -S main.cpp
```

На этапе компиляции выполняется **декорирование** имён функций; таким образом, если остановить ключом `-S` сборку после этого этапа, то в полученном

ассемблерном файле имена будут изменены компилятором. В декорированное имя C++-функции включается информация обо всех её параметрах (явных и неявных). Имена C-функций изменяются более предсказуемо, так как для них не поддерживается перегрузка (в большинстве случаев имена не изменяются; на некоторых платформах к ним может добавиться фиксированный префикс или суффикс).

Конкретный алгоритм декорирования зависит от компилятора, платформы и указанного соглашения о вызове. В статье Агнера Фога «Calling conventions for different C++ compilers and operating systems» [9] приведено, в числе прочего, описание алгоритмов декорирования наиболее популярных компиляторов. В частности, имена C-функций при компиляции gcc на платформах GNU/Linux и BSD не изменяются вообще. На 32-разрядной платформе Microsoft Windows имена C-функций при компиляции приобретают дополнительное ведущее подчёркивание (то есть `printf` преобразуется в `_printf`). Подробнее искажение имён на этапе компиляции рассматривается в разделе 6.2.6.

3. **Ассемблирование.** Ассемблерный код, созданный компилятором, транслируется в объектный код для соответствующей платформы. Останов компиляции файла после этапа ассемблирования обеспечивается ключом `-c`:

```
1 $ g++ -c main.cpp
```

При ассемблировании имена функций сохраняются.

4. **Компоновка** (линковка). Объектные файлы, созданные ассемблером, объединяются компоновщиком (линкером, редактором связей) в исполняемый файл.

На данном этапе компоновщик ищет реализации для всех внешних (`extern`) функций по именам. Соответственно, имена, которые в разных модулях носит одна и та же функция, на этапе компоновки должны совпадать.

Интегрированные среды разработки (IDE) выполняют все этапы автоматически.

4.1.3. Особенности GCC

> Дверь почти полностью состояла из маленьких дверок и окошек, на которых значилось «Для собак», «Для мелких собак», «Для кошек», «Для мышек», «Для сов», «Для жаворонков», «Для дятлов»...
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Личное дело Мергионы или Четыре чёртовы дюжины*

Рассмотрим расширения, распознаваемые компиляторами GCC, а также некоторые особенности их использования при сборке программы вручную. В частности, как было сказано выше, для остановки сборки после заданного этапа используются ключи командной строки (так, `-E` — останов после препроцессинга, `-S` — компиляции, `-c` — ассемблирования); для запуска сборки с нужного этапа — расширение файла.

Расширения файлов исходного кода

Чтобы начать сборку с определённого этапа, достаточно задать для файла расширение, соответствующее этому этапу. Вообще, компилятор — одна из немногих программ, которые учитывают расширение файла при его обработке [58].

Расширение `.s` соответствует ассемблерному файлу. Таким образом, команды `$ g++ main.s` и `$ gcc main.s` эквивалентны и выполняют ассемблирование и компоновку ассемблерного файла `main.s`, минуя этапы препроцессинга и компиляции с ЯВУ.

Расширение `.o` соответствует объектному файлу, так что команды `$ g++ main.o` и `$ gcc main.o` выполняют только компоновку файла `main.o`.

В случае, когда необходимо выполнить препроцессинг, ассемблирование и компоновку, выбросив только этап компиляции с ЯВУ (именно такая последовательность оптимальна при сборке модулей, вручную написанных на ассемблере), используется расширение `.S`.

```
1 $ g++ main.S
```

Большинство современных файловых систем чувствительны к регистру имён, а современные операционные системы, такие как GNU/Linux и BSD, различают регистр при обработке, так что имена `main.s` и `main.S` будут различаться.

Операционная система Microsoft Windows не различает регистра имён файлов (хотя наиболее часто используемая ею файловая система NTFS теоретически чувствительна к регистру), так что для файлов, требующих препроцессинга, используется расширение `.sx`. Компиляторы GCC трактуют расширение `.sx` аналогично `.S`.

Многие интегрированные среды разработки «не знают» расширений `.s` и `.sx`, так что их необходимо не только вручную добавить в проект, но и указать, что они должны компилироваться и компоноваться как в режиме отладочной сборки, так и в оптимизированном.

Изменение имени выходного файла

Исполняемый файл, полученный после компиляции и ассемблирования GCC, независимо от количества и имён файлов с исходным кодом по умолчанию будет называться `a.out` (assembler output).

Это имя можно изменить, используя ключ `-o`, после которого указывается желаемое имя выходного файла:

```
1 $ g++ main.cpp -o prog
```

Таким образом исполняемый файл, полученный после сборки main.cpp (отсутствие ключей остановки сборки соответствует выполнению всех этапов), получит имя `prog`.

Исполняемый файл в большинстве операционных систем не имеет расширения и отличается от неисполняемого правами доступа. При желании, используя ключ `-o`, можно задать для результирующего исполняемого файла любое имя с любым расширением.

Компиляция проекта, состоящего из нескольких модулей

При компиляции проекта, включающего несколько модулей, шаги препроцессинга, компиляции и ассемблирования повторяются для каждого файла исходного кода. Затем из полученных объектных файлов компоновщик собирает единый исполняемый файл (рис. 4.2).

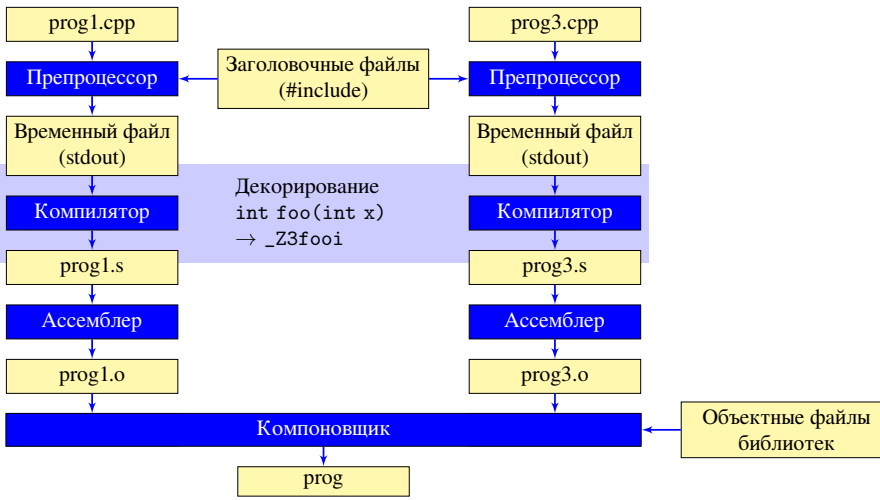

Рис. 4.2. Совместная компиляция нескольких модулей

Это можно выполнить одним запуском компилятора из коллекции GCC, указав в командной строке имена всех файлов исходного кода:

```
1 g++ -o prog prog1.cpp prog3.cpp
```

Если попытаться собрать каждый из модулей отдельно, мы получим ошибки компоновки (так как во всех модулях, кроме главного, отсутствует головная функция — $main()$, а в главном — нет функций, описанных в остальных).

Можно остановить сборку после этапа компиляции модулей:

```
1 g++ -c prog1.cpp
2 g++ -c prog3.cpp
```

Затем из полученных объектных файлов одним запуском компоновщика можно получить исполняемый файл:

```
g++ -o prog prog1.o prog3.o
```

Ручная сборка небольших проектов обычно выполняется одной командой, в интегрированных средах разработки этапы, как правило, разделяются.

Импорт и экспорт функций

Наиболее универсальным способом использования в одной программе нескольких языков программирования является статическая совместная компоновка модулей, написанных на разных языках.

При статической компоновке каждый модуль необходимо скомпилировать из соответствующего языка и ассемблировать, остановив сборку на стадии объектных файлов (напомним, что в GCC для этого используется ключ `-c`). Полученные объектные файлы собираются компоновщиком в единый исполняемый файл (рис. 4.3).

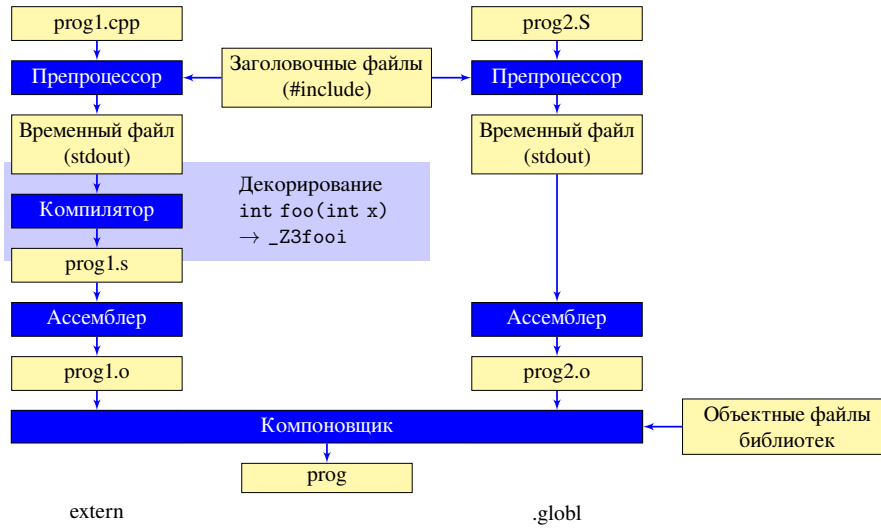

Рис. 4.3. Совместная компиляция модулей на разных языках

Сочетание модулей на языке высокого уровня и на ассемблере используется так часто, что компиляторы коллекции GCC корректно собирают подобный набор модулей одной командой сборки многомодульного проекта, как показано на рис. 4.3:

```
g++ prog1.cpp prog2.S
```

Останов сборки и компоновка отдельной командой в этом случае не нужны.

Интегрированные среды разработки, поддерживающие компиляторы коллекции GCC, также автоматически выполняют сборку проекта на языке высокого уровня, содержащего ассемблерные модули.

Необходимо отметить, что для корректной работы проекта с ассемблерными модулями необходимо соблюсти несколько условий, подробно рассмотренных в разделе 6.2. Так, чтобы функцию можно было использовать в других модулях, её необходимо сделать видимой для компоновщика. В C++ для этого служит спецификатор `extern`, в языке ассемблера GAS — директива `.globl`. Чтобы имена одной и той же функции на этапе компоновки были одинаковы во всех модулях, необходимо учесть декорирование имён (а также неотключаемое их искажение в некоторых версиях Microsoft Windows). И, наконец, чтобы функция корректно отработала на этапе выполнения программы, необходимо, чтобы её описание в одном модуле и вызов в другом следовали одному и тому же соглашению о вызове.

4.2. Препроцессор

Чрез горы, степь, моря, леса,
Вседневно ты по свету скачешь,
Волшебною ширинкой машешь
И производишь чудеса.

Г. Р. Державин. На счастие

Первая стадия компиляции программы на C/C++ — обработка исходного кода препроцессором. Препроцессор «не понимает» языков C, C++ или ассемблера и обрабатывает собственный язык — директивы препроцессора. Директива начинается с символа # и заканчивается переводом строки, в частности, `#define`, `#undef`, `#include`, `#if`, `#ifdef`, `#ifndef`, `#else`, `#elif`, `#endif`.

После завершения препроцессинга в тексте программы не остаётся ни директив препроцессора, ни имён определяемых ими макросов.

В настоящее время в программировании на языке C++ препроцессор используется в основном для двух задач — условной компиляции и копирования файла, содержащего заголовки функций, классов и т. п. в несколько файлов исходного кода. Также препроцессор поддерживает **макросы,** которые могут применяться как для обеспечения корректного решения описанных выше задач, так и самостоятельно.

Макросы представляют собой текстовую подстановку, выполняющуюся на этапе препроцессинга, и никак не связаны с особенностями используемого языка — C/C++ или ассемблера. Для того, чтобы отличать их от конструкций языка, принято

давать макросам имена, состоящие только из заглавных букв. Их возможности не ограничиваются использованием в условной компиляции.

Тем не менее использование макросов небезопасно и не должно (за исключением условной компиляции) применяться при программировании на высоком уровне.

4.2.1. Включение файла

Не в совокупности ищи единства,
но более — в единообразии разделения.

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

Включение файлов с заголовками выполняется директивой `#include`: запись `#include имя_файла` целиком копирует указанный файл на место, где была эта директива. Имя включаемого файла может содержать путь к нему и заключается в угловые скобки или кавычки. Если имя файла заключено в угловые скобки (`#include <iostream>`), файл должен располагаться в одной из папок со стандартными заголовочными файлами, если имя файла в кавычках (`#include "myheader.h"`) — он должен находиться в папке проекта.

В имени включаемого файла не должно быть комментариев (сочетание `/*` трактуется как маска имени файла, в частности, `"dir/*"` — все файлы в папке *dir*). Зато имя может включать макросы, что позволяет реализовать различные наборы включаемых файлов для различных версий или платформ.

Заголовочные файлы могут включаться как в файлы, содержащие определения функций, так и в другие заголовочные файлы. В первом случае возможна ситуация, когда в файл с определениями в итоге включается несколько копий одного и того же заголовочного файла. Для предотвращения многократного включения внутри заголовочного файла необходимо применять директивы условной компиляции, как показано в листинге 4.1.

Листинг 4.1. Защита от повторного включения

```
1 #ifndef THIS_UNIT_ALREADY_INCLUDED
2 #define THIS_UNIT_ALREADY_INCLUDED
3 ... // весь текст заголовочного файла
4 #endif
```

В актуальный стандарт C++ планировалось включить поддержку модулей, аналогичных модулям языка Паскаль. Это позволило бы отказаться как от использования директивы `#include`, так и от ручной защиты от многократного включения, но в окончательную редакцию C++17 модули не вошли.

4.2.2. Условная компиляция

И...
заколдованное место:
вдруг
проспект
обрывает разбег.

В. В. Маяковский. Хорошо!

Условная компиляция обеспечивается директивами `#if`, `#ifdef`, `#ifndef`, `#else`, `#elif`, `#endif`, обеспечивающими удаление части текста до начала этапа компиляции.

Директивы семейства `#if*` и `#elif` используют условие, которое не должно зависеть от кода C/C++ или ассемблера. Для этого используются **макросы препроцессора,** определяемые директивой `#define`.

Условие директивы `#if` может включать целочисленные литералы, арифметические операторы, макросы и специальный оператор препроцессора `defined`. Истинным считается ненулевое значение условия. Унарный оператор `defined(NAME)` может использоваться только в условиях препроцессора. С его помощью можно узнать, определён ли макрос с именем `NAME`. Для часто употребляемой конструкции `#if defined(NAME)` существует синоним `#ifdef NAME`, для `#if !defined(NAME)` — синоним `#ifndef NAME`.

В простейшем случае текст, расположенный от директивы `#if*` до `#endif` остаётся в коде после препроцессинга в том случае, когда условие истинно и исключается, если условие ложно. Подобная конструкция, в частности, используется для описания отладочных фрагментов которые не должны войти в окончательную сборку программы (листинг 4.2), а также в заголовочных файлах для защиты от повторного включения в один и тот же файл (листинг 4.1).

Листинг 4.2. Отладочный фрагмент

```
1 #ifdef DEBUG
2 ...  // включается, если определён макрос DEBUG
3 #endif
```

Если между директивой семейства `#if*` и `#endif` находится директива `#else` (листинг 4.3), то в том случае, когда условие истинно, остаётся фрагмент между `#if*` и `#else`, а фрагмент от `#else` до `#endif` удаляется, в случае, если условие ложно — наоборот.

Листинг 4.3. Выбор одного из фрагментов

```
1 #ifdef FLAG
2 ...  // включается, если макрос FLAG определён
3 #else
```

```
4 ...  // включается, если макрос FLAG не определён
5 #endif
```

Используя директиву `#elif`, можно организовать выбор из нескольких фрагментов. В окончательный вариант текста, который будет компилироваться, войдёт только один из фрагментов, расположенных между директивами `#if*` и соответствующей `#endif` и разделённых директивами `#elif` и `#else`.

4.2.3. Макросы

> Для лёгких, для мелких вещей такое перемещение можно и надо делать (да оно так и само делается) искусственно.
>
> *В. В. Маяковский. Как делать стихи*

Макрос определяется с помощью директивы `#define`. В простейшем случае за директивой следует имя определяемого макроса, а за ним до конца строки — текст, на который производится замена (значение или определение макроса). Имя макроса отделяется от директивы `#define` и значения пробельными символами.

Листинг 4.4. Определение макроса без параметров

```
1 #define THE_NUMBER 13
```

После определения макроса `THE_NUMBER` согласно листингу 4.4, приведённого в файле с исходным кодом (непосредственно в его тексте или в тексте включённого заголовочного файла) строка `THE_NUMBER` будет до конца файла с исходным кодом (либо до удаления определения с помощью директивы `#undef`) заменяться на строку `13`. Вхождения строки `THE_NUMBER`, находящиеся до определения этого макроса, останутся без изменений.

При использовании макроса без параметров в тексте его имя заменяется на значение без каких-либо изменений, то есть `int i = THE_NUMBER+1` будет заменяться на `int i = 13+1`. Имя макроса заменяется только в том случае, когда оно является целым словом (то есть отделено от других строк пробельными символами или знаками препинания), в частности, строка `THE_NUMBER_2` не будет заменена на `13_2`.

При этом заменяется любое вхождение макроса как целого слова, то есть, в частности, описание функции `int f(int THE_NUMBER)` будет заменено на `int f(int 13)`, что вызовет ошибку компиляции. В менее благоприятном случае сообщения об ошибке может и не быть. В частности, определение `#define true 0` не приведёт к сбою, но работа программы будет некорректной. Для предупреждения подобных ситуаций необходимо отделять имена макросов препроцессора от имён, используемых в программе. Обычно имена макросов записываются заглавными буквами и не должны быть слишком короткими (в частности, имя `N` с большей веро-

ятностью будет использовано в программе, чем `THE_NUMBER`, поэтому определение `#define N 13` не очень удачно).

Если после имени макроса в строке определения нет ничего, кроме, может быть, пробельных символов, такой макрос имеет пустое значение.

Листинг 4.5. Определение макроса с пустым значением

```
1 #define FLAG
```

Макросы с пустым значением обычно используются только в директивах условной компиляции `#ifdef` или `#ifndef`, которые проверяют не значение, а факт наличия макроса. Если такой макрос встречается в тексте, он заменяется на пустую строку.

Удалить определение макроса можно с помощью директивы `#undef`.

Листинг 4.6. Удаление макроса

```
1 #undef THE_NUMBER
```

В тексте, лежащем после директивы, приведённой в листинге 4.6, строка `THE_NUMBER` останется без изменения.

Параметры макросов

С помощью директивы `#define` можно также определить **макросы с параметрами** — лексемы, которые принимают параметры подобно функциям, но фактически являющиеся **текстовой заменой** (более гибким аналогом меню Replace текстового редактора) и раскрываются не во время выполнения (как функции) и не во время компиляции (как шаблоны C++), а до анализа и компиляции программы, никак не сообразуясь с типами переменных, текстом программы и так далее.

При описании макроса после директивы `#define` указывается имя макроса, за которым в скобках (без пробелов) следуют имена параметров, отделённые запятыми и определение макроса, отделённое пробелом.

Листинг 4.7. Определение макроса с двумя параметрами

```
1 #define MAX(num1, num2) ((num1) > (num2) ? (num1) :
      (num2))
```

При использовании макроса в тексте после его имени также ставятся круглые скобки, где перечисляются фактические значения параметров макроса.

```
1 int j = MAX(9, i);
```

При подстановке макрос заменяется своим значением, причём на место имён параметров вписывается соответствующий текст.

Параметры макроса при подстановке никак не проверяются. Если в результате такой текстовой подстановки возникнет ошибка, это выяснится только на этапе компиляции, причём не всегда сообщение об ошибке будет вменяемым.

В листинге 4.7 параметры макроса в его определении берутся в скобки, чтобы избежать неприятных ситуаций в том случае, если параметрами будут не имена переменных и литералы, а строки, представляющие собой более сложные выражения C++. Если макрос представляет собой вычисление выражения, то и его тоже лучше взять в скобки, что также сделано в листинге 4.7.

Например, определим макрос `SQUARE(x)` для вычисления квадрата параметра `x`. Макрос, определённый как в листинге 4.8, вычисляет неверное значение в случае, если его параметр является выражением.

Листинг 4.8. Неудачное определение макроса с параметрами

```
1 #define SQUARE(x) x*x
```

В частности, текст `i = SQUARE(2+2)` раскроется в `i = 2+2*2+2`, что даст `i`, равное $2 + 4 + 2 = 8$, а не $(2 + 2)^2 = 16$. Определение из листинга 4.9 заменит `SQUARE(2+2)` на `((2+2)*(2+2))` так что значение квадрата параметра в данном случае будет рассчитано корректно.

Листинг 4.9. Более корректное определение макроса с параметрами

```
1 #define SQUARE(x) ((x)*(x))
```

Значение квадрата выражения, модифицирующего свои переменные, будет всё равно вычисляться некорректно. В частности, `SQUARE(i++)` будет раскрыто как `((i++)*(i++))`, так что переменная i будет увеличена два раза. Единственный выход — не использовать такие выражения как параметры подобных макросов.

Объёмные макросы

Определение макроса должно занимать одну строку. Если строка-подстановка не помещается в строку файла, то в качестве знака переноса строки используется обратная косая черта.

Листинг 4.10. Определение объёмного макроса

```
1 #define DISPLAY_ARRAY(arr, size) {\
2         int i;\
3         for (i = 0; i < size; i++) {\
4                 printf("%d ", arr[i]);\
5         }\
6         printf("\n");\
7 }
```

«Склейка» нескольких строк в одну с помощью косой черты допустима не только в макросах, но и в любом месте программы, но в большинстве прочих случаев не имеет смысла, так так перевод строки в C/C++ является корректным пробельным символом.

Закавычивание строк

Параметры макроса можно взять в кавычки, используя оператор #.

Листинг 4.11. Макрос, заключающий аргумент в кавычки

```
1 #define QUOTES(x) #x
```

Тогда следующий код

```
1 cout <<  QUOTES(1+2) << " " << QUOTES(x) << " " <<
      QUOTES(мяу) << " " << QUOTES("мяу") << endl;
```

выведет

```
1 1+2 x мяу "мяу"
```

Чаще всего этот оператор используется в отладочной печати, так как позволяет вывести на стандартный вывод или сохранить в файл имя переменной.

Конкатенация строк

Параметры можно «склеивать» друг с другом и с произвольными строками с помощью оператора ##. Пример такого макроса приведён в листинге 4.12.

Листинг 4.12. Макрос, объявляющий две переменные

```
1 #define DEF_X_Y(typename) typename x##typename = 1, \
2     y##typename = 0; \
3     cout << typeid(x##typename).name() << " " \
4     << x##typename << endl;
```

Получив имя типа как параметр (например, `int`), макрос `DEF_X_Y` формирует текст, который объявляет и инициализирует две переменные `x<имя типа>` и `y<имя типа>`, а также выводит на стандартный вывод характеристику типа и значение переменной `x<имя типа>`. Следующий код не вызовет ошибок компиляции.

```
1     DEF_X_Y(int)
2     yint = xint+1;
```

Конкатенация строк может быть использована для изменения имён функций или переменных «на лету» в зависимости от версии программы или используемой платформы, что иногда необходимо.

4.3. Ассемблерные вставки в код C++

Растопи мой лёд,
А и достань Бел-камень
Из горюч-ключа.

С. А. Калугин. Весна

Для вставки одной или нескольких инструкций ассемблера в код на C++ используется ключевое слово `asm` [7, 10, 25].

Стандарт C++ описывает использование `asm` следующим образом:

```
asm ( string-literal ) ;
```

конкретный вид `string-literal` при этом не регламентируется. Обычно такие вставки используются для передачи кода непосредственно ассемблеру.

Содержимое таких вставок зависит как от архитектуры целевого аппаратного обеспечения (набор команд, регистров и т. д.), так и от компилятора (мнемоники команд, порядок операндов, синтаксис и т. д.).

Используемая операционная система определяет только обращения *непосредственно к интерфейсам операционной системы* (системные вызовы Linux и BSD, функции API Windows т. п.). Вычисления, а в тридцатидвухбитных системах также и обращение к стандартной библиотеке C (libc) или к кроссплатформенным библиотекам типа Qt, описываются одинаково под любой операционной системой (при этом имена функций могут отличаться, что подробнее описано в разделе 6.2.6).

Таким образом, механизм ассемблерных вставок в код на языке C++ позволяет получить переносимую между различными операционными системами программу, включающую фрагменты на ассемблере.

4.3.1. Синтаксис ассемблерных вставок в GCC

Дай мне Света суть,
Дай мне сутры Света —
Я застыл во снах.

С. А. Калугин. Весна

Ассемблерная вставка в программу, собираемую компилятором GCC, может быть описана с использованием двух ключевых слов: `asm` либо `__asm__` [63, 67]. Эти формы равнозначны и используют одинаковый синтаксис. Форма `__asm__` применяется, когда стандартное ключевое слово `asm` конфликтует с чем-либо в программе.

GCC поддерживает расширенный синтаксис вставок, включающий, кроме `string-literal`, ещё несколько секций, и позволяющий корректно встроить ассемблерную вставку в код на C/C++.

Также доступен и базовый синтаксис `asm ( string-literal );`.

Если код во вставке содержит более одной команды, то строки необходимо разделять, явно вставляя символ перевода строки `\n` или используя необработанные литералы C++11 (раздел 4.3.5).

Базовая форма

Базовая форма ассемблерной вставки выглядит следующим образом.

Листинг 4.13. Базовая форма вставки

```
1 asm [volatile] (
2     "команды и директивы ассемблера"
3     "как последовательная текстовая строка"
4     );
```

Ключевое слово `volatile` для базовой формы не оказывает никакого эффекта, так как такая вставка не оптимизируется компилятором никогда.

Вставка в базовой форме может использоваться в случаях, когда взаимодействие с данными программы на ЯВУ не требуется:

```
1 asm("int $3"); // вызов программного прерывания №3
```

Внутри ассемблерной вставки в базовой форме можно обращаться по именам к регистрам, а также к глобальным переменным программы (листинг 4.14).

Листинг 4.14. Увеличение глобальной переменной n

```
1 int n = 12;
2
3 int main(){
4     asm ("incl n");
5     cout << n <<endl;
6     return 0;
7 }
```

Локальные переменные функций размещаются компилятором в стеке (причём не всегда в порядке объявления), поэтому к ним необходимо обращаться, используя *расширенный ассемблер GCC,* а именно **параметры вставок.**

Необходимо также учитывать, что в регистрах, используемых во вставке, ранее компилятором могла быть размещена какая-либо регистровая переменная. Для базовой формы вставок нет никакого способа сообщить компилятору, что регистр изменён; и компилятор не определяет этого автоматически, что может привести к краху программы.

На практике описанную выше базовую форму ассемблерных вставок (без параметров) не стоит использовать *никогда*.
Только расширенная форма даёт возможность корректного взаимодействия с программой на ЯВУ.

Расширенная форма с выходными параметрами

Расширенных форм вставки в GCC две. Первая (с выходными и входными параметрами) выглядит следующим образом (листинг 4.15).

Листинг 4.15. Расширенная форма с выходными параметрами

```
1 asm [volatile] (
2     "команды и директивы ассемблера"
3     "как последовательная текстовая строка"
4     : [<выходные параметры>] : [<входные параметры>] :
      [<перезаписываемые элементы>]
5     );
```

Ключевое слово `volatile` используется для того, чтобы указать компилятору, что вставляемый ассемблерный код может обладать побочными эффектами, поэтому попытки оптимизации могут привести к логическим ошибкам.

Расширенная форма с метками выхода

Вторая форма расширенной ассемблерной вставки (с входными параметрами и метками выхода) имеет вид, приведённый в листинге 4.16.

Листинг 4.16. Расширенная форма с метками выхода

```
1 asm [volatile] goto (
2     "команды и директивы ассемблера"
3     "как последовательная текстовая строка"
4     :: <входные параметры> : <перезаписываемые элементы> :
      <метки>
5     );
```

Ключевое слово `goto` указывает, что ассемблерный код может делать переходы на метки, перечисленные в соответствующей секции.

Обращение к параметру-метке предваряется префиксом %ℓ (от *label*), за которым идёт порядковый номер метки в списке всех параметров; псевдоним для метки указать нельзя.

4.3.2. Параметры, перезаписываемые элементы, выходные метки вставок расширенного синтаксиса

Дай мне свет во снах,
Дай луча глоток мне,
Дай ростку родник.

С. А. Калугин. Весна

Ассемблерные вставки расширенного синтаксиса включают несколько секций, отделённых двоеточиями: описание выходных параметров (только для первой формы, `asm` без `goto`), входных параметров, перезаписываемых элементов (clobbers) и выходных меток (только для второй формы, `asm goto`).

Нумерация параметров и меток — сквозная, начиная с нуля. Общее их количество ограничено: $input + output + goto \leqslant 30$.

Обратиться к параметру внутри вставки можно, используя префикс `%` и псевдоним: `%[Value]`, `%[X]` (если параметр соответствует какой-либо переменной ЯВУ, то псевдоним может как совпадать, так и не совпадать с именем этой переменной). Если псевдоним не определён, используются номер параметра: `%0` для первого, `%1` для второго и т. д.

Чтобы избежать конфликтов с именами регистров, регистры во вставке с расширенным синтаксисом указываются с префиксом `%%`, например, `%%eax`.

Выходные параметры

Секция выходных параметров состоит из описаний отдельных параметров, разделённых запятыми.

Описание выходного параметра в общем случае имеет вид [24]:

```
1       [ [asmSymbolicName] ] constraint (cvariablename)
```

где

[asmSymbolicName] определяет псевдоним параметра (может отсутствовать). Область определения такого псевдонима — вся ассемблерная вставка. Псевдоним может быть любым допустимым идентификатором C++, окружённым квадратными скобками (в частности, `[X]`). Два разных параметра не могут использовать один псевдоним.

constraint — строковая константа, описывающая ограничения на расположение параметра. Для выходного параметра начинается с символов `=`, `+` или `=&` (см. ниже), за которыми следует собственно ограничение (раздел 4.3.3).

cvariablename — выражение C++ (lvalue), куда будет записано значение выходного параметра (обычно имя переменной).

Выходной параметр не может быть непосредственным значением и размещается в каком-либо регистре или памяти.

Выходные параметры в регистрах. Если выходной параметр `[X]` размещён *в каком-либо регистре* (будем обозначать его ρ), то внутри вставки обращение к параметру `%[X]` эквивалентно имени регистра ρ, а после ассемблерного кода вставки компилятором будет добавлена инструкция копирования значения из ρ в `cvariablename`[1].

=/=&/+: инициализация и совмещение регистровых выходных параметров. Если при этом ограничение выходного параметра `[X]` в регистре ρ начинается с:

=, то регистр ρ никак не инициализируется перед вставкой, а *в том же регистре ρ может быть размещён какой-либо из входных параметров* (скорее всего в регистре ρ *будет* размещён один из входных параметров, так как компилятор стремится минимизировать общее число задействованных во вставке регистров);

=&, то регистр ρ никак не инициализируется перед вставкой (аналогично =), но (в отличие от =) в регистре ρ не может быть размещён никакой другой параметр (см. раздел 4.3.6);

+, то регистр ρ инициализируется перед вставкой значением `cvariablename` (значение `cvariablename` копируется в ρ), и в регистре ρ не может быть размещён никакой другой параметр.

Выходные параметры в памяти. Если выходной параметр `[X]` размещён *в памяти,* то выражение `cvariablename` также должно обязательно быть в памяти[2]. Внутри вставки обращение к параметру `%[X]` эквивалентно адресу `cvariablename`. Никаких дополнительных копирований значения перед и после вставки компилятором не добавляется независимо от `=/=&/+` в начале строки ограничений `[X]` (тем не менее лучше использовать те же правила при выборе `=/=&/+` — тогда код будет легче читаться).

Входные параметры

Секция входных параметров следует за секцией выходных, отделяется двоеточием и также состоит из описаний отдельных параметров, разделённых запятыми.

Описание входного параметра в общем случае:

```
1       [ [asmSymbolicName] ] constraint (cexpression)
```

где

[asmSymbolicName] определяет псевдоним параметра, аналогично псевдонимам выходных параметров.

[1] Если `cvariablename` — имя переменной, сама эта переменная отнюдь не обязательно будет размещена компилятором в регистре.

[2] Если `cvariablename` — имя переменной, то для гарантированного помещения её в память при её объявлении (а не в начале ассемблерной вставки!) можно указать ключевое слово `volatile`, чтобы компилятор не оптимизировал эту переменную.

constraint — строковая константа, описывающая ограничения на расположение параметра (раздел 4.3.3). В отличие от ограничений выходных параметров, не содержит `=/=&/+`.

cexpression — выражение C++, откуда берётся значение входного параметра.

Выходной параметр может размещаться в каком-либо регистре, в памяти или быть непосредственным значением.

Если входной параметр `[I]` размещён *в регистре* (будем обозначать его ρ), то перед вставкой компилятором будет добавлена инструкция копирования значения `cexpression` в регистр ρ, а внутри вставки обращение к параметру `%[I]` эквивалентно имени регистра ρ.

Если входной параметр `[I]` размещён *в памяти,* то выражение `cexpression` также должно обязательно быть в памяти. Внутри вставки обращение к параметру `%[I]` эквивалентно адресу `cexpression`.

Если входной параметр `[I]` является *непосредственным значением,* то и выражение `cexpression` также должно быть константой, вычисляемой во время компиляции. Внутри вставки обращение к параметру `%[I]` эквивалентно константе `cexpression` с префиксом непосредственного значения `$`. Снять префикс `$` можно, используя модификатор `c` (раздел 4.3.4).

Перезаписываемые элементы (clobbers)

Код в ассемблерной вставке может прямо или косвенно изменять значения не только параметров, но и прочих регистров, других участков памяти, а также значения регистра флагов.

Для указания компилятору, какие именно элементы (кроме параметров) меняет вставка, используется список перезаписываемых (clobber, «сбитых») элементов [24].

Если во вставке явно или неявно модифицируется какой-либо регистр, его имя в виде строки необходимо указать в списке перезаписываемых элементов. Имя может быть указано как с префиксом `%` (в частности, `"%eax"`), так и без него (как `"eax"`). Если этого не сделать, компилятор, размещая параметры с ограничениями `"r"`, `"g"` и т. п., может поместить их в эти регистры, и значение такого параметра будет изменяться непредсказуемо.

Если во вставке изменяется значение в памяти, не считая явно указанных выходных параметров (например, записываются данные в массив), в список перезаписываемых элементов необходимо добавить специальное значение `"memory"`.

При указании `"memory"` в списке перезаписываемых элементов вставка будет барьером памяти: все операции работы с памятью, которые были в программе до ассемблерной вставки, выполнятся до неё, а те, что стоят в программе после — будут после. В противном случае компилятор может менять местами как команды,

реализующие операторы C++, так и команды ассемблерной вставки (в том числе перемешивая их).

Если во вставке изменяется значение регистра флагов (в частности, флаги меняют все арифметические инструкции), в список перезаписываемых элементов необходимо добавить специальное значение `"cc"`.

4.3.3. Ограничения на расположение параметра

Синевой во льдах
Облегло мой лог,
Облик льдом облит.

С. А. Калугин. Весна

Если расположение параметра не важно, в качестве ограничения можно указать **g** (general). Обычно для выходных параметров ограничение `g` эквивалентно `rm` (расположение в произвольном регистре или в памяти), для входных — `rim` (в произвольном регистре, как непосредственное значение или в памяти).

Но при расположении без ограничений возможны ситуации, когда оба операнда одной команды окажутся в памяти, или целочисленный операнд команды FPU — в регистре общего назначения (что недопустимо для x86). Чтобы избежать некорректного размещения, нужны более строгие ограничения.

В регистрах

Параметры вставки могут быть размещены *в регистрах*: общего назначения (РОН), SSE/AVX (xmm) и т. п. при помощи одного из следующих ограничений [24]:

r — произвольный регистр (для x86 — РОН), выбираемый компилятором. При выборе *не рассматриваются:*
- регистры из списка перезаписываемых элементов;
- регистры, где размещены другие параметры той же секции (для размещения выходного параметра — другие выходные, входного — входные), то есть два разных выходных или два разных входных параметра не могут быть расположены в одном регистре (но выходной и входной — могут);
- для некоторых версий компилятора — те регистры, которые по соглашению не могут изменяться функцией.

Предпочтение отдаётся регистрам, которые по соглашению могут изменяться функцией, а для входных параметров — тем, где уже размещён один из выходных (с префиксом = строки ограничений), чтобы сократить общее количество используемых вставкой регистров.

Ограничение `r` доступно для любого процессора.

Для размещения *входного параметра* в качестве ограничения можно указать **псевдоним или номер выходного параметра, размещённого в регистре** — тогда и входной разместится в том же регистре.

Для x86 доступны также платформо-специфичные ограничения.

Ограничения для размещения в РОН (целочисленные регистры):

q — любой из регистров, который можно адресовать по байтам младшего слова (A, B, C, D; выбор из этого списка — аналогично `r`);
U — любой из регистров, которые по соглашению могут изменяться функцией;
a — регистр A;
b — регистр B;
c — регистр C;
d — регистр D;
S — регистр si;
D — регистр di.

При размещении параметра в РОН ограничением можно задать только номер регистра (в частности, A, а не C или D), но не размер. Размер регистра-параметра определяется размером копируемой в него переменной (eax для int, rax для $long\ long$ и т. д.) и может быть изменён модификаторами (раздел 4.3.4).

Если по какой-то причине необходимо разместить параметр *в любом РОН, кроме* A, это можно сделать, задав ограничение `r` и либо указав регистр eax в списке перезаписываемых элементов (тогда в A не будет размещён ни один параметр), либо разместив в A *другой параметр той же секции.*

Ограничения для размещения в регистрах FPU:

f — произвольный регистр FPU $st(i)$;
t — вершина стека FPU $st(0)$;
u — второй регистр в стеке FPU $st(1)$.

Ограничения для размещения в регистрах SSE (xmm):

x — произвольный регистр SSE;
v — произвольный регистр из доступных с префиксом EVEX ($xmm0 - xmm31$);
Yz — первый регистр SSE ($xmm0$).

Влияние префикса `=/=&/+` строки ограничений регистровых *выходных* параметров на размещение регистровых *входных* параметров см. в разделе 4.3.2.

В памяти

Для размещения параметра *в памяти* можно использовать ограничение:

m — память.

При размещении параметра в памяти его значение никуда не копируется; используется исполнительный адрес переменной. Ограничение `m` доступно для любого процессора (как и `r`, `i`, `g`).

В виде непосредственного значения

Для размещения параметра *в виде непосредственного значения* (константы), можно использовать ограничение:

i — значение, известное на этапе компиляции или компоновки, без ограничений по значению.

Доступно для любого процессора, но только для *входных* параметров.

Комбинированные

Для одного параметра вставки можно указать несколько вариантов размещения (в частности, `rm`, `rim`, `ir` и т. п.) В этом случае компилятором выбирается один из указанных вариантов.

Выходные флаг-параметры

Для некоторых платформ, в частности, x86, доступны выходные параметры, задаваемые регистром флагов (если такая возможность поддерживается, определён макрос препроцессора `__GCC_ASM_FLAG_OUTPUTS__`).

Ограничение выходного флаг-параметра для x86 записывается как `=@cccond`, где `cond` — одно из ограничений, доступных для команд jCC или $setCC$; в частности, `=@ccz`, `=@ccnz`, `=@ccc`, `=@ccge` и т. д. (таблица 5.11).

Соответствующая переменная должна быть целочисленной и получает значение 1, если комбинация флагов `cond` присутствует в регистре $flags$ после вставки, и 0 иначе. Значение 0 или 1 формируется командой $setCC$ и при необходимости расширяется до размера переменной.

Это далеко не полный список как общих, так и специфичных для платформы x86 ограничений на размещение параметров вставок. Полные и актуальные данные доступны в документации GCC [24], разделы Extended Asm — Assembler Instructions with C Expression Operands и Constraints for asm Operands.

4.3.4. Модификаторы параметров

> Слышишь — капли там —
> Из обломанной ветки, да по губам,
> И кора мокра...
>
> *С. А. Калугин. Весна*

Иногда в коде программы требуется подставить не значение параметра в неизменённом виде, а какую-либо его характеристику. В этом случае необходимо использовать так называемые модификаторы параметров (таблица 4.1).

Модификатор указывается между префиксом `%` и именем параметра.

Модификаторы параметров ассемблерных вставок GCC

Таблица 4.1

Модификатор	Действие
z	Печать суффикса размера команды (b, s, w, l, q, t), соответствующего размеру параметра. Актуально для параметров в памяти либо непосредственных значений, если у команды нет операнда-регистра
c	Печать константы без префикса `$`
b	Печать имени младшего байта регистра (`%al` для регистра A)
h	Печать имени старшего байта младшего слова регистра (`%ah` для регистра A)
w	Печать имени младшего слова регистра (`%ax` для регистра A)
k	Печать имени младшего двойного слова регистра (`%eax` для регистра A)
q	Печать 64-битного варианта имени регистра (`%rax` для регистра A)

В частности, при инициализации параметра `[dmem]`, находящегося в памяти, непосредственным значением, необходимо указать размеры операндов. В GCC это делается при помощи суффикса размера (раздел 5.1.5). Явное указание суффикса сделает программу неустойчивой к изменению типа переменной, передающейся как `[dmem]`. Если суффикс указан с помощью модификатора `z`:

```
"mov%z[dmem] $0, %[dmem]\n"
```

данная команда будет корректно инициализировать переменную как типа $short$, так и int или $long\ long$.

Печать константы без префикса `$` необходима, если эта константа используется не как непосредственный операнд команды, а как-то иначе. В частности, такая константа может быть частью адреса.

```
"movl $13,  %c[FieldDisp](%[Struct])\n"
```

Приведённый фрагмент ассемблерной вставки инициализирует поле структуры, расположенной по адресу `[Struct]`. Смещение поля задано параметром `[FieldDisp]`.

Модификаторы печати имени части регистра доступны только для параметров в регистрах, причём печать младшего байта и старшего байта младшего слова —

только в тех, где эти байты можно адресовать. В тридцатидвухбитном режиме как младший байт, так и следующий за ним можно адресовать только для $A-D$. В шестидесятичетырёхбитном младший байт адресуется для всех шестнадцати регистров общего назначения с помощью префикса REX. Второй байт доступен только для $A-D$, причём не в любой ситуации (использование префикса REX запрещает доступ к $ah-dh$).

4.3.5. Практическое использование вставок

Серебром в ночи,
Пропитавши почвы,
Прорастаю свод...

С. А. Калугин. Весна

Рассмотрим несколько фрагментов программного кода, использующих вставки.

Определение доступных расширений

Пусть требуется узнать, поддерживает ли процессор расширение AVX. Это можно сделать, задав $eax = 1$ и выполнив команду $cpuid$. Команда $cpuid$ изменяет значение четырёх регистров eax, ebx, ecx, edx (в 64-битном режиме старшие части регистров A, B, C, D не используются); поддержке AVX соответствует единичное значение бита 28 регистра ecx (отсутствию поддержки — нулевое значение бита).

Сначала опишем вставку, которая получает 32-битное значение регистра ecx целиком.

Листинг 4.17. Получение ecx с битом AVX

```
1  unsigned int C;
2  asm(
3  "cpuid\n"
4  : "=c"(C)
5  : "a"(1)
6  : "ebx", "edx"
7  );
8  bool AVX_bit = ( C&(1<<28) ) !=0;
```

Соответственно, выходным параметром будет регистр C, значение которого копируется в 32-битную переменную (здесь также `C`). Входным — регистр A, значение которого задаётся равным единице (так как литерал `1` без суффикса соответствует типу int, который на современных платформах 32-битен, то и регистр-параметр A будет 32-битным eax).

Регистры A, B и D изменяются командой $cpuid$, но не требуются для анализа. Регистр A является входным параметром, поэтому не может быть указан в списке перезаписываемых, но B и D (ebx и edx) необходимо там указать.

Команда $cpuid$ не изменяет ни флагов, ни памяти по указателю, поэтому специальных значений `"cc"` и `"memory"` в списке перезаписываемых элементов не будет.

Теперь перенесём выделение бита 28 регистра ecx во вставку.

Листинг 4.18. Выделение бита AVX

```
1     bool AVX_bit;
2     asm(
3     "cpuid\n"
4     "test $(1 << 28), %%ecx\n"
5     : "=@ccnz"(AVX_bit)
6     : "a"(1)
7     : "ebx", "ecx", "edx", "cc"
8     );
```

Здесь выходным параметром будет комбинация флагов nz ($ZF \neq 0$), по которой взводится/сбрасывается значение переменной `AVX_bit`.

Регистр C всё ещё изменяется командой $cpuid$, но уже не является выходным параметром, то есть должен быть описан в списке перезаписываемых элементов. Также вставка теперь меняет флаги (команда $test$).

Теперь опишем код, который выполняет различные фрагменты кода на C/C++ в зависимости от поддержки AVX или SSSE4.3 (бит 20 регистра C).

Листинг 4.19. Различные ветви для AVX и SSE

```
1  int func()
2  {
3      asm goto (
4      "cpuid\n"
5      "test $(1 << 28), %%ecx\n"
6      "jnz %l1\n"
7      "test $(1 << 20), %%ecx\n"
8      "jnz %l2\n"
9      :: "a"(1)
10     : "ebx", "ecx", "edx", "cc"
11     : has_avx, has_sse4
12     );
13     return -1;
14
15 has_avx:
16     func_avx();
```

```
17      return 1;
18
19  has_sse4:
20      func_sse();
21      return 2;
22  }
```

Для этого понадобится вторая форма расширенной ассемблерной вставки, с входными параметрами и метками выхода — $asm\ goto$. У такой вставки нет выходных параметров (отсутствует секция между первыми двумя двоеточиями), но присутствует дополнительная секция меток (четвёртое двоеточие, после которого следует перечень меток, на которые можно передать управление из вставки).

Внутри вставки к меткам можно обратиться по номеру параметра-метки (сквозному с нуля): $\%\ell 1$ для `has_avx`, $\%\ell 2$ для `has_sse4` (номер 0 соответствует входному параметру в A). Если управление не будет передано ни на одну из меток (в данном случае — если не поддерживается ни AVX, ни SSE4.3), после вставки будет выполнена следующая за ней команда (строка 13 листинга).

Деление

На C/C++ нет оператора, который бы за один шаг вычислял частное и остаток целочисленного деления. Используем для расчёта вставки.

Пусть требуется разделить x = `0x80008001` на $y = 4$ как беззнаковые 32-битные числа; частное x/y записать в переменную z, а остаток $x\%y$ — в r.

Листинг 4.20. Беззнаковое деление с остатком

```
1       unsigned int x, y, z, r;
2       x = 0x80008001;
3       y = 4;
4       asm(
5       "xor %%edx, %%edx\n"
6       "div %[divisor]\n"
7       : "=a"(z), "=&d"(r)
8       : "a"(x), [divisor]"r"(y)
9       : "cc"
10      );
```

Беззнаковое деление с остатком выполняется командой div; при этом, если делитель, частное и остаток 32-битные, то делимое должно быть 64-битным и размещаться в паре регистров $edx{:}eax$.

Выходными параметрами при делении будут частное и остаток, извлекаемые после div из регистров eax и edx в переменные z и r соответственно — неименованные (так как во вставке нет явного обращения к ним) параметры `0` и `1`.

Входными параметрами будут делимое x и делитель y.

32-битное делимое x необходимо разместить в регистре eax (что делается ограничением `"a"` неименованного входного параметра 2) и расширить до 64 бит на edx:eax как беззнаковое, то есть заполнить старшую часть (регистр edx) нулями (что выполняется zero idiom $xor\ \%edx, \%edx$).

32-битный делитель (для него указан псевдоним `[divisor]`, так как это явный операнд команды div) может быть размещён в произвольном регистре, кроме eax и edx (во избежание конфликта с делимым — см. раздел 4.3.6). В регистре eax уже размещён другой входной параметр 2, и `[divisor]` туда не попадёт. Чтобы избежать размещения `[divisor]` в регистре edx, необходимо указать, что выходной параметр 1 в edx не может быть совмещён ни с каким входным (ограничение `"=&d"`).

Код вставки (команда div) меняет флаги, поэтому в списке перезаписываемых элементов необходимо указать специальное значение `"cc"`. Явно обнуляемый регистр edx не указывается в списке перезаписываемых элементов, так как в нём размещён выходной параметр 1.

Вместо обнуления регистра edx перед беззнаковым делением командой xor можно разместить в нём входной неименованный параметр 3 с нулевым значением.

Листинг 4.21. Беззнаковое деление с остатком

```
1     asm(
2     "div %[divisor]\n"
3     : "=a"(z), "=d"(r)
4     : "a"(x), "d"(0), [divisor]"r"(y)
5     : "cc"
6     );
```

В этом случае входной параметр `[divisor]` не будет размещён ни в eax, ни в edx — они уже заняты неименованными входными параметрами 2 и 3.

Временные регистры

Использовать под временные данные фиксированные регистры и указывать их в списке перезаписываемых не вполне корректно [52].

Более правильным будет ввести фиктивный выходной параметр, размещаемый в регистре (`=&r`, либо более конкретное ограничение — подробнее указано в разделе 4.3.3), так как это даст компилятору больше свободы при оптимизации.

В тексте вставки можно использовать данный параметр для хранения произвольных временных данных.

Листинг 4.22. Фиктивный выходной параметр как временный регистр

```
int src = 1, dst, tmp;
asm(
    "movl %[SRC], %[TMP]\n"
    "movl %[TMP], %[DST]\n"
    :[DST]"=m"(dst), [TMP]"=&r"(tmp)
    :[SRC]"m"(src)
);
```

В листинге 4.22 показана пересылка память-память через временный регистр, где выбор регистра отдан компилятору.

Разделение инструкций

При компиляции соседние строки ассемблерной вставки склеиваются, как склеиваются части любой строковой константы — точно так же, как в объявлении вида

```
    char *s = "abcd"
        "ABCD";
```

которое задаёт строку `"abcdABCD"`, не разделённую посередине никаким символом. То есть вставка

```
    asm(
    "xor %%edx, %%edx"
    "div %[divisor]"
    : "=a"(z), "=&d"(r)
    : "a"(x), [divisor]"r"(y)
    : "cc"
    );
```

На самом деле выглядит как

```
    asm(
    "xor %%edx, %%edxdiv %[divisor]"
    : "=a"(z), "=&d"(r)
    : "a"(x), [divisor]"r"(y)
    : "cc"
    );
```

и вызывает логичное сообщение о некорректном имени регистра «edxdiv».

Таким образом, если во вставке необходимо использовать более одной инструкции, то в конце каждой строки необходимо поместить суффикс `\n` для разделения инструкций (листинг 4.20). Если желательно иметь красивый выходной файл, можно использовать суффикс `\n\t`, если форматирование выходного файла безразлично — можно использовать вместо `\n` разделитель `;`.

Начиная со стандарта C++11 можно также использовать необработанные (raw) литералы.

4.3.6. Проблемы при написании вставок

> Когда вошел контролёр, пронырливый как коростель,
> Он сказал, что заполнил пустые места, и в каждом стоит постель.
>
> *С. А. Калугин. Ефрейтор Расчёскин*

Неожиданные значения выходных параметров во вставках в большинстве случаев связаны или с конфликтом входных и выходных долгоживущих параметров, или с недозаполненной секцией перезаписываемых элементов.

Всегда необходимо помнить, что компилятор стремится минимизировать общее число задействованных во вставке регистров; а в регистрах, незадействованных во вставке — размещает данные ЯВУ.

Конфликт выходных и входных долгоживущих параметров

Если при написании кода из листинга 4.20 не запретить совмещение неименованного выходного параметра в регистре *D* со входными, то вставка будет выполняться некорректно.

Листинг 4.23. Некорректный код

```
1     asm(
2     "xor %%edx, %%edx\n"
3     "div %[divisor]\n"
4     : "=a"(z), "=d"(r)
5     : "a"(x), [divisor]"r"(y)
6     : "cc"
7     );
```

В этом случае компилятор, скорее всего, разместит входной параметр `[divisor]` также в регистре *D* (в целях сокращения числа используемых регистров), и, так как регистр *D* обнуляется перед делением, результатом выполнения вставки всегда будет деление на ноль.

Тем не менее, не стоит без необходимости («на всякий случай») запрещать совмещение для всех выходных параметров — нехватка регистров приведёт к генерации компилятором неэффективного кода.

Неуказание перезаписываемых элементов

Если в секции перезаписываемых элементов не указать регистр, явно или неявно изменяемый вставкой — в этом регистре может быть размещён входной

или выходной параметр. Таким образом, этот регистр будет изменяться и при явном/неявном обращении к нему, и при обращении к параметру, что приведёт к некорректному значению и этого параметра, и всех зависящих от него значений.

Неуказание в списке перезаписываемых элементов специальных значений `"cc"` и `"memory"` в тех случаях, когда флаги или память по указателю изменяются вставкой, также может повлечь за собой некорректное выполнение как самой вставки, так и кода на C/C++, окружающего вставку, хотя в простых случаях проблемы могут быть незаметны.

Контрольные вопросы

1. Какие стадии включает компиляция программы с помощью GCC?
2. Какое расширение имеет файл с исходным кодом на языке ассемблера?
3. Какое расширение имеет файл с исходным кодом на языке C++?
4. Как изменить имя выходного файла при сборке?
5. Как собрать программу, состоящую из нескольких модулей?
6. Каким ключевым словом открывается ассемблерная вставка?
7. Как из ассемблерной вставки обратиться к локальным переменным?
8. Какие вы знаете ограничения на размещение параметров ассемблерных вставок?

Глава 5. Синтаксис и команды GNU Assembler x86

А потому, после того, как будешь свободен, будь деятелен.

Коран. 94.7

Язык ассемблера — простейший символический язык программирования, каждая команда которого транслируется в одну команду машинного языка. Также существуют операторы ассемблера, не соответствующие машинным командам — директивы, комментарии, пустые операторы.

Набор команд ассемблера определяется как архитектурой используемого компьютера, так и собственно ассемблером — транслятором с символического языка в объектный код. Команды имеют текстовые мнемонические обозначения (мнемоники). При этом одной и той же мнемонике может соответствовать несколько опкодов, выполняющих схожие действия над операндами, расположенными в разных местах или разного размера. Часто существует один опкод для восьмибитных операндов и другой — для операндов, имеющих размер 32, 64 или 16 бит (для него разрядность операндов определяется текущим режимом и префиксами). Таким образом, иногда команды обрабатывают восьмибитные операнды немного иначе, чем любые другие. Кроме того, одному опкоду может соответствовать несколько разных мнемонических обозначений.

В данной главе описывается часть набора команд GNU Assembler (GAS) для архитектуры x86 с использованием традиционного синтаксиса AT&T, а также особенности этого синтаксиса.

5.1. Особенности GNU Assembler

А тот, кто сторожит баржу, спесив
И вообще не святой;
Но тот, кто сторожит баржу, красив
Неземной красотой.

Б. Б. Гребенщиков. Стерегущий баржу

GAS, как и его предок, ассемблер Unix as, использует так называемый синтаксис AT&T System V/386, часто называемый просто синтаксисом AT&T или синтаксисом GAS [8, 43].

Также для процессоров семейства Intel x86 часто используется синтаксис, предложенный фирмой Intel. Основными отличиями синтаксиса Intel от AT&T считаются обратный порядок операндов, другие обозначения адресации и невозможность явного указания разрядности операции. Менее известно различие в мнемонических

обозначениях команд. Современные версии ассемблера GAS поддерживают оба варианта синтаксиса.

Основными недостатками синтаксиса Intel является неоднозначность и трудность чтения инструкций. Кроме того, синтаксис Intel используется только для процессоров Intel или совместимых с ними.

Синтаксис AT&T иногда называется кроссплатформенным, так как GCC и, соответственно, GAS реализован для множества различных архитектур. Полной кроссплатформенности при использовании языка ассемблера достичь невозможно, так как у каждой платформы свой набор команд, регистров и методов адресации, но использование схожего синтаксиса облегчает переход между ними.

Также инструкции, записанные в соответствии с синтаксисом AT&T, легче читаются. Даже обозначение адреса в памяти, которое вначале кажется контринтуитивным, распознаётся однозначно. Косвенный адрес в памяти, записанный по правилам синтаксиса AT&T, невозможно перепутать с непосредственным значением, что происходит в диалектах Intel.

5.1.1. Общие правила

И малое замкнулось на великом,
И Млечный Путь раскрылся для меня!

С. А. Калугин. Млечный путь

Так как GAS в основном используется на одном из этапов компиляции программы на C/C++, многие синтаксические конструкции GAS и C/C++ совпадают.

В программе могут использоваться латинские буквы, цифры, а также нижнее подчёркивание и точка. Допустимые пробельные символы — пробел и табуляция; они могут сочетаться в любом порядке. Перевод строки является разделителем операторов.

Допускаются многострочные комментарии /* в стиле C */ и однострочные // в стиле C++. Также для различных платформ поддерживаются платформоспецифичные виды однострочных комментариев. В частности, для x86, кроме однострочного комментария в стиле C++, поддерживается символ комментария #, но он считается устаревшим.

Оператор ассемблера целиком размещается на одной строке. В начале строки может быть одна или несколько меток, заканчивающихся двоеточием. Если первый символ оператора — точка, то это — директива ассемблера (первая строка листинга 5.1). Набор основных директив совпадает для всех архитектур, но для многих платформ есть и специфичные (в частности, директивы определения данных).

Листинг 5.1. Директива и команда

```
1 the_label:     .directive    ...
```

```
2 another_label:            // Пустой оператор
3             instruction   operand_1, operand_2, ...
```

Пустой оператор может состоять только из пробельных символов или быть пустой строкой (вторая строка). Оператор, начинающийся с буквы, представляет собой мнемоническое обозначение машинной команды, за которым при необходимости следуют операнды, разделённые запятыми (третья строка листинга 5.1).

Строковые литералы ограничиваются двойными кавычками, экранирующим символом является обратный слеш «\», спецсимволы кодируются аналогично C/C++. Числовые литералы также описываются аналогично C/C++.

5.1.2. Основные директивы

Кто море удержал брегами
И бездне положил предел,
И ей свирепыми волнами
Стремиться дале не велел?

М. В. Ломоносов. Ода, выбранная из Иова

Директива ассемблера не соответствует никакой машинной команде. Рассмотрим несколько наиболее употребительных директив; их можно разбить на несколько классов.

Директивы определения секций

Как было описано в разделе 3.2, код программы и различные виды данных должны располагаться в различных диапазонах адресного пространства. По историческим причинам эти диапазоны называются сегментами (соответствующие фрагменты исходного кода и исполняемого файла — секциями). Начало содержимого того или иного сегмента в исходном ассемблерном коде отмечается специальными директивами.

С начала файла до первой директивы располагается сегмент кода. Указать продолжение сегмента кода можно директивой **.text**.

Сегмент данных открывается директивой **.data**. В принципе, описание статических данных в сегменте кода не вызовет ошибки, но такие данные будет невозможно модифицировать, так как сегмент кода защищён от изменений.

Для сегментов стека и кучи нет соответствующих секций, они заполняются динамически в процессе выполнения программы.

Директивы определения данных

В сегменте `.data` статические данные описываются также с помощью директив.

После директивы определения данных указывается литерал подходящего типа или несколько литералов, перечисленных через запятую. В памяти соответственно резервируется одна или несколько ячеек соответствующего размера, которые инициализируются указанными значениями.

Для того, чтобы дать адресу ячейки имя, перед соответствующим определением необходимо поставить метку (листинг 5.2).

Листинг 5.2. Определение статических данных

```
1 foo: .long 0, 1, 2
2 bar: .double -8.7
```

Важно помнить, что ассемблер, в отличие от языков высокого уровня, не является типизированным. Таким образом, если, в частности, по адресу bar расположено восьмибайтовое значение двойной точности $-8{,}7$, а программист обратится к нему как к числу одинарной точности (четыре байта), это не вызовет сообщения об ошибке, но прочитанное значение будет другим.

Для инициализации памяти целыми значениями различного размера используются следующие директивы: **.byte** — однобайтовое (восьмибитное) целое, **.short** — шестнадцатибитное, **.long** — тридцатидвухбитное, **.quad** — шестидесятичетырёхбитное. Размер и порядок байтов определяются платформой; приведены размеры для x86 (они же наиболее распространённые). Также существуют директивы **.word** и **.int**, для x86 определяющие шестнадцати- и тридцатидвухбитные целые соответственно.

Значения с плавающей запятой одинарной (32 бита) и двойной (64 бита) точности описываются директивами **.float (.single)** и **.double**.

Для инициализации памяти строковыми константами различного вида используются директивы **.string (.asciz)** и **.ascii**.

Функции стандартной библиотеки C используют строки, завершающиеся нулём; их можно описать директивой **.string (.asciz)** (листинг 5.3).

Листинг 5.3. Определение строки, завершающейся нулём

```
1 msg: .string "Hello, world!\n"
```

Если после директивы указывается несколько строковых литералов через запятую, завершающий ноль добавляется после каждого.

Строка без завершающего нуля описывается директивой **.ascii** (листинг 5.4).

Листинг 5.4. Определение строки без завершающего нуля

```
1 msg:
2 .ascii "Hello, world!\n"
3 len = . - msg // символу len присваивается длина строки
```

Для обработки подобных строк нужно знать их длину (её нельзя определить, анализируя содержимое памяти). Для этого используется специальный символ «.» — адрес текущего оператора (в том числе ячейки с данными).

Директивы определения данных точно так же сработают и будучи размещёнными в сегменте кода (`.text` или неименованная секция в начале программы), но такое размещение будет ошибкой. Если данные попадут во фрагмент кода, который выполняется, они будут интерпретированы как команды, что, скорее всего, приведёт к сбою при декодировании. Даже если данные находятся в той части кода, которая не получает управления, их будет невозможно модифицировать.

Прочие директивы

Парные директивы **.rept** . . . **.endr** соответствуют повторению фрагмента между ними, в частности

Листинг 5.5. Директива `.rept`

```
1 .rept 4
2 .long 0
3 .endr
```

интерпретируется как четырёхкратное повторение оператора `.long 0`:

Листинг 5.6. Эквивалентное описание данных без использования `.rept`

```
1 .long 0
2 .long 0
3 .long 0
4 .long 0
```

Директивы `.rept ... .endr` могут применяться и к командам. При этом происходит именно многократное дублирование фрагмента кода в исполняемом файле, а не циклическое повторение одной и той же его копии.

Директива **.globl (.global)** делает символ доступным компоновщику (видимым из других модулей).

Листинг 5.7. Перевод символа $main$ в глобальную область видимости

```
1 .globl main
```

Переменные и функции, имена которых сделаны общедоступными при помощи директивы `.globl` или `.global` (возможны оба написания), могут быть импортированы, в частности, в модуль на C++ с помощью ключевого слова `extern`.

Парные директивы **.func** . . . **.endfunc** включают в исполняемый файл отладочную информацию о функции (только при сборке в отладочном режиме).

Таким образом, если в файле несколько функций, можно указать для отладчика их границы.

Листинг 5.8. Границы функции $sqr()$

```
1 .globl sqr
2 .func sqr
3         sqr:
4                 movl 4(%esp), %eax
5                 imull %eax, %eax
6                 ret
7 .endfunc
```

Директивы `.func ... .endfunc` не влияют ни на что, кроме отладочной информации. В режиме Release игнорируются.

5.1.3. Порядок операндов

Путь-дорога, господа!
Вы откуда и куда?

П. П. Ершов. Конёк-горбунок

В GAS принят порядок записи операндов слева направо, следуя европейскому направлению письма. Соответственно, инструкция GAS обычно имеет вид:

```
1 mnemonic source, destination
```

то есть вначале указывается источник, затем приёмник.

Для команд с тремя операндами (один из них в x86 — всегда непосредственное значение) вначале записывается непосредственное значение, затем источник, затем приёмник.

```
1 mnemonic immediate, source, destination
```

Если среди операндов нет приёмника (в частности, команды с двумя непосредственными операндами, такие как `enter`), порядок в AT&T совпадает с порядком, указанным в документации Intel [8, 70].

При этом, если команда принимает операнды в регистрах или памяти, но не модифицирует их (в частности, команды сравнения `cmp` или выделения бита `bt`), в большинстве случаев один из операндов всё равно считается приёмником. Каждая из приведённых команд входит в семейство, большая часть команд которого модифицирует этот операнд.

В частности, рассмотрим одну из наиболее употребительных мнемоник ассемблера — команду пересылки (копирования) `mov`. Она соответствует оператору присваивания языков высокого уровня. Её операнды — источник (обозначим его

src) и приёмник ($dest$). В синтаксисе Intel пересылка $dest = src$ имела бы вид `mov dest, src`; в используемом в данном пособии синтаксисе AT&T она имеет вид `mov src, dest`. Например, команда `movb $0x05, %al` помещает значение 5 в регистр al.

5.1.4. Адресация операндов

> Поскоблите язык — и вы увидите пространство
> и его шкуру.
>
> *В. Хлебников. Зангези*

Параметры команд ассемблера, в отличие от операндов ЯВУ, не могут быть произвольными выражениями. В разделе 3.6.1 были описаны различные виды адресации. Рассмотрим обозначения, принятые в GAS для методов адресации явно передаваемых параметров команд x86.

1. **Непосредственная** — константа, значение которой при компиляции непосредственно включается в код команды (адрес глобальной переменной или выражение, вычисляемое на этапе компиляции, также является непосредственным значением).
   Непосредственные операнды отмечаются префиксом `$`. Например, `$0`, `$13`, `$0xFFFFFFFF`, `$(0 + 1 + 2*2 - 7/4)` (значение, равное 4), `$n` (адрес глобальной переменной n).
2. **Прямая** (абсолютная) — переменная в памяти по фиксированному адресу (статическая или глобальная), адрес при компиляции также включается в код команды.
   Операнды, описываемые статическим адресом в памяти, не имеют префикса. Например, `0` (вызовет ошибку чтения по нулевому адресу), `n` (значение глобальной переменной n).
3. **Прямая относительная**, также rip-relative или PC-relative, от program counter — переменная или функция располагается в памяти по фиксированному адресу, но в команду включается не сам адрес, а его смещение относительно указателя команд ip.
   Для адресов в коде (функций, меток для перехода) неявно применяется по умолчанию как в тридцатидвухбитном, так и в шестидесятичетырёхбитном режиме. Операнд не имеет префикса и в ассемблером коде выглядит так же, как и прямой абсолютный адрес: `call func`, `jmp label`.
   В шестидесятичетырёхбитном режиме появилась возможность использовать прямую относительную адресацию и для данных. Операнд выглядит как базовый адрес со смещением, где базой явно задан указатель команд: `lea msg(%rip), %rsi` (здесь `msg` — метка в секции данных). Относительная адресация используется только для базового регистра rip. Аналогичная запись

с другой базой соответствует косвенной адресации и использованию *абсолютного*, а не относительного адреса `msg`.

4. **Регистровая** — переменная в регистре, в команду при компиляции включается имя (номер) регистра.
   Операнды в регистрах отмечаются префиксом `%`. Например, `%eax`, `%dh`, `%bp`, `%rsi`, `%r13`.
5. **Косвенно-регистровая (косвенная)** — переменная в памяти, указатель на неё в регистре (или наборе регистров).
   Например, `(%ebp)` — значение в памяти по адресу ebp. Можно указать смещение относительно адреса, хранимого в регистре: `4(%esp)` — значение в памяти по адресу $esp + 4$.
   В x86-совместимых процессорах для косвенной адресации можно использовать до двух регистров и, кроме того, до двух констант. Таким образом, для вычисления адреса используется до четырёх параметров: `4(%ebp, %edi, 8)` — значение в памяти по адресу $ebp + 8edi + 4$. Часть параметров может отсутствовать: `(%edx, %esi, 8)` — значение по адресу $edx + 8esi$, `(%edx, %esi)` — по адресу $edx + esi$, `(,%esi, 8)` — по адресу $8esi$.

Компоненты адреса

В языке ассемблера x86 конструкция косвенной адресации включает в себя вычисление адреса и его разыменование (частичным аналогом может быть оператор обращения к элементу массива на ЯВУ — `[]`, а для сокращённых форм — разыменование указателя — `*`, но при этом косвенная адресация — более сложный и гибкий механизм).

Как было сказано в разделе 3.6.3, команда x86 может содержать до четырёх полей, задающих адрес — номер базового регистра $Base$, номер индексного регистра $Index$, показатель масштаба индексного регистра $Scale$ и смещение $Displacement$.

Используя для обозначения разыменования $*$, как в C++, результат вычисления адреса с разыменованием в полной форме (с четырьмя параметрами) можно записать как

$$*\big(Base + \sigma \cdot Index + Displacement\big) \tag{5.1}$$

где $Base$ и $Index$ — значения соответствующих регистров (32-разрядные для соответствующей платформы), $Displacement$ — целое знаковое число (смещение), σ — натуральное число (масштабный коэффициент — степень двойки 2^{Scale}, причём только $1, 2, 4$ или 8 из-за размера соответствующего поля в теле команды). Одно или оба числовых значения, а также любой из регистров могут быть опущены (если не указан масштаб, используется $\sigma = 1$, вместо остальных пропущенных параметров используется 0).

Полная форма косвенной адресации

Полная форма косвенной адресации (вычисления адреса с разыменованием) в GAS, соответствующая (5.1), имеет вид:

```
displacement(%base, %index, σ)
```

Любой из компонентов может отсутствовать, в этом случае опускается и соответствующий разделитель (только в одном случае — когда отсутствует база, но есть индекс — разделяющая их запятая сохраняется, чтобы отличать эту ситуацию от базы без индекса).

Таким образом, прямая адресация в принципе может рассматриваться как частный случай косвенной, когда оба регистра и масштабный коэффициент опущены вместе со скобками, и адрес равен смещению $Displacement$.

Например, следующая команда использует все четыре параметра и загружает в A значение $*\big(bp + D \cdot 4 - 4\big)$ (команда `mov src, dest` загружает в приёмник $dest$ значение источника src, `l` — суффикс размера).

```
movl  -4(%ebp, %edx, 4), %eax   // A = *(bp + 4*D - 4)
```

Чаще используются сокращённые варианты адресации, когда указывается только часть параметров [6, 8].

Базовая косвенная адресация со смещением

Если используется только параметр $Base$, получим эквивалент разыменования указателя в C++. В частности, следующая команда записывает четырёхбайтовое значение по адресу C в регистр D.

```
movl  (%ecx), %edx       // D = *C
```

С параметрами $Base$ и $Displacement$ получим $*\big(Base + Displacement\big)$, что соответствует обращению к полю структуры ($Base$ — адрес структуры, константа $Displacement$ — относительное смещение нужного поля), к параметру функции или к локальной переменной. Следующая команда загружает значение из адреса $bp - 4$) в регистр A.

```
movl  -4(%ebp), %eax     // A = *(bp - 4)
```

При передаче параметров функции через стек обратиться к ним внутри функции можно только используя адресацию относительно указателя стека sp. На вершине стека, то есть по адресу $*sp =$`(%esp)`, находится адрес возврата. Под ним (но по бóльшему адресу, так как стек растёт вниз) помещаются параметры.

Базово-индексная косвенная адресация

При использовании всех параметров, кроме $Displacement$, получим $*\big(Base + \sigma \cdot Index\big)$, что соответствует обращению к элементу массива. Действительно, адрес элемента одномерного массива складывается из адреса начала массива, индекса элемента и размера элемента, то есть запись $M[i]$ эквивалентна $*\big(M + i \cdot sizeof(M[0])\big)$. Если размер элемента равен $1, 2, 4$ или 8, он может быть масштабным коэффициентом (σ) и к элементу можно обратиться, используя три из четырёх параметров адреса: $*\big(Base + Index \cdot \sigma\big)$.

В частности, адрес i-го элемента массива M из чисел типа `int` равен $M + i \cdot 4$. Если адрес начала массива M находится в регистре C, а индекс — в si, то элемент $M[i]$, или $*(M + i \cdot 4)$, будет записан как `(%ecx, %esi, 4)`. Соответственно, запись $M[i]$ типа int в регистр A будет выглядеть следующим образом:

```
1 movl (%ecx, %esi, 4), %eax  // A = *(C + 4*si) = C[si]
```

Если размер элемента равен одному байту (тип $char$), адрес можно записать ещё компактнее:

```
1 movl (%ecx, %esi), %eax  // A = *(C + si) = C[si]
```

На платформах, отличных от x86 и x86-64, могут использоваться другие методы адресации и, соответственно, немного другие обозначения для них.

5.1.5. Размер операндов команды

> Еду я на своём камазике...
> А из-за поворота навстречу мне жигулище!
>
> *Фольклор*

Большая часть мнемоник соответствует не одной команде уровня архитектуры команд, а целому семейству однотипных команд, которые выполняют одни и те же действия над операндами различного расположения или различных размеров и, соответственно, имеют разные коды.

Размер операндов маркируется суффиксом, добавляемым к базовой форме мнемоники; например, копирование (базовая форма команды — `mov`) из edx в eax (размер операндов $long$) записывается как `movl %edx, %eax`. Суффиксы перечислены в таблице 5.1.

Необходимо отметить, что для целочисленных команд и команд обработки вещественных чисел одни и те же суффиксы означают различную разрядность. Некоторые суффиксы допустимы только для одного семейства команд. Для целочисленных команд суффиксы `s` и `w` обозначают 16-битное целое и в целом равноправны (для команды `mov` используется только `w`, так как существует другая команда с базовой формой `movs`).

Суффиксы размера операндов

Таблица 5.1

Суффикс	Целый операнд (бит)	Вещественный операнд (бит)
b	byte (8)	
s	short (16)	single (32)
w	word (16)	
l	long (32)	double (64)
q	quad (64)	
t		ten bytes (80)

У команд с операндами разных размеров указывается два суффикса. Порядок суффиксов, как и порядок операндов — слева направо (от источника к приёмнику). Так, копирование целого числа со знаковым расширением (базовая форма команды — `movs`) из *al* в *edx* выглядит как `movsbl %al, %edx`. Возможны двойные суффиксы `bl` (от *byte* к *long*), `bw` (от *byte* к *word*) и `wl` (от *word* к *long*) и так далее. Суффикс `s` не используется как компонент составного суффикса (таблица 5.2).

Двойные суффиксы размера для копирования целых чисел с расширением

Таблица 5.2

Суффикс	Источник (бит)		Приёмник (бит)
bw	byte (8)	→	word/short (16)
bl	byte (8)	→	long (32)
bq	byte (8)	→	quad (64)
wl	word/short (16)	→	long (32)
wq	word/short (16)	→	quad (64)
lq	long (32)	→	quad (64)

Если суффикс не указан, GAS определяет размер по регистровому операнду. Такое поведение несовместимо с оригинальным ассемблером AT&T Unix, который предполагает, что отсутствие суффикса означает размер операнда *long*. Эта несовместимость не влияет на компиляцию с ЯВУ, так как компиляторы всегда выставляют суффиксы размера [8].

Если размер не удалось определить по операндам (то есть используются либо непосредственные операнды, либо расположенные в памяти), по умолчанию для основного набора команд принимается размер $long$ (32 бита). Такая ситуация не всегда вызывает ошибку компиляции, но в некоторых случаях приводит к странному результату.

При отсутствии суффикса размера у команды FPU для целых операндов, находящихся в памяти, используется размер $short$ (16 бит), а для вещественных — одинарная точность ($float$, 32 бита), так что при работе с FPU надо быть особенно внимательным к суффиксам.

5.1.6. Мнемоники

Научный вестник,
пожалуйста, не пугайтесь!
Полный перечень
так называемых ругательств!

В. В. Маяковский. Клоп

Первоначальные мнемонические обозначений команд процессора предлагаются его разработчиками в документации, описывающей набор команд. В дальнейшем ассемблеры в основном используют именно их. Большая часть мнемоник GAS (их базовые формы) также совпадает с документацией Intel.

Тем не менее, часть обозначений различается. В частности, отличаются базовые формы команд копирования со знаковым расширением ($movs$ в GAS, $movsx$ в Intel) и копирования с беззнаковым расширением ($movz$ в GAS, $movzx$ в Intel); подробнее они описаны в разделе 5.2.4. Впрочем, для данных команд некоторые шестидесятичетырёхбитные версии GAS используют обозначения Intel; для этих версий мнемоники $movs$ и $movz$ некорректны.

Синтаксис AT&T предлагает для команд знакового расширения (их неявным аргументом всегда является регистр A; подробнее в разделе 5.2.4) обозначения, построенные по схеме $cStD$ (convert S to D), где S — суффикс размера источника, D — суффикс размера или обозначение расположения (в случае расширения в пару регистров) приёмника. В документации Intel приведены другие обозначения: они построены по схеме cSD или $cSDe$ и используют другие обозначения размера. При программировании в GAS с использованием синтаксиса AT&T можно без ограничений использовать для команд расширения регистра A как вариант AT&T, так и вариант Intel.

Опкоды дальнего перехода (с указанием сегмента и абсолютного адреса) в AT&T соответствуют мнемоникам `lcall`/`lret` (long call/long return) и `ljmp` (long jump), в то время как Intel обозначает их как `call far`/`retf` и `jump far`. Для этих команд GAS также поддерживает оба варианта.

Для несимметричных арифметических команд обработки чисел с плавающей точкой (`fsub`/`fsubr` и `fdiv`/`fdivr`) GAS использует те же мнемоники, что и Intel, но при этом реализует качественно иное поведение (раздел 5.3.5).

В шестидесятичетырёхбитном режиме команда загрузки шестидесятичетырёхбитного непосредственного значения в регистр обозначается `movabs` в синтаксисе AT&T (загрузка абсолютного адреса). Синтаксис Intel не выделяет единственную команду с шестидесятичетырёхбитным непосредственным операндом из семейства команд пересылки и обозначает её как `mov`.

5.1.7. Префиксы

Не будь цветов, все ходили бы в одноцветных одеяниях!

К. П. Прутков.
Мысли и афоризмы, не включённые в «Плоды раздумья»

Как уже было сказано, регистры и непосредственные операнды обозначаются специальными префиксами. Для ассемблера x86 имена регистров начинаются с `%` (`%eax`, `%dl`), а непосредственные значения (константы) отмечаются префиксом `$`, например, `addl $5, %eax` (добавить константу 5 к регистру A).

Дополнительно возможны префиксы `0x` для шестнадцатеричных констант, `0` для восьмеричных и `0b` для двоичных. Десятичные константы записываются без ведущих нулей, шестнадцатеричные и двоичные могут иметь ведущие нули после префикса.

Префикс непосредственного операнда `$` указывается перед префиксом системы счисления (`$0xFF`, `$0577`, `$0b101`).

На платформах, отличных от x86 и x86-64, могут использоваться другие префиксы для указания метода адресации операнда.

5.2. Основные команды

ЭТО не работает на восьмиразрядных машинах.

Программистский фольклор

Основной набор команд x86 включает команды обработки целых чисел и разнообразные команды управления вычислениями. Полный список команд приведён в первом томе руководства разработчика программного обеспечения для архитектур Intel 64 (так архитектура x86-64 называется в документации Intel) и IA-32 [16], а подробное описание — во втором [17]. Также набор инструкций описан в третьем томе руководства разработчика AMD [3].

Структура команды такова, что если у команды два операнда, они не могут оба находиться в памяти. Таким образом, если указано, что операнды могут быть

переменными в памяти или регистрами, то возможны комбинации регистр-память, память-регистр и регистр-регистр.

Если не указано иное, используются следующие обозначения. Операнд, принимающий значение (приёмник) может быть обозначен либо как $dest$, если он может быть регистром или переменной в памяти, либо как $dreg$ или $dmem$, если он может быть соответственно только регистром или только в памяти. Неизменяемый операнд (источник) может быть обозначен как src (регистр, переменная в памяти или непосредственное значение), srm (регистр или переменная в памяти), $sreg$ (регистр), $smem$ (переменная в памяти). Непосредственно адресуемая константа обозначается как imm.

Для большинства команд источник и приёмник должны быть одного размера. Это может быть байт, два байта и четыре байта (для шестидесятичетырёхбитных систем — до восьми байт).

Наиболее часто используемые команды доступны как в тридцатидвухбитном, так и в шестидесятичетырёхбитном режимах (`mov`, `lea` и т. д.); некоторые — только в шестидесятичетырёхбитном (в частности, `movabs`). Некоторые команды тридцатидвухбитного режима недоступны в шестидесятичетырёхбитном, но для аналогичных операций введены новые (`syscall` вместо `sysenter`).

Есть и такие команды, которые доступны в тридцатидвухбитном режиме, но полностью исключены из шестидесятичетырёхбитного. В частности, это команды коррекции двоично-десятичной арифметики, проверка выхода за границы `bound`, условный вызов прерывания `into` и другие [74].

В данном пособии описывается только малая часть доступных команд x86. В частности, во избежание путаницы в описание не вошли команды, полностью исключённые из шестидесятичетырёхбитного режима.

5.2.1. Общие команды

> Повесть строится из слов как строительной единицы здания.
>
> *В. Хлебников. Зангези*

В таблице 5.3 приведены некоторые наиболее употребительные команды x86-совместимых процессоров.

Команда `nop` ничего не делает и не изменяет флагов. Её опкод соответствует команде `xchg %al, %al`. Используется в основном для реализации малых задержек, а также компиляторами и программистами уровня архитектуры команд для выравнивания кода.

Команда `xchg`, в свою очередь, меняет местами значения источника и приёмника. Соответственно, источник не может быть непосредственным значением.

Основные общие команды

Таблица 5.3

Команда	Действие
`nop` `nop srm`	Ничего не делает *(no operation)*
`mov src, dest`	Присваивание $dest = src$ *(move)*
`movabs imm64, dreg64`	В 64-битном режиме присваивание абсолютного 64-битного адреса $dreg64 = imm64$
`lea smem, dreg`	Вычисление адреса $smem$ и запись его в $dreg$ $dreg = \&smem$ *(load effective address)*
`xchg srm, dest`	Обмен значений srm и $dest$
Работа со стеком	
`push src`	Помещение src в стек (уменьшает указатель стека)
`pop dest`	Выталкивание значение из стека в $dest$ (увеличивает указатель стека)

Присваивание и вычисление адреса

Наверное, самой популярной командой является команда пересылки `mov src, dest` — аналог оператора присваивания $dest = src$ языков высокого уровня. Рассмотрим некоторые примеры её работы:

```
movl $4, %eax   // eax = 4
movb $42, %al   // al = 42
movl %eax, (%esi)       // *esi = eax
movl %eax, 4(%esi)      // *(esi+4 байта) = eax
movl $some_var, %eax    // eax = &some_var
movl $some_var+4, %eax  // eax = &some_var+4 байта
movl some_var, %eax     // eax = some_var
movl %eax, foo  // foo = eax
```

Аналогом оператора получения адреса (оператор $\&$ в C++) является команда `lea`. Если `mov smem, dreg` загружает в регистр $dreg$ значение по адресу $smem$, то `lea smem, dreg` загружает в $dreg$ сам адрес $smem$.

Например, следующая команда загружает в A значение $*\big(bp + 4D - 4\big)$, используя косвенную адресацию — вычисление адреса из четырёх компонент с разыменованием:

```
movl    -4(%ebp, %edx, 4), %eax // A = *(bp + 4*D - 4)
```

Команда `lea` загружает в приёмник адрес источника, что компенсирует разыменование, то есть команда

```
leal    -4(%ebp, %edx, 4), %eax // A = bp + 4*D - 4
```

загружает в A значение $bp + 4D - 4$.

Адрес статической переменной в тридцатидвухбитном режиме (то есть при использованиями прямой абсолютной адресации) может быть загружен в регистр двумя способами — копированием адреса как тридцатидвухбитной константы или с помощью вычисления адреса:

```
movl $msg, %esi // si = &msg
leal  msg, %esi // si = &msg
```

Непосредственным операндом первой команды и смещением без базы во второй будет абсолютный тридцатидвухбитный адрес метки `msg`.

В шестидесятичетырёхбитном режиме предпочтительной является прямая относительная (rip-relative) адресация. В этом случае загрузка должна осуществляться командой `lea`:

```
lea msg(%rip), %rsi     // si = ip + (&msg - ip) = &msg
```

Смещением в соответствующей команде будет не абсолютный шестидесятичетырёхбитный адрес метки `msg`, а вычисленная ассемблером тридцатидвухбитная знаковая разность адреса `msg` и адреса следующей команды ip.

Использование в данной команде вместо rip любого другого регистра приведёт к тому, что в поле смещения будет записана не разность шестидесятичетырёхбитного адреса метки `msg` и значения базового регистра, а собственно адрес `msg` [61], причём усечённый до 32 бит:

```
lea msg(%rsp), %rsi     // si = sp + &msg
```

Таким образом, прямая относительная адресация не является частным случаем косвенной, хотя для их описания используется одна синтаксическая конструкция; эти виды адресации необходимо различать.

Если по какой-то причине требуется загрузить именно абсолютный шестидесятичетырёхбитный адрес как константу, это можно сделать командой `movabs`:

```
movabs $msg, %rsi       // si = &msg
```

Команда `mov` в шестидесятичетырёхбитном режиме может содержать не более чем тридцатидвухбитный непосредственный операнд.

Хотя операндом команды `lea` является указатель на адрес в памяти, этот адрес не обязан быть корректным и вообще существовать (ошибка доступа выдаётся при попытке чтения или записи по некорректному адресу, а не при вычислении его значения); соответственно, `lea` часто используется как команда целочисленной

арифметики для вычисления линейной комбинации $r_1+2^s\cdot r_2+\delta$, так как позволяет выполнить умножение на константу и сложение за один шаг:

```
leal    8(,%eax,4), %eax    // A = A*4 + 8
leal    (%eax,%eax,2), %eax // A = A*2 + A = A*3
```

В отличие от «настоящих» арифметических команд, `lea` не изменяет флагов.

Работа со стеком

Для работы со стеком предназначены в основном команды `push` и `pop`. Они работают только с операндами размером 4 или 2 байта, то есть указатель вершины стека всегда выравнен на 2 байта (его начальное значение делается двоично-круглым). В GNU/Linux стек по соглашению выравнен по $long$ (на 4 байта).

Команда `push src` помещает источник в стек. При этом указатель стека sp уменьшается на размер источника.

Таким образом, если попытаться смоделировать работу команды `push` при помощи команды пересылки, то, в частности `pushl $13` (здесь суффикс $l = long$ необходим, так как разрядность операнда невозможно определить без явного указания) эквивалентна последовательному уменьшению sp и записи значения в память:

```
sub  $4, %esp    // esp -= sizeof(long)
movl $13, (%esp) // *esp = 13
```

Комбинация команд изменения sp и пересылки неэффективна, так как она и выполняется медленнее, чем `push`, и занимает больше места в памяти. Тем не менее, иногда необходимо зарезервировать в стеке место для локальных переменных, начальное значение которых пока неизвестно. В этом случае можно воспользоваться командой `sub $size, %esp`.

Команда `pop dest` — извлечение значения из стека и помещение его в приёмник $dest$ — увеличивает указатель стека sp на размер приёмника.

Таким образом, `popl %eax` можно также выполнить с помощью команд:

```
1 movl (%esp), %eax // eax = *esp
2 add  $4, %esp     // esp += sizeof(int)
```

Комбинация команд изменения sp и пересылки здесь так же менее эффективна, чем `pop`. При этом отдельная команда `add $size, %esp` для удаления элемента или набора элементов из стека «в никуда» используется очень часто. Она быстрее, чем однократный вызов `pop`, так как не обращается к памяти; короче множественного вызова `pop`, а также не требует указания приёмника.

5.2.2. Передача управления, вызов и возврат

> Он один остался в живых. Он вошёл сквозь контуры двери.
> Он поднялся на башню. Он вышел в окно.
> И он сделал три шага — и упал не на землю, а в небо.
> Она взяла его на руки, потому что они были одно.
>
> *Б. Б. Гребенщиков. На её стороне*

Команды передачи управления (таблица 5.4) делятся на две основные группы. Некоторые из них просто замещают указатель команд новым адресом, то есть передают управление новому фрагменту кода аналогично оператору `goto` языка C++. Другие перед передачей управления запоминают адрес следующей по счёту команды, так что затем можно вернуться к выполнению последовательности команд. Такие команды соответствуют вызовам разного рода подпрограмм (в том числе функций, прерываний, системных вызовов); каждой из них соответствует своя команда возврата, которая должна находиться в конце соответствующей подпрограммы.

Простая передача управления

К командам «безвозвратной» передачи управления относятся команда безусловного перехода `jmp src` и семейство команд условного перехода `jCC src`. Команды условного перехода отличаются только тем, что передача управления осуществляется только при наличии некоторой комбинации флагов CC в регистре $flags$.

Операнд команд передачи управления src может быть непосредственным значением (обычно меткой $label$), регистром или памятью. В первом случае неявно используется прямая относительная адресация, так что в соответствующий машинный код включается не абсолютный адрес $label$, а смещение относительно текущего указателя команд $label - ip$. Это позволяет получить переносимый код.

Если операнд команды перехода находится в регистре или памяти, то это — абсолютный адрес перехода. Использование такой адресации позволяет выбирать адрес перехода во время выполнения программы.

Вызов и возврат

Команды вызова используются для передачи управления подпрограмме — последовательности команд, завершающихся командой возврата. Команды вызова и возврата всегда бывают парными.

Любая команда вызова сохраняет в определённом месте адрес той команды, которая следует за ней (адрес возврата), некоторые из них также сохраняют и другие

Команды передачи управления, вызова и возврата

Таблица 5.4

Команда	Действие
`jmp src`	Безусловный переход по адресу src ($goto\ src$)
`jCC src`	Условный переход по адресу src (если верно условие src)
Вызов и возврат из функций	
`call src`	Вызов подпрограммы — помещает в стек адрес следующей инструкции (адрес возврата) и переходит по адресу src
`ret [imm]`	Возврат из подпрограммы — снимает со стека адрес возврата и помещает его в указатель команд. Если указан параметр imm, снимает со стека ещё imm байтов.
Вызов и возврат из программного прерывания	
`int imm8`	Вызов прерывания с номером $imm8$ — помещает в стек флаги $flags$, затем адрес возврата, после чего переходит к обработчику прерывания $imm8$
`iret`	Возврат из прерывания — снимает со стека адрес возврата и флаги, возвращает к прерванной программе
Вызов и возврат из системного вызова (32 бита)	
`sysenter`	Быстрый системный вызов
`sysexit`	Возврат из системного вызова
Вызов и возврат из системного вызова (64 бита)	
`syscall`	Быстрый системный вызов
`sysret`	Возврат из системного вызова

данные (флаги, указатель стека и т. д). Парная к ней команда возврата восстанавливает сохранённые элементы и помещает в указатель команд адрес возврата. Таким образом, после выполнения подпрограммы управление перейдёт обратно к вызвавшей её программе и продолжится именно с той команды, которая следует за командой вызова.

Для вызова подпрограммы любого вида (функции или системного вызова) допустимо использовать только ту команду, которая является парной к завершающей эту подпрограмму команде возврата. В противном случае произойдёт крах.

Команды вызова и возврата не осуществляют передачу в подпрограмму параметров и возврат значения. Эти действия выполняются вручную и регламентируются соглашениями о вызовах (подробнее механизм вызова рассматривается в разделе 6.2).

В систему команд x86 входят три пары команд вызова/возврата.

1. Команды `call/ret` предназначены для вызова функций и процедур, описанных в самой программе и прикладных библиотеках.
2. Команды `int/iret` предназначены для программного обращения к прерыванию.
   В современной прикладной программе явный вызов программного прерывания обычно используется только для обращения к ядру операционной системы (системного вызова, подробнее в разделе 6.2.9).
3. Команды, предназначенные специально для системных вызовов.
   В тридцатидвухбитном режиме это `sysenter/sysexit`, в шестидесятичетырёхбитном — `syscall/sysret`.

Вызов и возврат из функций

Вызов функции в ассемблере выполняется командой `call`. Эта команда имеет один операнд — адрес подпрограммы в памяти.

Команда `call foo` сохраняет указатель команд в стеке, управление передаётся foo. Возврат из подпрограммы выполняется командой `ret`, которая должна находиться в конце кода подпрограммы. — управление передаётся адресу, снятому со стека.

В листинге 5.9 показана подпрограмма $foo()$, прибавляющая к значению регистра eax константу 5, а также её вызов.

Листинг 5.9. Функция и её вызов

```
1 // Вызывающая программа
2   movl $10, %eax
3   call foo
4   // теперь %eax == 15
5 ...
6 // Функция foo()
7 foo:
8   addl $5, %eax
9   ret
```

Так же, как и для команд перехода `jmp/jCC`, если операндом команды `call` является метка $label$, неявно используется прямая относительная адресация (в машинный код включается смещение относительно текущего указателя команд $label - ip$), а если операнд в регистре или памяти — это абсолютный адрес перехода, задаваемый соответственно регистровой или косвенной адресацией.

Вызов подпрограммы по указателю применяется, в частности, для реализации механизма виртуальных функций, адрес которых выбирается из таблицы виртуальных методов на этапе выполнения программы.

Вызов и возврат из прерывания

Для вызова прерывания необходимо указать его восьмибитный номер $imm8$ (то есть номера прерываний могут принимать значения от 0 до 255). Каждому номеру прерывания соответствует специальный системный регистр, содержащий адрес обработчика этого прерывания.

Команда вызова прерывания `int imm8` помещает в стек сначала регистр флагов $flags$, затем адрес возврата. Если обработчик выполняется с привилегиями ядра операционной системы, в специальном регистре сохраняется также указатель стека, так как система использует другой стек. После этого управление передаётся обработчику прерывания $imm8$.

Команда возврата из прерывания `iret` восстанавливает указатель стека (при необходимости), флаги и передаёт управление по адресу возврата (из стека при этом извлекаются оба помещённых туда командой `int` машинных слова).

Необходимо отметить, что в документации AMD команда вызова программного прерывания `int` относится к командам общего назначения, а соответствующая команда возврата `iret` — к системным [3].

Один из номеров прерываний в тридцатидвухбитных операционных системах обычно используется для системных вызовов.

Вызов и возврат из системных вызовов

Начиная с Pentium II, доступна предложенная Intel команда `sysenter`, ускоряющая обращение к ядру. Адрес возврата и другие сохраняемые данные помещаются командой `sysenter` в специальные регистры, что быстрее обращения к памяти. В конце обработчика системного вызова их восстанавливает команда `sysexit`.

В шестидесятичетырёхбитном режиме использование команды `sysenter` невозможно.

Для быстрого обращения к функциям ядра в шестидесятичетырёхбитном режиме применяется команда `syscall`, предложенная AMD. Она также сохраняет данные для возврата в регистрах. Для возврата из системного вызова в шестидесятичетырёхбитном режиме предназначена команда `sysret`.

Отметим, что команда возврата из системного вызова (`sysexit` или `sysret`) используется только в обработчике этого вызова, то есть в коде ядра операционной системы.

Конкретная команда, используемая для системного вызова (`int`, `sysenter` или `syscall`), определяется используемым ядром. Используемые в Linux команды и соглашения системных вызовов описаны в разделе 6.2.9.

5.2.3. Обнуление регистра

— Начало? — лицо Эдуарда приобрело обиженное выражение. — То есть к нулю? Но это же вырожденный случай!

А. В. Жвалевский, И. Е. Мытько. Сестрички и другие чудовища

Исторически для обнуления регистров использовались команды побитового исключающего «или» с одинаковыми операндами `xor %reg, %reg` и вычитания регистра из самого себя `sub %reg, %reg`, так как они выполнялись быстрее команды пересылки `mov $0, %reg`, а также занимали меньше места. Зависимость по данным в ранних моделях процессора не имела значения, так как вычисления не были конвейеризированы.

После введения конвейера традиция обнуления регистров командами `xor` и `sub` сохранилась. Поэтому в современных моделях процессоров команды обнуления регистров (zero idioms) распознаются при декодировании и выполняются как не имеющие зависимостей по данным.

Таким образом, сейчас руководство по оптимизации Intel [15] снова рекомендует использовать для обнуления регистров общего назначения команды:

```
1 xor %reg, %reg
2 sub %reg, %reg
```

Для регистров расширения XMM распознаются следующие команды обнуления:

```
1 xorps/pd  %xmmreg,  %xmmreg
2 pxor  %xmmreg,  %xmmreg
3 subps/pd  %xmmreg,  %xmmreg
4 psubb/w/d/q  %xmmreg,  %xmmreg
```

Для некоторых архитектур используются и другие команды обнуления регистров расширения X/Y/ZMM [15].

При этом команды `xor` и `sub`, не распознающиеся как zero idioms, выполняются медленнее из-за зависимости по данным (даже если результатом будет ноль).

5.2.4. Команды целочисленной арифметики

В одном потоке чехарды
Игра числа и чисел сроки.

В. Хлебников. Зангези

Из-за ограниченного количества операндов в системе команд x86 практически нет привычных по языкам высокого уровня неразрушающих арифметических

операторов. Один из операндов, как правило, используется и как исходное данное, и как ячейка для записи результата. В частности, аналогом ассемблерной команды сложения `add src, dest` в C++ будет не оператор «плюс», не изменяющий свои операнды ($dest = src_1 + src_2$), а оператор «+=» ($dest \mathrel{+}= src$, то есть $dest = dest + src$).

Некоторые команды, предназначенные для обработки целых чисел, перечислены в таблице 5.5. Также в таблице 5.5 представлены команды, которые часто используются для выполнения арифметических операций над целыми числами, но не относятся к арифметическим — вычисление эффективного адреса `lea` и битовые сдвиги.

Команды сложения и вычитания

К этой группе, кроме собственно сложения и вычитания, относятся также команды сравнения и изменения знака. В некоторых источниках [75] к командам сложения и вычитания относят также команды инкремента и декремента. которые выставляют только пять из шести флагов состояния (PF, AF, ZF, SF, OF).

Команда сравнения `cmp src, dest` эквивалентна команде вычитания `sub src, dest`, но не изменяет приёмник — только выставляет флаги в соответствии со знаком разности $dest - src$. Команды инкремента (увеличения приёмника $dest$ на единицу) и декремента (уменьшения на единицу) выполняются быстрее, чем добавление или вычитание единицы командами `add/sub` и не меняют флаг CF.

Как было сказано в разделе 2.5, представление отрицательных чисел выбиралось так, чтобы знаковые числа можно было складывать и вычитать с помощью беззнакового сумматора. Соответственно, операции сложения и вычитания не делятся на знаковые и беззнаковые. Команды из группы сложения и вычитания выставляют значения всех шести флагов состояния (CF, PF, AF, ZF, SF, OF) соответственно результату, так что программист, понимая, какого рода числа он обрабатывает, может выбрать для анализа нужные флаги.

Числа, разрядность которых превышает разрядность системы, при необходимости можно складывать и вычитать по частям. Для этого вначале младшие части обрабатываются командами `add/sub`, затем к остальным в порядке возрастания адресов — `adc/sbb`, учитывающие перенос из младшей части. Части могут иметь любую разрядность (в частности, шестибайтовые целые можно разбить на две части — четыре и два байта или на шесть однобайтовых), но логичнее использовать четырёхбайтовые части на тридцатидвухбитной системе и восьмибайтовые — на шестидесятичетырёхбитной.

Команды целочисленной арифметики

Таблица 5.5

Команда	Действие
`inc dest`	Инкремент $++dest$ $(dest = dest + 1)$
`dec dest`	Декремент $--dest$ $(dest = dest - 1)$
Сложение и вычитание	
`add src, dest`	Сложение $dest \mathrel{+}= src$ $(dest = dest + src)$
`adc src, dest`	Сложение с переносом из предыдущей части $dest \mathrel{+}= src + CF$ $\Big(dest = dest + (src + CF)\Big)$
`sub src, dest`	Вычитание $dest \mathrel{-}= src$ $(dest = dest - src)$
`cmp src, dest`	Вычитание $dest - src$ без изменения $dest$ (сравнение $dest$ и src)
`sbb src, dest`	Вычитание с переносом из предыдущей части $dest \mathrel{-}= src + CF$ $\Big(dest = dest - (src + CF)\Big)$
`neg dest`	Изменение знака $dest = -dest$
Расчёт линейной комбинации	
`lea` δ`(r1,r2,`σ`), dreg`	$dreg = r1 + \sigma \cdot r2 + \delta$ (не изменяет флагов)
Умножение и деление	
`mul srm`	Беззнаковое умножение $D{:}A = A \cdot srm$ (таблица 5.6)
`imul srm`	Знаковое умножение $D{:}A = A \cdot srm$ (таблица 5.6)
`imul srm, dreg`	Умножение $dreg \mathrel{*}= srm$ $(dreg = dreg \cdot srm)$
`imul imm, srm, dreg`	Знаковое умножение $dreg = imm \cdot srm$
`div srm`	Беззнаковое деление с остатком (таблица 5.6) $\begin{cases} A = (D{:}A)/srm \\ D = (D{:}A)\%srm \end{cases}$
`idiv srm`	Знаковое деление с остатком (таблица 5.6) $\begin{cases} A = (D{:}A)/srm \\ D = (D{:}A)\%srm \end{cases}$
Масштабирование (битовый сдвиг)	
`shr times, dest`	Беззнаковое деление $dest \mathrel{/}= 2^{times}$
`sar times, dest`	Знаковое математическое деление $dest \mathrel{/}= 2^{times}$ (остаток предполагается неотрицательным)
`shl times, dest` `sal times, dest`	Умножение $dest \mathrel{*}= 2^{times}$

Вычисление линейной комбинации регистров

Также для арифметических вычислений используется команда вычисления эффективного адреса `lea`, которая, в соответствии с возможностями косвенной

адресации, может рассчитать выражение $dreg = r1 + \sigma \cdot r2 + \delta$, где $dreg, r1, r2$ — регистры, σ — константа 1, 2, 4 или 8, δ — произвольная тридцатидвухбитная константа (может быть опущен любой из регистров и любая из констант).

Команда `lea` предназначена для манипуляций с беззнаковыми данными (указателями), но смещение δ интерпретируется как знаковое. Так как разрядность $r1$ и $r2$ совпадает с разрядностью результата $dreg$, результат совпадает со знаковым.

В отличие от «настоящих» арифметических команд, `lea` не изменяет флагов.

Команды умножения и деления

Самые старые команды умножения рассчитывают произведение заданного множителя srm на неявный операнд — регистр A той же разрядности, что и srm. Разрядность произведения при этом вдвое больше разрядности множителей, так что младшая половина $A \cdot srm$ помещается в регистр A на место неявного множителя, а старшая — в регистр D той же разрядности. Исключением является случай с восьмибитными множителями — так как на момент появления команд умножения уже существовали шестнадцатибитные регистры, результат $al \cdot srm$ размещается в ax (таблица 5.6). Старшая половина результата отличается для знаковой и беззнаковой интерпретации множителей, так что существуют две команды описанного действия — `mul` для беззнакового умножения и `imul` для знакового.

Команды умножения и деления неявного аргумента A

Таблица 5.6

Размер srm	**Действие** `[i]mul srm`	**Действие** `[i]div srm`
4 байта	$edx : eax = eax \cdot srm$	$\begin{cases} eax = (edx : eax)/srm \\ edx = (edx : eax)\%srm \end{cases}$
2 байта	$dx : ax = ax \cdot srm$	$\begin{cases} ax = (dx : ax)/srm \\ dx = (dx : ax)\%srm \end{cases}$
1 байт	$ax = al \cdot srm$	$\begin{cases} al = ax/srm \\ ah = ax\%srm \end{cases}$

Введённая позже команда `imul srm, dreg` рассчитывает только младшую половину произведения, а она совпадает для знаковых и беззнаковых чисел. Таким образом, двухоперандную форму команды `imul` можно использовать и для знакового, и для беззнакового умножения.

Трёхоперандная форма `imul imm, srm, dreg` также рассчитывает только младшую половину произведения, но перед этим константа `imm` при необходимости расширяется. Данная форма соответствует двум опкодам — с константой `imm`, разрядность которой соответствует разрядности источника и приёмника (в этом случае расширение не требуется) и с восьмибитной константой `imm8` [17]. Во

втором случае случае imm8 расширяется как знаковое, поэтому трёхоперандную форму imul следует считать командой знакового умножения.

Если произведение помещается в младшей половине произведения, все формы команд mul/imul сбрасывают оба флага CF и OF. Если в старшей половине есть значащие биты (для двух- и трёхоперандной форм imul это значит, что результат некорректен), оба этих флага взводятся [53]. Значения флагов нуля и знака не определены [75].

Для деления существуют только однооперандная форма. Делимое (неявный операнд) всегда вдвое больше делителя (явного операнда srm) и располагается в паре регистров $D:A$ (старшая половина — в D, младшая — в A), кроме случая восьмибитного делителя (таблица 5.6). Необходимо помнить об этом и корректно инициализировать регистр D перед делением.

Таким образом, команды деления обратны однооперандной форме умножения. Соответственно, деление также будет беззнаковым (div) и знаковым (idiv).

После деления $D:A$ на srm частное помещается на место младшей половины делимого (в A), остаток — на место старшей половины (в D). Если старшая половина делимого содержит значащие биты, возможна ситуация, когда частное не помещается в отведённом для него регистре. Соответственно, результат деления будет некорректным.

Масштабирование (умножение и деление на 2)

Умножение и деление на 2^{times} ($times$ трактуется как беззнаковое число) может также быть выполнено с помощью битовых сдвигов (раздел 5.2.5).

Умножение на 2^{times} выполняется сдвигом влево (shl/sal), беззнаковое деление — беззнаковым сдвигом вправо (shr). Остаток при делении сдвигом не вычисляется (при делении сдвигом на 2 однобитовый остаток равен CF). Необходимо отметить, что знаковый сдвиг вправо соответствует математическому определению деления с остатком (остаток предполагается неотрицательным даже при $dest < 0$), а не тому, что реализовано в команде div (подробнее см. раздел 2.7.3).

Расширение целых чисел

Также к командам целочисленной арифметики можно отнести команды расширения (таблица 5.7).

Современная система команд x86 включает два вида команд, которые используются для расширения — пересылка из источника малой разрядности в приёмник большей и удвоение разрядности неявного операнда в регистре A.

Существует две команды пересылки с расширением — movz для беззнакового расширения (дополнения нулями) и movs для знакового (дополнения знаковым

Команды расширения (увеличения разрядности)

Таблица 5.7

Команда	Действие
`movz srm, dreg`	$dreg = srm$ с беззнаковым расширением (размер srm меньше $dreg$)
`movs srm, dreg`	$dreg = srm$ со знаковым расширением (размер srm меньше $dreg$)
`cStD`	Знаковое расширение регистра A (таблица 5.8)

битом). Некоторые версии GCC, а также документация Intel, используют для них соответственно мнемоники `movzx` и `movsx`.

В отличие от простой пересылки `mov`, для команд пересылки с расширением приёмник может быть только регистром, источник — регистром или переменной в памяти.

При пересылке возможно увеличение разрядности более чем в два раза, поэтому, если источник находится в памяти, для команды обязательно нужно указывать два суффикса (раздел 5.1.5).

Также существует набор команд для удвоения разрядности неявного операнда в регистре A (таблица 5.8).

Мнемоники команд знакового расширения A

Таблица 5.8

Размер	Расширение в регистр A			Расширение в пару $D:A$		
	Действие	**Intel**	**AT&T**	**Действие**	**Intel**	**AT&T**
$8 \to 16$	$al \to ax$	cbw	cbtw	—		
$16 \to 32$	$ax \to eax$	cwde	cwtl	$ax \to dx:ax$	cwd	cwtd
$32 \to 64$	$eax \to rax$	cdqe	cltq	$eax \to edx:eax$	cdq	cltd
$64 \to 128$	—			$rax \to rdx:rax$	cqo	cqto

Практически для всех случаев есть две команды — расширение A до A вдвое большей разрядности и расширение A до пары $D:A$. Последний вариант необходимо использовать перед командами, использующими пару регистров $D:A$ как источник, в частности, командами деления $(D:A)/srm$.

Для команд удвоения разрядности регистра A есть два набора мнемоник — исторически используемые в ассемблере Unix (AT&T) и предложенные Intel.

Мнемоники AT&T для команд удвоения разрядности регистра A строятся по схеме $cStD$ (convert S to D), где S — размер источника, D — размер приёмника или символ d для пары регистров (кроме `cqto`).

Мнемоники Intel построены по одной из двух схем — cSD или $cSDe$. Исторически на шестнадцатибитных машинах первыми доступными вариантами удвоения были $al \to ax$ и $ax \to dx : ax$, так что они получили имена без суффикса e. В дальнейшем суффикс e использовался для расширения $A \to A$, а расширение $A \to D : A$ выполняется командой без суффикса.

Для команд удвоения разрядности A GAS поддерживает оба набора мнемоник — AT&T и Intel — перечисленные в таблице 5.8.

Увеличить разрядность неявного операнда A более чем в два раза с помощью команд таблицы 5.8 можно только последовательным применением нескольких команд удвоения.

Все команды удвоения разрядности A выполняют знаковое расширение. Беззнаковое расширение $A \to D : A$ может быть выполнено явным обнулением регистра D.

5.2.5. Битовые операции

Она может двигать,
Она может двигать собой,
В полный рост —
Она знает толк в полный рост

Б. Б. Гребенщиков. Она может двигать

Некоторые команды, предназначенные для обработки битовых строк, перечислены в таблице 5.9.

Система команд x86 включает поразрядные логические операции, все описанные в разделе 2.7 битовые сдвиги, а также команды выделения бита по номеру.

Поразрядные логические операции «и», «или», «не» и «исключающее или» изменяют в соответствии с полученным результатом три флага состояния — флаги нуля, знака и чётности.

Команды битового сдвига принимают два операнда: сдвигаемое значение $dest$ и беззнаковое количество сдвигов $times$. Количество $times$ может быть непосредственным значением или регистром cl, причём даже в шестидесятичетырёхбитных системах используются только младшие шесть его бит (в тридцатидвухбитных — пять).

При $times = 1$ происходит сдвиг в указанную сторону на один бит. Значение бита, вышедшего за разрядную сетку, после выполнения команды заносится в CF. Освободившаяся с другого конца $dest$ ячейка инициализируется в соответствии с видом сдвига.

При $times > 1$ однобитовый сдвиг повторяется $times$ раз.

Знаковый и беззнаковый сдвиги используется для быстрого умножения и деления на степени двойки. Сдвиги вправо эквивалентны соответственно знаковому

Основные битовые операции

Таблица 5.9

Команда	Действие
Поразрядные операции	
`not dest`	Побитовая инверсия $dest = \sim dest$
`and src, dest`	Побитовое «и» $dest \,\&= src \;\; (dest = dest \;\&\; src)$
`test src, dest`	Побитовое «и» $dest \;\&\; src$ без изменения $dest$
`or src, dest`	Побитовое «или» $dest \,\vert= src \;\; (dest = dest \,\vert\, src)$
`xor src, dest`	Побитовое «исключающее или» $dest \,\hat{}= src \;\; (dest = dest \,\hat{}\, src)$
Битовые сдвиги	
`shr times, dest`	Беззнаковый (логический) сдвиг вправо $dest = (unsigned) dest >> times$ Освободившиеся старшие разряды заполняются нулями, младшие теряются, кроме последнего, который попадает в CF
`sar times, dest`	Знаковый (арифметический) сдвиг вправо $dest = (signed) dest >> times$ Освободившиеся старшие разряды заполняются знаковым битом, младшие теряются, кроме последнего, который попадает в CF
`shl times, dest` `sal times, dest`	Сдвиг влево (`shl` и `sal` — синонимы) $dest = dest << times$ Освободившиеся младшие разряды заполняются нулями, старшие теряются, кроме последнего, который попадает в CF
`ror times, dest`	Циклический сдвиг $dest$ вправо
`rol times, dest`	Циклический сдвиг $dest$ влево
`rcr times, dest`	Циклический сдвиг через флаг переноса $dest \cup CF$ вправо
`rcl times, dest`	Циклический сдвиг через флаг переноса $dest \cup CF$ влево
Загрузка idx-го бита числа во флаг CF	
`bt idx, dest`	$CF = dest[idx]$
`btc idx, dest`	$CF = dest[idx]$ с последующей инверсией бита $dest[idx] = \neg dest[idx]$
`btr idx, dest`	$CF = dest[idx]$ с последующим сбросом бита $dest[idx] = 0$
`bts idx, dest`	$CF = dest[idx]$ с последующей установкой бита $dest[idx] = 1$

(в этом случае остаток предполагается неотрицательным как для положительных, так и для отрицательных делимых) или беззнаковому делению на 2^{times}. В случае однобитового сдвига (деления на два) остаток попадает в CF. Для бóльших значений сдвига остаток не вычисляется.

Сдвиг влево эквивалентен умножению на 2^{times}, если результат умножения помещается в $dest$. Если не помещается, старшая часть произведения теряется.

Кроме того, с помощью команд семейства `btX` можно выделить отдельный бит числа. Эти команды принимают два операнда — число-приёмник, один бит которого будет скопирован в флаг CF и затем изменён, и номер бита idx — непосредственное значение или регистр. Для младшего бита $idx = 0$. Одна из команд семейства, `bt`, не изменяет значение битов в числе, но для единообразия её операнд, из которого выделяется бит, также считается приёмником.

5.2.6. Флаги

Грудью вперёд бравой!
Флагами небо оклеивай!

В. В. Маяковский. Левый марш

Все арифметические команды устанавливают по результатам вычислений флаги состояния.

Команды группы *сложения/вычитания* (`add/sub` и т. д., но не `inc/dec`) выставляют все шесть флагов состояния CF, PF, AF, ZF, SF, OF в соответствии с результатом:

- флаг переноса (беззнакового переполнения) CF в случае переноса/заёма за пределы разрядной сетки (беззнакового переполнения);
- флаг чётности PF, если количество единиц в младшем байте результата чётно;
- флаг вспомогательного переноса AF, если в младшем байте был перенос между тетрадами;
- флаг нуля ZF, если результат равен нулю;
- флаг знака SF, если старший (знаковый) бит результата равен 1;
- флаг знакового переполнения OF, если произошло знаковое переполнение (перенос/заём из знакового бита, но не за пределы разрядной сетки, или наоборот).

Команды `inc/dec` не меняют CF, выставляя PF, AF, ZF, SF, OF.

При этом `add $-1, dest` и `sub $1, dest` устанавливают флаги по-разному, в частности, при сложении числа `-1` (что на 32-разрядной платформе равно `0xFFFFFFFF`) с нулём не происходит переноса в старший бит ($OF = 0$); при вычитании единицы из нуля возникает заём из старшего бита ($OF = 1$).

Побитовые команды (`and, or, xor`) выставляют флаги SF, ZF и PF в соответствии с результатом аналогично группе сложения/вычитания, флаги переноса и знакового переполнения сбрасываются: $CF = OF = 0$. Значение флага AF не определено.

Команды *умножения* выставляют флаги $CF = OF$ в зависимости от того, выходит ли результат за разрядность множителей. Значение остальных флагов

не определено. После команд *деления* все шесть флагов имеют неопределённое значение.

Существуют команды, которые только выставляют флаги и не меняют значения своих операндов. Они предназначены для сравнения чисел. Это:

– `cmp` — то же самое, что и `sub` (группа сложения/вычитания), но операнд-приёмник не изменяется (используется для сравнения целых чисел);
– `test` — то же самое, что и `and` (группа побитовых операций), но операнд-приёмник не изменяется (используется для сравнения битовых строк).

Основной набор инструкций x86 не содержит команд для обработки и, в частности, сравнения вещественных чисел. Предназначенные для этого инструкции сравнения относятся к набору команд FPU (раздел 5.3.7), но могут взаимодействовать с регистром $flags$. Вещественные числа можно сравнить командой `fcomi` и подобными ей. После сравнения флаги состояния сопроцессора копируются в $flags$ (вручную или автоматически — в зависимости от используемой команды сравнения) таким образом, что результат сравнения можно анализировать так же, как для целых беззнаковых чисел: ZF указывает на равенство, CF — на $dest < src$; кроме того, в PF копируется флаг несравнимости операндов.

Кроме того, флаги можно установить или сбросить вручную с помощью специальных команд или загрузив изменённый регистр $flags$ (таблица 5.10).

Команды обработки флагов

Таблица 5.10

Команда	Действие
Установка отдельных флагов	
`stc/clc/cmc`	Установка (set, $CF = 1$)/сброс (clear, $CF = 0$)/инверсия ($CF =! CF$) флага переноса CF
`std/cld`	Установка/сброс флага направления DF
`sti/cli`	Установка/сброс флага разрешения прерываний IF
Обработка $flags$ в целом или фрагментов	
`lahf/sahf`	Сохранение младшего байта $flags$ в ah/загрузка ah в $flags$
`pushf/pushfd/pushfq`	Загрузить младшие 16/32/64 бита $flags$ в стек
`popf/popfd/popfq`	Выгрузить 16/32/64 бита из стека в $flags$ (в младшую часть)

Младший байт регистра флагов, содержащий большую часть флагов состояния, можно загрузить для анализа в регистр ah командой `lahf` *(Load Flags into AH Register)*. Обратная операция выполняется командой `sahf` *(Store AH into Flags)*. Регистр $flags/eflags$ можно полностью поместить в стек командами `pushf/pushfd`, загрузить из стека — командами `popf/popfd` соответственно. При загрузке флагов из ah или стека зарезервированные биты не загружаются в $flags$.

5.2.7. Условные команды

Жезлом
правит,
чтоб вправо
шёл.
Пойду
направо.
Очень хорошо.

В. В. Маяковский. Хорошо!

Существует несколько семейств команд, действие которых определяется значением флагов состояния в регистре $flags$. Это команды условного перехода `jCC`, условной установки байта `setCC` и условной пересылки `cmovCC` и `fcmovCC`.

Команда `fcmovCC` относится к набору команд FPU и описана также в разделе 5.3.4 (таблица 5.15), но условие CC определяется значением регистра $flags$, а не собственного регистра состояния FPU.

Мнемоники таких команд состоят из двух частей — общего для всех команд семейства обозначения действия (`j` от *jump,* `set` и т. п.) и обозначения условия CC. Условие не может быть произвольным. Существует определённый набор обозначений CC, каждому из которых соответствует некоторое состояние флагов в регистре $flags$ — условие.

Условия

Рассмотрим доступные варианты условий, их обозначения и связь с арифметическими операциями (таблица 5.11).

Каждое из условий имеет некоторое буквенное обозначение CC, приведённое в первом столбце. Одно и то же условие может обозначаться по-разному, в частности, «меньше или равно» — `le` и «не больше» — `ng`, но машинный код в таких случаях одинаков. Различные обозначения одного условия помещены в одну ячейку таблицы и разделяются косой чертой.

Мнемоники одного семейства с разными условиями, в частности, условные переходы `je` и `jl`, ассемблируются в разные машинные коды.

Условие складывается из некоторой комбинации флагов состояния в регистре $flags$, указанной во втором столбце. Эти флаги определяются результатом последней команды. Различные виды арифметических команд выставляют их в соответствии с полученным результатом (см. раздел 5.2.6). В частности, команды группы сложения/вычитания изменяют все шесть флагов состояния (часто используемые для реализации цикла команды `inc/dec` — все, кроме CF); побитовые команды — флаги SF, ZF и PF. В третьем столбце таблицы указаны свойства результата, приводящие к подобному сочетанию флагов.

Условия и их связь с флагами состояния $flags$

Таблица 5.11

CC	Флаги	Арифметика	sub src, dest / cmp src, dest
`e/z`	$ZF = 1$	Результат равен нулю *if zero*	$dest = src$ $src = dest$ *if equal*
`ne/nz`	$ZF = 0$	Результат не равен нулю *if not zero*	$dest \neq src$ $src \neq dest$ *if not equal*
`c/` `b/nae`	$CF = 1$	Есть беззнаковое переполнение *if carry*	$dest < src$ как беззнаковое $src > dest$ *if below / if not above or equal*
`be/na`	$\begin{bmatrix} CF = 1 \\ ZF = 1 \end{bmatrix}$	Есть беззнаковое переполнение или результат равен нулю	$dest \leqslant src$ как беззнаковое $src \geqslant dest$ *if below or equal / if not above*
`nc/` `nb/ae`	$CF = 0$	Нет беззнакового переполнения *if not carry*	$dest \geqslant src$ как беззнаковое $src \leqslant dest$ *if not below / if above or equal*
`nbe/a`	$\begin{cases} CF = 0 \\ ZF = 0 \end{cases}$	Нет беззнакового переполнения и результат не равен нулю	$dest > src$ как беззнаковое $src < dest$ *if not below or equal / if above*
`s`	$SF = 1$	Старший (знаковый) бит результата равен 1	*if sign*
`ns`	$SF = 0$	Старший (знаковый) бит результата равен 0	*if not sign*
`o`	$OF = 1$	Есть знаковое переполнение	*if overflow*
`no`	$OF = 0$	Нет знакового переполнения	*if not overflow*
`l/nge`	$SF \neq OF$	Результат отрицателен (знак равен 1 и корректен или равен 0, но некорректен)	$dest < src$ как знаковое $src > dest$ *if less / if not greater or equal*
`le/ng`	$\begin{bmatrix} SF \neq OF \\ ZF = 1 \end{bmatrix}$	Результат отрицателен или равен нулю	$dest \leqslant src$ как знаковое $src \geqslant dest$ *if less or equal / if not greater*
`nl/ge`	$SF = OF$	Результат неотрицателен (знак равен 0 и корректен или равен 1, но некорректен)	$dest \geqslant src$ как знаковое $src \leqslant dest$ *if not less / if greater or equal*
`nle/g`	$\begin{cases} SF = OF \\ ZF = 0 \end{cases}$	Результат положителен (неотрицателен и не равен нулю)	$dest > src$ как знаковое $src < dest$ *if not less or equal / if greater*
`p/pe`	$PF = 1$	Число единичных бит младшего байта результата чётно *if parity / if parity even*	
`np/po`	$PF = 0$	Число единичных бит младшего байта результата нечётно *if not parity / if parity odd*	
`u`	$PF = 1$	src и $dest$ несравнимы (только для `fcmovCC`)	*if unordered*
`nu`	$PF = 0$	src и $dest$ сравнимы (только для `fcmovCC`)	*if not unordered*

Часто перед условной командой вызывается команда сравнения `cmp src, dest`, выставляющая флаги аналогично команде `sub src, dest` (то есть её результатом будет $dest - src$), но не изменяющая $dest$. В четвёртом столбце указаны соотношения между $dest$ и src для каждого условия. Большинство обозначений условий образовано именно от них.

Для *беззнаковых* операндов $dest$ и src признаком отрицательности результата $dest - src$ (то есть соотношения $dest < src$) будет заём в старший бит при вычитании, то есть беззнаковое переполнение $CF = 1$. Равенство операндов достигается при $dest - src = 0$, что отмечается флагом нуля $ZF = 1$. Соответственно, $dest > src$ может быть, если $dest \not< src$ и при этом $dest \neq src$, то есть $CF = ZF = 0$. Таким образом, любое соотношение между беззнаковыми операндами можно выразить через флаги CF и ZF.

Чтобы отличить условия знакового и беззнакового сравнения, для беззнакового вместо термина «меньше» часто используется термин «ниже» *(below)*, вместо «больше» — «выше» *(above)*. Соответственно, условие $CF = 1$, когда $dest - src < 0$ и $dest < src$, обозначается как `b` *(below)*, а $CF = 0$, то есть $dest - src \geqslant 0$ и $dest \geqslant src$ — как `ae` *(above or equal)*.

Для *знаковых* операндов знак результата невозможно определить только по знаковому биту (флагу SF), так как этот бит может быть искажён знаковым переполнением. То есть если знак равен единице ($SF = 1$), но в процессе вычислений произошло знаковое переполнение ($OF = 1$), то знаковый бит неверен и результат на самом деле положителен. Таким образом, результат будет отрицательным в двух случаях: $\begin{cases} SF = 1 \\ OF = 0 \end{cases}$ (знаковый бит — единица и переполнения не было) и $\begin{cases} SF = 0 \\ OF = 1 \end{cases}$ (было переполнение и знаковый бит — ноль). Обычно это условие записывается в виде $SF \neq OF$. Отрицательность результата команды сравнения $dest - src$ означает, что $dest < src$ как знаковое, так что условие $SF \neq OF$ записывается как `l` *(less)*.

Соответственно, при $SF = OF$ знаковый результат неотрицателен, а для команды сравнения $dest - src \geqslant 0$ означает $dest \geqslant src$ — `ge` *(greater or equal)*.

Флаг переноса CF используется многими командами «не по назначению», поэтому, кроме обозначений `b`/`nae` и `nb`/`ae`, условия $CF = 1$ и $CF = 0$ имеют синонимы `c` и `nc` (эти синонимы не могут быть использованы для условной пересылки вещественных чисел `fcmovCC`).

После сравнения вещественных чисел флаг вещественной несравнимости выгружается в бит PF регистра $flags$, поэтому для команд условной пересылки вещественных чисел (и только для них) условие $PF = 1$ записывается как `u` (операнды несравнимы), а $PF = 0$ — как `nu` (операнды сравнимы).

Условные и безусловные переходы

В системе команд x86, а соответственно, и в языке ассемблера, нет операторов, аналогичных операторам C++ `if`, `while`, `for` и т. п. Ветвления и циклы реализуются при помощи команд условного и безусловного перехода [53].

В таблице 5.12 приведены эти команды.

Команды передачи управления

Таблица 5.12

Команда	Действие
`jmp label`	Безусловный переход (*goto*) по адресу *label*
`jCC label`	Переход по адресу *label*, если верно условие CC (кроме `u` и `nu`)

Безусловный переход `jmp` является аналогом оператора `goto` языка C++ — передаёт управление команде по адресу *label*.

Команды условного перехода `jCC` передают адресу *label* при выполнении какого-либо условия (чаще всего при определённой комбинации флагов в регистре $flags$). Если условие не выполнено, `jCC` не делает ничего, и выполняется команда, следующая за `jCC` по тексту программы.

Условие CC может быть любым из перечисленных в таблице 5.11, кроме `u` и `nu` (но могут использоваться `p`/`pe` и `np`/`po`).

В частности, команда `jnae label` *(jump if not above or equal)* передаст управление на метку *label* в случае $CF = 1$. Если перед командой условного перехода выполнялась команда `cmp src, dest`, управление будет передано на метку *label* в случае, если $dest \not\geqslant src$ как беззнаковые числа. Это условие эквивалентно $dest < src$. Действительно, команды `jnae` и `jb` *(jump if below)* имеют один и тот же опкод. Также этот опкод соответствует мнемонике `jc` *(jump if carry)*.

Кроме того, в набор инструкций современных процессоров входят унаследованные от Intel 8086 команды псевдоцикла `loop`, псевдоцикла с анализом флага нуля `loope`/`loopz` и `loopne`/`loopnz`, а также такие команды условного перехода, как `jcxz` и `jecxz` (переход, если регистр cx/ecx равен нулю). По своему действию команда `loop label` эквивалентна командам `dec %ecx; jz label`, при этом `loop` не меняет флаги $flags$. В случае команд `loope`/`loopz` и `loopne`/`loopnz` анализируется не только cx/ecx, но и флаг нуля ZF (управление на метку передаётся, если $\begin{cases} cx \neq 0 \\ ZF = 1 \end{cases}$ и $\begin{cases} cx \neq 0 \\ ZF = 0 \end{cases}$ соответственно).

Эти команды были введены в набор 8086 для получения более компактного кода (однобайтовая инструкция `loop` заменяет связку двух однобайтовых `dec+jz`) и экономии дорогой памяти. При этом пара инструкций `dec+jz` выполняется быстрее `loop` [10, 28], легче читается и позволяет организовывать вложенные

циклы. В настоящее время оптимизация направлена на ускорение, соответственно, использования команд псевдоцикла `loop`, `loope/loopz`, `loopne/loopnz` (а также команд `jcxz` и `jecxz`) следует избегать.

Условная пересылка

Для каждого условия CC, кроме команды условного перехода `jCC`, существует команда условной пересылки `cmovCC src, dest`, выполняющая присваивание $dest = src$, если соответствующее условие верно.

В таблице 5.13 показаны различные команды безусловной и условной пересылки.

Команды пересылки данных

Таблица 5.13

Команда	Действие
`mov src, dest`	$dest = src$
`movabs imm64, dreg64`	$dreg64 = imm64$ (только шестидесятичетырёхбитный режим)
`movs srm, dreg` `movz srm, dreg`	$dreg = srm$ с расширением
`cmovCC srm, dreg`	$dreg = srm$, если верно CC (кроме `u` и `nu`)
`fcmovCC %st(i), %st(0)`	$st(0) = st(i)$ (регистры FPU), если верно CC (`e, ne, b/nae, be/na, ae/nb, a/nbe, u` и `nu`)
`setCC dest8`	$dest8 = \begin{cases} 1, & \text{если верно } CC \text{ (кроме } \texttt{u} \text{ и } \texttt{nu}) \\ 0, & \text{иначе} \end{cases}$

Команды условной пересылки не полностью аналогичны `mov`: источник может быть только регистром или в памяти, приёмник — только регистром. Пересылаемое значение не может иметь размер 8 бит.

Для флагов, которые могут быть установлены командами сравнения FPU (CF, ZF, PF) существует также команда условной пересылки в стеке FPU из $st(i)$ в $st(0)$ `fcmovCC %st(i), %st(0)` (раздел 5.3.4, таблица 5.16).

Установка байта по условию

Для каждого условия CC существует команда установки байта по условию `setCC dest8`, выполняющая присваивание $dest8 = 1$, если соответствующее условие верно, и $dest8 = 0$ иначе (последняя строка таблицы 5.13).

Приёмник $dest8$ может быть как регистром, так и переменной в памяти, но только однобайтовыми.

5.3. Команды FPU

> Я — разомкнутый круг, обрету в этом браке смыкание круга.
> Мой укрывшийся в глине двойник, я ищу твою руку!
>
> *С. А. Калугин. Скульптор лепит автопортрет*

Команды расширения FPU, или математического сопроцессора, предназначены для обработки числовых данных в формате с плавающей точкой.

FPU выполняет все вычисления в 80-битном расширенном формате. Для обмена данными с памятью используются также вещественные числа одинарной (32 бита) и двойной (64 бита) точности, соответствующие стандарту IEEE 754-2008, а также знаковые целые числа в дополнительном коде (16 или 32 бита) и знаковые упакованные двоично-десятичные числа (BCD, 80 бит).

Регистры данных FPU образуют стек с плавающей вершиной. Соответственно, система команд FPU идеологически отличается от основной системы команд. Один из операндов вычислений — всегда вершина стека FPU.

Мнемоническое обозначение команд сопроцессора характеризует особенности их работы. Все мнемонические обозначения начинаются с символа `f` (FPU). Вторая буква мнемонического обозначения (если она не является частью имени действия, как в `finit`) определяет тип операнда в памяти, с которым работает команда:

– `i` — целое двоичное число со знаком;
– `b` — целое двоично-десятичное (BCD) число;
– отсутствие буквы для арифметических команд обозначает вещественное число.

Последняя буква `p` в мнемоническом обозначении команды означает, что последним действием команды обязательно является извлечение операнда из стека (удвоенная `pp` — из стека извлекаются оба операнда).

Размер операнда в памяти, если он используется, задаётся суффиксом команды в соответствии с правилами синтаксиса AT&T. Если суффикс опущен, подразумевается `s` (вещественное число одинарной точности или шестнадцатибитное целое). Размер BCD-операнда всегда составляет 80 бит.

Команды FPU не могут иметь непосредственных операндов и, за исключением команды выгрузки слова состояния, не могут работать с регистрами основного процессора. Также команды FPU, за исключением современных команд сравнения вещественных чисел, не влияют на флаги основного процессора.

Если не указано иное, используются следующие обозначения. Операнд-приёмник может быть обозначен либо как $dest$, если он может быть регистром сопроцессора или переменной в памяти либо как $dmem$, если он может быть только в памяти. Операнд-источник может быть обозначен как src (регистр сопроцессора или переменная в памяти) или $smem$ (переменная в памяти).

5.3.1. Внутреннее представление чисел

Мое сердце из масти,
Кровь — диэтиламид;
Не надо смотреть на меня,
Потому что иначе ты вымрешь, как вид.

Б. Б. Гребенщиков. Таможенный блюз

Значения в сопроцессоре представлены в нестандартном 80-битном формате с плавающей запятой, называемом форматом с двойной расширенной (или просто расширенной) точностью, описанном в разделе 2.8.2.

Нормализованное двоичное представление вещественного числа имеет вид [51, 77]:

$$(-1)^s \cdot 2^p \cdot \mu, \quad 0{,}1_2 \leqslant \mu < 1 \tag{5.2}$$

где p — порядок числа, μ — мантисса, s определяет знак. Таким образом, все значащие разряды мантиссы находятся в дробной части. Старший из них (следующий сразу после запятой) для нормализованного числа всегда равен единице.

Старший бит 80-битного формата — знак s, порядок занимает следующие 15 бит и представляется кодом с избытком $2^{14} - 2$ (так называемый смещённый порядок). В оставшиеся 64 бита записывается дробная часть мантиссы, включая ведущую единицу.

В частности, единица в нормализованном представлении имеет вид $(-1)^0 \cdot 2^1 \cdot 0{,}1_2$. Тогда значение смещённого порядка (после добавления избытка) будет равно $2^{14} - 1$:

$1 = (-1)^0 \cdot 2^1 \cdot 0{,}1_2 \quad \rightarrow$

Знак	Порядок	Мантисса
0	$2^{14} - 1$	100...

$=$

Знак	Порядок	Мантисса
0	011...11	100...

Таким образом, вещественное число расширенной точности, равное единице, имеет вид `3FFF 8000 0000 0000 0000 0000 0000 0000`. Это подтверждает исследование с помощью отладчика.

Значение порядка, состоящее из пятнадцати нулей, зарезервировано под специальные значения, таким образом, минимально возможное значение порядка корректного вещественного числа имеет вид 00...001 и равно $p_{min} = 1 + \left(-2^{14} + 2\right) = -2^{14} + 3$. Соответственно, минимальное положительное число, представимое в нормализованном виде в формате расширенной точности, равно $X_{min} = 2^{p_{min}} \cdot 0{,}1_2 = 2^{-2^{14}+2} =$ `0001 8000...00`. Числа в диапазоне $(0, X_{min})$ представляются в виде $2^{p_{min}} \cdot \mu, \quad 0 < \mu < 0{,}1_2$ и называются **денормализованными**. В поле смещённого порядка таких чисел при этом записываются нули. В частности, $\frac{X_{min}}{2} =$

$2^{p_{min}} \cdot 0{,}01_2 = 2^{p_{min}-1} \cdot 0{,}1_2$, но представляется это число как `0000 4000...00`, в чём можно убедиться при помощи отладчика. Если попытаться прочесть такую запись как корректное число, то получим нулевой знаковый бит, нулевой смещённый порядок, что соответствует порядку $p_{min} - 1$, и мантиссу $0{,}0100..._2$, то есть $(-1)^0 \cdot 2^{p_{min}-1} \cdot 0{,}01_2 = \frac{X_{min}}{4}$, что неверно. Денормализованные числа — один из видов **специальных значений,** которые нельзя раскодировать по общему правилу.

Представление отрицательных вещественных чисел, в том числе из диапазона $(-X_{min}, 0)$, отличается от представления их модулей только знаковым битом.

Как было сказано в разделе 2.8.2, в некоторых источниках нормализованной формой мантиссы считается число, включающее один разряд целой части и 63 бита дробной [16] или целое беззнаковое 64-битное число с единицей в старшем разряде [83]. Обе этих трактовки приводят к тому же самому двоичному представлению, что и описанная выше.

Виды значений

Регистры сопроцессора могут содержать следующие значения:

- вещественные числа — порядок не равен 0 и не состоит из всех единиц, старший бит мантиссы равен 1;
- денормализованные вещественные числа — порядок и старший бит мантиссы равны 0, но мантисса не равна нулю;
- нули ($+0{,}0$ и $-0{,}0$, в соответствии со знаковым битом) — порядок и мантисса равны нулю;
- бесконечности ($+\infty$ и $-\infty$, в соответствии со знаковым битом, обозначаются как `+inf` и `-inf`) — порядок состоит из всех единиц, старший бит мантиссы — единица, остальные равны нулю;
- нечисла двух типов:
  - сигнальные нечисла (при появлении такого значения в стеке генерируется исключение недействительной операции);
  - тихие нечисла (не генерируют исключения, но результат вычислений с операндом-нечислом — тоже нечисло):
    - вещественная неопределённость nan (знаковый бит не имеет значения) — порядок состоит из всех единиц, два старших бита мантиссы — единицы, остальные нули;
    - другие тихие нечисла — порядок состоит из всех единиц, два старших бита мантиссы — единицы, остальные — не все нули;
- недопустимые значения.

Начиная с 80387 некоторые ранее недопустимые значения стали нечислами различного типа, и наоборот — многие недопустимые для современных сопроцессоров значения были корректными нечислами в ранних дискретных моделях.

Если один из операндов равен произвольному тихому нечислу, он интерпретируется как вещественная неопределённость. Если вещественная неопределённость является результатом операции, она может быть равной только описанному значению nan.

5.3.2. Возможные форматы экспорта-импорта

> У меня есть что-то, я могу поделиться с тобой.
> И это алая дверь.
>
> *Б. Б. Гребенщиков. Алая дверь*

Регистры сопроцессора могут содержать только вещественные числа расширенной точности или специальные значения формата расширенной точности. Тем не менее, при выгрузке значений из стека возможно преобразовать их в различные форматы трёх основных видов — с плавающей запятой, целые двоичные и целые двоично-десятичные.

Соответственно, при явной загрузке значений из памяти в стек FPU или выполнении вычислений с операндом в памяти возможен экспорт значений из этих форматов.

Форматы с плавающей запятой

FPU поддерживает импорт и экспорт в стандартные форматы с плавающей запятой одинарной и двойной точности, соответствующие стандарту IEEE 754-2008. Также возможен импорт-экспорт в нестандартный 80-битный формат двойной расширенной точности, совпадающий с внутренним представлением чисел FPU.

Конкретный выбор формата определяется суффиксом команды (раздел 5.1.5). Суффикс s соответствует одинарной точности (32 бита, $float$), l — двойной (64 бита, $double$), t — нестандартному формату расширенной точности (80 бит, для GCC этот формат соответствует типу $long\ double$).

Если суффикс размера не указан, используется одинарная точность ($float$).

Целые форматы

Поддерживается импорт и экспорт в двоичные знаковые целые форматы от двух до восьми байт. При экспорте значение округляется в соответствии с текущими настройками FPU. Отрицательные числа представлены в дополнительном коде.

Выбор формата определяется суффиксом команды (раздел 5.1.5). Суффикс s соответствует короткому целому (16 бит, $short$), l — длинному (32 бита, $long$ и чаще всего int). Импорт и экспорт в шестидесятичетырёхбитное целое (то есть суффикс q) в FPU не поддерживается.

Если суффикс размера не указан, число импортируется или экспортируется как короткое (16-битное) знаковое целое, в большинстве реализаций языка C++ соответствующее типу $short$.

Двоично-десятичный формат

FPU поддерживает экспорт и импорт только в один вид двоично-десятичных чисел — это 80-битный упакованный целый BCD-формат в виде значения со знаком.

Всего такое число занимает десять байт. Старший из них — знаковый. Его старший бит хранит знак числа — ноль соответствует положительному числу, единица — отрицательному. Младшие семь бит знакового байта не имеют значения. Остальные девять байтов содержат модуль числа в виде восемнадцати упакованных десятичных цифр.

Таким образом, BCD-формат FPU, как и форматы с плавающей запятой, включает два нуля: $+0$ и -0.

5.3.3. Общие команды

> — Статус-кво! — раздался каменный голос судьи.
> — Восстановим статус-кво!
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Девять подвигов Сена Аесли. Подвиги 5-9*

Исторически набор команд FPU включает команды для начальной настройки сопроцессора, а также для синхронизации с центральным процессором. В настоящее время синхронизация не требуется.

Сброс FPU

Так как ранние модели сопроцессора FPU были отдельными устройствами, перед началом работы было необходимо определить, есть ли сопроцессор в системе, и, в случае его наличия, инициализировать сопроцессор. Для инициализации предназначена команда `finit` — сброс сопроцессора.

Команда `finit` восстанавливает значения по умолчанию в регистрах cw, sw, tw, а начиная с 80387 — fip и fdp. Управляющее слово инициализируется значением `0x037F` (округление к ближайшему, 64-битная мантисса, все исключения замаскированы — то есть можно спокойно делить на 0, брать корень из отрицательных чисел и т. п., но результат будет не числом). Слово состояния обнуляется ($top = 0$, никакие флаги исключений не установлены). Регистры данных никак не изменяются, но все они помечаются пустыми в слове тегов tw. Регистры fip и fdp обнуляются.

Современные операционные системы сбрасывают и настраивают сопроцессор во время загрузки. Выполнять сброс вручную не стоит, так как это может повлиять на выполнение дальнейших расчётов на ЯВУ.

Ожидание синхронизации

Оригинальный арифметический сопроцессор, выполненный в виде отдельной микросхемы, мог работать параллельно с центральным процессором. Для их синхронизации использовалась команда `wait/fwait`. Этим мнемоникам соответствует один и тот же машинный код. Эта команда приостанавливает работу либо FPU, либо центрального процессора — в зависимости от того, какой из них «вырвался вперёд» — и ждёт отстающего. Кроме того, многие команды управления сопроцессором реализованы в двух вариантах — с ожиданием и без. Мнемоника команды без ожидания отличается префиксом `n` после префикса FPU `f`, например, `fnstsw` и `fstsw`. При этом, согласно документации Intel, машинный код команды без префикса `n` состоит из кода команды `wait/fwait` и кода команды с префиксом `n`. В частности, команда `fstsw` полностью эквивалентна последовательности `fwait + fnstsw`.

В современных процессорах параллельная работа команд FPU и основного набора невозможна, так что команда `wait/fwait` эквивалентна `nop`. Соответственно, из двух команд — с префиксом `n` и без — в настоящее время необходимо выбирать вариант с префиксом.

5.3.4. Загрузка, выгрузка и пересылка данных

> И падут предо мною преграды стекла,
> Я смогу без препятствий входить в зеркала!
>
> *С. А. Калугин. Скульптор лепит автопортрет*

Невозможно напрямую загрузить в стек сопроцессора значение регистра основного процессора или, наоборот, выгрузить значение из стека FPU в регистр CPU. Также невозможно загрузить в стек произвольную константу. Допускается только загрузка данных из памяти в вершину стека FPU (имена соответствующих команд включают суффикс `ld`, от load) и выгрузка вершины стека в память (суффикс `st`, от store).

Это необходимо учитывать при написании ассемблерных вставок — все входные и выходные параметры, использующиеся как аргументы инструкций сопроцессора, должны располагаться в памяти. В частности, листинг 5.10 показывает вычисление значения выражения $x + a$ и запись результата в y.

Для этого в стек FPU загружается x (значение x оказывается на вершине стека и получает обозначение $st(0)$), затем к нему прибавляется a, затем полученное значение выгружается в y.

Листинг 5.10. Вычисление $y = x + a$ вставкой в код C++

```
1  const volatile double a = 12;
2  double x = 1, y;
3  asm(
4      "fldl %[X]\n"  // st(0) = %[X]
5      "faddl %[A]\n" // st(0) = %[X] + %[A]
6      "fstpl %[Y]\n" // %[Y] = %[X] + %[A], стек пуст
7      :[Y]"=m"(y)
8      :[X]"m"(x), [A]"m"(a)
9      :"cc"
10 );
```

Параметры (как входные `[X]` и `[A]`, так и выходной `[Y]`) расположены в памяти. К константе a (значению входного параметра `[A]`) применён модификатор `volatile`, чтобы компилятор не оптимизировал её и разместил в памяти, как и необходимо.

В списке перезаписываемых регистров GCC не позволяет описывать элементы стека сопроцессора. Это не приводит к ошибкам, так как временные переменные не помещаются в стек сопроцессора.

Если вычисления должны быть не вставкой в код C++, а частью программы на ассемблере, все числа, включая константы (кроме, может быть, тех, для загрузки которых есть специальные команды), необходимо разместить в памяти.

Листинг 5.11. Вычисление $y = x + a$

```
1 .data
2 a: .double 12
3 x: .double 1
4 y: .double
5 .text
6   fldl x
7   faddl a
8   fstpl y
```

При выходе из вставки или функции стек сопроцессора должен быть таким же, как на входе — обычно пустым, если только через него не возвращается значение (тогда в стеке не должно быть ничего, кроме возвращаемого значения).

Размер числа, загружаемого из памяти или выгружаемого в память, определяется суффиксом команды (таблица 5.1). При отсутствии суффикса целый операнд загружается из 16 бит или соответственно усекается при экспорте до 16 бит (*short*), а вещественный загружается или записывается с одинарной точностью (*float*, 32 бита). Таким образом, в отличие от команд основного набора, для команд FPU, работающих с данными в памяти, при неуказании суффикса размера подразумевается суффикс `s`.

Загрузка данных в стек FPU

Для загрузки данных в стек сопроцессора предназначен набор инструкций `f*ld` (load, таблица 5.14).

Команды загрузки данных в стек FPU

Таблица 5.14

Команда	Действие
`fld src`	Помещает вещественное число src на вершину стека FPU Если источник src в памяти, его размер определяется суффиксом команды (по умолчанию — 32 бита, $float$)
Загрузка целых чисел	
`fild smem`	Помещает целое знаковое число $smem$ на вершину стека FPU Размер источника определяется суффиксом команды (по умолчанию — 16 бит, $short$)
`fbld smem`	Помещает целое двоично-десятичное число $smem$ на вершину стека FPU Размер источника — 80 бит
Загрузка констант	
`fldz`	Загрузка 0
`fld1`	Загрузка 1
`fldpi`	Загрузка π
`fldl2t`	Загрузка $\log_2 10$
`fldl2e`	Загрузка $\log_2 e$
`fldlg2`	Загрузка $\log_{10} 2$
`fldln2`	Загрузка $\ln 2$

После загрузки значение преобразуется в число с двойной расширенной точностью (80 бит). Ячейка, куда было помещено значение, получает обозначение $st(0)$, номера ранее занятых ячеек увеличиваются на единицу (ранее обозначавшееся как $st(0)$ значение становится $st(1)$ и так далее).

В стек можно поместить значение одного из элементов стека сопроцессора, значение из памяти или одну из предопределённого набора констант. Невозможно напрямую загрузить в стек сопроцессора значение регистра основного процессора (если подобная необходимость возникает, это делается в два приёма через промежуточную переменную в памяти).

Выгрузка данных из стека FPU

Для выгрузки данных из стека сопроцессора предназначен набор инструкций `f*st[p]` (таблица 5.15).

Выгружаемое значение — вершина стека FPU $st(0)$. Суффикс `p` (pop), который может присутствовать в имени команды после суффикса `st` (store), соответствует выталкиванию $st(0)$ из стека, так что значение, ранее обозначавшееся как $st(1)$, получает обозначение $st(0)$. Отсутствие суффикса `p` соответствует копированию, так что старое значение $st(0)$ остаётся на вершине стека. Суффикс размера располагается после полного имени команды, включающего суффиксы `st` и (при необходимости) `p`.

Команды выгрузки данных из стека FPU

Таблица 5.15

Команда	Действие
`fst dest` `fstp dest`	Копирует $st(0)$ в $dest$ Выталкивает $st(0)$ в $dest$ Приёмник $dest$ может быть переменной в памяти или пустым регистром FPU Если $dest$ в памяти, его размер определяется суффиксом команды (по умолчанию — 32 бита, $float$)
Выгрузка с округлением	
`fist dmem` `fistp dmem`	Копирует $st(0)$ в $dmem$ как целое Выталкивает $st(0)$ в $dmem$ как целое Размер приёмника определяется суффиксом команды (по умолчанию — 16 бит, $short$)
`fbst dmem` `fbstp dmem`	Копирует $st(0)$ в $dmem$ как двоично-десятичное целое Выталкивает $st(0)$ в $dmem$ как двоично-десятичное целое Размер приёмника — 80 бит

Ниже показан пример использования команд загрузки и выгрузки (листинг 5.12).

Листинг 5.12. Последовательная загрузка и выгрузка данных

```
1 double x = 5.7, y;
2 float f;
3 long double L;
4 int i = 10;
5
6 asm(                  //      st: 0  1  2  3
7     "fldl %[x]\n"     // в стеке: x
8     "fldz\n"          // в стеке: 0, x
```

```
    "fld1\n"        // в стеке: 1, 0, x
    "fildl %[i]\n"  // в стеке: i, 1, 0, x
    "fstps %[f]\n"  // в стеке: 1, 0, x     f = i
    "fstpt %[L]\n"  // в стеке: 0, x        L = 1
    "fstpl %[y]\n"  // в стеке: x           y = 0
    "fistpl %[i]\n" // стек пуст            i = x

    :[y]"=m"(y), [i]"+m"(i), [f]"=m"(f), [L]"=m"(L)
    :[x]"m"(x)
    :"cc"
)

#define PRINT(val) cout << #val << " = " << val << "  ";

PRINT(x)
PRINT(y)
PRINT(i)
PRINT(f)
PRINT(L)
```

Вначале в стек сопроцессора последовательно загружаются четыре значения: вещественная переменная двойной точности $x = 5{,}7$, константы — ноль и единица, а также целое 32-битное число $i = 10$.

После загрузки всех четырёх значений в стеке сопроцессора находятся следующие значения:

$$st(0) = 10 = i$$
$$st(1) = 1$$
$$st(2) = 0$$
$$st(3) = 5{,}7 = x$$

Все они внутри стека хранятся в 80-битном вещественном формате.

Затем верхнее значение $st(0)$, равное последнему загруженному значению $i = 10$, выталкивается из стека и записывается по адресу параметра $[f]$, преобразованное в вещественное число одинарной точности. Новое значение вершины стека $st(0)$ после выталкивания — единица. Соответственно, изменятся и обозначения более глубоких элементов стека: $st(1) = 0$ и $st(2) = x$.

Затем новое значение вершины стека, равное единице, выталкивается в параметр $[L]$ как 80-битное число (суффикс t — $ten\ bytes$, что для компиляторов GCC соответствует типу $long\ double$). Ноль выталкивается из стека и записывается в $[y]$ как число двойной точности. Последний оператор выталкивает значение x в параметр $[i]$ как длинное целое (int), после чего стек остаётся пустым. Значение $5{,}7$ округляется в соответствии с текущими настройками округления, в данном случае — к ближайшему, то есть получим $[i] = 6$.

Соответственно, результат отладочной печати в конце листинга выглядит следующим образом: `x = 5.7  y = 0  i = 6  f = 10  L = 1`.

Используя команды выгрузки или загрузки из памяти, необходимо внимательно следить за суффиксами команд. В вышеописанном примере команда `fstp %[y]` не вызвала бы ошибки ни во время компиляции, ни во время выполнения, но переменная y получила бы весьма странное значение. По умолчанию (без указания суффикса) `fstp` записывает снятое с вершины стека значение как вещественное число одинарной точности, то есть из 64 бит переменной y будут перезаписаны только первые 32, причём в формате, не соответствующем типу $double$.

Пересылка данных внутри стека FPU

Для пересылки данных внутри стека сопроцессора можно использовать команды `fld st(i)` для загрузки копии значения $st(i)$ в вершину стека и `fst st(i)` для помещения значения $st(0)$ в ранее пустую ячейку $st(i)$. Кроме того, существует две специализированные команды (таблица 5.16).

Команды пересылки данных FPU

Таблица 5.16

Команда	Действие
`fcmovCC %st(i), %st(0)`	Присваивание $st(0) = st(i)$, если верно CC (`e, ne, b/nae, be/na, ae/nb, a/nbe, u` и `nu`)
`fxch` `fxch %st(i)`	Меняет местами $st(0)$ и $st(1)$ Меняет местами $st(0)$ и $st(i)$
`ffree %st(i)`	Помечает $st(i)$ как свободный (при этом *нумерация прочих элементов стека FPU не меняется)*

Команда условного копирования `fcmovCC` использует как условие флаги регистра $flags$, а не регистра состояния sw. При этом для неё доступны не все условия CC, перечисленные в таблице 5.11, и даже не все синонимы доступных условий. Используемые условия перечислены в таблице 5.17.

Условия `fcmovCC` включают те биты регистра флагов $flags$, которые могут быть прямо или косвенно (путём сохранения слова состояния sw и загрузки его части в $flags$) установлены командами сравнения FPU, то есть флаги CF, ZF, PF.

Команда обмена регистров `fxch` на самом деле не копирует данные, а переименовывает регистры, так что её выполнение практически не занимает времени. Так как большинство команд работает с вершиной стека, переименование регистров с помощью `fxch` часто бывает удобным.

Условия `fcmovCC` и их связь с флагами состояния $flags$

Таблица 5.17

CC	Условие (флаги)	Условие (f*cmp src)	
`e`	$ZF = 1$	$st(0) = src$	*if equal*
`ne`	$ZF = 0$	$st(0) \neq src$	*if not equal*
`b/nae`	$CF = 1$	$st(0) < src$	*if below / if not above or equal*
`be/na`	$\begin{bmatrix} CF = 1 \\ ZF = 1 \end{bmatrix}$	$st(0) \leqslant src$	*if below or equal / if not above*
`nb/ae`	$CF = 0$	$st(0) \geqslant src$	*if not below / if above or equal*
`nbe/a`	$\begin{cases} CF = 0 \\ ZF = 0 \end{cases}$	$st(0) > src$	*if not below or equal / if above*
`u`	$PF = 1$	src и $st(0)$ несравнимы	*if unordered*
`nu`	$PF = 0$	src и $st(0)$ сравнимы	*if not unordered*

Загрузка и выгрузка управляющих регистров

Содержимое управляющих регистров также может быть сохранено в памяти (таблица 5.18).

Команды загрузки и выгрузки управляющих регистров FPU

Таблица 5.18

Команда	Действие
`fnstcw dmem16`	Выгрузка управляющего слова cw в память
`fldcw smem16`	Загрузка управляющего слова cw из памяти
`fnstsw dest16`	Выгрузка (разрушающая) слова состояния sw в память или регистр ax

Управляющее слово cw можно как выгрузить в память по заданному адресу, так и загрузить из неё.

Слово состояния сопроцессора sw можно только сохранить в память, а также в регистр ax (и только в этот регистр).

После выгрузки слова состояния sw командой `fnstsw` теряется значение специальных флагов $C0{-}C3$.

5.3.5. Основные арифметические команды

Багровый и белый пришли в мои песни.
Мы здесь не ради парада.
Мы стоим вместе и падаем вместе;
И я буду петь тебе, если ты будешь рада.

Б. Б. Гребенщиков. Поутру

Основные арифметические команды сопроцессора выполняют базовые бинарные арифметические операции — сложение, вычитание, умножение и деление. Хотя бы один операнд должен быть в вершине стека сопроцессора $st(0)$. Результат помещается на место одного из операндов (приёмника) в стек сопроцессора, заменяя старое значение. Приёмник должен быть в стеке сопроцессора, но не обязательно на его вершине.

Каждая из основных арифметических команд может быть записана в нескольких формах. Они различаются положением источника и приёмника, также некоторые из форм после вычисления результата выталкивают источник из стека сопроцессора, что обозначается суффиксом p.

Обозначения основных арифметических команд

Четырём арифметическим операциям в FPU соответствует шесть различных операций. При этом каждой из симметричных относительно перестановки операндов арифметических операций — сложению и умножению — соответствует по одной операции FPU: сложение `fadd` и умножение `fmul`. Несимметричным операциям — вычитанию и делению — соответствует по две операции FPU, отличающиеся порядком операндов. Это соответственно прямое вычитание `fsub` и обратное вычитание `fsubr`, а также прямое деление `fdiv` и обратное деление `fdivr` (таблица 5.19).

Все формы основных арифметических команд используют два явно или неявно заданных операнда. Один из них всегда в вершине стека $st(0)$, другой (обозначим его ξ) может быть в памяти или в регистре $st(i)$. Кроме того, один из этих операндов является приёмником $dest$, второй — источником src.

Внимание!
Ассемблер Unix исторически использовал для основных арифметических команд FPU те же мнемонические обозначения, что и предложенные Intel, но другую семантику операндов.
Таким образом, в GAS поведение мнемоник несимметричных операций (`fsub`/`fsubr` и `fdiv`/`fdivr`) качественно иное, чем описанное в документации Intel и учебниках, описывающих синтаксис Intel.

Основные арифметические операции FPU

Таблица 5.19

Команда	Действие Intel	Действие GAS*
`fadd` (сложение)	$dest = dest + src = st(0) + \xi$	
`fsub` (вычитание)	$dest = dest - src$	$dest = st(0) - \xi$
`fsubr` (обратное вычитание)	$dest = src - dest$	$dest = \xi - st(0)$
`fmul` (умножение)	$dest = dest \cdot src = st(0) \cdot \xi$	
`fdiv` (деление)	$dest = dest/src$	$dest = st(0)/\xi$
`fdivr` (обратное деление)	$dest = src/dest$	$dest = \xi/st(0)$

* ξ — операнд, не лежащий на вершине стека.
Может быть как источником src, так и приёмником $dest$, в зависимости от используемой формы.

Согласно документации Intel (и в ассемблерах с синтаксисом Intel) прямое вычитание `fsub` вычисляет $dest - src$, а обратное `fsubr` — $src - dest$, то есть результаты команд `fsub %st(0), %st(i)` и `fsub %st(i), %st(0)` не только записываются в различные регистры, но и отличаются знаком.

В GAS, в соответствии с традиционным поведением Unix-ассемблеров, `fsub` вычисляет $st(0) - \xi$ даже в том случае, если приёмником является ξ. В частности, команды `fsub %st(0), %st(i)` и `fsub %st(i), %st(0)` вычисляют одно и то же значение, но помещают его в разные регистры. Обратное вычитание `fsubr` вычисляет $\xi - st(0)$.

Таким образом, команде `fsub %st(0), %st(i)` соответствует опкод, который, согласно документации Intel, должен соответствовать команде `fsubr` [59]. Анализ сгенерированного компилятором из коллекции GCC кода это подтверждает. Аналогично ведут себя `fdiv`/`fdivr`. Такое поведение в случае сочетания синтаксиса AT&T и платформы x86 в некоторых источниках описывается как баг GCC [54], но из соображений совместимости с имеющимся кодом меняться не будет.

Поведение Intel и GAS совпадает в тех случаях, когда приёмником является $st(0)$, в том числе в ситуациях, когда источник находится в памяти. Также поведение Intel и GAS полностью совпадает для симметричных операций — сложения и умножения.

Формы основных арифметических команд

Согласно документации Intel, сопроцессор использует шесть форм [48] основных арифметических команд (таблица 5.20). Строка XXX соответствует выполняемой операции (`add`, `sub`, `subr`, `mul`, `div`, `divr`).

Шесть форм основных арифметических команд FPU

Таблица 5.20

Команда	Действие
`fXXXp`	Источник — $st(0)$, приёмник — $st(1)$, после выполнения источник $st(0)$ извлекается из стека (то есть результат получает обозначение $st(0)$). Данная форма эквивалентна `fXXXp %st(0), %st(1)` (ассемблируется в тот же опкод)
`fXXX smem`	Источник — память (вещественное число), приёмник — $st(0)$, указатель стека не изменяется. Размер источника определяется суффиксом команды, может быть одинарной или двойной точности, но не 80-битным (по умолчанию — 32 бита, $float$)
`fiXXX smem`	Источник — память (целое знаковое число), приёмник — $st(0)$, указатель стека не изменяется. Размер источника определяется суффиксом команды, может быть 16- или 32-, но не 64-битным (по умолчанию — 16 бит, $short$)
`fXXX %st(i), %st(0)`	Источник — $st(i)$, приёмник — $st(0)$, указатель стека не изменяется
`fXXX %st(0), %st(i)`	Источник — $st(0)$, приёмник — $st(i)$, указатель стека не изменяется
`fXXXp %st(0), %st(i)`	Источник — $st(0)$, приёмник — $st(i)$, после выполнения источник $st(0)$ извлекается из стека (то есть результат получает обозначение $st(i-1)$)

Если посмотреть на опкоды этих форм [17], видно, что опкод формы без параметров `fXXXp` полностью совпадает с опкодом формы с двумя параметрами `fXXXp %st(0), %st(1)`. Напротив, формы `f[i]add smem` для различной разрядности источника $smem$ имеют по два различных опкода.

В частности, для операции сложения `fadd` возможны следующие формы:

а) `faddp` выполняет сложение $st(1) = st(0) + st(1)$ и выталкивание $st(0)$ из стека, так что после этой операции результат оказывается в $st(0)$ (эквивалент `faddp %st(0), %st(1)`);

б) `fadd smem` — $st(0) = st(0) +$ вещественное $smem$;

в) `fiadd smem` — $st(0) = st(0) +$ целое $smem$;
г) `fadd %st(i), %st(0)` — $st(0) = st(0) + st(i)$;
д) `fadd %st(0), %st(i)` — $st(i) = st(0) + st(i)$;
е) `faddp %st(0), %st(i)` — $st(i) = st(0) + st(i)$ и выталкивание $st(0)$ из стека, так что после этой операции результат оказывается в $st(i-1)$.

Большинство ассемблеров, в частности, GAS, поддерживает и некоторые дополнительные формы основных арифметических команд, оба операнда которых находятся в стеке. В частности, для формы без операндов `fXXXp` практически во всех ассемблерах принят синоним `fXXX`. Но, так как мнемоника без суффикса `p` не отражает выполняемое выталкивание $st(0)$ из стека, её использование не рекомендуется.

Кроме того, по аналогии с `fXXX smem` поддерживается форма `fXXX %st(i)` с приёмником в $st(0)$, а также `fXXXp %st(i)` с приёмником изначально в $st(i)$, а после выталкивания $st(0)$ — в $st(i-1)$.

В GAS, кроме всего прочего, доступна «нелегальная» форма записи `fXXXp %st(i), %st(0)`, например, `fsubp %st(i), %st(0)`. Такая запись вызывает при компиляции предупреждение, но не ошибку (хотя по сути является ошибочной, источник $st(i)$ невозможно вытолкнуть из стека) и преобразуется в `fsubp %st(0), %st(i)`.

Подобные формы лучше не использовать из-за неочевидности расположения операндов. При этом неуказание части операндов в программе не даёт преимущества в исполняемом файле, так как любая форма из перечисленных дополнительных форм арифметических команд будет ассемблироваться в тот же опкод, что и форма с двумя явно указанными операндами.

Практическое использование основных арифметических команд

Ниже показано использование основных арифметических команд для расчёта значения выражения $x + \frac{1}{i} + a \cdot \pi$. Так как используется GAS, команда `fdivr` без операндов рассчитывает $st(1)/st(0)$, после чего источник $st(0)$ выталкивается из стека FPU.

В листинге 5.13 приведена функция `double foo(double x, int i, double a)`, соответствующая тридцатидвухбитному соглашению о вызове cdecl (см. раздел 6.2.4).

Листинг 5.13. Расчёт $y = x + \frac{1}{i} + a \cdot \pi$ как функция

```
1 .globl foo
2 foo:                  // st(0),  st(1),  st(2),  st(3)
3   fldl 4(%esp)        // x
4   fldpi               // pi,     x
5   fld1                // 1,      pi,     x
6   fildl 12(%esp)      // i,      1,      pi,     x
```

```
7   fdivr                 // 1/i,    pi,     x
8   fldl  16(%esp)        // a,      1/i,    pi,     x
9   fmulp %st(0), %st(2) // 1/i,    pi*a,   x
10  faddp               // 1/i+pi*a, x
11  faddp               // 1/i+pi*a+x (результат)
```

Операнды, в соответствии с соглашением cdecl, передаются в стеке в памяти (первый параметр x находится по адресу $sp+4$ и занимает восемь байт, так что следующий параметр, i, располагается по адресу $\&x+8 = sp+4+8 = sp+12$ и параметр a — по адресу $sp+16$), поэтому их можно загрузить командами `f*ld` в стек регистров FPU. Возвращаемое вещественное значение, согласно тому же соглашению, передаётся в $st(0)$, поэтому оно не выталкивается после вычислений.

Далее показан тот же код расчёта значения выражения $x+\frac{1}{i}+a\cdot\pi$, оформленный как вставка в программу на C++, где x, i и a — значения переменных (листинг 5.14).

Листинг 5.14. Расчёт $y = x + \frac{1}{i} + a \cdot \pi$ как вставка

```
1  const volatile double a = 0.01;
2  double x = 5, y;
3  int i = 10;
4  asm(                 //          st(0), st(1), st(2), st(3)
5      "fldl %[x]\n"    // в стеке: x
6      "fldpi\n"        // в стеке: pi,    x
7      "fld1\n"         // в стеке: 1,     pi,    x
8      "fildl %[i]\n"   // в стеке: i,     1,     pi,    x
9      "fdivr\n"        // в стеке: 1/i,   pi,    x
10     "fldl  %[A]\n"   // в стеке: A,     1/i,   pi,    x
11     "fmulp %%st(0), %%st(2)\n"  // в стеке: 1/i,   pi*A,  x
12     "faddp\n"        // в стеке: 1/i+pi*A, x
13     "faddp\n"        // в стеке: 1/i+pi*A+x
14     "fstpl %[y]\n"   // стек пуст, y = 1/i + pi*A + x
15
16     :[y]"=m"(y)
17     :[x]"m"(x), [A]"m"(a), [i]"m"(i)
18     :"cc"
19 );// y = x + 1/i + a*pi
```

Приведённый код — не единственный способ расчёта значения указанного выражения. В зависимости от того, в каком порядке программист будет рассчитывать компоненты выражения, может различаться как порядок команд, так и сами команды (в частности, возможно использование прямого деления `fdiv`, а не обратного `fdivr`).

5.3.6. Дополнительные арифметические и трансцендентные команды

Тарелки не влетали в окно,
и все мои слова оставались со мной.

Б. Б. Гребенщиков. Джунгли

Дополнительные арифметические и трансцендентные команды [17, 34] работают с вершиной стека $st(0)$ и, при необходимости, с $st(1)$. Для них не указывают явных операндов. Соответственно, каждая из команд этой группы имеет только одну форму.

Некоторые дополнительные арифметические и трансцендентные команды перечислены в таблице 5.21.

Использование этих команд не перезаписывает значения, лежащие в стеке ниже неявных аргументов. Если у команды только один аргумент в $st(0)$ и один результат, результат записывается в $st(0)$ на место аргумента. Если у команды один аргумент в $st(0)$ и два результата (`fptan`, `fsincos` и т. д.), то один из результатов помещается в $st(0)$, второй затем помещается в стек сверху (так что первый результат оказывается в $st(1)$, второй — в $st(0)$).

В случае команд с двумя аргументами $st(0)$, $st(1)$ и одним результатом чаще всего результат помещается в $st(1)$, затем $st(0)$ выталкивается из стека, так что после этой операции результат оказывается в $st(0)$. Таким образом, результат замещает собой аргументы (в таблице 5.21 такая ситуация соответствует обозначению $\left[st(1) \to st(0)\right]$ для результата).

Иногда (в частности, `fscale`) команда с двумя аргументами в $st(0)$ и $st(1)$ записывает результат в $st(0)$, оставляя аргумент в $st(1)$ в стеке.

Результат трансцендентных и тригонометрических команд (`fsin`, `fcos`, `fsincos`, `fptan`, `fpatan`, `f2xm1`, `fyl2x`, `fyl2xp1`) всегда помечается как неточный (исключительная ситуация #P).

Пример использования тригонометрических команд для расчёта значения выражения $a \cdot \cos(x) + \sin(x)$ показан в листинге 5.15.

Листинг 5.15. Расчёт $y = a \cdot \cos(x) + \sin(x)$

```
1  const volatile double a = 100;
2  double x = M_PI/6, y;
3  asm(                 // в стеке: st(0),           st(1)
4      "fldl %[X]\n"    // в стеке: X
5      "fsincos\n"      // в стеке: cos(X)           sin(X)
6      "fmull %[A]\n"   // в стеке: A*cos(X)         sin(X)
7      "faddp\n"        // в стеке: A*cos(X) + sin(X)
8      "fstpl %[Y]\n"   // стек пуст, Y = A*cos(X) + sin(X)
9
10     :[Y]"=m"(y)
```

Дополнительные арифметические и трансцендентные команды FPU

Таблица 5.21

Команда	Действие
`fabs`	$st(0) = \lvert st(0) \rvert$
`fchs`	$st(0) = -st(0)$
`frndint`	округление $st(0)$ до целого по текущим правилам
`fsqrt`	$st(0) = \sqrt{st(0)}$
`fptan`	$\begin{cases} st(0) = 1 \\ st(1) = \operatorname{tg}\big(st(0)\big) \end{cases}$ — частичный тангенс $st(0)$
`fsincos`	$\begin{cases} st(0) = \cos\big(st(0)\big) \\ st(1) = \sin\big(st(0)\big) \end{cases}$ `fsincos` выполняется столько же времени, сколько `fsin` или `fcos` (и вдвое меньше раздельного расчёта синуса и косинуса)
`fsin`	$st(0) = \sin\big(st(0)\big)$
`fcos`	$st(0) = \cos\big(st(0)\big)$
`fpatan`	$\Big[st(1) \to st(0)\Big] = parctg\left(\frac{st(1)}{st(0)}\right)$ — частичный арктангенс $\frac{st(1)}{st(0)}$. Результат в диапазоне $[-\pi, \pi]$
`fxtract`	$st(0)$ — мантисса и знак $st(0)$, $st(1)$ — несмещённый порядок $st(0)$
`fscale`	$st(0) = st(0) \cdot 2^{\lfloor st(1) \rfloor}$, $st(1)$ остаётся в стеке
`f2xm1`	$st(0) = 2^{st(0)} - 1$ Значение $st(0)$ должно лежать в пределах от -1 до $+1$, иначе результат не определён
`fyl2x`	$\Big[st(1) \to st(0)\Big] = st(1) \cdot \log_2\big(st(0)\big)$, $st(0) \geqslant 0$. Если регистр $st(0)$ содержал ноль, результат (если $ZM = 1$) будет равен бесконечности со знаком, обратным $st(1)$
`fyl2xp1`	$\Big[st(1) \to st(0)\Big] = st(1) \cdot \log_2\big(st(0) + 1\big)$, $st(0)$ от $-(1 - \frac{\sqrt{2}}{2}) \approx -0{,}3$ до $(1 + \frac{\sqrt{2}}{2}) \approx 1{,}7$, иначе результат не определён. Команда `fyl2xp1` дает бóльшую точность для $st(0)$, близких к нулю, чем `fyl2x` для суммы того же $st(0)$ и 1
`fprem1`	$\Big[st(1) \to st(0)\Big] = st(0) \bmod st(1)$ — частичный остаток по IEEE 754. Применяется, в частности, для уменьшения аргументов периодических функций: остаток от деления $3 \cdot \pi + 1{,}2$ на π равен $1{,}2$

```
11      :[X]"m"(x), [A]"m"(a)
12      :"cc"
13  );      // y = a*cos(x) + sin(x)
```

Для всех тригонометрических команд операнд считается заданным в радианах и не может быть больше 2^{63} или меньше -2^{63}. Если операнд выходит за эти пределы, флаг $C2$ устанавливается в единицу, значение $st(0)$ и стек не изменяются.

Частичный арктангенс `fpatan` отличается от математического определения арктангенса тем, что принимает два аргумента, соответствующие координатам некоторой точки $\begin{cases} st(0) = x \\ st(1) = y \end{cases}$ и возвращает результат в диапазоне $[-\pi, \pi]$, равный азимуту заданной точки (x, y). Соответственно, знаки аргументов определяют квадрант результата.

Чтобы получить результат в диапазоне $(-\frac{\pi}{2}, \frac{\pi}{2})$, то есть в соответствии с математическим определением $arctg(x)$, необходимо задать точку в первом или четвёртом квадрантах, то есть с положительной абсциссой — $\begin{cases} st(0) = 1 \\ st(1) = x \end{cases}$.

Остальные обратные тригонометрические функции можно получить с помощью команды `fpatan` и арифметических команд, используя основное тригонометрическое тождество и задавая координаты соответствующих точек.

5.3.7. Сравнение вещественных чисел

> Я крушу зеркала, чтоб не видеть, как смотрит двойник;
> Зеркала, разбиваясь, сочатся багровым и алым.
>
> *С. А. Калугин. Скульптор лепит автопортрет*

FPU включает несколько семейств команд сравнения вещественных чисел. Все они сравнивают приёмник $st(0)$ с некоторым источником src. По аналогии с командой целочисленного сравнения можно сказать, что анализируется знак разности $st(0) - src$. Так как приёмником является $st(0)$, поведение команд сравнения не различается для GAS и Intel.

Некоторые из них помещают результат в слове состояния sw, откуда его надо вручную копировать в регистр флагов $flags$ (при этом осмысленное значение приобретают CF, ZF, PF). Они поддерживаются, но считаются устаревшими. Более современные команды сравнения помещают результат непосредственно во флагах CF, ZF, PF регистра $flags$.

Также система команд FPU включает `fxam`, которая определяет вид значения в $st(0)$ в соответствии с разделом 5.3.1.

Знак нуля при сравнении не учитывается, то есть считается, что $-0 = +0$.

Команды сравнения

Все команды сравнения вещественных чисел [75] сравнивают вершину стека — приёмник $st(0)$ с другим операндом — источником src (таблица 5.22).

Команды сравнения FPU

Таблица 5.22

Команда	Источник	Флаги	Особенности
`fcom[p[p]]`	$st(1)$	$C0, C3, C2$	
`fcom[p] src`	src		
`fucom[p[p]]`	$st(1)$		Не генерируется исключения
`fucom[p] src`	src		при сравнении с nan
`ficom[p] smem`	$smem$		$smem$ — целое число
`ftst`	0		
`fcomi[p] %st(i), %st(0)`	$st(i)$	CF, ZF, PF	
`fucomi[p] %st(i), %st(0)`	$st(i)$		Не генерируется исключения при сравнении с nan

По результатам сравнения (в соответствии со знаком разности $st(0) - src$) устанавливается значение трёх флагов: отрицательности, нуля и несравнимости (таблица 5.23). Операнды считаются несравнимыми, если хотя бы один из них — тихое нечисло (любые тихие нечисла как операнды команд обрабатываются, как вещественная неопределённость nan, поэтому обычно говорят, что операнды несравнимы, если хотя бы один из них равен nan).

Значение флагов при сравнении

Таблица 5.23

Соотношения	Флаги		
	Отрицательности $C0/CF$	Нуля $C3/ZF$	Несравнимости $C2/PF$
$st(0) > src$ $st(0) - src > 0$	0	0	0
$st(0) = src$ $st(0) - src = 0$	0	1	0
$st(0) < src$ $st(0) - src < 0$	1	0	0
$st(0)$ и src несравнимы	1	1	1

Действие команд сравнения одинаково для синтаксиса AT&T и синтаксиса Intel. Мнемоника может включать суффикс p, в этом случае приёмник $st(0)$ после сравнения выталкивается из стека. Если явный операнд не задан (то есть источником считается $st(1)$), может также использоваться суффикс pp — в этом случае после сравнения из стека выталкиваются оба операнда, $st(0)$ и $st(1)$. Если источник задан явно и находится в памяти, необходимо указывать также суффикс размера по тем же правилам, что и для арифметических команд.

Если хотя бы одно из сравниваемых значений — нечисло, для бóльшей части команд сравнения (без префикса u) это недействительная арифметическая операция #IA. Если соответствующее исключение не замаскировано (раздел 3.4.2), работа программы прерывается, если замаскировано — устанавливается флаг несравнимости. Команды неупорядоченного сравнения, мнемоники которых включают префикс u, считают операцию сравнения с тихим нечислом, в частности, вещественной неопределённостью, действительной и устанавливают в этом случае флаг несравнимости. Если хотя бы одно из сравниваемых значений — неподдерживаемое значение или сигнальное нечисло, операция сравнения недействительна (#IA) для всех команд.

По набору используемых флагов команды сравнения делятся на две группы — часть их выставляет биты слова состояния sw ($C0, C3$ и $C2$), часть — биты регистра $flags$ (CF, ZF и PF).

В слове состояния сопроцессора sw результат сохраняют команды сравнения оригинального FPU 8087 и 80387. В настоящее время такой способ также доступен в силу преемственности набора команд x86, но неоптимален. Начиная с Pentium Pro, доступен более быстрый вариант. Современные процессоры включают команды сравнения с суффиксом i (`fcomi, fcomip, fucomi, fucomip`), которые напрямую устанавливают флаги CF, ZF, PF в $flags$. Неиспользуемые три флага состояния $flags$ сбрасываются в 0; биты $C0, C2, C3$ слова состояния сопроцессора не изменяются.

Если при сравнении целых чисел в регистре $flags$ выставляется значение тех же флагов, которые выставляются по результатам арифметических действий, то в FPU флаги, выставляемые устаревшими командами сравнения в слове состояния sw, отличаются от тех, что устанавливаются, в частности, при вычитании.

Анализ результатов сравнения

Условные команды, даже из набора FPU, не могут анализировать флаги слова состояния FPU sw. Соответственно, если используется одна из устаревших команд сравнения, сохраняющая результат в cw, после её выполнения необходимо вручную перенести его в регистр флагов $flags$ основного процессора.

Это выполняется в два этапа:

– слово состояния sw выгружается в регистр ax командой `fnstsw`;

– старший байт ax загружается в младший байт регистра флагов $flags$ командой `sahf`.

При загрузке старшего байта sw во $flags$ флаг отрицательности $C0$ помещается во флаг беззнакового переполнения CF, флаг нуля $C3$ — в аналогичный ему по смыслу ZF, а флаг несравнимости $C2$ — во флаг чётности PF. Другие флаги младшего байта $flags$ получают фактически неопределённое значение. Таким образом, результат можно анализировать как результат сравнения беззнаковых целых чисел.

Результат современных команды сравнения, напрямую устанавливающих флаги CF, ZF, PF и обнуляющих остальные флаги состояния в регистре $flags$, можно анализировать как результат сравнения беззнаковых целых чисел без дополнительных действий.

Определение вида значения

Кроме команд сравнения, анализирующих разность двух значений $st(0) - src$ как число, набор команд FPU включает также команду `fxam`, которая анализирует тип содержимого вершины стека (нормальное число, ноль, бесконечность, денормализованное число и т. д.). Эта команда достаточно старая, поэтому записывает результат в слово состояния FPU.

Команда `fxam` выставляет в соответствии с значением $st(0)$ все четыре специальных флага $C0 - C3$ слова состояния sw (таблица 5.24).

Значение флагов при определении вида $st(0)$

Таблица 5.24

Значение в $st(0)$	**Флаги**			
	$C0$	$C1$	$C2$	$C3$
Недопустимое значение	0	Знаковый бит $st(0)$	0	0
Ноль	0		0	1
Денормализованное число	0		1	1
Нормализованное число	0		1	0
Бесконечность	1		1	0
Неопределённость (nan)	1		0	0
Пустой регистр	1		0	1

Флаг $C1$ всегда устанавливается равным знаковому биту $st(0)$, даже если в нём находится значение, не имеющее знака (вещественная неопределённость или недопустимое значение). Необходимо отметить, что при загрузке флагов FPU

в регистр $flags$ бит $C1$ попадает на зарезервированный разряд и, соответственно, игнорируется.

Команда `fxam` корректно работает даже при пустом стеке. Если регистр данных r_{top}, соответствующий вершине стека, помечен в регистре тегов tw как пустой, флаги $C0, C3, C2$ получают значения, указанные в последней строке таблицы 5.24, а $C2$ — значение знакового бита r_{top}.

Если $st(0)$ не пуст, флаги $C0, C3, C2$ соответствуют виду содержащегося в нём значения (более подробно виды значений FPU описаны в разделе 5.3.1).

5.4. Команды SSE/AVX — x/ymm

> Багровый и белый отброшен и скомкан,
> в зелёный бросали горстями дукаты,
> а чёрным ладоням сбежавшихся окон
> раздали горящие жёлтые карты.
>
> *В. В. Маяковский. Ночь*

2024.01.31 Раздела пока нет, смотрите презентации (имена файлов $*$`xmm`$*$).

Контрольные вопросы

1. Какой порядок операндов принят в синтаксисе AT&T?
2. Какие вы знаете команды передачи управления?
3. Какие вы знаете команды пересылки данных?
4. Какие команды используются для обнуления регистра?
5. Какие команды используются для выполнения арифметических операций над целыми числами?
6. Какие команды используются для выполнения арифметических операций над вещественными числами?
7. Какие команды используются для выполнения тригонометрических операций?
8. Какие команды используются для сравнения вещественных чисел?
9. Какие флаги регистра $flags$ содержат результат сравнения вещественных чисел?

Глава 6. Программирование на языке Ассемблера

Есть великая правда у тех, кем хранится завет
Но для тех, кто им стал, нет завета и истины нет.

С. А. Калугин. Королевская свадьба

Некоторые приёмы программирования на ассемблере существенно отличаются от используемых в языках высокого уровня. При этом GNU Assembler является неотъемлемой частью процесса компиляции этих языков, в первую очередь — C/C++. Соответственно, структура программы на GNU Assembler аналогична C/C++, кроме того, полностью доступна стандартная библиотека libc. Данная глава показывает как возможную связь программ на C/C++ и ассемблере, так и различия в реализации алгоритмов.

Если не указано иное, примеры соответствуют тридцатидвухбитной платформе. Вызовы функций описываются в соответствии с тридцатидвухбитным соглашением `cdecl` и без учёта искажения имён (см. раздел 6.2).

6.1. Структура программы на ассемблере

Я родился уже помня тебя, просто не знал, как тебя звать
Дох от жажды в твоих родниках — я не знал, как тебя знать

Б. Б. Гребенщиков. Если бы не ты

Программа обязательно должна включать точку входа — адрес, с которого начинается её выполнение. По умолчанию компоновщик GCC ищет точку входа по имени $\_start$ (здесь нижнее подчёркивание — неотъемлемая часть имени, а не компенсация возможного искажения имён компилятором). Для программ на C/C++ по адресу $\_start$ находится стартовый код библиотеки libc, который, в частности, инициализирует все используемые библиотекой ресурсы и вызывает так называемую головную функцию $main()$. После этого программа выполняется по определённому программистом алгоритму (в частности, с помощью цикла обработки сообщений можно реализовать событийно-ориентированную модель) и при определённых обстоятельствах должна корректно завершать свою работу.

Минимальная программа запускается и немедленно завершает работу. Также в учебных целях часто описывается программа, выводящая на экран приветствие «Hello, world!».

Использование libc можно отключить при компиляции. В этом случае необходимо отказаться не только от вспомогательных функций этой библиотеки, но и от $main()$ (либо вручную реализовать вызывающий её стартовый код).

6.1.1. Программирование с использованием libc

> Какое наслаждение для шляпника сознавать, что весь мир приходит в движение для того, чтобы он мог произвести и продать эту шляпу!
>
> *К. Маркс. Капитал*

По умолчанию в GCC программа (как на языке C/C++, так и на языке ассемблера) собирается с поддержкой стандартной библиотеки libc. Соответственно, стартовой (главной) функцией программы является C-функция `int main(int argc, char *argv[])`.

Стартовая функция $main()$ может находиться как в модуле на языке C/C++, так и в ассемблерном модуле. В последнем случае необходимо, чтобы эта функция была доступна компоновщику и чтобы её имя соответствовало имени C-функции $main()$ с учётом искажения имён, а если используются параметры $argc$ и $argv$ — чтобы соглашение о вызове соответствовало C-функциям на данной платформе. Подробнее эти моменты будут рассмотрены в разделе 6.2.

Минимальная программа с использованием libc

Минимальная программа на C/C++ выглядит следующим образом (листинг 6.1).

Листинг 6.1. Минимальная программа с использованием libc (C++)

```
1 int main()
2 {
3     return 0;
4 }
```

Головная функция $main()$ здесь завершается с кодом 0 сразу после запуска. Параметры функции $main()$ — $argc$ и $argv$ — здесь не используются и, как позволяет стандарт, опущены.

Приведём код соответствующей ей минимальной программы на ассемблере GAS с использованием стандартной библиотеки libc (листинг 6.2).

Листинг 6.2. Минимальная программа с использованием libc

```
1 .globl main // головная функция (libc)
2 main:
3       xor %eax, %eax // A ^= A, то есть A = 0
4       ret // return A
```

Директива `.globl main` делает функцию $main()$ видимой для компоновщика. Метка `main:` показывает начало самой функции.

Команда `ret`, в отличие от оператора C++ return, не принимает возвращаемое значение как параметр. Целочисленный результат в соответствии с соглашениями о вызовах (раздел 6.2) всегда подразумевается в регистре A.

Соответственно, чтобы вернуть код успешного завершения программы (0), необходимо обнулить регистр A (eax для 32-битного кода и rax для 64-битного). В данном случае это делается при помощи побитового исключающего «или» (эта команда компактнее явного копирования нуля в регистр и выполняется быстрее) При этом для быстрого обнуления 64-битного регистра rax также рекомендуется 32-битная команда `xor %eax, %eax` без префикса REX, так что минимальная программа 6.2 корректна как в 32-битном, так и в 64-битном режиме.

Параметры $argc$ и $argv$ располагаются в соответствии с используемом соглашением о вызове, то есть находятся в стеке для тридцатидвухбитных систем и в регистрах для шестидесятичетырёхбитных.

Имя функции $main()$, как и имена других функций libc, в GNU/Linux и BSD (кроме Mac OS X) не искажается (здесь и далее, если не сказано иное, рассматривается 32-битный либо 64-битный GNU/Linux).

Для того, чтобы минимальная программа работала также под Microsoft Windows и Mac OS X, необходимо компенсировать искажение имени $main$ (подробнее в разделе 6.2.6):

Листинг 6.3. Минимальная программа с использованием libc (искажение имён компенсировано)

```
1 .globl FNAME(main) // головная функция (libc)
2 FNAME(main):
3       xor %eax, %eax
4       ret
```

Макрос препроцессора FNAME, предназначенный для компенсации искажения имён, также описан в разделе 6.2.6.

Приветствие миру

Для вывода на экран строки `"Hello, world!\n"` используем функцию библиотеки libc $printf()$ (листинг 6.4), так как воспользоваться в ассемблерной программе потоком стандартного вывода `std::cout` и оператором вывода в поток `<<` затруднительно из-за декорирования имён. Также можно использовать более простую функцию libc $puts()$.

Листинг 6.4. Программа, выводящая на экран приветствие (C++)

```
1 int main()
2 {
```

```
3     printf("Hello, world!\n");
4     return 0;
5 }
```

Аналогичная программа на ассемблере уже не может быть реализована одинаково для разных ОС и разрядности (листинг 6.5).

Листинг 6.5. Программа, выводящая на экран приветствие (ассемблер)

Начало (общее)

```
1 .data
2   msg:
3   .string "Hello, world!\n"
4 .text
5 .globl FNAME(main)
```

а) 32 бита, cdecl

```
6 FNAME(main):
7   sub $12, %esp
8   pushl $msg
9
10  call FNAME(printf)
11  add $4, %esp
12  add $12, %esp
13  xor %eax, %eax
14  ret
```

б) 64 бита, System V

```
6 FNAME(main):
7   sub $8, %rsp
8   lea msg(%rip), %rdi
9   mov $0, %al
10  call FNAME(printf)
11
12  add $8, %rsp
13  xor %eax, %eax
14  ret
```

в) 64 бита, Microsoft

```
6 main:
7   sub $8, %rsp
8   lea msg(%rip), %rcx
9   sub $32, %rsp
10  call printf
11  add $32, %rsp
12  add $8, %rsp
13  xor %eax, %eax
14  ret
```

Начало (строки 1-5 листинга 6.5) не зависит от платформы и содержит описание строки `"Hello, world!\n"` в сегменте данных (директива `.data`). Адрес начала строки зафиксирован меткой msg.

Директива `.text` в строке 4 говорит о том, что последующие строки уже относятся к сегменту кода.

Внутреннее содержание функции $main()$ (строки 6-14) различается в зависимости от используемого соглашения о вызове.

Вариант а) соответствует 32-битным GNU/Linux, BSD (включая Mac OS X) и Microsoft Windows; вариант б) — 64-битным GNU/Linux и BSD (включая Mac OS X); вариант в) — 64-битной Microsoft Windows (макрос FNAME не используется, так

как 64-битное соглашение Microsoft использует только одна ОС, и она не искажает имена С-функций).

В строке 7 указатель стека sp выравнивается на 16 (пролог). Соответственно, в строке 13 (эпилог) восстанавливается исходное значение sp — чтобы при выполнении команды ret на вершине стека находился адрес возврата.

В строке 8 адрес msg строки `"Hello, world!\n"` помещается на место, соответствующее первому параметру функции.

В строке 9 листинга 6.5, б), так как функция $printf()$ имеет переменное число параметров, указывается количество параметров, передаваемых через xmm-регистры (для функций с постоянным набором параметров это не требуется). В строке 9 листинга 6.5, в) резервируется теневое пространство согласно 64-битному соглашению Microsoft.

В строке 10 вызывается функция $printf()$. В строке 11 из стека удаляются стековые параметры (листинг 6.5, а) или теневое пространство (листинг 6.5, в).

В строке 13 в регистр A помещается нулевой код завершения. Строка 14 завершает функцию $main()$.

Подробнее все действия описаны ниже (разделы 6.2.4, 6.2.6, 6.2.5).

В листинге (листинг 6.5, а) строки 11 (зачистка параметров $printf()$) и 12 (восстановление sp после выравнивания) можно объединить, заменив командой `add $16, %esp`. В листинге (листинг 6.5, в) также можно объединить пары строк 7 и 9 (в `sub $40, %rsp`), а также 11 и 12 (в `add $40, %rsp`). Они разнесены исключительно для наглядности.

Форматированный вывод

Если необходимо передать функции вывода несколько параметров

Листинг 6.6. Программа, выводящая на экран два числа (C++)

```
1 char *pfmt = "Переменные: %d %d\n";
2 int foo = 13;
3 int main()
4 {
5   printf(pfmt, 19, foo);
6   return 0;
7 }
```

по соглашению `cdecl` (листинг 6.7, а) эти параметры передаются в обратном порядке (то есть на вершине стека оказывается первый).

Как и выше, вариант а) соответствует 32-битным GNU/Linux, BSD (включая Mac OS X) и Microsoft Windows; вариант б) — 64-битным GNU/Linux и BSD (включая Mac OS X); вариант в) — 64-битной Microsoft Windows.

Листинг 6.7. Программа, выводящая на экран два числа (ассемблер)

Начало (общее)

```
1 .data
2   fmt: .string "Переменные: %d %d\n"
3   foo: .int 13
4 .text
5 .globl FNAME(main)
```

а) 32 бита, cdecl

```
6 FNAME(main):
7   sub $12, %rsp
8   pushl foo
9   pushl $19
10  pushl $fmt
11
12  call FNAME(printf)
13  addl $3*4, %esp
14  add $12, %esp
15  xor %eax, %eax
16  ret
```

б) 64 бита, System V

```
6 FNAME(main):
7   sub $8, %rsp
8   lea fmt(%rip), %rdi
9   mov $19, %esi
10  mov foo(%rip), %edx
11  mov $0, %al
12  call FNAME(printf)
13
14  add $8, %rsp
15  xor %eax, %eax
16  ret
```

в) 64 бита, Microsoft

```
6 main:
7   sub $8, %rsp
8   lea fmt(%rip), %rcx
9   mov $19, %edx
10  mov foo(%rip), %r8d
11  sub $32, %rsp
12  call printf
13  add $32, %rsp
14  add $8, %rsp
15  xor %eax, %eax
16  ret
```

Программа 6.7, как и 6.6, вызывает $printf(\&fmt, 19, foo)$, то есть на экран будет выведено: `Переменные: 19 13`.

В программе 6.7 две глобальные (расположенные в сегменте данных) переменные — строка fmt и целое число foo. При этом в функцию $printf()$ необходимо передать адрес начала строки $\&fmt$ и значение числа foo.

Обращение к адресу в памяти (операнду без префикса) для всех команд ассемблера, кроме lea, предполагает чтение значения по этому адресу, что и используется для записи параметра foo в стек (строка 8 листинга 6.7, а) и в регистры (строки 10 листингов 6.7, б) и в).

Для того, чтобы оперировать не со значением по адресу, а непосредственно с адресом, используется команда lea (строки 8 листингов 6.7, б) и в), запись адреса

строки fmt в регистры). Для 32-битного кода также можно загрузить адрес fmt в регистр (`lea fmt, %eax`) и затем уже загрузить его в стек (`push %eax`); но, так как в 32-битном режиме fmt адресуется не относительно rip, а абсолютно, то же действие можно выполнить более компактно — записав абсолютный адрес fmt в стек как константу (строка 10 листинга 6.7). В 64-битном режиме адрес глобальной переменной не может быть записан в стек как константа, потому что константой не является (рассчитывается по смещению относительно rip).

6.1.2. Программирование без libc

> Натурализм здесь — видимость, и только эстетическая видимость, создаваемая большими и малыми робинзонадами.
>
> *К. Маркс. Капитал*

Минимальная программа с libc (листинг 6.2) после ассемблирования занимает 4704 байт. В этот размер входят библиотечные функции, обеспечивающие обработку параметров, вызов стартовой функции $main()$ и завершение программы после возврата управления из $main()$.

Отключить использование libc при сборке позволяет ключ `-nostdlib`. В этом случае взаимодействие с операционной системой, в том числе завершение программы, необходимо осуществлять напрямую, с помощью системных вызовов.

Точкой входа в этом случае будет непосредственно метка $\_start$.

Каждая операционная система имеет свой набор функций и свой способ их вызова (раздел 6.2.9). В большинстве тридцатидвухбитных операционных систем системные вызовы осуществляются с помощью программных прерываний. При этом, если в GNU/Linux, BSD и FreeDOS системные вызовы хорошо документированы, то в Microsoft Windows как механизм их вызова, так и набор функций постоянно меняются и скрыты от прикладного программиста. Вместо прямых системных вызовов под Microsoft Windows предлагается использовать функции библиотеки Windows API.

В GNU/Linux к функциям операционной системы в тридцатидвухбитном режиме можно обратиться с помощью прерывания `0x80`. Номер функции указывается в регистре eax. Вызов может принимать до шести аргументов в регистрах $ebx, ecx, edx, esi, edi, ebp$.

Минимальная программа без libc

Рассмотрим минимальную программу, не использующую функции libc (в том числе $main()$) для GNU/Linux. Сразу после запуска она должна завершиться с кодом 0. Для завершения программы используется системный вызов с номером 1 — $sys\_exit()$. Его единственный параметр — код возврата.

Листинг 6.8. Минимальная программа без libc

```
1 .globl _start
2 _start:             // точка входа
3     movl $1, %eax   // № функции 1 (sys_exit)
4     xorl %ebx, %ebx // параметр: код завершения 0
5     int $0x80       // системный вызов
```

Если код 6.8 сохранён как файл `nsmin.S`, собрать его без стандартной библиотеки можно командой:

```
1 $ gcc -o nsmin  nsmin.S  -nostdlib
```

Полученный исполняемый файл занимает 600 байт.

Приветствие миру

Для вывода строки на экран ядром Linux используется системный вызов с номером 4 — $sys\_write()$. Он предназначен для записи в файл; требует трёх параметров — дескриптор файла, указатель на начало записываемых данных и длина этих данных в байтах. Согласно концепции Unix всё есть файл; для вывода на экран используется специальный дескриптор 1 ($stdout$).

Листинг 6.9. Вывод приветствия при помощи системных вызовов Linux

```
1  .data
2      msg:
3      .ascii "Hello, world!\n"
4      len = . - msg   // длина строки
5  .global _start      // точка входа в программу
6  _start:
7      movl $4, %eax   // № функции 4 (sys_write)
8      movl $1,   %ebx // - поток №1 (stdout)
9      movl $msg, %ecx // - указатель на выводимую строку
10     movl $len, %edx // - длина строки
11     int $0x80       // системный вызов
12     movl $1, %eax   // № функции 1 (sys_exit)
13     xorl %ebx, %ebx // параметр: код завершения 0
14     int $0x80       // системный вызов
```

Для вывода более сложных данных, в частности, чисел, необходимо вручную сформировать в программе выводимую в файл $stdout$ строку. Такой код, предназначенный для взаимодействия с системными вызовами, займёт существенный объём, так что в итоге выигрыш от неиспользования libc может оказаться несущественным.

6.2. Подпрограммы и функции

> Рассказ есть зодчество из слов.
> Зодчество из «рассказов» есть сверхповесть.
>
> *В. Хлебников. Зангези*

Как сказано в разделе 4.1.3, одним из способов соединения кода на различных языках программирования является вызов внешних функций, описанных в модулях, соединяемых с головным на этапе компоновки.

Функции языка высокого уровня являются частным случаем **подпрограмм** — последовательностей команд, завершающихся командой возврата. Для вызова подпрограммы используется команда `call`, которая помещает в стек адрес возврата, а затем передаёт управление на начало вызываемой подпрограммы; для возврата управления вызывающей программе — команда `ret`, которая передаёт управление адресу, снятому со стека.

Таким образом, при вызове внешних функций необходимо решить четыре основные задачи. Первые две связаны с возможностью связать вызов функции из одного модуля с её описанием в другом на стадии компоновки; третья и четвёртая требуются для корректного взаимодействия вызывающей программы и функции на этапе выполнения.

1. Имена функций (как вызываемых из данного модуля, так и тех, которые описаны в данном модуле и могут быть вызваны извне) должны быть видимы для компоновщика.

Для этого используются ключевое слово `extern` в C++ и директива `.globl` в языке ассемблера.

2. Имя одной и той же функции на этапе компоновки должно выглядеть одинаково как в том модуле, где она описана, так и в том, где она вызывается.

Для этого необходимо отказаться от такой возможности языка C++, как перегрузка (она приводит к декорированию имён) с помощью дополнительной строки `"C"` для ключевого слова `extern`. Кроме того, многие версии операционной системы Microsoft Windows требуют от компиляторов дополнительно искажать имена; это необходимо компенсировать вручную при помощи макросов.

3. Параметры должны помещаться вызывающей программой именно туда, где их будет искать вызываемая функция; возвращаемое значение функции также должно оказаться на том месте, где его ожидает вызывающая программа.

Для языков высокого уровня протокол взаимодействия вызывающей и вызываемой программ называется соглашением о вызовах. Используемое соглашение определяется платформой, операционной системой, языком высокого уровня, компилятором, а также специальными ключевыми словами при описании функции. Соответственно, функцией можно назвать подпрограмму, следующую необходимому соглашению о вызове.

4. Функция перед возвратом должна удалить из стека все те данные, которые она поместила поверх адреса возврата, и ни в коем случае не удалять больше, чем поместила.

Баланс стека должен быть сохранён, иначе во время возврата из функции управление будет передано не туда (а именно — по адресу, равному значению в текущей вершине стека), что приведёт к некорректной работе программы и, возможно, к её краху.

Рассмотрим процесс взаимодействия вызывающей программы и функции подробнее.

6.2.1. Требования к вызовам функций

> И может быть мы сразу друг друга поймём,
> Если у нас один и тот же разъём.
>
> *Б. Б. Гребенщиков. Жёлтая луна (USB)*

К механизму вызова подпрограммы (в различных языках используется также термины «функция», «метод», «процедура») можно сформировать ряд требований.

1. Возможность передачи управления на произвольный адрес.
2. Возврат управления назад после завершения подпрограммы.
3. Вложенные вызовы подпрограмм.
4. Сохранение и восстановление регистров вызывающей программы.
5. Передача заданного количества аргументов.
6. Возврат значения.
7. Выделение и освобождение памяти под локальные переменные подпрограмм.

В системе команд x86 реализованы только первые три из них. Обеспечить выполнение остальных можно только в том случае, если вызывающая и вызываемая программа «договорятся», где будут находиться передаваемые аргументы и локальные переменные.

В некоторых источниках считается, что функцией можно назвать только подпрограмму, написанную на языке высокого уровня. При этом подпрограмма, написанная на ассемблере и соответствующая используемому в данном языке высокого уровня соглашению о вызове, может быть вызвана наравне с написанными на ЯВУ. Таким образом, логичнее считать термин «функция» либо синонимом подпрограммы, либо обозначать им подпрограмму, соответствующую одному из общепринятых соглашений.

6.2.2. Механизм вызова подпрограммы

Что такое заклинание, понятно всем.
Это когда говоришь — а оно случается.

А. В. Жвалевский, И. Е. Мытько.
Порри Гаттер. Приложения

В системе команд x86 для реализации механизма подпрограмм используются всего две команды:

– команда вызова подпрограммы `call`, единственным аргументом которой является адрес начала подпрограммы;
– команда возврата из подпрограммы `ret`.

Пусть следующая команда, расположенная по адресу c_i — `call f` (рис. 6.1, а). Команда `call` помещает в стек адрес следующей по порядку команды c_{i+1} —

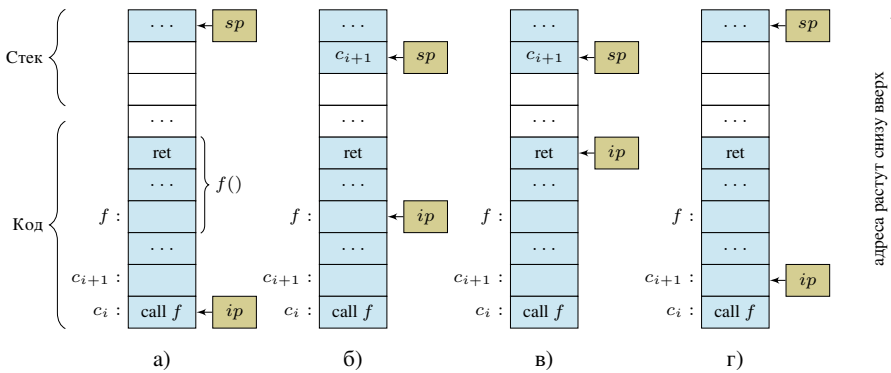

Рис. 6.1. Изменение указателя стека командами вызова и возврата

адрес возврата, после чего в указатель команд ip помещается адрес f, так что эта команда становится следующей для исполнения процессором (рис. 6.1, б). Когда в процессе исполнения подпрограммы f встретится команда `ret` (рис. 6.1, в), из стека извлекается верхнее машинное слово — там должен быть адрес возврата — и помещается в указатель команд ip (рис. 6.1, г). Соответственно, выполнение вызывающей программы продолжится со следующей за `call` команды.

Параметры и возвращаемое значение

Параметры могут передаваться в подпрограмму через стек или регистры. Вызывающая программа должна разместить параметры в условленных местах до того, как управление будет передано подпрограмме. Соответственно, параметры,

передаваемые через стек, окажутся под адресом возврата, то есть будут иметь бóльшие адреса.

Возвращаемое значение функции не может передаваться вызывающей подпрограмме через стек, так как при выполнении команды `ret` в стеке не должно остаться ничего после адреса возврата. Соответственно, возвращаемое значение может передаваться в вызывающую подпрограмму только через регистр.

Иногда значение, которое, согласно синтаксису языка высокого уровня, является возвращаемым, не может быть размещено в регистре (в частности, это может быть объект). В этом случае зарезервированное для него место (или его адрес) фактически передаётся как ещё один параметр.

Таким образом, «настоящее» возвращаемое значение может быть только числом. Если это целое число или указатель, в программах для x86 для возврата используется регистр A. Вещественное значение возвращается через вершину стека FPU $st(0)$ или через $x/y/zmm0$.

Конкретное расположение параметров и возвращаемого значения определяется **соглашением о вызове** (см. раздел 6.2.4).

Локальные переменные

Локальные переменные также могут располагаться в регистрах или памяти (стеке).

Так как память под стековые локальные переменные подпрограммы выделяется подпрограммой после передачи управления на её начало, эти переменные будут расположены в стеке над адресом возврата (так как стек растёт вниз — по меньшим адресам).

6.2.3. Локальные переменные

Чужой нос другим соблазн.

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

Как уже говорилось в разделе 3.2, локальные переменные подпрограммы хранятся в стеке; также программист или оптимизирующий компилятор может поместить часть локальных переменных в регистрах общего назначения. Это не предписано системой команд, но является общепринятым.

Размещение локальных переменных в регистрах, которые по соглашению (см. раздел 6.2.4) могут изменяться подпрограммой (изменяемые — обычно A, C, D и др.) не требует дополнительных действий.

Напротив, размещение локальных переменных в регистрах, которые по соглашению не могут изменяться подпрограммой (неизменяемые — обычно B, bp и др.),

а также в стеке, требует помещения в начало и конец подпрограммы специальных фрагментов кода — пролога и эпилога соответственно.

Локальные переменные в неизменяемых регистрах

Если внутри функции нужно использовать неизменяемые регистры, то в прологе их исходное значение необходимо сохранить в стеке, а в эпилоге — восстановить (рис. 6.2).

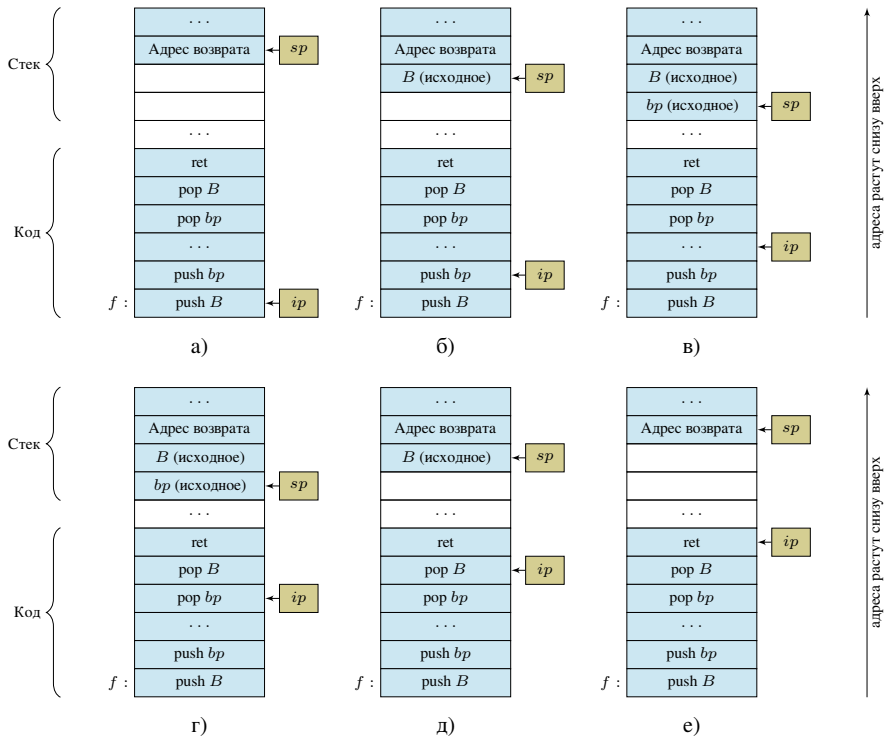

Рис. 6.2. Сохранение-восстановление неизменяемых регистров (часть пролога и эпилога)

Из-за принципа работы стека восстановление регистров (рис. 6.2, г-е) происходит в порядке, обратном сохранению (рис. 6.2, а-в).

Локальные переменные в стеке, классический пролог/эпилог

В шестнадцатибитном режиме работы x86 переменные нельзя было адресовать через sp (базовыми регистрами в косвенной адресации могли быть только B и bp),

поэтому старейший вариант пролога/эпилога (рис. 6.3) предполагает адресовать

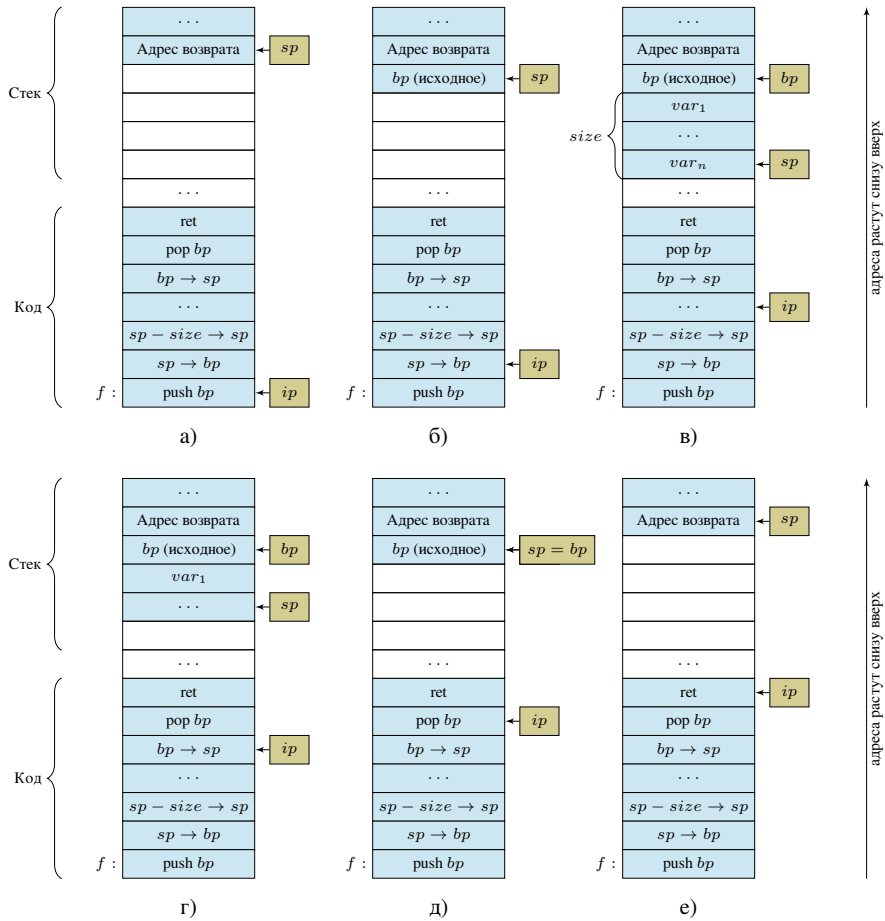

Рис. 6.3. Размещение локальных переменных в стеке (классический вариант пролога и эпилога)

их через bp. Регистр bp во всех соглашениях относится к неизменяемым, поэтому сохраняется в начале пролога (рис. 6.3, а-б) и восстанавливается в конце эпилога (рис. 6.3, д-е).

Далее в прологе в bp помещалась копия текущего значения sp (таким образом, непосредственно по адресу bp после этого находится копия старого значения bp), а в стеке резервировались $size$ байтов под локальные переменные (рис. 6.3, б-в).

Соответственно, в эпилоге $f()$ старое значение sp восстанавливалось из его копии bp (рис. 6.3, г-д).

Тогда внутри $f()$ относительно bp можно адресовать как стековые локальные переменные (с отрицательными смещениями), так и стековые параметры (под адресом возврата в стеке, растущем вниз, то есть с положительными смещениями).

Для большей компактности в системе команд 80186 были введены специальные команды — `enter` как эквивалент пролога с сохранением bp и `leave` для соответствующего эпилога (команда `enter` в настоящее время не используется, так как выполняется дольше, чем пролог из трёх отдельных команд).

Основным недостатком классического пролога/эпилога является то, что регистр bp уже не может быть использован внутри функции f для чего-то иного, чем адресация локальных переменных. Это критично для тридцатидвухбитного режима, где уже возможна адресация стековых переменных и параметров непосредственно через sp, но регистров общего назначения всё ещё только восемь.

Локальные переменные в стеке, оптимизированный пролог/эпилог

Оптимизирующие компиляторы тридцатидвухбитного и шестидесятичетырёхбитного режимов адресуют локальные переменные через sp (рис. 6.4).

В этом случае после сохранения старого значения bp в этом регистре можно разместить дополнительную локальную переменную (var_{n+1} на рис. 6.4). Если это не нужно, и внутри функции регистр bp не используется — не нужны и команды $\mathrm{push}\ bp$ и $\mathrm{pop}\ bp$ соответственно в прологе и эпилоге.

Если в процессе выполнения функции $f()$ вершина стека sp не меняется, в эпилоге указатель sp увеличивается на ту же величину $size$ (рис. 6.4, в) и г), так что к моменту выхода из подпрограммы на вершине стека окажется адрес возврата (рис. 6.4, г). В противном случае необходимо соответственно корректировать как смещения переменных относительно sp после *каждого* изменения sp, так и добавляемое в эпилоге значение ($\widetilde{size}$ на рис. 6.4).

Чтобы избежать этого, изначальное значение $size$ при ручном программировании часто выбирают с запасом (под все локальные стековые переменные самой $f()$ и ещё стековые параметры вложенных вызовов) и с учётом выравнивания — тогда $\widetilde{size} = size$ и смещения постоянны.

Локальные переменные над стеком

Если внутри функции $f()$ нет вложенных вызовов, компилятор часто не резервирует место под локальные переменные, а располагает их в формально незанятой области над вершиной стека sp (по меньшим адресам) — рис. 6.5.

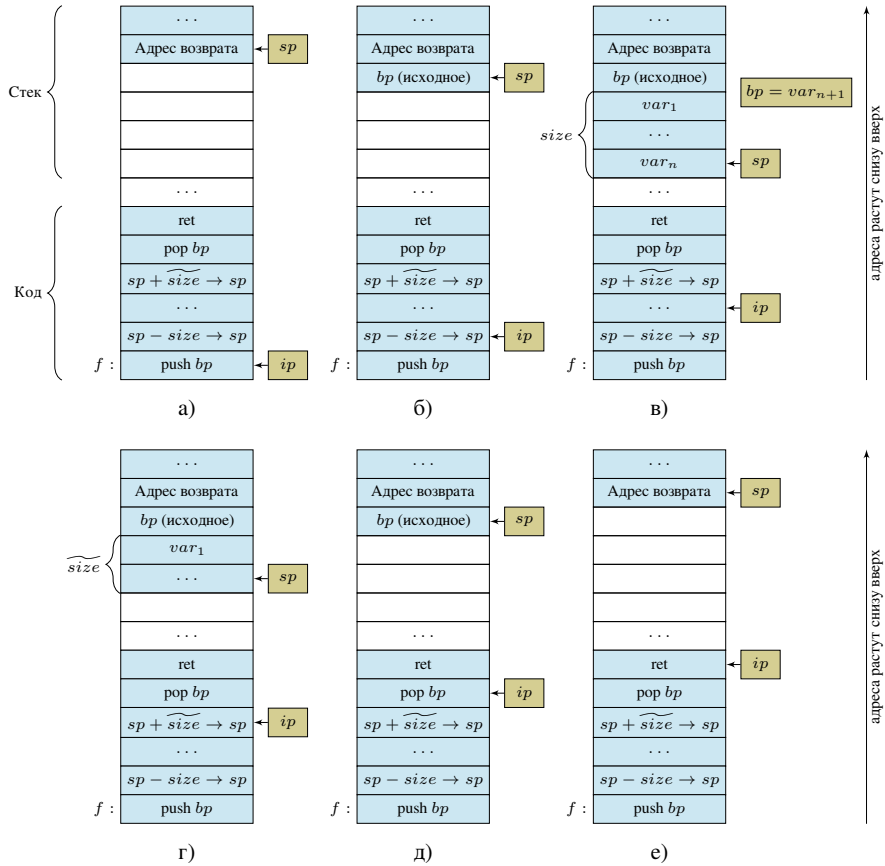

Рис. 6.4. Размещение локальных переменных в стеке
(оптимизированный вариант пролога и эпилога, 32/64)

Соответственно, пролог и эпилог сокращаются до сохранения-восстановления неизменяемых регистров (а если внутри функции ни один из них не используется — исчезают вовсе, как и показано на рис. 6.5).

Адресация локальных переменных в этом случае так же проста, как и для классического пролога/эпилога. Переменные имеют отрицательные постоянные смещения относительно sp: на рис. 6.5 адрес четырёхбайтовой переменной var_1 равен

$$\&var_1 = sp - \text{sizeof}(var_1) = sp - 4;$$

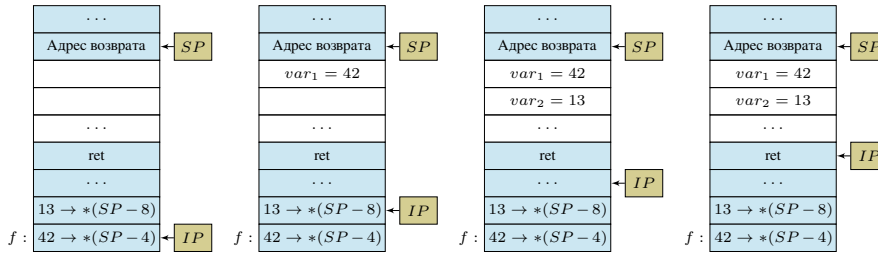

Рис. 6.5. Размещение локальных переменных над стеком — только если внутри $f()$ нет вложенных вызовов (32/64)

адрес var_2, если переменные расположены без зазоров — значению

$$\&var_2 = \&var_1 - \text{sizeof}(var_2) = sp - \text{sizeof}(var_1) - \text{sizeof}(var_2) = sp - 8$$

и так далее.

Тем не менее при наличии вложенных вызовов функций в теле функции f подобный вариант невозможен, так как команда $call$ перезапишет локальные переменные новым адресом возврата.

Кроме того, незанятая формально область над вершиной стека может быть перезаписана обработчиками исключений и прерываний (исключение — красная зона соглашения System V).

Размещение локальных переменных происходит внутри вызываемой подпрограммы и не затрагивает данные вызывающей программы. При ручном программировании можно использовать как классическую, так и любую из оптимизированных форм пролога и эпилога.

Следует отметить два момента:

– при компиляции с языка высокого уровня порядок локальных переменных в стеке может не совпадать с порядком их объявления;
– содержимое резервируемой в стеке памяти, как и начальное значение регистров, не определено, поэтому локальные переменные обязательно нужно инициализировать.

6.2.4. Соглашения о вызовах

> Если же вы хотите, чтобы произошло не что-то где-то,
> а что надо и здесь, придётся подбирать выражения.
> Точнее — заклинания.
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Порри Гаттер. Приложения*

Соглашение о вызовах определяет протокол взаимодействия вызывающей и вызываемой программ; в частности, необходимо согласовать следующие правила.

1. Способ передачи параметров (через стек, через регистры, смешанный; а также используемые регистры и их порядок).
2. Порядок размещения параметров в стеке (порядок Pascal подразумевает, что первый параметр помещается в стек первым, порядок C — что первый параметр помещается последним, непосредственно перед адресом возврата).
3. Как передаётся указатель $this$ (для методов объекта).
4. Какие регистры могут изменяться подпрограммой.
5. Кто очищает стек и сохраняет/восстанавливает регистры.
6. Инструкции вызова и возврата из подпрограмм.
7. Возврат значения из подпрограммы (функции).

На платформе x86 для вызова и возврата из подпрограммы используются соответственно команды `call` и `ret`; а значение обычно возвращается через регистр A. Параметры обычно передаются либо через стек, либо смешанным способом: первые из тех, что можно разместить в отведённых регистрах, передаются через регистры, оставшиеся — через стек.

Остальные пункты по-разному реализованы в различных языках, компиляторах, операционных системах и для различной разрядности. Подробно эти различия рассмотрены в исследовании Агнера Фога [9].

Тридцатидвухбитные соглашения о вызовах

В таблице 6.1 приведены наиболее популярные соглашения о вызовах, используемые на 32-битных платформах. Регистры для передачи параметров используются в указанном порядке. Параметры, не поместившиеся в регистрах, передаются через стек. Если столбец «Параметры в регистрах» пуст, через стек передаются все параметры. Если параметр меньше стекового слова — он расширяется до стекового слова (в 32-битном режиме — 32 бита, то есть 4 байта).

Указатель $this$ обычно передаётся первым параметром. Для соглашения gnu regparm можно указать количество параметров в регистрах (от одного до трёх).

Кроме того, регистры делятся на те, которые подпрограмма может изменять по своему усмотрению (соответственно, если они используются в вызывающей программе, вызывающей программе необходимо сохранить их перед обращением

Тридцатидвухбитные соглашения о вызовах

Таблица 6.1

Соглашение	Параметры в регистрах	Порядок	Очистка стека	Изменяемые регистры	Неизменяемые регистры	Результат
cdecl		C	вызывающая программа	eax, ecx, edx, $st(0)-st(7)$, $x/y/zmm$	ebx, ebp, esi, edi	eax, $edx{:}eax$, $st(0)$
pascal		Pascal	функция			
winapi (stdcall)		C	функция			
gnu		C	this — функция, остальные — вызывающая программа			
gnu fastcall	ecx, edx	C	функция			
gnu regparm (3)	eax, edx, ecx	C	функция			
Borland fastcall	ecx, edx	Pascal	функция			
Microsoft fastcall	ecx, edx	C	функция			

к подпрограмме и восстановить после того, как подпрограмма закончит работу) и те, которые должны сохранить своё значение (если в подпрограмме потребуется использовать один из таких регистров, то сохранить и потом восстановить их исходное значение должна сама подпрограмма).

Согласно Фогу, в тридцатидвухбитных программах, как в Microsoft Windows, так и в Unix-подобных операционных системах (GNU/Linux, BSD, Mac OS X), подпрограмма может изменять регистры eax, ecx, edx, регистры сопроцессора $st(0) - st(7)$ и регистры расширений $xmm/ymm/zmm$. Неприкосновенными должны остаться ebx, ebp и esi, edi.

Целочисленное возвращаемое значение размером не более четырёх байт (32 бит) возвращается через регистр eax. Целочисленное значение размером 64 бита ($long\ long$) — через пару регистров $edx{:}eax$ (старшие 32 бита возвращаемого значения находятся в регистре edx, младшие — в eax). Вещественное возвращаемое значение — через стек FPU: на вершине стека $st(0)$ должен находиться результат функции, прочие ячейки стека FPU должны быть пусты.

Стек выравнивается как минимум на одно стековое слово (4 байта). При этом некоторые компиляторы (в частности, GCC для GNU/Linux и Mac OS X) выравнивают стек на 16 байт перед вызовом функции (таким образом, непосредственно после вызова $sp = 16x - 4$), но это не закреплено соглашением нигде, кроме Mac OS X [9].

Шестидесятичетырёхбитные соглашения о вызовах

На шестидесятичетырёхбитных платформах применяется всего два соглашения о вызовах (таблица 6.2). Оба они развивают 32-битное соглашение cdecl (порядок

Шестидесятичетырёхбитные соглашения о вызовах

Таблица 6.2

Общие положения System V amd64 psABI и Microsoft 64:

- **порядок стековых параметров:** C;
- **выравнивание** rsp **перед** $call$**: на 16 байт** (на 32 или 64, если через стек передаётся 32- или 64-байтовое целое);
- **очистка стека:** вызывающая программа.

Соглашение	Параметры в регистрах	Особенности работы со стеком	Изменяемые регистры	Неизменяемые регистры	Результат
System V amd64 psABI	$rdi, rsi, rdx, rcx,$ $r8, r9,$ $xmm0{-}xmm7$ при переменном кол-ве параметров — кол-во xmm-параметров в al	красная зона 128 байт над стеком, обеспечивает ОС	$rax, rcx, rdx,$ $rsi, rdi,$ $r8{-}r11,$ $st(0){-}st(7),$ $x/y/zmm$	$rbx, rbp,$ $r12{-}r15$	$rax,$ $rdx{:}rax,$ $xmm0,$ $st(0)$
Microsoft 64	$rcx/xmm0,$ $rdx/xmm1,$ $r8/xmm2,$ $r9/xmm3$ при переменном кол-ве парам-в — $double$ из $xmm0$ дублируется в rcx (без округления), $xmm1$ в rdx и т. д.	теневые 32 байта под адресом возврата, обеспечивает вызывающая программа	$rax, rcx, rdx,$ $r8{-}r11,$ $st(0){-}st(7),$ $x/y/zmm$ кроме младших частей $6{-}15$	$rbx, rbp,$ $rsi, rdi,$ $r12{-}r15,$ $xmm6{-}$ $-xmm15$	$rax,$ $xmm0$

параметров в стеке C, очистка стека вызывающей программой) и позволяет передать часть параметров через регистры. К сожалению, они несовместимы между собой.

Соглашение System V используют все современные операционные системы, работающие на x86-64 (GNU/Linux, BSD, в том числе Mac OS X, и т. п.), кроме Microsoft Windows. Соответственно, 64-битное соглашение Microsoft используется в ОС Microsoft Windows для x86-64.

Основные различия между соглашениями System V и Microsoft

1. **Использование регистров для передачи параметров.**
   System V предполагает передачу первого из целочисленных параметров через регистр di, второго и далее — через si, D, C, $r8$, $r9$. Параметры с плавающей запятой ($double$ или $float$, но не десятибайтовые $long\ double$) передаются через регистры от $xmm0$ до $xmm7$, по одному в каждом регистре. Всего через регистры может передаваться $6 + 8 = 14$ параметров. Седьмой целочисленный параметр, девятый вещественный или параметры сложных типов (большие структуры, объекты, десятибайтовый вещественный тип расширенной точности FPU $long\ double$) передаются через стек.
   Таким образом, функции $\mathrm{foo}(\mathrm{int}\ i, \mathrm{double}\ x)$ и $\mathrm{bar}(\mathrm{double}\ x, \mathrm{int}\ i)$ согласно System V получают параметры одинаковым образом: целочисленный 32-битный параметр i передаётся через di, x с плавающей запятой — через $xmm0$.
   Если функция имеет **переменное число параметров** (как $printf()$ или $scanf()$), то количество параметров, передаваемых через xmm-регистры (то есть параметров типа $double$ или $float$), необходимо поместить в регистр al.
   Соглашение **Microsoft** предполагает передачу первого параметра, если он целочисленный, через C, а если вещественный — через $xmm0$. Второй параметр передаётся либо через D, либо через $xmm1$; третий — через $r8$ или $xmm2$; четвёртый — через $r9$ или $xmm3$. Всего через регистры может передаваться до четырёх параметров. Пятый параметр любого типа, а также параметры сложных типов (большие структуры, объекты) передаются через стек. Использование десятибайтового типа расширенной точности FPU в 64-битных программах не рекомендуется Microsoft. Более того, при переключении между потокам состояние FPU сохраняется только для пользовательских программ, но не для драйверов 64-битного ядра ОС Microsoft Windows.
   Таким образом, функция $\mathrm{foo}(\mathrm{int}\ i, \mathrm{double}\ x)$ согласно Microsoft получает первый (целочисленный) параметр i через ecx, второй (с плавающей запятой) x — через $xmm1$; функция $\mathrm{bar}(\mathrm{double}\ x, \mathrm{int}\ i)$ — первый (с плавающей запятой) x — через $xmm0$, второй (целочисленный) i — через D.
   Если функция имеет **переменное число параметров**, то параметры, передаваемые через xmm-регистры: а) расширяются до $double$, даже если имеют тип $float$; б) копируются (без округления) в соответствующий регистр общего назначения (из $xmm0$ в rcx, из $xmm1$ в rdx, из $xmm2$ в $r8$, из $xmm3$ в $r9$). К параметрам, передающимся через стек, это не относится.
2. **Изменяемые и неизменяемые регистры.**
   По соглашению System V регистры si и di являются изменяемыми.
   По соглашению Microsoft регистры $xmm6 - xmm15$ (младшие 128 бит соответствующих y/zmm-регистров) являются неизменяемыми и должны сохраняться функцией.
3. **Особенности работы со стеком.**

Соглашение System V предусматривает красную зону над стеком (в незанятом пространстве с адресами, меньшими rsp) размером 128 байт. Красная зона не изменяется прерываниями и системными вызовами, что обеспечивается ОС и обработчиками прерываний. Соглашение System V не требует от вызывающей программы выделять дополнительное пространство в стеке.

Соглашение Microsoft требует от вызывающей программы обеспечить 32 байта теневого пространства в стеке перед вызовом функции. Теневое пространство располагается над стековыми параметрами функции, если они есть (но, после вызова — под адресом возврата) и предназначено, согласно документации Microsoft [64], для сохранения регистровых параметров ($32 = 4 \cdot 8$). Тем не менее, согласно Фогу, теневое пространство размером в 32 байта необходимо обеспечить (и оно может быть перезаписано), даже если функция не принимает параметров в регистрах. Соглашение Microsoft не обеспечивает сохранности незанятой области над стеком.

4. **Возвращение результата.** Соглашение System V позволяет использовать пару регистров $D{:}A$ для возвращения небольших структур и объектов, а также $st(0)$ для 10-байтового числа расширенной точности.

Общие положения соглашений System V и Microsoft

1. **Выравнивание стека.**
   Стек в 64-битных системах перед вызовом функции выравнивается как минимум на 16 байт (два 8-байтовых стековых слова): $sp = 16x$. Если среди стековых параметров есть 32- или 64-байтовое целое, то стек выравнивается соответственно на 32 или 64 байта.
   После вызова функции в стек помещается 8-байтовый адрес возврата, соответственно, стек оказывается невыравненным ($sp = 16x - 8$). Если функция содержит вложенные вызовы, её пролог должен включать выравнивание стека (а эпилог, соответственно — восстановление исходного значения sp). В частности, возможно использование классических пролога/эпилога, которые включают сохранение/восстановление 8-байтового регистра rbp и выравнивают тем самым стек. Также выравнивание можно восстановить, зарезервировав 8 байт (либо $32 - 8 = 24$ байт, либо $64 - 8 = 56$ байт) памяти в стеке под локальные переменные путём уменьшения значения sp на 8 (либо соответственно 24 или 56) в прологе (и увеличения на ту же величину в эпилоге).
2. **Возвращение результата.**
   Целочисленный результат размером 32 бита и менее ($char, short, int$) расширяется до 32 бит (знаковый — знаковым битом, беззнаковый — нулями) и возвращается через регистр eax. При изменении младших 32 бит (eax) старшие 32 бита rax автоматически обнуляются, так что старший (знаковый) бит 64-битного регистра rax при возвращении результата размером не более 32 бит всегда будет нулём.

Целочисленный результат размером 64 бита ($long\ long$) возвращается через регистр rax.

Результат с плавающей запятой ($double$ или $float$, но не десятибайтовый $long\ double$) возвращается через регистр $xmm0$.

3. **Передача целочисленных параметров через 32- и 64-битные регистры.**
Целочисленные параметры размером 32 бита и менее расширяются до 32 бит (знаковые — знаковым битом, беззнаковые — нулями) и передаются через 32-битные регистры (для System V — $edi, esi, edx, ecx, r8d, r9d$, для Microsoft — $ecx, edx, r8d, r9d$); старшие 32 бита соответствующих регистров при этом автоматически обнуляются.
Целочисленные параметры размером 64 бита ($long\ long$) передаются через 64-битные регистры (для System V — $rdi, rsi, rdx, rcx, r8, r9$, для Microsoft — $rcx, rdx, r8, r9$).
Указатель $this$ для нестатических методов объекта передаётся первым параметром.
4. **Изменяемые и неизменяемые регистры.**
Для обоих 64-битных соглашений изменяемыми (scratch) являются регистры A, C, D, $r8-r11$, стек FPU $st(0)-st(7)$, первые шесть AVX-регистров $x/y/zmm0-x/y/zmm5$, регистры маски операндов $k0-k7$ расширения AVX-512 (расширения zmm).
Неизменяемыми (callee-save) для обоих соглашений являются регистры B, bp, $r12-r15$.

6.2.5. Описание функций на ассемблере

> Итак, в предыдущих главах вы узнали о сути колдовства, секрете вечного счастья и основных правилах техники безопасности.
>
> *А. В. Жвалевский, И. Е. Мытько. Порри Гаттер. Приложения*

Пусть требуется описать функцию $foo()$, рассчитывающую для целых беззнаковых чисел x, y значение $z = x/8 + y + 1$. На языке высокого уровня она будет иметь вид, приведённый в листинге 6.10.

Листинг 6.10. Функция $foo()$ на языке C++

```
1 unsigned foo(unsigned x, unsigned y)
2 {
3     return x/8 + y + 1;
4 };
```

Так как делитель $8 = 2^3$ является степенью двойки, беззнаковое деление $x/8$ можно заменить беззнаковым сдвигом $x >> 3$.

В принципе, если функция предназначена для использования внутри ассемблерного файла и гарантированно не будет вызываться языком высокого уровня, она может и не соответствовать стандартным соглашениям о вызове. Таким образом, можно реализовать собственные нестандартные соглашения, позволяющие, в частности, передать параметры через регистры даже на тридцатидвухбитной платформе или вернуть несколько результатов в разных регистрах.

Тем не менее, если нестандартного поведения от функции не требуется, лучше использовать стандартные соглашения, так как в перспективе может понадобиться вызвать функцию из модуля на ЯВУ.

Описание функции $foo()$ на ассемблере

Рассмотрим описание функции $foo()$ на ассемблере в соответствии с 32-битным соглашением cdecl (листинг 6.11, а), а также 64-битными соглашениями System V (6.11, б) и Microsoft (6.11, в).

Листинг 6.11. Функция $foo()$ на ассемблере

а) 32 бита, cdecl

```
1 .globl foo
2 foo:
3   sub $12, %esp
4   mov 16(%esp), %eax
5   shr $3, %eax
6   add 20(%esp), %eax
7   inc %eax
8   add $12, %esp
9   ret
```

б) 64 бита, System V

```
1 .globl foo
2 foo:
3   sub $8, %rsp
4   mov %edi, %eax
5   shr $3, %eax
6   add %esi, %eax
7   inc %eax
8   add $8, %rsp
9   ret
```

в) 64 бита, Microsoft

```
1 .globl foo
2 foo:
3   sub $8, %rsp
4   mov %ecx, %eax
5   shr $3, %eax
6   add %edx, %eax
7   inc %eax
8   add $8, %rsp
9   ret
```

Директива `.globl` в строке 1 делает функцию $foo()$ видимой для внешних модулей. Если функцию планируется вызывать только из того же модуля, где она описана, она не нужна.

В строке 2 находится метка foo:, показывающая начало одноимённой функции.

Если функцию $foo()$ планируется вызывать из ЯВУ, необходимо учесть не только соглашение о вызове, но и декорирование имён (отключение декорирования описано в разделе 6.2.7), а также искажение при отключённом декорировании (так, в 32-битной ОС Microsoft Windows и всех версиях Mac OS X даже при отключённом декорировании функция C foo на уровне ассемблера превращается в $\_foo$; подробное описание в разделе 6.2.6).

В строке 3 указатель стека sp выравнивается на 16 (пролог). Соответственно, в строке 8 (эпилог) восстанавливается исходное значение sp — чтобы при выполнении команды ret на вершине стека находился адрес возврата. В cdecl (листинг 6.11, а) выравнивание на 16 байт в явном виде требуется только для Mac OS X; тем не менее, компиляторы GCC выравнивают sp и для GNU/Linux.

В добавленном для выравнивания пространстве можно расположить локальные переменные функции $foo()$.

Если в функции $foo()$ нет вложенных вызовов других функций и не используются AVX-команды, выравнивать стек не обязательно даже на 64-битной платформе, и строки 3 и 8 (пролог и эпилог) не нужны. В 32-битной ОС Microsoft Windows стек выравнивается на 4 байта, и строки 3 и 8 также не нужны (листинг 6.12).

В строках 4-7 на основе параметров x и y вычисляется возвращаемое значение $foo()$.

В соответствии с 32-битным соглашением `cdecl` (листинг 6.11, а), параметры x и y находятся в стеке и занимают там по одному 4-байтовому стековому слову. Таким образом, после вызова $foo()$ на вершине стека (ячейка `(%esp)`) находится адрес возврата; в ячейке памяти, смещённой на четыре байта относительно вершины стека sp (по адресу $sp+4$, что обозначается как `4(%esp)`) — первый параметр x, по адресу $sp+8$ (ячейка `8(%esp)`) — второй параметр y (листинг 6.12, без дополнительного выравнивания).

Листинг 6.12. Функция $foo()$ (выравнивание на 4 — для 32-битной ОС Microsoft Windows)

```
1 .globl FNAME(foo)
2 FNAME(foo):
3   mov 4(%esp), %eax
4   shr $3, %eax
5   add 8(%esp), %eax
6   inc %eax
7   ret
```

После выравнивания ($sp+12 \rightarrow sp$) смещения изменятся: смещение x превратится в $4+12=16=$ `0x10`, смещение y — в $8+12=20=$ `0x14`.

В соответствии с 64-битными соглашениями, 32-битные целочисленные параметры x и y находятся в 32-битных регистрах: согласно System V — в регистрах edi и esi, согласно Microsoft — в ecx и edx соответственно.

Таким образом, в строке 4 первый параметр x копируется в регистр eax; в строке 5 выполняется беззнаковый, или логический сдвиг вправо (shift right) eax на три бита, что эквивалентно беззнаковому делению на 8. в строке 6 к eax добавляется второй параметр y; в строке 7 — единица. После выполнения строк 4-7 $eax=x/8+y+1$.

Согласно всем соглашениям x86/x86-64, целочисленный результат размером не более 4 байт возвращается через регистр eax. Результат вычислений находится именно там.

В строке 9 следует возврат из функции (ret).

Вызов функции $foo()$

Вызов описанной функции, в частности, расчёт значения $foo(17, 2)$, выглядит следующим образом (листинги 6.13, а-в).

Листинг 6.13. Вызов функции $foo()$ на ассемблере

а) 32 бита, cdecl

```
1 pushl $2
2 pushl $17
3
4 call foo
5 add $2*4, %esp
6 mov %eax, ...
```

б) 64 бита, System V

```
1 mov $17, %edi
2 mov $2,  %esi
3
4 call foo
5
6 mov %eax, ...
```

в) 64 бита, Microsoft

```
1 mov $17, %ecx
2 mov $2,  %edx
3 sub $32, %rsp
4 call foo
5 add $32, %rsp
6 mov %eax, ...
```

Команда $call$, в отличие от оператора вызова функции на ЯВУ, не позволяет передать параметры и получить возвращаемое значение. Она только помещает в стек адрес команды, следующей после вызова подпрограммы (адрес возврата), а затем передаёт управление на начало подпрограммы.

Таким образом, перед вызовом подпрограммы командой $call$ фактические параметры необходимо вручную поместить туда, где их ожидает увидеть подпрограмма, а после завершения подпрограммы — вручную скопировать результат из условленного места.

Если подпрограмма является функцией ЯВУ, расположение параметров и возвращаемого значения регламентируется соглашением о вызовах, соответствующим ЯВУ, ОС и разрядности программы.

Для 32-битного соглашения `cdecl` (листинг 6.13, а) параметры должны находиться в стеке, причём на вершине находится первый параметр x. Соответственно, фактические параметры $x = 17$ и $y = 2$ нужно загрузить в стек, что и делает команда `pushl` (суффикс l, то есть $long$, явно задаёт размер).

Для 64-битных соглашений System V и Microsoft (листинг 6.13, б-в) они должны находиться в регистрах, куда и помещаются командой mov.

Это делают строки 1-2 листингов а-в).

Функция $foo()$ имеет постоянный набор параметров, так что модификация регистра al перед вызовом для соглашения System V не требуется.

Строка 3 листинга 6.13, в) резервирует теневое пространство согласно соглашению Microsoft.

В строке 4 вызывается функция $foo()$. При этом в стек помещается адрес следующей команды (строки 5) — адрес возврата, после чего управление передаётся на метку foo, то есть начало функции.

После завершения работы функции стековые параметры (а для соглашения Microsoft — ещё и теневые 32 байта) необходимо вручную удалить из стека. Это делает строка 5 листингов 6.13, а) (к указателю стека esp добавляется общий размер параметров — $2 \cdot 4 = 8$ байтов) и в) (к указателю стека rsp добавляется 32 байта — размер теневого пространства).

Строка 6 листингов 6.13, а-в) копирует результат функции $foo()$ из регистра eax (где $foo()$ его оставляет по соглашению) куда-то ещё.

Сохранение изменяемых функцией регистров

Если вызывающая подпрограмма хранит какие-то долгоживущие данные в регистре, изменяемом подпрограммой (A, C, D и т. д.) их необходимо сохранить перед вызовом функции (в стеке) и восстановить после её завершения.

В частности, в листинге 6.14 сохраняется и восстанавливается регистр A.

Листинг 6.14. Вызов функции $foo()$ с сохранением/восстановлением регистра A

а) 32 бита, cdecl

```
1 push %eax
2
3 pushl $2
4 pushl $17
5 call foo
6 add $8, %esp
7 mov %eax, ...
8 pop %eax
```

б) 64 бита, System V

```
1 push %rax
2
3 mov $17, %edi
4 mov $2,  %esi
5 call foo
6
7 mov %eax, ...
8 pop %rax
```

в) 64 бита, Microsoft

```
1 push %rax
2 sub $32, %rsp
3 mov $17, %ecx
4 mov $2,  %edx
5 call foo
6 add $32, %rsp
7 mov %eax, ...
8 pop %rax
```

Так как в этом регистре по соглашению после выхода из функции содержится её возвращаемое значение, оно (если оно требуется вызывающей программе) должно быть скопировано или использовано до восстановления оригинального значения eax.

При этом значения регистров, которые по используемому соглашению о вызове могут быть изменены функцией, в вызывающей программе необходимо сохранять, даже если текущая реализация конкретной функции $foo()$ их не меняет (в следующей версии функции они могут быть использованы).

Наилучшим выходом будет использовать изменяемые функциями регистры только как временные и не хранить там долгоживущие переменные.

Для хранения долгоживущих переменных предназначены неизменяемые функциями регистры (B, bp и т. д.). Их использование (как и создание локальных переменных подпрограмм) подробнее рассмотрено в разделе 6.2.3.

6.2.6. Искажение имён при компиляции

> ...Подразделение было секретным и для конспирации его фамилию официально сокращали до одной буквы — О. Теперь лейтенант скучал по прежней фамилии, которая состояла из тринадцати букв и начиналась с «З».
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Здесь вам не причинят никакого вреда*

Имена функций, задаваемые программистом, в процессе компиляции искажаются; наиболее заметные изменения связаны с процессом **декорирования** (name mangling). Механизм декорирования имён отсутствовал в языке C. Язык C++, в отличие от C, поддерживает перегрузку функций, то есть программа, написанная на C++, может содержать множество функций, носящих одно и то же имя. При этом на этапе компоновки для корректной сборки программы у каждой функции должно быть уникальное имя. Соответственно, на этапе компиляции в имя каждой функции включается информация о всех её параметрах (явных и неявных), причём так, что в изменённом имени используются только допустимые символы.

Алгоритм декорирования не стандартизирован; различные компиляторы для различных платформ используют разные схемы.

Декорирование имён можно отключить вместе с возможностью перегрузки, объявив функцию внешней C-функцией `extern "C"`. Большинство современных операционных систем вообще не искажает имён таких функций (рис. 6.6, а).

Тем не менее, некоторые компиляторы искажают имена неперегружаемых функций — к ним может быть приписан префикс или суффикс. Конкретный способ искажения зависит от используемого ЯВУ (и, соответственно, соглашения о вызове), ОС, разрядности и компилятора.

Так, 32-битные компиляторы для Microsoft Windows, а также компиляторы любой разрядности для всех версий Mac OS X при компиляции добавляют к именам C-функций (то есть при отключённом декорировании) префикс `_` (ведущее нижнее подчёркивание).

Функции стандартной библиотеки C (libc) и головная функция $main()$ являются C-функциями, и их имена в этом случае также подвергаются искажению (то есть `printf` преобразуется в `_printf`, `main` — в `_main`).

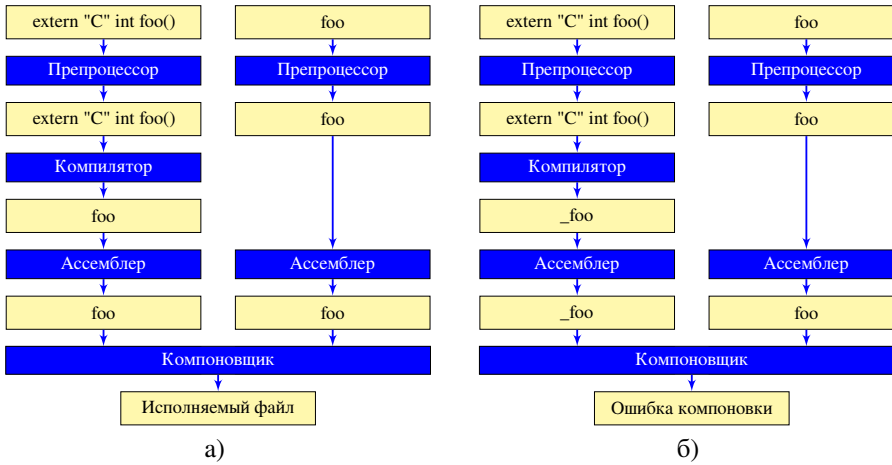

Рис. 6.6. Компиляция C-функции без искажения имён (а) и с искажением, принятым в Mac OS X и 32-разрядной Microsoft Windows (б)

Ассемблер не искажает имён даже в Mac OS X и 32-битной Microsoft Windows, так что совместное использование C++-модулей (cpp-файлов) и ассемблерных модулей (S-файлов) без учёта искажения в этих ОС приводит к ошибкам компоновки (рис. 6.6, б).

Действительно, если используемый компилятор искажает имена внешних C-функций, то ссылка на внешнюю функцию `extern "C" int foo()`, упоминаемую в некотором C++-модуле (main.cpp), на этапах ассемблирования и компоновки будет выглядеть как `_foo` и не может быть сопоставлена с функцией `foo`, описанной в ассемблерном модуле (unit.S).

Таким образом, для корректной компоновки под Mac OS X и 32-битной Microsoft Windows имя данной функции в объектном файле, полученном из unit.S (а значит, и в самом unit.S), также должно быть `_foo`. При этом в других операционных системах имена не искажаются, так что для корректной компоновки в GNU/Linux имя этой же функции должно выглядеть как `foo`.

Кроссплатформенности (частичной) в этом случае можно достичь использованием макросов для компенсации искажения имён в unit.S. Опишем макрос `FNAME` с параметром s — именем функции, который либо добавляет к s ведущее подчёркивание (тогда его нужно описать как `#define FNAME(s) _##s`), либо ничего с s не делает (`#define FNAME(s) s`) и вместо имени функции, например, foo, будем указывать `FNAME(foo)` (рис. 6.7, а) и б).

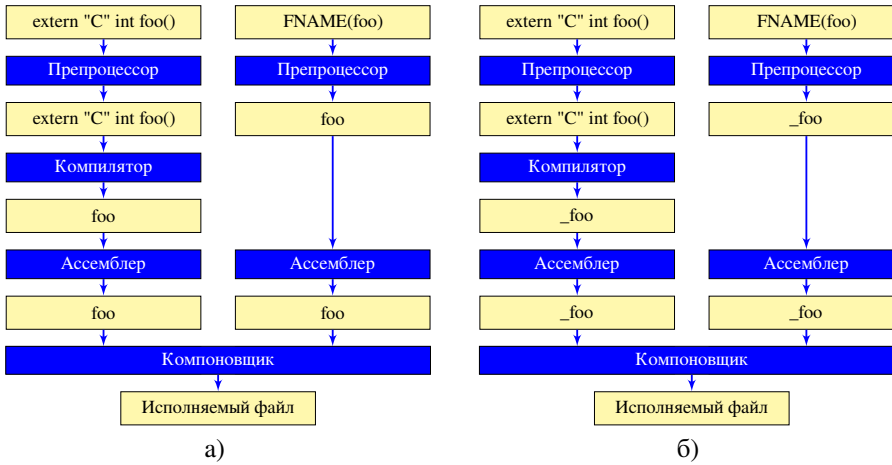

Рис. 6.7. Компиляция С-функции без искажения имён (а) и с компенсацией искажения (б)

Подчёркивание необходимо добавлять под любой версией компилятора для Mac OS X и 32-битной версией компилятора для Microsoft Windows (и не нужно для остальных, в том числе для 64-битных компиляторов для Microsoft Windows).

Для этого можно воспользоваться предопределёнными макросами препроцессора: `__APPLE__` для Mac OS X и `_WIN32`. При этом макрос `_WIN32` определён также и в 64-битных компиляторах для Microsoft Windows, так что необходимо отдельно проверить также наличие макроса `_WIN64` (листинг 6.15).

Листинг 6.15. Макрос для компенсации искажения имён

```
1 #ifdef __APPLE__
2 #define FNAME(s) _##s
3 #elif _WIN64
4 #define FNAME(s) s
5 #elif _WIN32
6 #define FNAME(s) _##s
7 #else
8 #define FNAME(s) s
9 #endif
```

Данное определение можно поместить в начало ассемблерного файла с расширением `.S` или в файл, включаемый в него директивой `#include`.

После этого макрос FNAME можно применять для компенсации искажения имён на уровне ассемблера во всех случаях — при экспорте имени функции (листинг 6.16):

Листинг 6.16. Файл unit.S: кроссплатформенный экспорт

```
1 .globl FNAME(foo)
2 FNAME(foo):
3   ...
```

при импорте (call FNAME(foo)) или при вызове библиотечных функций (call FNAME(printf)).

На уровне ЯВУ (в C/C++) применять макрос FNAME не нужно — там для искажения имён есть компилятор.

6.2.7. Импорт функций из модулей на ассемблере в код на C++

> Вы представляете, какой жест при взмахе волшебной палочкой выглядит наиболее эффектно, куда её направлять в начальной фазе ворожбы и куда прятаться, если она вдруг заработает.
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Порри Гаттер. Приложения*

Функции, описанные в ассемблерном модуле, необходимо описать в коде C++ как внешние (extern). После спецификатора extern, согласно стандарту C++, могут быть указаны строки "C++" (подразумевается по умолчанию) или "C" (различные компиляторы могут поддерживать и иные строки) для указания компоновщику, какой язык использовался при написании внешней функции. Конкретные свойства таких функций не описываются в стандарте. На практике "C++" подразумевает декорирование (mangling) имён функций (так как C++-функции должны поддерживать полиморфизм) и, для 32-битных систем, разные соглашения для разных компиляторов (передачу параметров по возможности через регистры для ускорения).

Указание "C" отключает декорирование имён (искажение имён в Mac OS X и 32-битной Microsoft Windows может быть компенсировано макросом FNAME, описанным в разделе 6.2.6). Для 32-битных платформ для C-функций используется соглашение о вызовах cdecl. Для 64-битных платформ C-функции, как и C++-функции, следуют соглашению, соответствующему операционной системе (System V или Microsoft).

Рассмотрим функцию $\mathrm{unsigned\ foo(unsigned}\ x, \mathrm{unsigned}\ y)$ из листингов 6.11, а-в) предыдущего раздела.

Чтобы не разделять 32-битную Microsoft Windows и 32-битные Unix-подобные системы (использующие одно соглашение о вызовах cdecl), а также 64-битную

Mac OS X и 64-битные GNU/Linux и BSD (использующие соглашение System V), компенсируем искажение имён (листинги 6.17, а-в).

Листинг 6.17. Функция $foo()$ на ассемблере (искажение имён компенсировано)

а) 32 бита, cdecl

```
1 .globl FNAME(foo)
2 FNAME(foo):
3   sub $12, %esp
4   mov 16(%esp), %eax
5   shr $3, %eax
6   add 20(%esp), %eax
7   inc %eax
8   add $12, %esp
9   ret
```

б) 64 бита, System V

```
1 .globl FNAME(foo)
2 FNAME(foo):
3   sub $8, %rsp
4   mov %edi, %eax
5   shr $3, %eax
6   add %esi, %eax
7   inc %eax
8   add $8, %rsp
9   ret
```

в) 64 бита, Microsoft

```
1 .globl foo
2 foo:
3   sub $8, %rsp
4   mov %ecx, %eax
5   shr $3, %eax
6   add %edx, %eax
7   inc %eax
8   add $8, %rsp
9   ret
```

Вариант а) соответствует 32-битным GNU/Linux, BSD (включая Mac OS X) и Microsoft Windows (в 32-битной Microsoft Windows можно опустить строки 3 и 8 и соответственно скорректировать смещения); вариант б) — 64-битным GNU/Linux и BSD (включая Mac OS X); вариант в) — 64-битной Microsoft Windows.

Ассемблерный модуль — в файл с расширением .S (назовём его unit.S). Он должен содержать описание макроса FNAME (листинг 6.15) и код функции $foo()$, соответствующий платформе (листинги 6.17).

Директива `.globl FNAME(foo)` делает функцию $foo()$ видимой для внешних модулей (с учётом искажения имён), то есть она может быть импортирована в модуль на C/C++.

Для импорта в C/C++, как сказано выше, используется ключевое слово $extern$. После импорта функция может использоваться так же, как и функция, описанная на языке C/C++:

Листинг 6.18. Файл `main.cpp`

```
1 #include <iostream>
2 using namespace std;
3 extern "C" unsigned foo(unsigned x, unsigned y);
4
5 int main()
6 {
7     unsigned y = foo(45, 5);
8     cout << y <<endl;
9     return 0;
```

```
10 }
```

В чистом C нет необходимости отключать декорирование, поэтому импорт функции $foo()$ выглядит как `extern unsigned foo(unsigned x, unsigned y)`.

6.2.8. Импорт функций из модулей на C++ в код на ассемблере

> Если заклинание не сработало нужным образом, обратитесь к разработчику. Возможно, вы неправильно его активировали (заклинание, а не разработчика).
>
> *А. В. Жвалевский, И. Е. Мытько.*
> *Порри Гаттер. Приложения*

Подпрограмма на ассемблере может обращаться не только к другим подпрограммам из того же модуля на ассемблере, но и к внешним, в частности, к функциям из других объектных файлов проекта или к стандартной библиотеке libc.

Для того, чтобы функция, описанная на языках C/C++, была доступна для экспорта в другие модули, используется ключевое слово $extern$, как и для импорта внешних функций (для отключения декорирования C++ также используется `extern "C"`):

Листинг 6.19. Файл `bar.cpp`

```
1 extern "C" int bar(int x);
2 int bar(int x)
3 {
4     return 3*x+1;
5 };
```

Для импорта функции в ассемблере не требуется никаких директив, достаточно знать её имя (с учётом искажения). Для работы с параметрами, если они есть, необходимо также знать соглашение о вызове.

Так, листинги 6.20 а-в) показывают вызов $bar(1)$.

Листинг 6.20. Вызов функции $bar()$ на ассемблере

а) 32 бита, cdecl

```
1 pushl $1
2
3 call FNAME(bar)
4 add $4, %esp
5 mov %eax, ...
```

б) 64 бита, System V

```
1 mov $1, %edi
2
3 call FNAME(bar)
4
5 mov %eax, ...
```

в) 64 бита, Microsoft

```
1 mov $1, %ecx
2 sub $32, %rsp
3 call bar
4 add $32, %rsp
5 mov %eax, ...
```

Как и выше, вариант а) соответствует 32-битным GNU/Linux, BSD (включая Mac OS X) и Microsoft Windows; вариант б) — 64-битным GNU/Linux и BSD (включая Mac OS X); вариант в) — 64-битной Microsoft Windows (макрос FNAME не используется, так как 64-битное соглашение Microsoft использует только одна ОС, и она не искажает имена С-функций).

6.2.9. Системные вызовы

По пояс в траве босыми ногами
Вот мы пришли, мы танцуем с богами.

Б. Б. Гребенщиков. Поутру

Системный вызов (system call) — обращение прикладной программы к ядру операционной системы для выполнения какой-либо операции. В принципе, системные вызовы соответствуют определению подпрограмм, но, так как ядро системы работает в привилегированном режиме, нельзя давать программе возможность передать управление на произвольный фрагмент кода ядра. Соответственно, количество функций, выполняемых ядром, ограничено. Сами эти функции, как правило, пронумерованы и для обращения к ним необходим номер, а не адрес. Кроме того, для системных вызовов используются другие соглашения; в частности, вместо `call`/`ret` применяются другие команды вызова и возврата.

Для обращения к ядру используются следующие способы:

1. Программное прерывание (команда `int`) — этот способ доступен на всех x86-совместимых системах. Как правило, для вызова всех функций ядра используется какой-то один номер прерывания, а номер самой функции передаётся через один из регистров.
2. Быстрый вызов ядра в тридцатидвухбитном режиме выполняется командой `sysenter`.
3. Быстрый вызов ядра в шестидесятичетырёхбитном режиме — командой `syscall`.

Системные вызовы различных ОС

Как и для функций, соглашение о вызовах описывает команду вызова, а также передачу параметров и возврат значения. Ядра различных операционных систем поддерживают различные соглашения.

– к ядру Linux на платформе x86 можно обратиться по программному прерыванию `int 0x80`, на x86-64 — с помощью команды `syscall`, номер функции и параметры передаются в регистрах;
– BSD на x86 также использует `int 0x80`, номер функции в регистре eax, параметры в стеке;

– FreeDOS предоставляет большую часть функций через `int 0x21`, также используются `int 0x20` (завершение программы), `int 0x29` (печать символа), `int 0x2E` (выполнение команды).

В большинстве операционных систем функции, выполняемые ядром, документированы и могут быть напрямую вызваны прикладной программой. Операционная система Microsoft Windows, напротив, скрывает их и меняет от версии к версии как сами функции, так и механизм их вызова. Прикладным программам предлагается использовать обёртки для обёрток над обёртками системных вызовов ядра Windows — функции Windows API из разделяемых библиотек.

Тем не менее, в различных источниках сообщается, что линейка Microsoft Windows NT/2000/XP/2003/Vista использует прерывание `int 0x2E`, а в Microsoft Windows XP/7/8 для обращения к ядру используется команда `sysenter` в тридцатидвухбитной версии и `syscall` в шестидесятичетырёхбитной.

Системные вызовы Linux

Обращение к ядру Linux в тридцатидвухбитном и шестидесятичетырёхбитном режимах производится разными командами (таблица 6.3). В регистре A должен быть номер функции (распределение функций по номерам также различается). Кроме того, системный вызов принимает до шести параметров в регистрах. Результат ядро помещает в регистр A.

Механизм системных вызовов Linux

Таблица 6.3

Разрядность	Вызов	№ функции	Параметры	Результат
32 бита	`int 0x80`	eax	$ebx, ecx, edx,$ esi, edi, ebp	eax
64 бита	`syscall`	rax	$rdi, rsi, rdx,$ $r10, r8, r9$	rax

В тридцатидвухбитном режиме, в частности, номеру 1 соответствует вызов $sys\_exit()$, 2 — $sys\_fork()$, 3 — $sys\_read()$, 4 — $sys\_write()$ и т. д. Каждая функция ядра имеет свой набор параметров [62, 69]. Так, при завершении программы вызовом $sys\_exit()$ ($eax = 1$) в ebx должен находиться код завершения программы. Если требуется передать от семи параметров и выше, из них формируется структура, адрес которой передаётся в ebx.

В шестидесятичетырёхбитном режиме номера иные, чем для тридцатидвухбитного ядра [68, 69]: 0 — $sys\_read()$, 1 — $sys\_write()$, 2 — $sys\_open()$, 3 — $sys\_close()$ и т. д.

6.3. Программирование нелинейных алгоритмов

То есть — происходящее ясно, но не поддаётся линейному описанию.

Б. Б. Гребенщиков. Козебар Мат

В языках высокого уровня существуют операторы цикла и условные операторы, используемые для реализации нелинейных алгоритмов. Система машинных команд предлагает только команды условного и безусловного перехода (хотя в наборе команд x86 есть команда `loop`, она не является полноценным аналогом цикла, к тому же не рекомендуется к использованию из-за медленной работы).

Тем не менее, с помощью команд перехода можно реализовать все нелинейные алгоритмические конструкции, а режим косвенной адресации позволяет обращаться к элементам составных структур данных. Для визуализации нелинейных алгоритмов воспользуемся схемами программы [31].

6.3.1. Условие с операторами в одной ветви

Сло́ва — нет, есть движения в пространстве
и его части — точек, площадей.

В. Хлебников. Зангези

Рассмотрим задачу, где в зависимости от некоторого условия требуется выполнить либо не выполнить некоторое действие.

Пусть необходимо заменить значение целой знаковой переменной x нулём, если оно отрицательно.

$$x = \begin{cases} x, & x \geqslant 0 \\ 0, & x < 0 \end{cases} \tag{6.1}$$

На языке C++ код, решающий эту задачу, будет использовать условный оператор (листинг 6.21).

Листинг 6.21. Условие (6.1), C++

```
1 if (x < 0)
2 {
3   x = 0;
4 }
```

Так как условный оператор включает только ветвь «да», а в ней — только простой оператор присваивания, эту конкретную задачу можно решить с помощью команд условной пересылки. Начиная с Pentium Pro, это наиболее быстрый способ присваивания по условию.

Кроме того, можно воспользоваться командой условного перехода для обхода кода ветви «да» в случае, когда условие не выполнено. Этот способ не только

поддерживается начиная с оригинального 8086, но и универсален. Так можно реализовать условный оператор со сколь угодно сложным кодом внутри.

Условная пересылка

Сравним x с нулём (оценим знак разности $x - 0$). Присваивание необходимо выполнить в случае, когда $x < 0$ как знаковое. Это соответствует условию `l` (*if less*) или, что то же самое, `nge` (*if not greater or equal*). С учётом размера типа int можно также добавить суффикс размера `l` (листинг 6.22).

Листинг 6.22. Условие (6.1), `cmovCC`

```
1 int x = -6;
2 asm
3 (
4   "cmpl $0, %[X]\n"
5   "cmovngel %[Zero], %[X]\n"
6   : [X]"+r"(x)
7   : [Zero]"rm"(0)
8   : "cc"
9 );
```

Так как источником для команды `cmovCC` не может быть константа, вводится входной параметр `[Zero]`, расположенный в памяти или регистре и равный нулю.

Обход части операторов с помощью команд условного перехода

Построим схему алгоритма (рис. 6.8, а) для решения этой задачи.

В отличие от операторов `if` большинства языков высокого уровня, ветвь, где должны выполняться операторы, лучше сделать ветвью «нет» (таким образом, по ветви «да» будет выполняться обход части программы).

Построим по данной схеме программу (рис. 6.8, б). Основная вертикаль схемы будет соответствовать последовательности команд в памяти, потоки, отходящие от вертикали — командам передачи управления, потоки, входящие в основную вертикаль — меткам, на которые передаётся управление. Если команда не является командой передачи управления, после неё выполняется непосредственно следующая, что соответствует движению вниз по основной вертикали.

Каждому блоку процесса здесь будет соответствовать линейный фрагмент кода (строка 6); блок решения включает установку флагов и завершится условным переходом по метке (строки 4-5); точка соединения двух потоков соответствует метке на строке 7.

Подобным способом можно реализовать условный оператор со сколь угодно объёмным кодом только в одной ветви. Необходимый код помещается на место строки 7, между командой условного обхода ветви и соответствующей меткой.

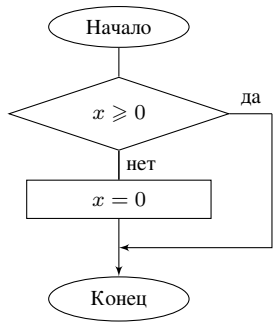

а)

```
1  int x = -6;
2  asm
3  (
4    "cmpl $0, %[X]\n"
5    "jge end_check\n"
6    "movl $0, %[X]\n"
7  "end_check:\n"
8    : [X]"+rm"(x)
9    : : "cc"
10 );
```

б)

Рис. 6.8. Алгоритм и реализация ветвления с операторами в одной ветви

6.3.2. Условие с операторами в двух ветвях

> Как на тенеписи, числаборцы пройдут перед вами, снятые в разных сечениях времени, в разных плоскостях времени.
>
> *В. Хлебников. Зангези*

Рассмотрим задачу, где в зависимости от некоторого условия требуется выполнить либо одно действие, либо другое.

Пусть в зависимости от условия необходимо выполнить один из двух операторов:

$$y(x) = \begin{cases} 1, & x \geqslant 0 \\ 0, & x < 0 \end{cases} \tag{6.2}$$

На языке C++ код, решающий эту задачу, будет использовать условный оператор с двумя ветвями (листинг 6.23).

Листинг 6.23. Условие (6.2), C++

```
1 if (x >= 0)
2 {
3   y = 1;
4 }
5 else
6 {
7   y = 0;
8 }
```

Из-за специфического кода ветвей данную задачу можно решить на ассемблере тремя способами.

Условная установка байта

Так как y равен либо нулю, либо единице, задачу можно решить с помощью команды условной установки байта.

Единичное значение y соответствует случаю, когда $x \geqslant 0$ как знаковое (*if greater or equal*), то есть мнемоника условия может быть записана как `ge`.

Листинг 6.24. Условие (6.2), `setCC`

```
int x = -7, y;
asm
(
  "cmpl $0, %[X]\n"
  "movl $0, %[Y]\n"
  "setgeb %[Y]\n"
  :[Y]"=m"(y)
  :[X]"rm"(x)
  : "cc"
);
```

Здесь мы записываем ноль в четырёхбайтовую переменную y, находящуюся в памяти (это не изменяет флагов), а затем устанавливаем по условию её младший байт (так как платформа x86 использует порядок байтов Intel, адрес младшего байта y совпадает с адресом y). Оба возможных значения y неотрицательны, поэтому дополнение нулями является корректным расширением и для знаковой, и для беззнаковой их интерпретации.

Также можно было использовать для хранения параметра `[Y]` регистр A, установить по условию байт al и специальными командами расширить его вначале до ax, а затем до четырёхбайтового eax. После завершения вставки значение eax (параметра `[Y]`) будет скопировано в переменную y.

При использовании для y однобайтового типа `char` вместо четырёхбайтового `int` расширение не будет нужным.

Условная пересылка

Данную конкретную задачу также можно решить с помощью команд условной пересылки. Такая реализация так же компактна, как листинг 6.24, и гораздо компактнее и быстрее универсальной реализации ветвления при помощи команд условного перехода.

Листинг 6.25. Условие (6.2), cmovCC

```
1  int x = 10, y;
2  asm
3  (
4    "cmpl $0, %[X]\n"
5    "movl $1, %[Y]\n"
6    "cmovll %[Zero], %[Y]\n"
7    : [Y]"+r"(y)
8    : [X]"rm"(x), [Zero]"rm"(0)
9    : "cc"
10 );
```

Вначале x сравнивается с нулём, затем y инициализируется единицей (что не влияет на флаги), затем значение y заменяется нулём в случае $x < 0$.

Обход части операторов с помощью команд условного перехода

Построим схему алгоритма (рис. 6.9, а) для решения этой задачи и затем выстроим блоки линейно вдоль одной вертикали (рис. 6.9, б).

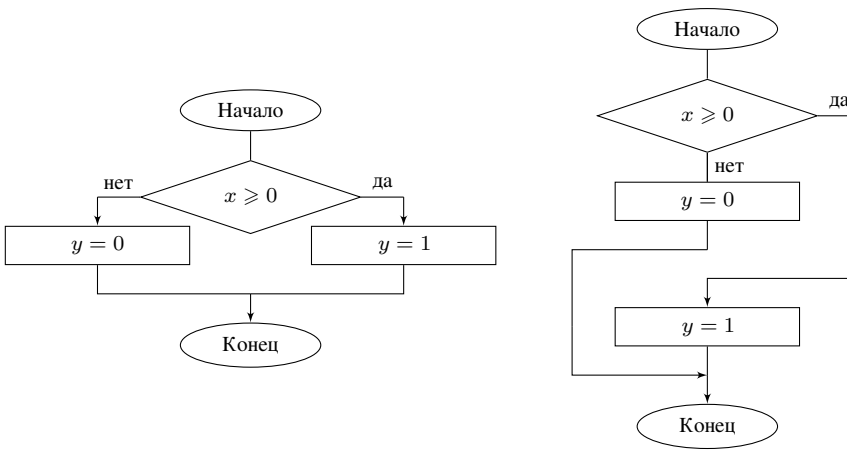

Рис. 6.9. Алгоритм ветвления

Схема на рис. 6.9, б) не вполне соответствует ЕСПД (стандарт предписывает минимизировать количество изломов и не удлинять линии потоков без необходимости, так как схемы алгоритмов предназначены в основном для чтения человеком)

но при таком расположении можно однозначно сопоставить расположение блоков на схеме и расположение команд в памяти.

Сопоставим каждому блоку рис. 6.9, б) одну или несколько команд ассемблера (рис. 6.10). В этом случае излом потока (отход от базовой вертикали без ветвления)

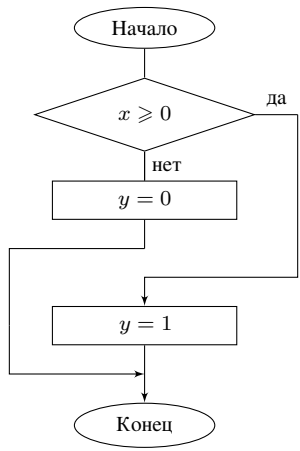

а)

```
1  int x = -6, y;
2  asm
3  (
4    "cmpl $0, %[X]\n"
5    "jge setting_1\n"
6    "movl $0, %[Y]\n"
7    "jmp end_check\n"
8  "setting_1:\n"
9    "movl $1, %[Y]\n"
10 "end_check:\n"
11   :[Y]"=rm"(y)
12   :[X]"rm" (x)
13   : "cc"
14 );
```

б)

Рис. 6.10. Алгоритм и реализация ветвления

будет соответствовать безусловному переходу, блок решения включает вычисление условия и условный переход, а точки входа боковых потоков-переходов в основной вертикальный поток соответствуют меткам (рис. 6.10, б).

У схемы на рис. 6.9, а) два возможных варианта «вертикализации» — изображённый на рис. 6.9, б) и тот, где ветвь «да» окажется выше ветви «нет». Эти варианты равноправны и оба приведут к одинаково корректным, но различным между собой программам. В данном разделе рассматривается вариант рис. 6.9, б).

Соответственно, и в программе код ветви «нет» (строка 6) окажется выше кода ветви «да» (строка 9).

В самом начале условного фрагмента вычисляется условие ветвления (строка 4). После него следует условный обход ближайшей ветви, для рис. 6.10 — пропуск ветви «нет», если условие $x \geqslant 0$ верно (`ge`, строка 5). Затем следует код ветви «нет» (строка 6; управление на неё передаётся естественным путём, если условие неверно). Чтобы после ветви «нет» выполнение естественным путём не перешло к ветви «да», в конце вставлена команда безусловного перехода к коду, следующему за условным фрагментом (переход к метке `end_check`, строка 7).

Затем следует метка начала ветви «да» и код самой ветви «да» (строки 8-9); после его окончания управление естественным путём переходит к `end_check`, которая завершает условный фрагмент (строка 10).

Описанный способ наиболее универсален и позволяет реализовать условный оператор со сколь угодно объёмным кодом ветвей. Необходимый код ветвей «нет» и «да» заместит соответственно строки 6 и 9.

6.3.3. Цикл

> Это войска пехотные *Эм* размололи глыбу объёма
> невозможного, камень-дикарь невозможного на муку
> <...> — и целое стало мукой бесконечно малых частей.
>
> *В. Хлебников. Зангези*

Цикл — единственная алгоритмическая конструкция высокого уровня, позволяющая передать управление назад. Соответственно, цикл на ассемблере можно реализовать только с помощью команд передачи управления.

Пусть необходимо найти сумму двоичных цифр беззнакового числа x.

Цикл с предусловием

Построим схему алгоритма для решения этой задачи, не используя парный блок цикла и выстроив блоки линейно вдоль одной вертикали (рис. 6.11, а), реализован цикл с предусловием).

При соединении блоков ещё немного отступим от требований ЕСПД и отделим точку, где боковой поток случая $CF \neq 0$ входит в основную вертикаль, от точки, где поток отходит от вертикали, чтобы перейти назад к началу итерации. Расположение этих точек выберем так, чтобы поток основной вертикали на каждом её участке шёл в естественном направлении — сверху вниз (это не только позволяет не рисовать стрелку для обозначения направления, но и соответствует выполнению кода, не включающего команд передачи управления).

Теперь сопоставим каждому блоку одну или несколько команд ассемблера. Отход потока от базовой вертикали будет соответствовать команде перехода, точки входа боковых потоков в основной вертикальный — меткам (рис. 6.11, б).

На рис. 6.11, б) в строках 1-4 представлена инициализация перед циклом, в строке 5 — метка начала итерации, строки 6-7 — вычисление и проверка условия выхода из цикла. Строки 8-11 представляют тело цикла. Строка 12 — возврат управления после окончания итерации назад (к предусловию выхода). Метка в строке 13 показывает начало неповторяющихся действий после выхода из цикла; в строках 14-16 представлены действия после цикла. Искомая сумма двоичных цифр x накапливается в переменной sum.

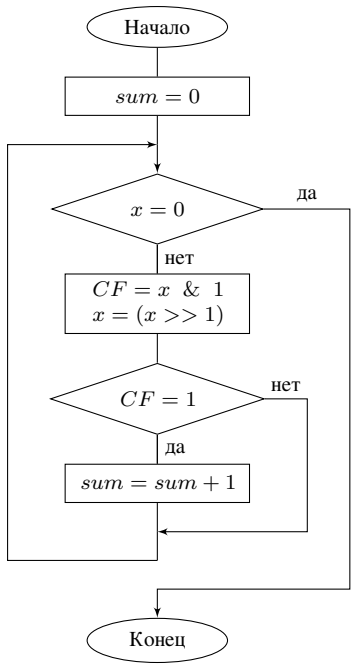

а)

```
1  int x = 7, sum;
2  asm
3  (
4    "xorl %[Sum], %[Sum]\n"
5  "begin_iteration:\n"
6    "cmpl $0, %[X]\n"
7    "je end_loop\n"
8    "shrl $1, %[X]\n"
9    "jnc end_iteration\n"
10   "incl %[Sum]\n"
11 "end_iteration:\n"
12   "jmp begin_iteration\n"
13 "end_loop:\n"
14 :[Sum]"=rm"(sum),[X]"+rm"(x)
15 : : "cc"
16 );
```

б)

Рис. 6.11. Алгоритм и реализация цикла с предусловием

Цикл с постусловием

Построим схему алгоритма, где условие анализируется в конце итерации цикла (рис. 6.12).

Здесь как схема, так и код компактнее, чем для цикла с предусловием, так как анализ условия цикла и возврат управления назад совмещены (строки 10-11 и соответствующий блок решения). Так как условие проверяется после итерации, тело цикла, независимо от начального значения условия выхода, выполнится хотя бы один раз.

Цикл с параметром можно реализовать либо как цикл с предусловием, как и в C/C++, либо как цикл с постусловием.

При этом, если счётчик цикла не является одновременно индексом массива в памяти, имеет смысл инициализировать счётчик максимальным значением $i = i_{max}$ и уменьшать его на каждом шаге $i = i - 1$. Это позволит избавиться от команды сравнения, так как команды декремента и вычитания не только изменяют

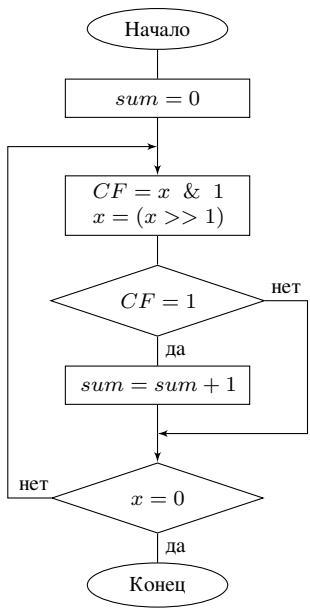

а)

```
1  int x = 7, sum;
2  asm
3  (
4    "xorl %[Sum], %[Sum]\n"
5  "begin_iteration:\n"
6    "shrl $1, %[X]\n"
7    "jnc end_iteration\n"
8    "incl %[Sum]\n"
9  "end_iteration:\n"
10   "cmpl $0, %[X]\n"
11   "jne begin_iteration\n"
12 :[Sum]"=rm"(sum),[X]"+rm"(x)
13 : : "cc"
14 );
```

б)

Рис. 6.12. Алгоритм и реализация цикла с постусловием

операнд i, но и выставляют флаги. При переходе от ненулевого значения к 0 получим $ZF = 1$, при переходе от неотрицательного значения, в частности нуля, к отрицательному — $CF = 1$ (при использовании вычитания, но не декремента) и $SF \neq OF$.

6.4. Взаимодействие со структурами данных

> Мы закрываем шапкой-невидимкой глаза и уши, чтобы иметь возможность отрицать самое существование чудовищ.
>
> *К. Маркс. Капитал*

Языки высокого уровня скрывают расположение сложных структур данных в памяти, предоставляя взамен такие абстракции, как массивы, структуры, объекты, а также высокоуровневые операторы для обращения к их компонентам. Для обращения к компонентам сложных структур данных из ассемблерного кода

необходимо уметь вычислять их адреса, а для этого необходимо представлять реализацию той или иной сложной структуры в одномерном пространстве памяти.

6.4.1. Массивы

Эм — распыление объёма на бесконечно малые части.

В. Хлебников. Зангези

Массив — структура данных в виде набора однородных компонент (элементов массива), расположенных в памяти непосредственно друг за другом (независимо от настроек выравнивания). Каждый элемент характеризуется своим номером — индексом. Элемент с наименьшим индексом располагается по младшему адресу.

В языке C++ наименьший индекс массива всегда равен 0, а имя массива является константным указателем на его начало. Таким образом, адрес i-го элемента массива M равен $M + i \cdot size$, где $size$ — размер одного элемента и, в случае, когда длина массива не равна нулю, может быть определён как `sizeof(M[0])`.

Для большинства простых типов (`char`, `bool`, `short`, `int`, `long`, `long long`, `float`, `double`, `size_t`, `ptrdiff_t`, `void*`) размер как на 32-, так и на 64-битной платформе равен $1, 2, 4$ или 8.

Соответственно, в ассемблере для получения элемента массива (если элементы массива имеют размер $1, 2, 4$ или 8) будут использованы три из четырёх компонент эффективного адреса `displacement(base, index, multiplier)` — база (адрес начала массива M), индекс и масштаб (размер элемента).

В частности, адрес i-го элемента массива M из чисел типа `int` на 32-разрядных и многих 64-разрядных платформах равен $M + i \cdot 4$, и элемент будет записан как `(M, i, 4)`. При этом база M и индекс i должны быть 32-разрядны (на соответствующей платформе) и располагаться в регистрах.

Листинг 6.26. Инициализация четырёхбайтового элемента массива `M[i]`

```
1 const int N = 8;
2 int M[N], i = 0;
3 asm
4 (
5 "movl $0, (%[M], %[I], 4)\n"
6 :[I]"+r"(i)
7 :[M]"r"(M)
8 :"memory"
9 );
```

Так как мы модифицируем во вставке элементы массива (а не сами параметры `[I]` и `[M]`), необходимо указать в списке перезаписываемых элементов специальное значение `"memory"`.

Для инициализации массива в целом необходим цикл. В листинге 6.27 показана инициализация нулями массива из элементов типа int (на большинстве платформ он четырёхбайтовый) циклом с предусловием, аналогичным циклу `for` языка C++.

Листинг 6.27. Инициализация массива `M` из четырёхбайтовых элементов

```
const int N = 8;
int M[N], i;
asm
(
"xorl %[I], %[I]\n"
"begin_iteration:\n"
"cmpl %[M_len], %[I]\n"
"jge end_loop\n"
"movl $0, (%[M],%[I],4)\n"
"incl %[I]\n"
"jmp begin_iteration\n"
"end_loop:\n"
:[I]"=&r"(i)
:[M_len]"i"(N), [M]"r"(M)
: "cc","memory"
);

for(i = 0; i < N; ++i)
{
    cout << M[i] << " ";
}
cout << endl;
```

Действительно, при выводе массива `M` мы увидим нули:

```
0 0 0 0 0 0 0 0
```

Если в массиве гарантированно есть хотя бы один элемент, можно сократить код, использовав постусловие (листинг 6.28).

Листинг 6.28. Инициализация непустого массива `M`

```
asm
(
"xorl %[I], %[I]\n"
"begin_iteration:\n"
"movl $0, (%[M],%[I],4)\n"
"incl %[I]\n"
"cmpl %[M_len], %[I]\n"
```

```
8  "jnge begin_iteration\n"
9  :[I]"=&r"(i)
10 :[M_len]"i"(N), [M]"r"(M)
11 : "cc","memory"
12 );
```

В приведённом выше коде на тип `int` у элементов массива указывают как суффикс `l` у команды `mov`, так и масштаб 4 при вычислении адреса. Обе характеристики важны: попытка опустить суффикс команды приведёт к ошибке, так как ни один из операндов команды `mov` здесь не является регистром и, следовательно, не имеет определённого размера.

Также суффикс и вычисление адреса должны соответствовать друг другу: хотя команды `movw $0, (%[M], %[I], 4)` и `movl $0, (%[M], %[I], 2)` синтаксически корректны и не вызовут ошибок компиляции, обе они при обработке массива из элементов типа `int` некорректны по смыслу. Команда `movw $0, (%[M], %[I], 4)` запишет по адресу $M[i]$ 16-битный ноль, который инициализирует только младшие два байта из четырёх; таким образом, значение элемента $M[i]$ останется неопределённым. Команда `movl $0, (%[M], %[I], 2)` перезапишет не $M[i]$, а либо элемент $M[i/2]$ (для чётного i), либо два старших байта одного элемента и два младших следующего (для нечётного i).

Избавиться от явного указания суффикса и масштаба можно, используя модификаторы параметров:

Листинг 6.29. Инициализация элемента массива `M[i]` размера `el_size`

```
1  const int N = 8;
2  short M[N];
3  int i = 3;
4  asm
5  (
6  "mov%z[el_type] $0, (%[M], %[I], %c[el_size])\n"
7  :[I]"+r"(i)
8  :[M]"r"(M), [el_size]"i"(sizeof(M[0])), [el_type]"m"(M[0])
9  : "memory"
10 );
```

Такой код будет компилироваться и выполняться корректно для любого типа элементов массива M, причём для типа `short` выбирается тот из синонимичных суффиксов, который не вызовет неоднозначности с командой `movs`. К сожалению, это потребовало введения двух новых входных параметров: константа `[el_size]` для масштаба `sizeof(M[0])` и `[el_type]`, равный `M[0]`, для определения суффикса размера (так как ни один из ранее использованных параметров — ни указатель M, ни индекс i — в общем случаем не совпадает по размеру с элементом массива).

В листинге 6.30 показана инициализация нулями массива из элементов целого типа.

Листинг 6.30. Инициализация массива `M` из элементов 2-8 байт

```
1  const int N = 8;
2  short M[N];
3  int i;
4  asm
5  (
6  "xorl %[I], %[I]\n"
7  "begin_iteration:\n"
8  "mov%z[el_type] $0, (%[M],%[I],%c[el_size])\n"
9  "incl %[I]\n"
10 "cmpl %[M_len], %[I]\n"
11 "jnge begin_iteration\n"
12 :[I]"=&r"(i)
13 :[M_len]"i"(N), [M]"r"(M),
14 [el_size]"i"(sizeof(M[0])),
15 [el_type]"m"(M[0])
16 : "cc","memory"
17 );
18
19 for(i = 0; i < N; ++i)
20 {
21     cout << M[i] << " ";
22 }
23 cout << endl;
```

Тип *short* (2 байта) в листинге 6.30 может быть заменён на типы *long* (4 байта) или *long long* (8 байт).

Код отработает корректно и в случае замены *short* на однобайтовое целое *char*, но вывод будет выглядеть пустым. При выводе на экран числа типа *char* стандартными средствами C++ отображается символ ASCII, код которого равен числу. Нулевой символ отображается как конец строки, то есть никак. Если же заменить в команде `mov` константу `$0` на номер печатного символа ASCII, в частности, на `$'y'`, вывод на экран покажет N заданных символов.

Масштаб, равный 1, может быть опущен. Таким образом, если размер элемента равен одному байту, то адрес i-го элемента массива M равен $M + i$ и сам элемент может быть записан и как `(M, i, 1)`, и как `(M, i)`.

Рассмотрим инициализацию массива кодами последовательных строчных латинских букв, начиная с `'a'` (листинг 6.31). Для хранения текущей буквы исполь-

зуется младший байт фиктивного выходного параметра `[X]`, помещаемого в один из регистров $A - D$.

Листинг 6.31. Инициализация массива строчными латинскими буквами

```
1  const int N = 8;
2  int i, x;
3  char M[N];
4  asm
5  (
6    "movb $'a', %b[X]\n"
7    "xorl %[I], %[I]\n"
8  "begin_iteration:\n"
9    "cmpl %[M_len], %[I]\n"
10   "jge end_loop\n"
11   "movb %b[X], (%[M],%[I])\n"
12   "incb %b[X]\n"
13   "incl %[I]\n"
14   "jmp begin_iteration\n"
15 "end_loop:\n"
16 :[I]"=&r"(i), [X]"=&q"(x)
17 :[M_len]"i"(N), [M]"r"(M)
18 : "cc","memory"
19 );
```

Вывод инициализированного таким образом массива приведёт к следующему результату:

```
a b c d e f g h
```

Если размер $size$ элемента отличен от $1, 2, 4$ или 8, он не может быть масштабом при вычислении адреса; таким образом, смещение i-го элемента относительно начала массива

$$offset = i \cdot size$$

необходимо вычислить отдельно и затем получить элемент как `(M, offset)`. Так как элементы массива, как правило, обрабатываются в цикле, это можно сделать последовательным сложением с $size$ на каждой итерации.

Один из возможных вариантов инициализации массива из элементов типа $long\ double$ (в GCC число $long\ double$ имеет размер 10 байт, а выделяемая под него память может занимать как 12, так и 16 байт) показан в листинге 6.32.

Листинг 6.32. Инициализация массива 80-битных вещественных чисел

```
1  const int N = 8;
```

```
int i;
long double M[N], *p;
asm
(
"movl %[M_len], %[rev_idx]\n"
"movl %[M],     %[el_addr]\n"
"begin_iteration:\n"
"fldpi\n"
"fstpt (%[el_addr])\n"
"addl %[el_size], %[el_addr]\n"
"decl %[rev_idx]\n"
"jnz begin_iteration\n"
:[rev_idx]"=&r"(i), [el_addr]"=&r"(p)
:[M_len]"i"(N), [M]"r"(M), [el_size]"i"(sizeof(M[0]))
: "cc","memory"
);
```

Каждый элемент получает значение π.

Для инициализации массива нулями можно воспользоваться тем, что нулевое вещественное значение состоит из одних нулей (листинг 6.33).

Листинг 6.33. Инициализация массива вещественных чисел нулями

```
asm
(
"xorl %[I], %[I]\n"
"begin_iteration:\n"
"movl $0, (%[M],%[I],4)\n"
"incl %[I]\n"
"cmpl %[M_len], %[I]\n"
"jnge begin_iteration\n"
:[I]"=&r"(i)
:[M_len]"i"(N*sizeof(M[0])/4), [M]"r"(M)
: "cc","memory"
);
```

Память, отведённая под массив M ($N \cdot \mathrm{sizeof}(M[0])$ байтов) целиком заполняется четырёхбайтовыми нулевыми блоками. В результате каждый элемент $M[i],\ i \in [0, N-1]$ получает нулевое значение, что можно увидеть, выведя M на экран поэлементно.

Многомерные массивы

Если массивы с одним индексом естественно отображаются на одномерное адресное пространство памяти, то о расположении элементов двумерного массива необходимо условиться дополнительно.

В большинстве ЯВУ элементы статических многомерных массивов располагаются в памяти так, что при движении от начала массива по возрастанию адресов быстрее всего меняется последний индекс. После того, как последний индекс достигнет максимального значения, увеличивается предпоследний и так далее.

В частности, статические двумерные массивы (матрицы) развёрнуты в одномерный по строкам — сначала идёт вся нулевая строка, затем вся первая и так далее, то есть в массиве

```
1 const int I = 8, J = 8;
2 int M[I][J];
```

адрес элемента $M[i][j]$ равен $M + (i \cdot J + j) \cdot size$, где $size =$`sizeof(M[0][0])`.

При обработке всех элементов матрицы можно рассматривать её как одномерный массив длины $I \cdot J$, так как все её элементы однородны и расположены в памяти непосредственно друг за другом. В этом случае индекс элемента $M[i][j]$ в этом массиве $index = i \cdot J + j$.

Обратное преобразование (расщепление при необходимости эффективного индекса на номера строки и столбца) выглядит следующим образом:

$$\begin{cases} i = index/J \\ j = index \bmod J \end{cases}$$

и может быть выполнено одной командой беззнакового деления.

Если требуется выполнить одно и то же действие, в частности, инициализацию, над всеми элементами матрицы, достаточно выполнить один проход, как по массиву $M[I \cdot J]$.

Динамические массивы

Динамические массивы, память под которые выделяется из кучи с помощью оператора $new[]$ или функций $*alloc()$ и освобождается $delete[]/free()$, могут быть только одномерными. При необходимости размещения в куче многомерного массива программист вручную либо разворачивает его в длинный одномерный, либо размещает в древоподобной структуре данных из нескольких небольших одномерных массивов. Способ обращения к элементу в таком случае зависит от способа организации данных.

Обращение к одномерному динамическому массиву, после того, как адрес его начала помещён в регистр, ничем не отличается от обращения к одномерному статическому.

6.4.2. Структуры и объекты

> *Эс* — пути движений, имеющие общую начальную
> и неподвижную точку (сой, солнце, сад, село).
>
> *В. Хлебников. Царапина по небу*

Структуры и объекты в C++ сочетают в себе несколько в общем случае разнородных компонент (полей), расположенных в определённом порядке. Каждое из полей имеет собственное имя, которое в сочетании с именем содержащей его структуры используется для доступа к полю.

В отличии от элементов массива, поля структуры могут располагаться в памяти с промежутками, размер которых может различаться в зависимости от настроек выравнивания.

Выравнивание данных

Хотя оперативная память — устройство с произвольным доступом, то есть возможно читать значения по любым адресам в любом порядке, время доступа различается в зависимости от расположения данных. Конкретные особенности временны́х характеристик обращения к оперативной памяти зависят от особенностей процессора и чипсета.

Тем не менее, есть несколько общих правил, позволяющих не потерять в производительности слишком сильно.

1. Выравнивание. Фактически процессор не работает с данными, взятыми напрямую из оперативной памяти. При чтении данные поступают в сверхоперативную память (кеш); изменения вначале фиксируются в кеше, затем попадают в оперативную память. Обмен между памятью и кешем производится пакетами, длина которых составляет от 32 до 128 байт. Начало пакета кратно его длине.

Таким образом, если элемент попадает на границу таких блоков-пакетов, для его загрузки потребуется два запроса к памяти [35].

Чтобы избежать таких ситуаций, достаточно (хотя и не всегда необходимо), чтобы граница между элементами в памяти была кратна определённому числу (таблица 6.4) — выравнена.

По умолчанию в C++ как размер простых типов, так и величина, которой кратен адрес начала такой переменной — величина выравнивания (кроме $long\ double$) соответствуют этим значениям.

Десятибайтовый тип $long\ double$ может иметь размер (sizeof) как 16, так и 12 байт; в последнем случае он выравнивается на 4 байта (а компиляторы из коллекции Microsoft Visual Studio полагают $long\ double = double$, таким образом, и размер, и величина выравнивания там равны 8).

Размер выравнивания для данных различных типов

Таблица 6.4

Размер данных	Граница
1 байт (8 бит)	Произвольная
2 байта (16 бит)	Кратная 2 байтам
4 байта (32 бита)	Кратная 4 байтам
8 байт (64 бита)	Кратная 8 байтам
10 байт (80 бит)	Кратная 16 байтам
16 байт (128 бит)	Кратная 16 байтам

2. Обход последовательно расположенных элементов в порядке возрастания адресов выполняется быстрее, чем в обратном.

Поля структур

Доступ к отдельным полям структуры на языке высокого уровня осуществляется по имени. При обработке на языке ассемблера придётся использовать смещение поля относительно начала структуры, которое будет зависеть не только от состава структуры, но и от компилятора и его настроек.

Обычно поля следуют в порядке объявления и начало поля кратно некоторой величине, значение которой для конкретного поля/типа, а также текущей версии и настроек в GCC можно получить с помощью оператора `__alignof__` (синтаксис аналогичен `sizeof`). При этом между началом одного поля и концом предыдущего может образоваться промежуток, также промежуток может образоваться после последнего элемента структуры. Соответственно, размер структуры может быть больше суммы размеров её полей; также размер структуры может меняться от перестановки полей между собой.

Изменить максимальную кратность выравнивания (часто называемую просто выравниванием) в GCC можно с помощью флага компиляции `-fpack-struct[=n]`. Также GCC для совместимости с компиляторами Microsoft поддерживает набор директив препроцессора `#pragma pack`, позволяющих задать различную кратность выравнивания для различных определений типов:

– `#pragma pack(n)` просто устанавливает новое значение выравнивания;
– `#pragma pack()` возвращает выравнивание по умолчанию (возможно, заданное `-fpack-struct[=n]`);
– `#pragma pack(push[,n])` сохраняет текущее выравнивание во внутреннем стеке и, при заданном n, устанавливает новое значение;

– `#pragma pack(pop)` восстанавливает выравнивание из вершины внутреннего стека (и удаляет эту запись оттуда).

Рассмотрим расположение полей и размер структур при различных настройках выравнивания (листинг 6.34).

Листинг 6.34. Структуры при различных значениях выравнивания

```
1  const int N = 10;
2  struct TSomeStruct
3  {
4      char Tag;
5      int  Val;
6  }
7  s1, a1[N];
8
9  #pragma pack (push, 1)
10 struct TSqueezedStruct
11 {
12     char Tag;
13     int  Val;
14 }
15 s2, a2[N];
16
17 #pragma pack (pop)
18 struct TAnotherStruct
19 {
20     char Tag;
21     int  Val;
22 }
23 s3, a3[N];
24
25 TSqueezedStruct s20, a20[N];
26
27 #define PRINT(I) cout << reinterpret_cast<char *>(&s##I.Tag) \
28     - reinterpret_cast<char *>(&s##I) << " " \
29  << reinterpret_cast<char *>(&s##I.Val) \
30     - reinterpret_cast<char *>(&s##I) \
31  << " "<< sizeof(s##I) << " " << sizeof(a##I) << endl;
32
33 PRINT(1)        // 0 4 8 80
34 PRINT(2)        // 0 1 5 50
35 PRINT(3)        // 0 4 8 80
36 PRINT(20)       // 0 1 5 50
```

Первое поле Tag всегда имеет нулевое смещение. Второе поле Val для структур $s1$ и $s3$ (выравнивание по умолчанию) смещено на четыре байта, так как адрес переменной типа int для наилучшей производительности должен быть кратен 4. В структурах $s2$ и $s20$ — при максимальной кратности выравнивания 1 — поле Val следует непосредственно за Tag. Следует отметить, что настройки выравнивания задаются при определении типа $TSqueezedStruct$, а не конкретных переменных $s2$ и $s20$.

Следует также отметить, что в массиве элементы всегда следуют друг за другом без промежутков.

На практике не рекомендуется изменять настройки выравнивания (особенно директивой `#pragma pack`, приводящей к несовместимости одинаково описанных структур), так как это может замедлить работу программы или даже нарушить её работоспособность.

При необходимости записи структуры в файл для избавления от дыр неопределённого размера лучше воспользоваться покомпонентной записью.

Для придания размеру дыр определённости необходимо по возможности описывать поля структуры в таком порядке (и, возможно, добавить ещё несколько неиспользуемых полей), чтобы границы между полями независимо от настроек выравнивания совпадали с рекомендуемыми значениями таблицы 6.4.

Листинг 6.35. Структура, выравненная вручную

```
1 struct TRobustStruct
2 {
3     char Tag;
4     char dummy[3]; // неиспользуемые поля для выравнивания
5     int  Val;
6 };
```

Листинг 6.35 показывает подобное описание. Независимо от настроек выравнивания размер структуры $TRobustStruct$ составляет 8 байт, а смещение поля Val — 4 байта.

Обращение к полю структуры

Адрес поля структуры равен сумме адреса структуры $base$ и смещения нужного поля $displacement$. Для обращения к полю структуры необходимо разыменовать его адрес $*(base + displacement)$.

Это соответствует косвенной адресации с двумя компонентами — базой $base$ и смещением $displacement$, что в GAS обозначается `displacement(base)`.

В листинге 6.36 показана инициализация полей Tag и Val структуры $TSomeStruct$, описанной в листинге 6.34.

Листинг 6.36. Инициализация структуры с выравниванием на 4 байта

```
1  TSomeStruct s;
2  asm
3  (
4  "movb $'a', (%[S])\n"
5  "movl $13, 4(%[S])\n"
6  :
7  :[S]"r"(&s)
8  : "memory"
9  );
10 cout << s.Tag << " " << s.Val << endl;
```

Вывод программы показывает корректность инициализации

```
a 13
```

Так как расположение полей зависит от настроек компиляции, более надёжно передавать смещения полей как параметры вставки (листинг 6.37).

Листинг 6.37. Инициализация структуры с неизвестным выравниванием

```
1  asm
2  (
3  "movb $'a', %c[tag_disp](%[S])\n"
4  "movl $13,  %c[val_disp](%[S])\n"
5  :
6  :[S]"r"(&s),
7   [tag_disp]"i"(reinterpret_cast<char *>(&s.Tag)
8      - reinterpret_cast<char *>(&s)),
9   [val_disp]"i"(reinterpret_cast<char *>(&s.Val)
10     - reinterpret_cast<char *>(&s))
11 : "memory"
12 );
```

Полученный код не зависит от настроек выравнивания, но очень тяжело читается.

Если код оформляется не как ассемблерная вставка, а как функция, принимающая структуру, описанную на C++, необходимо либо передавать смещения полей как параметры функции и рассчитывать адреса вручную (что сильно замедлит выполнение), либо задаться конкретными значениями (возможно, при помощи макросов препроцессора), либо, что лучше всего, описывать структуру таким образом, чтобы при любых настройках выравнивания отсутствовали дыры между полями и не менялись смещения полей (аналогично листингу 6.35).

Контрольные вопросы

1. Какая команда передаёт управление подпрограмме?
2. Какая команда возвращает управление вызывающей программе?
3. Что такое адрес возврата?
4. Какие вы знаете соглашения о вызове?
5. Как импортировать ассемблерную функцию в проект на C++?
6. Как, согласно ЕСПД, изображается блок «терминатор»?
7. Как, согласно ЕСПД, изображается блок «процесс»?
8. Как, согласно ЕСПД, изображается блок «решение»?
9. Как располагаются в памяти элементы массива?
10. Как найти размер массива, зная размер элемента и их количество?
11. Что такое выравнивание полей структуры?
12. Зачем нужно выравнивание данных?

Глава 7. Программирование на языке высокого уровня: C++

Два программиста быстро находят общий язык.
Как правило, это C++.

Программистский фольклор

Для разработки программного обеспечения часто используется язык общего назначения C, а также разработанный на его основе объектно-ориентированный язык C++.

Программированию на C++ посвящён отдельный курс. Вспомним некоторые особенности этого языка, полезные при исследовании содержимого оперативной памяти или сочетании программы на C++ с ассемблерными функциями или вставками.

Синтаксис языков C и C++ стандартизирован. В настоящее время существует четыре стандарта языка C:

- **C89 (ANSI C)** ANSI X3.159-1989;
- **C90** ISO/IEC 9899:1990;
- **C99** ISO/IEC 9899:1999, последняя правка от 2007-11-15;
- **C11** ISO/IEC 9899:2011 от 2011-12-19.

Доступ к текстам стандартов платный. Последний бесплатно доступный черновик C11 — **n1570** от 2011-04-12.

Также существует четыре стандарта C++. Последний, C++17, опубликован в декабре 2017 г. Начато обсуждение пятой версии — C++20.

- **C++98** ISO/IEC 14882:1998;
- **C++11** ISO/IEC 14882:2011;
- **C++14** ISO/IEC 14882:2014;
- **C++17** ISO/IEC 14882:2017 (последний бесплатно доступный черновик — **n4659** от 2017-03-21).

Не все компиляторы поддерживают последние стандарты в полном объёме. Некоторые компиляторы (особенно это касается коллекции Microsoft Visual Studio) реализованы с нарушениями стандарта. Кроме того, многие компиляторы дополнительно поддерживают не описанные в стандарте языка расширения, такие, как OpenMP.

В данном пособии рассматриваются основные возможности языка, реализованные для всех компиляторов.

7.1. Структура программы

> Но вот Эм шагает в область сильного слова «Могу».
> Слушайте, слушайте моговест мощи!
>
> *В. Хлебников. Зангези*

Выполнение программы на C или C++ начинается с функции $main()$. Она называется головной, стартовой или главной функцией программы.

Функция $main()$ описана в разделе [**basic.start.main**] стандарта C++. Она должна быть определена как $int\ main()$ или как $int\ main(int,\ char*[])$. Обычно используются обозначения $int\ main(int\ argc,\ char\ *argv[])$.

Функцию $main()$ иногда называют точкой входа в программу, но это не совсем так. С точки зрения компоновщика, точка входа — это метка $\_start$. Для программ на C/C++ по адресу $\_start$ находится стартовый код библиотеки libc, который, в частности, инициализирует все используемые библиотекой ресурсы и глобальные объекты, готовит параметры для стартовой функции $main()$, вызывает её, а после возврата управления из $main()$ завершает программу.

При вызове исполняемого файла программы ему часто передаются так называемые параметры командной строки. Обычно это имя обрабатываемого файла (например, `pdflatex paper.tex`) или настройки для работы (`ls -la`) В частности, щелчок мыши в графической оболочке по файлу с данными эквивалентен запуску какой-либо программы с именем щёлкнутого файла в качестве параметра.

Параметры командной строки разделяются пробелами; например, здесь

```
grep str */*.tex *.tex
```

программа `grep` (поиск в текстовых файлах) вызывается с тремя параметрами — `str` (искомая строка), `*/*.tex` и `*.tex` (имена файлов для поиска). Нулевым параметром командной строки считается само имя исполняемого файла.

Общее количество параметров, включая имя исполняемого файла — это $argc$, первый аргумент функции $main()$. Массив строк $argv$ содержит сами эти параметры.

Возвращаемое значение функции $main()$ — код завершения программы. Он равен нулю в случае успешного завершения и ненулевому коду ошибки в противном случае.

Корректный код завершения позволяет оболочке учитывать итоги выполнения программы. В частности, следующий однострочный скрипт оболочки

```
pdflatex paper && bibtex paper
```

запускает программу `bibtex` (сборка библиографии) только в том случае, если программа `pdflatex` (сборка текста) корректно завершилась.

7.2. Типы данных

На данные свои взирая объективно,
Задумал типы я и идеал создал...

К. П. Прутков. Безвыходное положение

Базовые типы C++ описаны в разделе Fundamental types ([**basic.fundamental**]) стандарта C++ [25]. Раздел Types ([**basic.types**]) описывает общие характеристики хранения данных в памяти.

7.2.1. Целые типы

Чтобы мы не увидели войну людей, шашек Азбуки,
а услышали стук длинных копий Азбуки.

В. Хлебников. Зангези

Существует пять стандартных **знаковых целых типов**:
– `signed char`;
– `signed short int` (синонимы: `short, signed short`);
– `signed int` (синонимы: `int, signed`);
– `signed long int` (синонимы: `long, signed long`);
– `signed long long int` (синонимы: `long long, signed long long`);
и пять соответствующих **беззнаковых целых типов** (каждый из них имеет тот же размер и те же требования к выравниванию, что и соответствующий знаковый):
– `unsigned char`;
– `unsigned short int` (синонимы: `unsigned short`);
– `unsigned int` (синонимы: `unsigned`);
– `unsigned long int` (синонимы: `unsigned long`);
– `unsigned long long int` (синонимы: `unsigned long long`).
Тип `char`, в зависимости от реализации, может быть знаковым или беззнаковым. Типы `char`, `signed char` и `unsigned char` имеют один размер и одинаковые требования к выравниванию.

Стандарт C++ не содержит явных значений разрядности типов.

Согласно стандарту, `char`, `signed char` и `unsigned char` занимают 1 байт. При этом, если байт на используемой программно/аппаратной платформе не восьмибитен, то и `char` *однобайтовый,* но *не одноктетный,* то есть занимает не 8 бит.

Таким образом, всякий объект любого типа (обозначим его `T`) может быть скопирован в массив `char [sizeof(T)]`.

В ряду целых типов каждый следующий тип имеет размер (и диапазон значений) не меньше предыдущего:

$$\texttt{sizeof(char)} \leqslant \texttt{sizeof(short)} \leqslant \texttt{sizeof(int)} \leqslant \texttt{sizeof(long)} \leqslant \\ \leqslant \texttt{sizeof(long long)}$$

Размеры стандартных целых типов C++ также должны соответствовать ограничениям раздела 5.2.4.2.1 стандарта C [20]. В этом разделе описаны значения, которые обязательно должны быть включены в диапазоны значений соответствующих типов (при этом указанные значения не обязательно должны быть граничными). Анализ этих значений приводит к следующим выводам о минимально допустимой разрядности стандартных типов (таблица 7.1).

Минимальная разрядность стандартных целых типов

Таблица 7.1

Тип	Разрядность, бит (не менее)
`char`	8
`short`	16
`int`	16
`long`	32
`long long`	64

Тип `int` должен соответствовать «естественной» разрядности архитектуры (расплывчатость этой формулировки и то, что по умолчанию разрядность данных в шестидесятичетырёхбитном режиме равна 32, приводит к тому, что практически на 64-битной платформе тип `int` чаще всего 32-разряден).

Типы `char`, `signed char` и `unsigned char` называются ещё **узкими (narrow) символьными типами**, так как они могут быть интерпретированы не только как числа, но и как символы; соответственно их размер должен быть таким, чтобы хранить представление любого символа из **базового набора.**

Единственное отличие узких символьных типов от других целых (кроме размера) — то, что операторы ввода/вывода в поток для них перегружены так, что отображают не значение переменной, а символ, код которого равен этому значению. Отображение чисел, не равных кодам символов ASCII, не определено и может быть разным для различных реализаций,

Все арифметические операции для `char`, `signed char` и `unsigned char` выполняются точно так же, как и для любого другого целого типа.

Для типа `unsigned char` каждой возможной комбинации разрядов должно соответствовать отдельное число. Для других типов это не обязательно.

Для представления **расширенного набора символов** введён специальный тип `wchar_t`, имеющий такой же размер, знаковость и требования к выравниванию, что и один из целых типов.

Тип `bool` может хранить только два значения — `true` и `false`.

Практическая реализация

> Всё, что явно не прописано в стандарте C++, может быть реализовано по-разному на различных платформах.
> Всё, написанное в этом разделе и в аналогичных разделах ниже, описывает в основном платформу x86 и наиболее популярные компиляторы. На других программно/аппаратных платформах (в частности, при использовании экзотического компилятора) эти закономерности могут быть нарушены.

Для представления беззнаковых чисел используется натуральный двоичный код (см. раздел 2.4 настоящего пособия); знаковые представляются дополнительным кодом (см. разделы 2.4–2.5). Таким образом, для всех целых типов, в частности, для `unsigned char`, каждой возможной комбинации разрядов соответствует отдельное число.

Для знаковых и беззнаковых типов по-разному реализованы некоторые арифметические и битовые операции, в частности, умножение (оператор `*`), деление (оператор получения частного `/` и оператор получения остатка от деления `%`), битовые сдвиги (операторы `<<,>>`), расширение при присваивании (если приёмник больше источника).

Беззнаковые целые типы должны подчиняться циклической арифметике по модулю 2^N.

char, wchar_t Тип `char` — восьмибитный и знаковый. При этом `char` и `signed char` не являются синонимами, хотя вычисления с их использованием компилируются в одинаковые конструкции. Именно, при перегрузке `f(char)` и `f(signed char)` считаются разными функциями и их имена декорируются по-разному (для сравнения, `f(int)` и `f(signed int)` не различаются и декорируются одинаково).

Базовым набором символов является ASCII. При интерпретации переменной типа `char` как символа значение этой переменной трактуется как ASCII-код. Таким образом, 64, 0x40 и '@' — это разные формы записи одного и того же числа (ASCII-код символа «собака» равен шестидесяти четырём).

Символы не из ASCII, в частности, русские буквы, в зависимости от реализации, могут быть представлены одной переменной типа `char` (кодировки koi8, cp1251, cp866; в этом случае с учётом знаковости `char` коды русских букв — 128–255 — трактуются как отрицательные, то есть `'ы' < 0 < 's'`) или цепочкой из несколь-

ких char'ов (кодировка UTF-8; в этом случае можно описать строку из русских букв как char [], но невозможно описать одну такую букву как char).

Понятие расширенного набора символов и тип wchar_t возникли с появлением Unicode. Широкий символьный тип wchar_t может содержать любое количество байтов. Как правило, при хранении символьной информации в wchar_t используются такие юникодные кодировки или их части, в которых каждый логический символ занимает не менее одного wchar_t (UTF-32, или, если поддерживается только часть набора символов Unicode — UTF-16). Расширенный набор символов, соответственно — та часть набора символов Unicode, которая поддерживается и может быть записана одним wchar_t.

Литералы, соответствующие широким строкам и символам, предваряются префиксом L. Для ввода/вывода широких символов и строк используются те же операторы, что и для узких, но другие потоки (wcin/wcout). Поток cout при выводе wchar_t отображает число, при выводе wchar_t* — адрес в шестнадцатеричном виде.

int, short, long, long long Тип int на 16-разрядных платформах занимал 16 бит, на 32-разрядных — 32 бита. На 64-битной платформе int чаще всего 32-разряден.

Тип short 16-разряден на 16-, 32- и 64-разрядных платформах.

Тип long на 16- и 32-разрядных платформах занимал 32 бита. На 64-битной платформе — 64.

Тип long long, если поддерживается, 64-разряден.

Таким образом в C++ не существует гарантированно 32-разрядного фундаментального целого типа.

Кроме фундаментальных типов, описанных в стандарте C++, поддерживаются также типы, описанные в стандарте C [20]. Современный стандарт языка C включает типы фиксированной разрядности, в частности, тридцатидвухразрядный int32_t.

7.2.2. Вещественные типы

Страшен очерк их лиц: смуглого дико и нежно пространства.

В. Хлебников. Зангези

Существует три стандартных **вещественных типа**:

- float;
- double;
- long double.

тип double обеспечивает не меньшую точность, чем float, long double — не меньшую точность, чем double.

Множество значений типа `float` является подмножеством множества значений типа `double`; множество значений типа `double` является подмножеством множества значений типа `long double`:

$$\texttt{float} \subseteq \texttt{double} \subseteq \texttt{long double}$$

Все они хранят данные с плавающей запятой.

Практическая реализация

Вещественные числа представляются в форматах с плавающей запятой различной точности, в соответствии со стандартом двоичной арифметики с плавающей точкой IEEE 754 [14, 83].

Процессоры семейства x86 имеют два набора команд для работы с вещественными числами с плавающей запятой. Это команды математического сопроцессора FPU и команды расширений XMM и YMM.

Модуль операций с плавающей запятой процессоров семейства x86 (floating point unit, FPU) поддерживает три типа вещественных чисел

- одинарной точности (32 бита);
- двойной точности (64 бита);
- с двойной расширенной точностью (80 бит, внутренний нестандартный формат FPU — 15 разрядов отводится под порядок, 64 под мантиссу).

Расширения XMM и YMM поддерживает два типа вещественных чисел — одинарной и двойной точности.

Типу `float` соответствует число одинарной точности, типу `double` — двойной.

Типу `long double` чаще всего соответствует 10-байтовое число расширенной точности. Размер выделяемой под переменную `long double` памяти при этом в зависимости от флагов компиляции (`-m96bit-long-double` и `-m128bit-long-double` в GCC), может быть равен 12 или 16 байт. Используются только первые 80 бит (10 байт), остальное — неиспользуемая память (заполнение).

В Microsoft Visual Studio типу `long double` соответствуют числа двойной точности (64 бита), хотя `long double` не считается синонимом `double`.

7.2.3. Специальные типы

> Волю осязаем как пустоту, как отсутствие преград,
> как отрицательный объём для движения.
>
> *В. Хлебников. Мысли и заметки*

Множество значений типа `void` пусто. Он, в частности, используется для описания функций, которые не возвращают значения, так как в C++ нет отдельного понятия процедуры или подпрограммы, не возвращающей значения.

Любое выражение может быть приведено к типу `void`.

Указатель `void*` считается нетипизированным. К типу `void*` может быть преобразован любой указатель.

7.2.4. Указатели

Пространство звучит через Азбуку.

В. Хлебников. Зангези

Каждому, простому или сложному, типу данных `T` в C++ соответствует свой тип указателя `T*` — адрес участка памяти, где лежит переменная типа `T` или массив таких переменных.

Все указатели — целые беззнаковые величины одного размера. По разрядности указателей в настоящее время определяется разрядность системы, так что на 32-битной платформе указатели занимают 32 бита, на 64-битной — 64.

Любой указатель может быть разыменован как массив, причём с использованием произвольного целого индекса. Таким образом, программист должен сам следить за количеством элементов по адресу, хранящемуся в переменной-указателе.

В C++ указатели на различные типы сами считаются различными типами. Соответственно, механизм типизации не позволяет неявно преобразовать указатели на различные типы друг в друга (в частности, `int*` в `char*`). Возможно только приведение к нетипизированному указателю `void*`. Это логично для строго типизированного языка высокого уровня, но не всегда удобно для низкоуровневого исследования данных.

Тем не менее, физически все указатели имеют одно строение — ячейка, где хранится адрес в памяти. Таким образом, указатели на разные типы могут быть преобразованы друг в друга с помощью оператора преобразования `reinterpret_cast` либо в два этапа через `void*`. Вначале исходный тип неявно или с помощью `static_cast` приводится к нетипизированному указателю `void*`, затем с помощью `static_cast` нетипизированный указатель приводится к требуемому типу.

Также с указателями связано два целых типа той же разрядности. Это знаковая разность указателей — `ptrdiff_t` и беззнаковая длина массива — `size_t`.

В C/C++ нет фундаментального строкового типа, хотя есть строковые литералы. Функции стандартной библиотеки C обрабатывают как строки указатели на массивы чисел типа `char`. Признаком конца строки служит нулевое значение очередного элемента массива (символ с кодом, равным нулю).

Указатель на массив чисел типа `wchar_t`, завершающийся элементом, равным нулю, также может быть интерпретирован как строка (так называемые «широкие» строки). Для их обработки используются функции с префиксом `w`.

7.3. Приведение типов

При встрече с медвежьим капканом
Пойди объясни, что ты не медведь.

Б. Б. Гребенщиков. Я хотел петь

В C++ есть четыре оператора явного преобразования (приведения) типов: `const_cast`, `static_cast`, `dynamic_cast` и `reinterpret_cast`. Кроме того, для совместимости поддерживается приведение в стиле C [76, 80].

const_cast убирает (или добавляет, но это редко используется) так называемые cv-спецификаторы (cv qualifiers) — `const` и `volatile`. Спецификатор `volatile` встречается редко, так что `const_cast` обычно применяется для снятия `const` при обращении к некорректно написанным сторонним библиотекам. При использовании остальных операторов приведения типов cv-спецификаторы остаются неизменными.

Листинг 7.1. Снятие спецификатора `const`

```
1 double x;
2 const double *px = &x;
3 // *px имеет тип const double, но переменная x неконстантна
4 double *y = const_cast<double *> (px); // const можно снять
```

Если приведение невозможно, выдаётся ошибка на этапе компиляции.
Необходимо помнить, что попытка записи в изначально константный объект или переменную приводит к неопределённому поведению. Таким образом, если `const_cast` требуется использовать в собственной программе, обычно лучше изменить программу так, чтобы его использование не требовалось.

static_cast статически (то есть на этапе компиляции) преобразует выражение одного типа к другому типу. Может быть использован везде, где допустимо неявное преобразование типов (в частности, преобразования чисел вроде `int i = 1.3`, преобразование указателя произвольного типа в нетипизированный указатель `void*`, указателя на производный класс в указатель на базовый или перечислимого типа в интегральный), а также для приведения:

- любого типа к типу `void` (допустимое, но обычно ненужное на практике преобразование);
- нетипизированного указателя `void*` к указателю произвольного типа;
- базового класса к ссылке на производный класс (допустимо, если объект на самом деле производного класса, но опасно, если это не так; чтобы иметь возможность проверить корректность, для такого преобразования лучше использовать `dynamic_cast` — но применимо это только для полиморфного базового класса);

– указателя на базовый класс к указателю на производный класс (аналогично, надёжнее использовать `dynamic_cast`, если это возможно);
– интегральных типов (`int`, `char` и т. п.) к перечислимым (`enum`).

Если приведение невозможно, выдаётся ошибка на этапе компиляции.

Позволяет привести одно значение к другому значению. Именно оператор `static_cast` наряду с неявными преобразованиями наиболее часто используется на практике.

dynamic_cast динамически (на этапе выполнения) приводит полиморфный базовый класс к производному с проверкой преобразования. Таким образом, чтобы можно было воспользоваться оператором `dynamic_cast`, в базовом классе должна быть хотя бы одна виртуальная функция (таблица виртуальных функций используется для определения реального типа объекта). Если это условие не соблюдено, выдаётся ошибка на этапе компиляции.

Используется для приведения

– указателя на базовый класс к указателю на производный класс:

```
1 dynamic_cast<derived_class *>(base_class_ptr_expr)
```

если приведение невозможно, будет возвращён NULL;

– базового класса к ссылке на производный класс:

```
1 dynamic_cast<derived_class &>(base_class_ref_expr)
```

если приведение невозможно, будет выброшено исключение `bad_cast`.

В отличие от других операторов приведения типов, `dynamic_cast` позволяет определить корректность преобразования на этапе выполнения программы и при необходимости обработать ошибку (NULL или исключение `bad_cast`).

reinterpret_cast интерпретирует память в соответствии с заданным типом без проверок. Используется для приведения указателя к указателю на другой тип, указателя к целому, целого к указателю, ссылки к ссылке, объекта к ссылке (в последнем случае фактически интерпретируется адрес объекта). Не может быть приведено одно значение к другому значению (для приведения значений используется `static_cast`).

Возможные варианты использования

Листинг 7.2. Варианты использования `reinterpret_cast`

```
1 reinterpret_cast<T2 *>(T1 *)
2 reinterpret_cast<integer_expression>(T *)
3 reinterpret_cast<T *>(integer_expression)
```

Например, допустимо:

Листинг 7.3. Корректное использование `reinterpret_cast`

```
double x = 1;
int i = -1;
char *pc = reinterpret_cast<char *>(&x);

// refu - ссылка на то же место в памяти, где расположена
    переменная i,
// но интерпретируется этот фрагмент памяти уже как unsigned
unsigned &refu = reinterpret_cast<unsigned &>(i);

// pu указывает на то же место в памяти, где расположена
    переменная i (аналогично)
unsigned *pu = reinterpret_cast<unsigned *>(&i);

// u - новая переменная, инициализированная текущим
    значением i в беззнаковой интерпретации (0xFFFFFFFF)
unsigned u = reinterpret_cast<unsigned &>(i);

// lox ссылается на первые (в x86 - младшие) 4 байта x и
    интерпретирует их как беззнаковое целое
unsigned &lox = reinterpret_cast<unsigned &>(x);
unsigned &hix = *(&lox + 4);    // старшие 4 байта x
```

Но нельзя выполнить

```
int i;
unsigned u = reinterpret_cast<unsigned>(i);
```

Для приведения разнотипных указателей рекомендуется использовать не `reinterpret_cast`, а двухступенчатое преобразование — вначале к нетипизированному указателю `void*`, а затем к необходимому типу — через `static_cast`.

Приведение в стиле C (C-style cast) — самое медленное преобразование, так как последовательно перебираются следующие вызовы:

1) `const_cast`;
2) `static_cast`;
3) `static_cast + const_cast`;
4) `reinterpret_cast`;
5) `reinterpret_cast + const_cast`.

Таким образом, приведение в стиле C универсально.

Листинг 7.4. Приведение в стиле C

```
double x = 1;
int i = -1;
```

```
3 char *pc = (char *)(&x);
4 unsigned &refu = (unsigned &)i;
5 unsigned *pu = (unsigned *)&i;
6 unsigned u = (unsigned)i;
```

Допустимо во всех случаях, но не рекомендуется из-за внешнего вида (считается, что приведение в стиле C найти в коде труднее, чем операторы `XXX_cast`).

7.4. Литералы C++

> Так что в лучших книгах всегда нет имён
> и в лучших картинах — лиц.
>
> *Б. Б. Гребенщиков. Сельские леди и джентльмены*

Литералы (символические константы) — фиксированное значение в коде программы (`3, 0xFF, 7.8`). Литералы могут использоваться как для инициализации именованных констант и переменных (в этом случае тип литерала приводится к типу соответствующей константы или переменной), так и непосредственно в теле программы (магические числа).

7.4.1. Целые

> Таковы числа 48, 317, 1053, 768, 243.
>
> *В. Хлебников. В мире цифр*

Целочисленные литералы начинаются с цифры или знака (+ или −) и не содержат десятичной запятой и показателя степени.

Для тех чисел, которые соответствуют кодам ASCII для печатных и некоторых управляющих символов, есть альтернативная форма записи — соответствующий символ в одинарных кавычках, например `'\0'` равен 0, `'\t'` — 9, `'2'` — 50, `'R'` — 82, `'r'` — 114. Для чисел, соответствующих номерам Unicode, добавляется префикс `L`, так, `L'ы'` равен 1099, или `0x044B`.

Префиксы системы счисления

Целочисленные литералы могут предваряться префиксом, обозначающим систему счисления:
0x, 0X — шестнадцатеричная;
0 (ведущий ноль) — восьмеричная;
0b, 0B — двоичная;
по умолчанию (без префикса) используется десятичная система. Так, одно и то же число может быть записано как `13, 015, 0xD` и `0b1101`.

Знак может быть поставлен только перед префиксом системы счисления, но не после него.

Суффиксы знаковости и размера

Целый литерал без суффикса имеет тип `int` (если значение выходит за пределы `int`, то используется минимальный знаковый тип, в который литерал помещается; ACSII-коды имеют тип `char`, Unicode-номера — `wchar_t`).

Для указания беззнакового типа литерала (без суффикса размера это тип `unsigned`) используется суффикс `u` или `U`.

Для указания размера используются следующие суффиксы:

l, L — `long`;

ll, LL — `long long`.

Так, `2ul` — беззнаковое число типа `unsigned long` (возможна также запись `2lu`).

Если значение литерала не помещается в тип, соответствующий суффиксу, выбирается более ёмкий.

К альтернативной символьной записи целых чисел суффиксы неприменимы.

7.4.2. Вещественные

Пи далее и далее в ночную темноту.

В. Хлебников. Царапина по небу

Литералы с плавающей запятой задают значения, которые должны иметь дробную часть (возможно, нулевую). Эти значения содержат разделитель целой и дробной частей (в соответствии с западной традицией — точку, `.`) и/или показатели степени: `34.56` $(34 + \frac{56}{100})$, `0.12` $(\frac{12}{100})$, `1.` (вещественное число 1), `1e4` (10^4), `5e-4` $(5 \cdot 10^{-4})$, `2.12e+2` $(2{,}12 \cdot 10^2 = 212)$, `0x1p10` $(1 \cdot 2^{10} = 1024)$, `0xF.Fp4` $(\mathrm{F{,}F}_{16} \cdot 2^4 = \mathrm{FF}_{16} = 255)$, `0x.8p0` $(0{,}8_{16} = \frac{1}{2})$, `0x.8p-1` $(0{,}8_{16} \cdot 2^{-1} = \frac{1}{4})$.

Системы счисления

Вещественные литералы могут быть заданы в двух системах счисления — десятичной и шестнадцатерично-двоичной.

Литерал в десятичной системе может иметь вид

$$M[\mathtt{e}S] = M[\cdot 10^S] \tag{7.1}$$

где M — значащие цифры, записанные в виде десятичного числа (возможно, со знаком и/или с дробной частью), S — десятичный порядок, записанный в виде целого десятичного числа. Порядок может быть опущен вместе с символом `e`. Регистр символа `e` может быть любым (`e`/`E`).

Литерал в шестнадцатерично-двоичной системе предваряется шестнадцатеричным префиксом `0x` или `0X` и обязательно включает двоичный порядок

$$\texttt{0x}M\texttt{p}S = M \cdot 2^S \tag{7.2}$$

M — значащие цифры, записанные в виде беззнакового шестнадцатеричного числа (возможно, с дробной частью), S — двоичный порядок, записанный в виде целого десятичного числа. Так как символ `e`/`E` является корректной шестнадцатеричной цифрой, порядок отделяется символом `p`/`P` (регистр может быть любым). В шестнадцатерично-двоичном вещественном литерале должны присутствовать обе компоненты M и S, даже если $M = 1$ или $S = 0$.

Знак может быть поставлен перед префиксом `0x`.

Суффиксы размера

Вещественный литерал без суффикса имеет тип `double` (если значение выходит за пределы `double`, то — `long double`). Для указания размера используются следующие суффиксы:

f, F — `float`;

l, L — `long double`.

Если значение литерала не помещается в тип, соответствующий суффиксу, выбирается более ёмкий.

7.4.3. Строки

> И уже из этого зерна росло дерево особой буквенной жизни.
>
> *В. Хлебников. Художники мира!*

Строковые литералы заключаются в двойные кавычки. Перед «широкими» строками ставится префикс `L`.

Русские строковые литералы могут быть как узкими, так и широкими. При этом представление полученной константы в памяти зависит от реализации. Если используются «узкие» строки, то количество символов в полученной строке, как правило, превышает количество букв в литерале за счёт того, что используется восьмибитный байт и кодировка UTF-8, так что одна русская буква представляется двумя элементами типа `char`.

Строковый литерал имеет тип `const char*` или `const wchar_t*` и является адресом соответствующего массива символов, завершающегося нулём — строки, расположенной в памяти.

Таким образом, узкая строка `"test"` занимает в памяти не четыре байта, а пять. Объявления

```
char s[] = { 't', 'e', 's', 't', '\0' };
```

и

```
char s[] = "test";
```

эквивалентны.

7.5. Средства автоматизации C++

— А почему ты решила, что я стою только у этих ворот? — хмыкнула МакКанарейкл.

А. В. Жвалевский, И. Е. Мытько.
Личное дело Мергионы или Четыре чёртовы дюжины

Языки C и C++ строго типизированы. Это позволяет избежать множества ошибок, но иногда требуется выполнить какое-нибудь одно действие над данными различных типов.

Для этого в языке C++ доступны два средства — шаблоны C++ и унаследованные от языка C макросы препроцессора (подробнее описаны в разделе 4.2).

Шаблоны раскрываются на этапе компиляции; при формировании нужной реализации учитываются фактические типы и значения параметров шаблона. Макросы — текстовая замена, производящаяся на этапе препроцессинга без учёта семантики текста.

7.5.1. Шаблоны C++

Ряд волшебных изменений
Милого лица.

А. А. Фет. Шёпот, робкое дыханье...

В языке C++ для выполнения единообразных действий над данными различных типов используются шаблоны. Существует два основных вида шаблонов — шаблонные функции и шаблонные классы.

Перед заголовком соответствующей функции или класса указывается дополнительный заголовок шаблона, который начинается с ключевого слова `template`, после которого в угловых скобках через запятую перечисляются параметры шаблона. Для каждого параметра указываются его тип и имя. Тип параметра шаблона может быть перечислимым (в частности, `int`, `char`, любое описанное пользователем перечисление) или описан ключевым словом `typename` или `class` (раздел [**temp.param**] стандарта утверждает, что семантика этих ключевых слов не различается), тогда параметр представляет собой имя типа C++.

Листинг 7.5. Шаблонная функция

```
template<typename T> int foo(T x)
{
  T y = x;
...
}
```

Внутри шаблонной функции или шаблонного класса имя параметра может быть использовано как целочисленная именованная константа или как имя типа C++, в соответствии с типом параметра.

Листинг 7.6. Шаблонный класс

```
template <typename T, int Rows, int Cols> class TMatrix
{
    T data[Rows][Cols];
    ...
};
```

При вызове шаблонной функции достаточно просто передать ей набор параметров — `j = foo(1)`. Компилятор сформирует по шаблону нужную реализацию и подставит её вызов. При необходимости можно явно указать вызываемую реализацию, подставив после имени функции список фактических параметров шаблона — `foo<int>(1.7)`. Пустые угловые скобки после имени — `foo<>(0)` — предписывают компилятору вызывать шаблон, а не одноимённую нешаблонную функцию, но реализация подбирается по фактическим параметрам функции. Если же указано только имя и существуют и шаблон, и подходящая нешаблонная функция, компилятор чаще выбирает нешаблонную функцию даже при неполном соответствии типов параметров. Шаблон будет вызван только в том случае, если на его основе можно сгенерировать функцию, лучше подходящую по всем параметрам [29].

Можно явно описать реализацию шаблона для какого-либо конкретного типа (специализацию). Чтобы компилятор имел возможность отличить специализацию от обычного описания функции или класса, перед её заголовком указывается заголовок шаблона с пустым списком параметров.

Листинг 7.7. Частная реализация шаблона для типа `long`

```
template <typename T> T f(T x)
{
    return x;
}
template <> long f(long x)
{
    return 2*x;
```

```
8 }
```

В этом случае при вызове шаблонной функции $f()$ с аргументом любого типа, кроме `long`, в том числе с аргументом типа `int`, она вернёт значение переданного аргумента x, а если вызвать $f()$ с аргументом типа `long` — его удвоенное значение $2x$.

7.5.2. Макросы препроцессора C/C++

Разворачивайтесь в марше!
Словесной не место кляузе.
Тише, ораторы!
Ваше
слово,
товарищ маузер.

В. В. Маяковский. Левый марш

Для выполнения единообразных действий над величинами разных типов также могут использоваться макросы препроцессора, подробнее описанные в разделе 4.2.

Так как макрос является по сути текстовой заменой, описанные в нём действия могут быть применены к данным любого типа. Невозможно описать отдельную реализацию для параметров определённого типа, имени, длины или вида. Не выполняется никаких проверок (а ошибки, возникающие на этапе компиляции из-за некорректного использования макросов, часто сложно интерпретировать).

При этом в макросе, в отличие от шаблонной функции, возможно обработать не только значение или тип переменной, но и её имя. В частности, макрос `PRINT`, описанный в листинге 7.8, выводит на стандартный вывод имя переменной (для этого используется оператор закавычивания строк препроцессором `#`) и её значение.

Листинг 7.8. Определение макроса отладочной печати переменной

```
1 #define PRINT(val) cout << #val << " = " << val << "  ";
```

Таким образом, строка `PRINT(x)PRINT(y)` будет преобразована препроцессором в:

```
1 cout << "x" << " = " << x << "  ";cout << "y" << " = " << y
      << "  ";
```

и, если переменные x и y существуют, выведет их значение. В частности, при вещественном $x = 5{,}7$ и целом $y = 0$ будет напечатано `x = 5.7  y = 0`.

7.6. Ввод-вывод

Человек ведёт переписку со всем земным шаром,
а через печать сносится даже с отдалённым потомством.

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

В языке C++ доступно два варианта платформонезависимого ввода-вывода — полиморфные операторы ввода-вывода в поток и функции стандартной библиотеки C (libc).

7.6.1. Ввод-вывод в поток

Тонут гении, курицы, лошади, скрипки.
Тонут слоны.
Мелочи тонут.

В. В. Маяковский. Человек

В библиотеке C++ описаны шаблонные классы потоков — объектов, куда может быть направлен ввод или откуда взят вывод. В качестве операторов ввода и вывода используются перегруженные операторы битового сдвига << и >>. Если левым операндом является поток, то оператор << выводит туда правый операнд и возвращает ссылку на этот поток. Аналогично перегружен оператор >>.

Используемые для вывода в поток перегруженные операторы << и >> реализованы для разных типов по-разному. Типы `char`, `signed char` и `unsigned char` отображаются в потоке как символы, код которых равен значениям переменных. Вывести значение такой переменной как число можно, преобразовав её в другой целый тип, в частности, `int` или `unsigned`, для чего можно использовать `static_cast`:

Листинг 7.9. Вывод первого байта x в поток как числа со знаком

```
1 char *p = reinterpret_cast<char *>(&x);
2 cout << static_cast<int>(*p);
```

или

Листинг 7.10. Вывод первого байта x в поток как числа без знака

```
1 unsigned char *p = reinterpret_cast<unsigned char *>(&x);
2 cout << static_cast<unsigned>(*p);
```

оба эти листинга выводят в поток `cout` первый байт объекта `x`, первый — как знаковое число, второй — как беззнаковое.

Прочие целые типы отображаются как значение в десятичной, восьмеричной или шестнадцатеричной системе счисления. Используемую систему счисления можно изменить, используя манипуляторы `hex, oct, dec` или `setbase()`. Манипуляторы `hex, oct` и `dec` меняют вывод целых чисел (но не `char`) на шестнадцатеричный, восьмеричный и десятичный соответственно. Манипулятор `setbase (int base)` позволяет задать основание; фактически можно выбрать только 8, 10 и 16. Теми же манипуляторами можно задать систему счисления для ввода чисел.

Знак отображается только в десятичной форме вывода; восьмеричная и шестнадцатеричная формы при выводе знаковых чисел представляют собой двоичное представление числа, приведённое к соответствующей системе счисления. Так, число -1 (так как в литерале не указан суффикс типа, число имеет тип `int`) в восьмеричной и шестнадцатеричной формах соответственно выглядит как `37777777777` и `ffffffff`.

Регистр шестнадцатеричных цифр `A..F` (а также символа `E` в экспоненциальной форме вывода вещественных чисел) задаётся манипуляторами `uppercase` и `lowercase`.

Манипулятор `setfill(int ch)` устанавливает символ заполнения равным `ch`. В частности, `setfill('0')` указывает, что числа нужно дополнять до ширины, указанной манипулятором `setw()`, не пробелами, а ведущими нулями.

Действие манипуляторов `hex`, `oct`, `dec`, `setbase()`, `uppercase`, `lowercase` и `setfill()` не прекращается после вывода/ввода одного числа и длится до изменения другим аналогичным манипулятором.

Ширина вывода устанавливается манипулятором `setw(int w)` только для следующего выводимого значения. Если выводимое значение не помещается в `w` знакомест, оно выводится целиком.

Таким образом, строка

Листинг 7.11. Вывод нескольких чисел в поток

```
1 cout << hex << setfill('0')
2     << setw(4) << 10 << " " << 20 << " "
3     << setw(3) << " " << setw(8) << 30 << " "
4     << setw(2) << 257 << endl;
```

поместит в поток `cout`

```
1 000a 14 00 0000001e 101
```

манипулятор `hex` действует на все целые числа; `setfill('0')` — на все выводимые данные, для которых ширина поля вывода превышает ширину данных (включая пробел, для которого установлена ширина поля вывода в 3 знакоместа); манипулятор `setw(4)` действует только на число 10 (`0xA`), `setw(3)` — только на выводимый после него пробел, `setw(8)` — только на число 30 (`0x1E`); `setw(2)` не влияет на вывод числа 257 (`0x101`), так как для его вывода нужно три знакоместа.

Порядок использования манипуляторов не важен.

7.6.2. Ввод-вывод с помощью libc

И при железных дорогах лучше сохранять двуколку.

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

Стандартная библиотека языка C (libc) включает множество функций ввода-вывода. Как и для любых функций стандартной библиотеки, подробную информацию о них можно найти в третьем разделе man-страниц GNU/Linux. В частности, команда `$ man 3 printf` выводит в консоль данные о функции `printf()`, а также об используемых ею форматных полях.

Вывод

Простой вывод строки s на стандартный вывод можно выполнить с помощью функции `int puts(const char *s)`.

Форматированный вывод данных различных простых типов осуществляется с помощью функции `int printf(const char *format, ...)`. Первый аргумент этой функции — форматная строка, содержащая некоторый набор форматных полей, а следующие — выводимые данные простых типов. Каждому полю обычно соответствует один параметр, выводимый функцией $printf()$ на экран, для некоторых видов полей также требуется один или два дополнительных целых параметра, уточняющих формат вывода.

Несмотря на то, что второй и последующие аргументы могут иметь различные типы, функция $printf()$, как и $scanf()$, не является ни шаблонной, ни перегруженной. Соответственно, её имя не декорируется и изменяется по правилам C-функций.

Форматное поле начинается с символа `%` и заканчивается буквой, обозначающей обобщённый вид формата, в соответствии с которым выводится значение (таблица 7.2). Символ процента можно вывести с помощью поля `%%`, которому не должно соответствовать никакого параметра функции $printf()$.

Между символом процента и форматом вывода могут присутствовать (но не обязательно) символы, уточняющие формат. Они располагаются в следующем порядке:

- флаги (таблица 7.3; флагов может быть несколько, один или ни одного);
- минимальная ширина поля вывода — число, звёздочка `*` (значение задаётся параметром) или другое описанное в документации значение;
- точность вывода (для целых форматов — общее количество выводимых цифр, для вещественных — после запятой); точность описывается аналогично мини-

Основные форматы вывода $printf()$

Таблица 7.2

Обозначение	Преобразование
Форматы вывода целых чисел	
`d, i`	Целое число выводится как знаковое десятичное значение
`o, u, x, X`	Целое число выводится как беззнаковое восьмеричное (`o`), десятичное (`u`) или шестнадцатеричное (`x, X`) значение без префикса
`c`	Целое число преобразуется к типу `unsigned char`, после чего выводится символ с соответствующим кодом
Форматы вывода вещественных чисел	
`e, E`	Вещественное число выводится в десятичном экспоненциальном формате
`f, F`	Вещественное число выводится в формате с десятичной запятой
`g, G`	Вещественное число выводится в десятичном экспоненциальном формате или формате с десятичной запятой, так, чтобы результат был наиболее компактным
`a, A`	Вещественное число выводится в шестнадцатеричном экспоненциальном формате с двоичным порядком с префиксом
Форматы вывода указателей	
`s`	Байты по указанному адресу выводятся как строка, завершающаяся нулём
`p`	Указатель выводится как шестнадцатеричное значение

мальной ширине поля — число, звёздочка * или другое описанное в документации значение и отделяется от минимальной ширины точкой;
– модификатор размера.

Любой из уточняющих символов может быть опущен.

Кроме форматных полей, в форматной строке $printf()$ могут присутствовать произвольные символы и управляющие последовательности (`\\n`, `\\t`, `\\\\` и т. п.). Символы выводятся на экран «как есть», вместо управляющих последовательностей выводятся соответствующие символы (в частности, `\\n` — перевод строки, `\\t` — табуляция, `\\\\` — одиночная обратная косая черта).

Таким образом, строка

```
printf("%+4d %03x\n", 19, 13);
```

поместит на стандартный вывод

```
␣+19␣00d
```

Основные флаги вывода $printf()$

Таблица 7.3

Обозначение	Действие
`#`	Значение выводится в «альтернативной форме». В частности, для форматов `o` и `x/X` добавляется префикс системы счисления (`0` и `0x/0X` соответственно)
`0`	Если длина значения в заданном формате меньше заданной минимальной ширины поля вывода, значение дополняется ведущими нулями до заданной ширины. При одновременном задании `0` и `-` флаг `0` игнорируется
`-`	Если длина значения в заданном формате меньше заданной минимальной ширины поля вывода, значение выравнивается по левому краю поля
`« »` (пробел)	Перед беззнаковыми числами (в позиции, соответствующей знаку) вставляется пробел. При одновременном задании `« »` и `+` флаг `« »` игнорируется
`+`	Перед положительными числами указывается знак $+$

Регистр шестнадцатеричных цифр `A`$-$`F` соответствует регистру буквенного обозначения формата.

Если целому аргументу функции $printf()$ поставить в соответствии вещественный формат вывода или наоборот, к нужному типу приводится не сам аргумент, а его адрес. То есть число, выведенное на экран, не будет соответствовать значению аргумента.

Ввод

Ввод данных в соответствии с заданным форматом осуществляется функцией `int scanf(const char *format, ...)`. Форматная строка функции $scanf()$ и подобных ей функций ввода состоит из последовательного описания ожидаемого формата вводимых данных и способа их обработки. Следующие за форматной строкой аргументы — адреса, куда записываются прочитанные и обработанные данные (количество этих адресов, как правило, соответствует количеству полей форматной строки).

Форматная строка функции $scanf()$ может содержать:

– пробельные символы, при этом любая комбинация любых пробельных символов (собственно пробела, табуляции, перевода строки и т. п.) в форматной строке соответствует любой, в том числе другой, вводимой комбинации любых пробельных символов либо их полному отсутствию в указанном месте;

– форматные поля, каждое из которых соответствует последовательности символов, которая может быть преобразована в некоторое значение (в частности, слово, символ, число), а значение — записано по одному из аргументов-адресов;
– иные символы, которые должны присутствовать во вводимых данных «как есть», в противном случае чтение прервётся и $scanf()$ завершит работу.

Форматное поле $scanf()$ начинается, как и для $printf()$, знаком процента `%` и заканчивается обозначением формата (таблица 7.4).

Основные форматы ввода $scanf()$

Таблица 7.4

Обозначение	Преобразование
Форматы ввода целых чисел	
`d`	Знаковое десятичное значение сохраняется как int
`i`	Знаковое значение с префиксом системы счисления (восьмеричное, десятичное или шестнадцатеричное) сохраняется как int
`o`	Беззнаковое восьмеричное значение сохраняется как $unsigned\ int$
`u`	Беззнаковое десятичное значение сохраняется как $unsigned\ int$
`x, X`	Беззнаковое шестнадцатеричное значение без префикса сохраняется как $unsigned\ int$
Форматы ввода вещественных чисел	
`e, E, f, g, a`	Вещественное значение сохраняется как $float$
Форматы ввода символьных последовательностей	
`s`	Слово (последовательность непробельных символов) сохраняется как строка, завершающаяся нулём
`[множество]`	Последовательность символов из заданного множества сохраняется как строка, завершающаяся нулём
`c`	Последовательность произвольных символов (включая пробельные; количество ограничено максимальной шириной поля ввода, по умолчанию — один символ) сохраняется как строка без завершающего нуля

Между ними могут присутствовать символы, уточняющие формат:
– символ `*`, обозначающий, что значение этого форматного поля не сохраняется (такие поля не учитываются при подсчёте возвращаемого значения $scanf()$);
– максимальная ширина поля ввода (в символах — широких `wchar_t` или узких `char`, в зависимости от типа сохраняемой строки) — десятичное число;
– модификатор размера (таблица 7.5), изменяющий тип сохраняемого значения.

Любой из уточняющих символов может быть опущен.

Основные модификаторы размера

Таблица 7.5

Модификатор	Тип приёмника
`hh`	*signed char* для знаковых целых значений, *unsigned char* для беззнаковых
`h`	*short* для знаковых целых значений, *unsigned short* для беззнаковых
`l`	*long* для знаковых целых значений, *unsigned long* для беззнаковых, *double* для вещественных; для символьных последовательностей — использование широких символов
`ll, L`	*long long* для целых значений, *long double* для вещественных

Для *scanf()* форматы `x` и `X` полностью эквивалентны, то есть любой из них соответствует чтению шестнадцатеричного числа с произвольным регистром цифр. Эквивалентны также `e, E, f, g, a` — любой из них позволяет прочесть вещественное число в любой форме.

Допустимое множество символов для формата `%[...]` задаётся так же, как для регулярных выражений в стиле Perl — перечисляется в квадратных скобках без разделителей. Так, `%[ab]` соответствует любому количеству символов `a` и `b` в любом порядке. С помощью дефисоминуса можно задать диапазон: `%[0-9]` соответствует любому набору цифр; с помощью символа циркумфлекса (крышки), следующего сразу после открывающей квадратной скобки, получается дополнение множества: `%[^\r\n]` соответствует символам, не равным возврату каретки и переводу строки, то есть всем символам до конца строки. Если необходимо указать среди символов закрывающую квадратную скобку, то этот символ должен перечисляться первым после открывающей квадратной скобки или циркумфлекса; циркумфлекс — на любом месте, кроме первого после открывающей скобки; дефисоминус — последним перед закрывающей скобкой. Так, `%[^]0-9-]` — любые символы, кроме закрывающей квадратной скобки, цифр и дефисоминуса.

Пробельные символы перед значениями любого формата, кроме `%c` и `%[...]` (но включая `%%`, соответствующий одиночному знаку процента), игнорируются. Все элементы форматной строки — жадные.

Если для форматов `%s` и `%[...]` не задана максимальная ширина поля ввода, то длина сохраняемой строки зависит только от того, что вводит пользователь и потенциально не ограничена. Это легко может привести к переполнению буфера, адрес которого передан соответствующим аргументом. При этом необходимо учесть, что максимальная ширина поля ввода не включает завершающий ноль, а также задаётся в символах `char/wchar_t`, а не в буквах, так что, если при вводе

русских строк в кодировке UTF-8 указать недостаточную максимальную ширину, строка может быть оборвана на полубукве.

Функция $scanf()$ возвращает количество успешно прочитанных и присвоенных значений. При корректных вводимых данных $scanf()$ вернёт число, равное количеству аргументов-адресов; в случае сбоя возвращаемое значение может быть меньше, в том числе равным нулю или константе EOF (она определяется как -1). Если на каком-то этапе реальные вводимые данные не соответствуют форматной строке, дальнейший ввод не читается и $scanf()$ завершает свою работу (при этом введённые, но не прочитанные данные остаются в буфере, так что следующий вызов $scanf()$ или другой функции ввода начнёт чтение с них).

Кроме $printf()/scanf()$, использующих стандартный вывод и стандартный ввод, библиотека libc включает аналогичные пары функций, отличающиеся использованием иного приёмника или источника данных — это $sprintf()/sscanf()$ для формирования и анализа строк и $fprintf()/fscanf()$ для записи и чтения текстовых файлов. Адрес источника/приёмника передаётся в них первым параметром, перед форматной строкой.

7.7. Отладочная печать

> Читай запись дел твоих!
> Ныне ты сам в состоянии требовать от себя отчёт.
>
> *Коран. 17.15*

В некоторых случаях использование окон отладчика по какой-то причине неудобно, в частности, иногда необходимо сформировать файл протокола, содержащий шестнадцатеричные представления множества объектов.

7.7.1. Средства исследования переменных

> Спрашивается: можно ли сделать инструмент оптический, помощью которого можно б было видеть вещи в море или в реках глубже, нежели как простыми глазами усмотреть можно.
>
> *М. В. Ломоносов. Задача, которую следует предложить на соискание премии*

Язык C++ предоставляет множество средств для исследования структуры объектов во время выполнения программы.

Идентификация типа

Для получения информации о типе объекта во время исполнения программы (run-time type identification — RTTI, раздел [**expr.typeid**] стандарта) в C++ используется оператор `typeid`. Оператор `typeid` принимает в качестве параметра имя типа или переменной и возвращает `const std::type_info`.

Класс `std::type_info` включает метод `name()`, возвращающий строку, характеризующую тип (не имя типа и не формат вывода). В частности, `typeid(int).name()` вернёт `"i"`, `typeid(double).name()` — `"d"`, а `typeid(long double).name()` — `"e"`. Составные типы характеризуются длинными многокомпонентными строками.

Размер объекта

Размер выделяемой под объект памяти можно узнать, используя оператор `sizeof`. Согласно стандарту C++ (раздел [**expr.sizeof**]), оператор `sizeof` возвращает количество байтов, используемое для представления операнда.

Размеры узких символьных типов `sizeof(char)`, `sizeof(signed char)` и `sizeof(unsigned char)` равны 1, для остальных стандартных типов определяется реализацией.

Дамп памяти

С точки зрения языка высокого уровня, указатели, хранящие адреса объектов различных типов, сами имеют разные типы. Это сделано для защиты от ошибок, чтобы не попытаться рассмотреть в памяти то, чего там нет (и не получить очень странное значение, например, нечаянно прочитав часть вещественного числа как целое) или не испортить соседние переменные, записывая объект большого размера в область, зарезервированную под меньший.

С точки зрения более низкого уровня, адреса объектов различных типов ничем не различаются, и программист сам должен помнить размер, структуру и назначение каждого объекта в памяти. Все адреса имеет один размер, соответствующий разрядности платформы, и, теоретически, любой адрес может быть преобразован к любому типу указателя.

На практике не любое преобразование указатель-указатель имеет смысл. Так как размер любого типа кратен размеру `char`, адрес любого объекта `x` может быть преобразован в указатель типа `char *`. Таким образом мы получим доступ к байтам, составляющим объект, как к массиву `char`'ов; размер этого массива — количество байтов в `x` — равен `sizeof(x)`.

Язык C++ позволяет преобразовать указатели на разные типы только с помощью самого наглого и не портируемого оператора преобразования — `reinterpret_cast`:

```
1 char *p = reinterpret_cast<char *>(&x);
```

В программировании на высоком уровне не рекомендуется использование `reinterpret_cast` вообще и преобразование типов указателей в частности, так как это небезопасно.

Низкоуровневое программирование небезопасно само по себе.

Тем не менее, преобразование адреса объекта в адрес цепочки байт, которая затем выводится в отладочный протокол — весьма эффективное средство исследования структуры этого объекта.

Вывод в поток

Для формирования файла-протокола можно воспользоваться потоками вывода. Ассоциировав в программе какой-либо файл с потоком типа `fstream`, мы получим возможность записи протокола непосредственно в этот файл. Выводя протокол в стандартный поток вывода (`cout`), мы сможем наблюдать протокол в консоли или сохранить его в файл, используя перенаправление стандартного потока вывода в командном интерпретаторе (в частности, `bash`):

```
1 $ program > /tmp/log.txt
```

(данная команда запускает программу `program` и направляет её стандартный вывод не в консоль, а в файл `/tmp/log.txt`). Второй способ более универсален, поэтому во всех примерах будем рассматривать стандартный поток вывода.

Таким образом, вывести в поток `cout` первый байт по адресу `p` в том, виде, который использован в окне Memory dump (две шестнадцатеричные цифры с ведущим нулём), можно следующим образом:

Листинг 7.12. Вывод первого байта по адресу p в шестнадцатеричном виде

```
1 unsigned char *p;
2 cout << hex << setfill('0') << setw(2) <<
      static_cast<unsigned>(*p);
```

используется тип `unsigned char`, чтобы расширение до `unsigned` гарантированно было беззнаковым, и выводимое значение поместилось в два знакоместа.

Адрес следующего элемента (с учётом того, что `p` — указатель на однобайтовый тип — следующего байта) равен `p+1` и так далее. Соответственно, зная адрес начала переменной, можно вывести в поток все составляющие её байты, сымитировав функциональность окна Memory dump.

Зная размер переменной (`sizeof(x)`), можно вывести на экран её побайтовое представление. Оно может не совпадать с шестнадцатеричным представлением из-за порядка байтов в словах. В шестнадцатеричном представлении цифры выводятся по-арабски, от старшей к младшей; побайтовый вывод показывает реальный

порядок байтов в памяти (на платформе x86 — от младшего к старшему), при этом цифры каждого байта выводятся от старшей к младшей.

7.7.2. Автоматизация отладочной печати

Всё, что они делают, вносится в книги.

Коран. 54.52

Для автоматизации отладочной печати лучше реализовать её в виде отдельной функции, чтобы упростить внесение изменений. Назовём эту функцию `MemoryDump()`. Пусть `MemoryDump()` получает в качестве аргумента исследуемый объект `x`, печатает данные о нём в стандартном потоке вывода и возвращает ничего (`void`).

Чтобы избежать приведения типа аргумента и, соответственно, искажения данных о нём, необходима отдельная реализация `MemoryDump()` для каждого возможного типа аргумента; при этом текст реализаций `MemoryDump()` для различных типов аргументов будет полностью совпадать. Для этого идеально подходит механизм **шаблонов (templates).**

Эта возможность C++ позволяет определить семейство функций, которые могут работать с различными типами данных. Так как нам нужно варьировать только тип аргумента, у шаблона будет один параметр — имя типа аргумента функции:

Листинг 7.13. Параметр шаблона — тип печатаемого значения

```
1 template<typename T>
2 void MemoryDump(T ...x)
3 {
4 ...
5 }
```

Для доступа к памяти, где реально находится объект, необходимо передать этой функций указатель или ссылку на него. С точки зрения низкого уровня указатель и ссылка — одно и то же; на уровне C++ передача по ссылке позволит использовать те же синтаксические конструкции, что и для исследования локальной переменной.

Листинг 7.14. Заголовок шаблона для печати дампа памяти

```
1 template<typename T>
2 void MemoryDump(T &x)
3 ...
```

Так как планируется не изменение, а только печать аргумента, правила хорошего тона требуют для него спецификатора `const` (соответственно, используемый в тексте `MemoryDump()` указатель `p` тоже должен быть константным). Получим

окончательный вариант шаблонной функции отладочной печати дампа памяти в виде листинга 7.15.

Листинг 7.15. Шаблон для печати дампа x

```
template<typename T>
void MemoryDump(const T &x)
{
    const unsigned char *p
        = reinterpret_cast<const unsigned char *>(&x);

    cout << "Type: " << typeid(x).name()
         << " Value: " << x << endl
         << "Size: " << sizeof(x) << endl
         << "Dump: " << hex << uppercase << setfill('0');

    for(size_t i = 0; i < sizeof(x); ++i)
    {
        cout << setw(2)<< static_cast<unsigned>(*(p+i)) << " ";
    }
    cout << dec << endl << endl;
}
```

Эта функция позволяет вывести в стандартный поток вывода байты любой переменной в том порядке, в котором они лежат в памяти. В частности, результатом следующего кода:

Листинг 7.16. Печать сведений о трёх переменных

```
int i = 1;
double d = 1;
long double ld = 1;

MemoryDump(i);
MemoryDump(d);
MemoryDump(ld);
```

будет:

Листинг 7.17. Значения, размеры и дамп переменных

```
Type: i Value: 1
Size: 4
Dump: 01 00 00 00

Type: d Value: 1
Size: 8
Dump: 00 00 00 00 00 00 F0 3F
```

```
 8
 9 Type: e Value: 1
10 Size: 12
11 Dump: 00 00 00 00 00 00 00 80 FF 3F 00 00
```

Для каждого такого вызова компилятор формирует отдельную функцию — реализацию шаблона `MemoryDump()` для конкретного типа аргумента. Такие реализации перегружают друг друга и имеют одно имя для C++; с точки зрения компоновщика разные реализации имеют разные имена, так как по-разному декорируются.

При вызове шаблонной функции `MemoryDump()` конкретная вызываемая реализация определяется типом передаваемого фактического параметра. Указывать реализацию явно (например, `MemoryDump<int>(i)`) здесь не только не нужно, но и вредно — если указанный тип реализации не совпадёт с настоящим типом передаваемого параметра, результат будет некорректен.

Для указателя данная функция выведет размер и представление в памяти самой переменной-указателя, а не тот фрагмент памяти, куда он указывает.

Если необходимо напечатать именно память, на которую указывает аргумент, необходимо модифицировать шаблонную функцию `MemoryDump()`. Получим листинг 7.18 (`CellCount` — количество ячеек типа `T` по адресу `px`).

Листинг 7.18. Шаблон для печати дампа памяти по адресу px

```
template<typename T>
void PointerMemoryDump(T *px, int CellCount)
{
    const unsigned char *p
        = reinterpret_cast<const unsigned char *>(px);
    size_t BytesCount = sizeof(*px)*CellCount;

    cout << "Type: " << typeid(px).name()
         << " Value: " << px << endl
         << "Size: " << sizeof(px) << endl
         << "Dump: " << hex << uppercase << setfill('0');

    for(size_t i = 0; i < BytesCount; ++i)
    {
        cout << setw(2)<< static_cast<unsigned>(*(p+i)) << " ";
    }
    cout << dec << endl << endl;
}
```

Тогда результатом выполнения листинга 7.19, печатающего сведения об указателе s и восьмибайтовом значении по этому указателю,

Листинг 7.19. Печать сведений об указателе и о значении

```
1 char *s = "abcdef";
2
3 MemoryDump(s);
4 PointerMemoryDump(s,8);
```

будет следующий вывод:

Листинг 7.20. Дамп памяти собственно указателя и значения по указателю

```
1 Type: Pc Value: abcdef
2 Size: 4
3 Dump: 08 96 04 08
4
5 Type: Pc Value: abcdef
6 Size: 4
7 Dump: 61 62 63 64 65 66 00 54
```

Таким образом, шаблонная функция `MemoryDump(s)` выводит данные об указателе `s`, а `PointerMemoryDump(s,8)` — о строке `s`, включающей семь узких символов (шесть латинских букв и завершающий строку нулевой символ). Видно, что, кроме семи байт строки, листинг 7.19 выводит ещё один, лишний, байт.

В отладочной печати, как и при изучении содержимого памяти при помощи инструментов интерактивной отладки, необходимо различать те переменные, которые содержат интересующее программиста значение и переменные-указатели, которые содержат адрес интересующего значения.

Контрольные вопросы

1. Как называется головная функция программы на C++?
2. Какие целые типы языка C++ вы знаете?
3. Какие вещественные типы языка C++ вы знаете?
4. Какие операторы преобразования типов C++ вы знаете?
5. Как записываются целые, вещественные, строковые литералы?
6. Как автоматизировать отладочную печать в C++?

Заключение

Усердный в службе не должен бояться своего незнанья;
ибо каждое новое дело он прочтёт.

К. П. Прутков. Плоды раздумья. Мысли и афоризмы

В данном пособии описана только малая часть безграничных возможностей Ассемблера.

Многие возможности низкоуровневого программирования доступны только на уровне операционной системы и тесно связаны с её архитектурой и особенностями. Соответственно, дальнейшее изучение архитектуры и системы команд x86, а также программирования на языке Ассемблера, неизбежно сопряжено с изучением операционных систем.

Прикладное программирование на ассемблере широко применяется в задачах криптографии. При программной реализации большинства современных алгоритмов использование только команд языков высокого уровня, позволяющих программисту абстрагироваться от конкретного представления данных, неэффективно. Ассемблер, напротив, легко позволяет рассмотреть блок данных одновременно как число и битовую строку. Кроме того, разработчики современных процессоров постоянно вводят новые команды, облегчающие реализацию популярных асимметричных схем.

Приложение А. Регламент курса

Так как в процессе изучения ОТИК выяснилось, что некоторые студенты, успешно сдавшие ОЭВМ и Асм, не знают, что такое бит — в 2024 экзамен либо зачёт будет **обязательным.**

Все будут мне отвечать на базовые вопросы: что такое бит, сколько у него состояний, какое максимальное число можно записать в k бит и т. п. Ответившие с $\geqslant 50$ баллами в семестре после этого получат оценку по баллам, с < 50 — отвечают ещё и по билету.

Соответственно, регламент, описанный ниже, не во всём будет актуален в 2024 году. Какие конкретно будут изменения — станет понятно не раньше мая.

А. И. Кононова

В данном разделе даны базовые положения регламента курса ОЭВМ [и Асм]. **Все особые случаи обсуждаются с преподавателем индивидуально,** решение в каждом случае принимается отдельно и только **после воплощения соответствующего случая в реальность.**

Итоговая оценка

Оценка формируется ОРИОКС автоматически по общей сумме баллов в момент закрытия ведомости: отлично (5) от 86 баллов, хорошо (4) от 70, удовлетворительно (3) от 50 баллов. При сумме, меньшей 50, в ведомости формируется оценка «неудовлетворительно» (2). Поля ОРИОКС «Текущая сумма баллов» и «Текущая оценка» в течение семестра неадекватны; отличаться могут как в бóльшую, так и в меньшую сторону.

Общая сумма баллов, рассчитываемая ОРИОКС и используемая для формирования оценки, *неполна* (включает только сумму обязательных КМ), если *в графе хотя бы одного обязательного КМ до текущей недели стоит «0» или «н».* Для корректного прогноза на 12–16 неделях студентам с суммой баллов, близкой к 50, за несданные обязательные КМ (кроме графы «Итог») выставляется 0,1 балла; такое КМ можно сдать и повысить оценку.

В момент закрытия ведомости общая сумма баллов корректна только в том случае, если все обязательные КМ, включая графу «Итог», имеют ненулевые (не «0» и не «н») значения. В последний день сессии формируются дополнительные ведомости: до этого момента КМ можно досдать, а баллы — повысить.

Неудовлетворительная оценка в конце сессии = долг.

Лабораторные работы

Основной путь прохождения курса — выполнение лабораторных работ (регламент лабораторных работ подробно описан в приложении Б). Если к сессии будут выполнены не все лабораторные работы, но общая сумма баллов не менее 50, а ответы на базовые вопросы корректны, курс считается успешно изученным.

Экзамен

К экзамену допускаются все (возможно повышение оценки с 0 до 3).

Корректный ответ на базовые вопросы — балл 1 в графе «Итог», после чего формируемая автоматически оценка учитывает все набранные в семестре баллы. **Ответ по билету оценивается не на баллы, а на оценку от 2 до 5.** Если полученная на экзамене оценка выше оценки по баллам — необходимое количество баллов добавляется в графы «Итог» и «Бонус (прочее)». Если оценка на экзамене равна оценке по баллам — в ОРИОКС ничего не меняется. Если оценка на экзамене меньше — в зависимости от ситуации возможен как поиск ошибки в ОРИОКС, так и сохранение текущих баллов. **Зачтение статей из Интернета и даже текста лекций ответом на вопрос не считается; оценивается как «неудовлетворительно».** Говорите своими словами. Поясняйте сказанное на примерах.

Порядок сдачи диф. зачёта для соответствующих групп аналогичен сдаче экзамена для ПИН-21-24. Возможность досрочной сдачи обсудим не раньше 14 недели.

Курсовая работа

Вместо лабораторных работ по согласованию с преподавателем может быть выполнена одна курсовая работа (по результатам выставляется оценка за весь курс).

До 3 недели включительно необходимо утвердить у преподавателя задание курсовой работы (маркируется значением 1 в графе «Курсовая» и оценками «0,1» за лабораторные работы) и индивидуальный график контрольных точек М1–М4; изменение контрольных точек в процессе работы допускается, но на каждые 4 недели должно приходиться не менее одной. Замечания, полученные при демонстрации очередного этапа работы, должны быть устранены в течение ближайших 1-2 недель (а не к следующей контрольной точке); **контрольная точка считается пройденной только после устранения всех замечаний.** Прохождение контрольной точки отмечается в журнале и маркируется 10 баллами в графе «Курсовая» (без оценки качества).

Оценивание курсовой происходит во время защиты (дата предлагается командой, но не позднее 16 недели); баллы-маркеры в графе «Курсовая» заменяются на

баллы оценки (не суммируются!). По результатам защиты выставляется **итоговая оценка за весь курс** (баллы в графе «Курсовая» подгоняются под результат).

Максимальная оценка при этом зависит от количества пропущенных контрольных точек: если пропущены все М1–М4 — оценка не выше «удовлетворительно», если две из четырёх — не выше «хорошо». Если вы считаете, что можете выполнить задание курсовой за две недели без дополнительных консультаций — сделайте его до 4 недели и получите баллы в ОРИОКС и оценку в зачётку без снижения.

Если команда или кто-то из её участников отказывается от курсовой работы и выполняет лабораторные — баллы-маркеры пройденных контрольных точек остаются для компенсации пропущенных занятий; если отказ был до 4 недели — максимальный балл за Л1–Л2 не снижается до 8 недели.

Сдавать контрольные точки и курсовую необходимо тому же преподавателю, кто дал задание (лектору или преподавателю лабораторных работ). Преподаватель лабораторных имеет право выдавать задания курсовых, но не обязан это делать.

Общие направления курсовых (выбирается студентом) — прямая или обратная разработка.

1. *Прямая разработка* — программирование на ассемблере: конкретное задание согласовывается с преподавателем на занятиях или по `illinc@mail.ru` (в частности, это может быть разработка библиотеки, реализующей на ассемблере заданный численный метод).

   Приблизительный состав контрольных точек для прямой разработки:
   - М1 (1–5 недели) — «макет» на C/C++, без ассемблера, выполняющий поставленное задание;
   - М2 (5–8 недели), М3 (9–12 недели), М4 (13–16 недели) — переписывание функций на ассемблер под выбранную платформу и отладка.
2. *Обратная разработка* — исследование исполняемых файлов: файлы и правила `https://github.com/readysloth/ASM-Crackmes-exe`

Прочие бонусные и штрафные баллы

Баллы, соответствующие решаемым на лекциях задачам, выставляются в графу «Зд (лек)». Посещаемость поточных лекций не оценивается.

Бонусные баллы за достижения, не описанные в данном пособии, выставляются в графы:

- «бонус (л/р)», если баллы назначает преподаватель лабораторных работ;
- «бонус (прочее)», если лектор;

штрафные баллы, не описанные в пособии, аналогично уменьшают эти же графы либо базовую оценку лабораторной работы.

КМ «Натяжка»

Баллы, не соответствующие никаким реальным достижениям студента, но необходимые для корректной работы ОРИОКС, выставляются в графу «Натяжка». Если студент с ненулевым КМ «Натяжка» что-либо досдаёт — КМ «Натяжка» обнуляется (при необходимости — пересчитывается после обнуления).

«Чего можно на троечку сдать» на зачётной неделе или в сессию

Выберите любой один из следующих вариантов:

- выполнить **контрольную работу** по целочисленным кодам и операциям в ЭВМ (КР) + **лабораторную работу Л1** (итоговая оценка «неуд.»/«3 с натяжкой»);
- получить и выполнить индивидуальное задание (от 0 до 100 баллов);
- выполнить лабораторные работы Л4–Л6 (оцениваются совокупно, итоговая оценка «неуд.»/«удовл.», в исключительных случаях может быть «хорошо»);
- сдать экзамен.

Крайне нежелательно сдавать лабораторные как в семестре:
а) сумма без бонусов в любом случае не превысит 60 баллов (таблица ЛРЕГЛ.1);
б) если **хотя бы в одной работе** есть признаки несамостоятельного выполнения — бонусные задания не засчитываются **для всех** $\Longrightarrow$ итоговая оценка «неуд.»/«удовл.»

Долги и пересдачи

Неудовлетворительную оценку можно пересдать (закрыть долг) в течение семестра после официальной даты экзамена.

1. До конца соответствующей сессии — новая оценка попадает в дополнительную ведомость, формально долг не образуется.
2. **До конца следующего семестра** — оформляется **направление** на пересдачу. Закрывать долг желательно **до** официальной даты пересдачи, указанной в ОРИОКС: найти преподавателя и получить у него задание.

Начиная со второго после экзамена семестра (следующая весна и позже), согласно новым указаниям проректора по учебной работе, направление не может быть оформлено без письменного разрешения ответственного кафедры.

Для закрытия долга необходимо:

- либо (на 3) написать КР и, при технической возможности, программу для проверки своих ответов (dec/hex-вывод, простейшие операции);
- либо (на 3/4/5) получить и выполнить индивидуальное задание.

Должник не имеет права сдавать тот же набор лабораторных работ, что и его однокурсники ранее, если только преподаватель не даст ему такое задание. Демонстрация должником полного комплекта лабораторных работ чужого авторства будет в лучшем случае оцениваться на 0 баллов, а в худшем — как неуважение к преподавателю и намеренная трата его времени.

Замечания и дополнения

Замечания и дополнения к данному документу можно отправить в письменном виде по адресу `https://gitlab.com/illinc/gnu-asm/issues`.

Принятое замечание/дополнение приносит первому приславшему его студенту от 1 до 8 бонусных баллов.

Обновление пособия

В течение семестра могут уточняться формулировки заданий и регламента лабораторных работ (если исходные вызывают недопонимание) и появляться новые бонусные задания. По необходимости дополняется/уточняется теория (главы 1–7).

Качественное обновление заданий и регламента лабораторных работ происходит только между семестрами; поэтому выполнять задания по версии пособия начала 2024 года можно до лета 2024 года. Но лучше всё-таки периодически скачивать актуальный файл `https://gitlab.com/illinc/gnu-asm/-/raw/main/gnu-asm-theory-labs.pdf?inline=false`.

Приложение Б. Лабораторный практикум по организации ЭВМ и GNU Assembler

Требования к выполнению лабораторных работ

В данном разделе описаны базовые требования к лабораторным работам, а также основные правила их оценивания. Преподаватель лабораторных работ может вводить **дополнительные как бонусные, так и штрафные баллы** по своему усмотрению.

Компилятор, IDE, отладчик

Программы для всех заданий необходимо собирать **компилятором из коллекции GCC** (для C++ — компилятор `g++`, для чистого C — `gcc`; для проектов, содержащих только ассемблер, подходят оба). GCC для ОС MS Windows — MinGW.

Для разработки могут быть использованы либо текстовый редактор и консольные инструменты сборки и отладки, либо любая IDE, поддерживающая GCC. Для отладки используется GNU Debugger (GDB), консольный либо встроенный в IDE.

Если студент хочет использовать IDE — рекомендуется свободная и бесплатная кроссплатформенная среда Qt Creator (доступна в репозиториях большинства дистрибутивов GNU/Linux; установочный файл для ОС MS Windows в настоящее время недоступен с российских IP); также возможно использование сред TheIDE (Ultimate++), Code::Blocks и др. Среда Microsoft Visual Studio не поддерживает других компиляторов, кроме Microsoft, и других ОС, кроме MS Windows, поэтому не может быть использована там, где иное не сказано явно.

Для сборки и запуска программ на удалённом сервере используются инструменты, предоставляемые этим сервером, в частности:

- `https://www.jdoodle.com/compile-assembler-gcc-online/` (ОС GNU/Linux 64) выполняет сборку и запуск исполняемого файла;
- `https://www.onlinegdb.com/online_c++_compiler` (ОС GNU/Linux 64) выполняет сборку и запуск; возможна отладка и просмотр регистров;
- `https://godbolt.org/` (ОС GNU/Linux 64) останавливается на этапе компиляции; сборка и запуск исполняемого файла в настоящее время не работают.

Группе НБ-31 можно использовать любые средства разработки на C/C++, так как у них нет обязательных лабораторных работ с элементами ассемблера.

Язык программирования

Задания всех лабораторных работ, **если не указан язык, выполняются на ассемблере,** в виде вставок в программу на языке C/C++ либо отдельных модулей.

Программы на чистом C++ (без ассемблерных вставок) должны собираться на любой платформе любым компилятором (недопустимо использование платформозависимых элементов).

Отчёт и оформление

При выполнении лабораторной работы непосредственно перед защитой отчёт оформлять не обязательно; достаточно демонстрации результатов и устных комментариев.

В ином случае по результатам выполнения работы оформляется отчёт в формате plain text, LaTeX, OpenDocument или PDF, а также программный код. Заголовок отчёта должен включать имя группы и ФИО авторов, а также тему работы. Отчёт должен содержать для каждого задания:

- номер и текст задания;
- номер и текст варианта (если есть);
- **операционную систему и разрядность,** для которых предназначена программа; если для всех заданий эти данные совпадают — можно указать это один раз в начале отчёта;
- ключевые фрагменты программного кода;
- результат выполнения задания: результаты измерений с комментариями и ссылки на программы.

Если отчёт оформлен не как комментарии к коду, полный текст программ копировать в отчёт не нужно (текст программ предоставляется отдельно).

Отчёт в формате plain text может быть совмещён с программным кодом (помещён в комментарии соответствующих модулей).

В начале каждого файла с исходным кодом должен находиться *комментарий*, содержащий краткое описание модуля. Описание модуля с головной функцией должно включать *тему лабораторной работы.*

Перед реализацией каждого задания должен находиться комментарий, содержащий *номер задания и номер варианта задания* в формате **Л1.з3, вариант 2;** при возможности — полный текст задания и соответствующего варианта.

Командная работа

Лабораторная работа выполняется совместно командой (двумя сидящими рядом студентами, при желании — одним или тремя). Команда из трёх человек выполняет дополнительные задания в некоторых лабораторных работах. Команды из четырёх и более студентов не допускаются на ВЦ МИЭТ (если занятия проходят вне ВЦ — на усмотрение преподавателя).

Команда, независимо от количества участников, выполняет **один вариант задания, соответствующий номеру команды** и оформляет один отчёт. Номер

команды в группе должен быть уникален; в спорных случаях назначается преподавателем. Каждый из соавторов должен уметь объяснить все результаты лабораторной работы и модифицировать свою часть кода.

Если команда может придти защищать лабораторную работу в полном составе — это необходимо сделать. Но если у кого-то нет возможности придти — лучше сдать работу в неполном составе, но вовремя. При этом все участники команды получают одну оценку; защищаться отдельно отсутствующему соавтору не нужно (если его отсутствие не становится систематическим). Неполная тройка всё равно выполняет задания для троек.

Команды могут разделяться на несколько (с уникальными номерами) или объединяться. Но если какая-то команда постоянно то делится, то объединяется синхронно с наличием/отсутствием заданий для троек — она получает штраф -2 балла к каждой уже сданной, сдаваемой или будущей лабораторной работе.

Оценивание

Работа, выполненная не полностью или с ошибками, может быть зачтена с оценкой ниже максимальной $\beta_{\max}$ (значения $\beta_{\max}$ для различных групп см. ниже; штраф за одно пропущенное обязательное задание см. в шапке лабораторной работы).

Работа с явными признаками несамостоятельного выполнения (несоответствие варианту, несоответствие программы заявленным ОС и разрядности, использование заданий предыдущего года и ранее, дословное совпадение отчёта, неумение его пояснить и т. п.) **может быть зачтена только после выполнения дополнительного задания** (при попытке сдать одновременно серию таких работ может быть дано одно задание объединённой тематики) **и не более чем на** $\beta_{\text{п}} \approx \frac{\beta_{\max}}{2}$ баллов (если с учётом опоздания максимум составляет менее $\beta_{\text{п}}$ — не более максимума). **Бонусные задания такой работы не засчитываются.** Таким образом, фактически в этом случае оценивается только дополнительное задание.

Необязательные для группы лабораторные работы с признаками несамостоятельного выполнения не могут быть зачтены в принципе.

Не зачтённые лабораторные работы помечаются в ОРИОКС литерой «н».

Снижение по времени

Из оценки лабораторной работы, сданной с опозданием более чем на две недели без уважительной причины, вычитается величина опоздания (таблица ЛРЕГЛ.1).

Если лабораторные работы выполняются не по порядку, но при этом на каждом занятии (кроме, возможно, первого) выполняется и сдаётся какая-либо работа, то они оцениваются как сданные без опоздания.

График снижения оценок за базовую часть лабораторных работ

Таблица ЛРЕГЛ.1

ОЭВМ и Асм: группы ПИН-21–24											
Неделя	max Л1	max Л2	max Л3	max Л4	max Л5	max Л6	max Л7	max Л8	max Л9	max ЛА	max ЛВ
1, 2	9										
3, 4	9	9	9								
5, 6	8	9	9	9							
7, 8	7	8	8	9	9	9					
9, 10	6	7	7	8	9	9	9				
11, 12	5	6	6	7	8	8	9	9	9		
13, 14	4	5	5	6	7	7	8	9	9	9	
15, 16	3	4	4	5	6	6	7	8	8	9	9
17, 18	2	3	3	4	5	5	6	7	7	8	9
сессия (досд.)	2	2	3	4	4	5	6	6	6	6	6
сессия (с нуля)	н	н	н	50 в совокупности			н	н	н	н	н

ОЭВМ: группы ПМ-31–32								
Неделя	max (**ЛС**)	max (**Л1**)	max (**Л2**)	max (**Л3**)	max (**Л4**)	max (**Л5**)	max (**Л6**)	max (**Л7**)
1, 2	12							
3, 4	12	12						
5, 6	11	12	12					
7, 8	10	11	12	12				
9, 10	9	10	11	12	12			
11, 12	8	9	10	11	12	12		
13, 14	7	8	9	10	11	12	12	
15, 16	6	7	8	9	10	11	12	12
17, 18	5	6	7	8	9	10	11	12
сессия (досд.)	5	6	7	8	8	8	8	8
ОЭВМ: группы ПИН-35–36 — аналогично ПМ-31–32 (без ЛС, зато с Л8)								
Неделя	max (**Л1**)	max (**Л2**)	max (**Л3**)	max (**Л4**)	max (**Л5**)	max (**Л6**)	max (**Л7**)	max (**Л8**)

ОЭВМ: группа НБ-31		
Неделя	max (**ЛС**)	max (**Л3**)
1, 2, 3, 4, 5, 6	30	
7, 8	28	
9, 10	26	
11, 12	24	30
13, 14	22	28
15, 16	20	26
17, 18	18	24
сессия	40 в совокупности	

Лабораторные работы на 17 неделе и позже

Лабораторные занятия по расписанию группы продолжаются с 1 по 16 неделю.

На 17 (зачётной) неделе и позже преподаватель может принимать лабораторные работы сообразно своему графику консультаций (может отличаться от расписания 1–16 недель); но имеет право и не принимать — если сумма баллов студента уже соответствует продемонстрированным им знаниям.

Особенности групп

График снижения оценок за базовую часть лабораторных работ показан в таблице ЛРЕГЛ.1. Максимально возможная оценка лабораторной работы $\beta_{\max}$ и максимальная оценка для работы с признаками несамостоятельного выполнения $\beta_{\text{п}}$: ПИН-21–24 — $\beta_{\max} = 9$, $\beta_{\text{п}} = 4$; ПМ-31–32 — $\beta_{\max} = 12$, $\beta_{\text{п}} = 6$; НБ-31 — $\beta_{\max} = 30$, $\beta_{\text{п}} = 15$.

Из-за большого количества КМ групп ПИН-21–24 графы «Зд (лек)» и «КР» могут быть объединены с «бонус (прочее)», а «Курсовая» — с «бонус (л/р)».

Для ПМ-31–32: если кто-то начинает сдавать лабораторные «с нуля» в сессию — набор лабораторных работ ЛС и Л4–Л6 (либо определяемый преподавателем индивидуально набор) оценивается в совокупности на оценку «неуд.»/«удовл.» (от 0 до 50 баллов).

Примечание для студентов, изучавших по индивидуальному плану ОТИК раньше, чем ОЭВМ [и Асм], что противоречит рабочей программе

В рамках курса ОЭВМ [и Асм], в отличие от ОТИК, рассматриваются коды, которые используются в ЭВМ по умолчанию:

- все рассматриваемые структуры данных — стандартные;
- все преобразования реализованы на уровне архитектуры команд командами из набора x86/x86-64, а на уровне ЯВУ — стандартными средствами языка C/C++.

Если вам кажется, что нужно писать сложную процедуру перекодирования откуда-то куда-то — вы неправильно поняли задание! Уточните у преподавателя.

Лабораторная работа 1 (0001 = 1)
Ввод-вывод при помощи libc

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: изучить размеры стандартных типов C/C++ на выбранной платформе; сопоставить размеры стандартных типов C/C++ на различных платформах; научиться использовать функции ввода-вывода libc.

Все задания данной лабораторной работы выполняются на чистом C/C++, без использования ассемблера. Как и для всего курса — если иное не указано явно, компилятор должен быть из коллекции GCC (среда Microsoft Visual Studio недопустима), подробнее в разделе «Компилятор, IDE, отладчик» регламента.

Штраф за одно пропущенное обязательное задание:
-1 балл, если лабораторная работа сдаётся на первом занятии;
-2 балла — если на втором и последующих.
Дополнительный бонус за сдачу на первом занятии: $+2$ балла.

Задание на лабораторную работу

Задание Л1.з1. Разработайте программу, выводящую на стандартный вывод группу, номер и состав команды при помощи функции $puts()$ библиотеки libc.

При работе в ОС MS Windows возможны проблемы с кодировкой русского языка. Если они возникли — используйте транслит или любые доступные вам способы настройки.

Задание Л1.з2. Укажите для платформы, где выполняется работа:
- ОС и разрядность ОС;
- компилятор (должен относиться к коллекции GCC/MinGW) и его версию;
- разрядность сборки (собираемая программа может работать в 32-битном режиме даже под 64-битной ОС — в режиме совместимости);
- архитектуру процессора, назначение платформы.

Компьютер с процессором x86/x86-64 под управлением GNU/Linux, BSD (в том числе Mac OS X) или MS Windows — платформа общего назначения.

При помощи оператора `sizeof` языка C/C++ выясните, сколько байтов занимают на выбранной платформе переменные следующих типов: `char, signed char, unsigned char, char*, bool, wchar_t, short, int, long, long long, float, double, long double, size_t, ptrdiff_t, void*`.

Штраф -2 балла, если выводятся только числа, без пояснений, и непонятно, где размер какого типа.

Бонус $+2$ балла, если при помощи макроса пояснения выводятся так, что в коде каждое имя типа в Л1.з2 встречается единожды.

Задание Л1.з3. Бонус +2 балла. Выполните измерения согласно заданию Л1.з2 на платформах, доступных на ВЦ (таблица Л1.1).

Платформы для измерения

Таблица Л1.1

Процессор	ОС	Компилятор	разрядность сборки
x86-64	GNU/Linux 64	GCC	64
x86-64	GNU/Linux 64	clang	64
x86-64	GNU/Linux 64	Intel	64
x86-64	MS Windows 64	GCC (MinGW)	64
x86-64	MS Windows 64	Microsoft	64
x86-64	MS Windows 64	Microsoft	32

Связка GNU/Linux 64 + GCC 64 широко используется в онлайн-компиляторах. На `godbolt.org` (ОС GNU/Linux 64) доступны сборка компиляторами GCC 64, clang 64 и ICC (Intel C++ Compiler) 64 с возможностью запуска; а также сборка без запуска для множества других компиляторов, в том числе для не-x86 процессоров.

ОС MS Windows 64 и компиляторы GCC и Microsoft доступны на ВЦ локально (для дистанционных занятий — на терминале ВЦ).

Не возбраняется использование инструментов, установленных дома.

Штраф −2 балла за платформу таблицы Л1.1, если в аудитории она доступна[1], а данных по ней нет.

Бонус +2 балла за платформу. При подготовке к работе выполните измерения на платформе, отсутствующей в таблице Л1.1 (укажите ОС, компилятор, режим (разрядность) сборки, архитектуру процессора, назначение платформы — без этих сведений баллы не начисляются).

Обратите внимание на размеры целочисленных типов и типов с плавающей запятой. Какие из них **на всех платформах таблицы Л1.1** имеют разрядность 16, 32, 64 бита, учитывая, что байт x86/x86-64 — октет (8 бит)?

Задание Л1.з4. Разработайте программу на языке C/C++, создающую массивы из $N = 5$ чисел и инициализирующую их N одинаковыми значениями x:

- Ms из 16-битных целых чисел ($x =$ `0xFADE`);
- Ml из 32-битных целых чисел ($x =$ `0x ADE1 A1DA`);
- Mq из 64-битных целых чисел ($x =$ `0x C1A5 51F1 AB1E`);
- Mfs из 32-битных чисел с плавающей запятой (x из таблицы Л1.2);
- Mfl из 64-битных чисел с плавающей запятой (x из таблицы Л1.2).

Тип элементов каждого из массивов определите по результатам заданий Л1.з2/Л1.з3.

[1] если платформа недоступна в лабораторной аудитории либо её убрали с ВЦ вообще (в 2021 году с ВЦ исчезла связка MS Windows 64 + GCC 32), штраф не начисляется

Варианты начальных значений элементов с плавающей запятой

Таблица Л1.2

$(№ - 1)\%2 + 1$	**Вариант**
1	$x = \frac{5}{3}$
2	$x = -\frac{8}{5}$

Не используйте тип *long* на 32/64-битных платформах, так как его размер нестабилен. На 16-битной платформе (если найдёте такую) $long$ может быть использован как 32-битный тип.

Не используйте типы фиксированной разрядности $intX\_t/uintX\_t$, так как модификаторы размера форматных полей $printf()/scanf()$ определены не для них, а для $short$, $long\ long$ и $double$.

Выведите каждый из массивов на экран при помощи функции libc $printf()$:

- каждый из целочисленных массивов дважды — как в знаковом десятичном (формат d), так и в шестнадцатеричном (X) виде, чтобы убедиться, что короткие значения не расширены до 32 бит, а длинные — не усечены; в шестнадцатеричном виде дополняйте код ведущими нулями до необходимого количества цифр (то есть: для 16-битных $short$ используйте $04hX$, для 32-битных на 32/64-битных платформах int — $08X$, для 64-битных на 32/64-битных платформах $long\ long$ — $016llX$);
- каждый из массивов с плавающей запятой также выведите дважды — с двумя знаками после десятичной запятой (формат f: для $float$ используйте $.2f$, для $double$ — $.2lf$) и в экспоненциальной форме (формат e: e и le).

Обратите внимание, что для типов, отличных от $int/unsigned/float$, необходимо указывать размер при помощи модификатора перед форматом ввода/вывода.

Штраф -1 балл, если вместо именованной константы N здесь и/или позже используется литерал 5.

Бонус $+1$ балл, если вывод массива в двух формах описан как функция и в последующих заданиях используется вызов этой функции, а не копирование и вставка; $+2$ **балла,** если эта функция описана как единый для всех массивов шаблон и принимает тип как параметр шаблона, а адрес начала M, длину N и форматы с модификатором размера как параметры функции; $+3$ **балла,** если вывод описан как единый для всех массивов макрос с соответствующими параметрами.

Задание Л1.з5. Для одного из массивов M (по варианту согласно таблице Л1.3) выведите на экран *адреса:*

Варианты массива M

Таблица Л1.3

$(№ - 1)\%5 + 1$	**Вариант**
1	Ms
2	Ml
3	Mq
4	Mfs
5	Mfl

– начала массива — M;
– начального (нулевого) элемента массива — $\&(M[0])$;
– следующего (с индексом 1) элемента массива — $\&(M[1])$;

при помощи функции libc $printf()$ как указатели (формат p). Сравните полученные значения между собой и с размером элемента массива M.

Задание Л1.з6. Для каждого массива M из пяти созданных введите с клавиатуры новое значение элемента $M[i]$, $i = 2$ при помощи функции libc $scanf()$.

Проанализировав возвращённое $scanf()$ значение, определите корректность ввода; при необходимости отобразите сообщение об ошибке при помощи функции libc $puts()$. Очистка буфера после некорректного ввода во всех заданиях данной лабораторной работы необязательна.

Выведите массивы на экран до и после ввода, каждый раз — в обеих формах, описанных в Л1.з4; убедитесь, что элемент $M[i]$ приобрёл ожидаемое значение, а другие элементы массива не изменились (если изменились — проверьте, верно ли вы указали модификатор размера).

В данном задании необходимо передать функции $scanf()$ адрес $M[i]$, а не промежуточной переменной — иначе нет смысла контролировать значение соседних элементов массива. **Штраф −2 балла,** если используется промежуточная переменная для ввода-вывода.

Задание Л1.з7. Бонус +1 балл. Если поддерживается модификатор размера hh, выполните задания Л1.з4 и Л1.з6 также для массива Mb из N 8-битных целых чисел (`0xED`).

Проверяйте перед защитой, действительно ли hh поддерживается! Если некорректность ввода/вывода выяснится в процессе защиты, задание не засчитывается.

Обходной способ ввода-вывода байта (с использованием либо потоков, либо $printf()/scanf()$) может быть оценен на +1 балл независимо от Л1.з7, но вы-

полнением Л1.з7 не является, так как неизбежно использование промежуточных переменных.

Задание Л1.з8. Бонус +1 балл. Для одного из массивов M (по варианту согласно таблице Л1.3) введите с клавиатуры новое значение всех пяти элементов при помощи одного вызова функции libc $scanf()$.

Проанализировав возвращённое $scanf()$ значение, определите корректность ввода; при необходимости отобразите сообщение о количестве введённых и не введённых элементов.

Выведите массив на экран до и после ввода; убедитесь, что количество изменившихся элементов соответствует ожиданиям.

Задание Л1.з9. Бонус +2 балла для пар, обязательное для троек. Введите с клавиатуры (каждую строку — одним вызовом $scanf()$):

а) слово (строку без пробелов) $s1$ (формат s без модификаторов);

б) слово $s2$ таким образом, чтобы принимающий его буфер гарантированно не переполнился: если буфер длины k — вводить не более $k-1$ символов (ширина поля ввода задаётся аналогично ширине поля вывода);

в) строку, возможно, содержащую пробелы $s3$ (формат `[]` — регулярное выражение Perl).

Выведите на экран при помощи функций libc строки «***$s1$***», «***$s2$***», «***$s3$***» (между звёздочками должна быть введённые строки, а не литералы s1-s3) и убедитесь, что ввод корректен.

Л1.1. Дополнительные бонусные и штрафные баллы

−3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л1.2. Ссылки на теоретические сведения

7.6.2. Ввод-вывод с помощью libc

Л1.3. Вопросы

1. Какие функции libc используются для форматированного ввода/вывода?
2. Как задаётся формат ввода/вывода для $scanf()/printf()$?
3. Как задаётся размер вводимых/выводимых чисел (а для строк — размер символа $char/wchar\_t$) для $scanf()/printf()$?

Лабораторная работа 2 (0010 = 2)
Представление данных в ЭВМ

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: изучить форматы представления чисел на примере выбранной платформы.

Все задания данной лабораторной работы выполняются на чистом C/C++, без использования ассемблера. Использование вывода в потоки (доступен только в C++) не штрафуется, но для подготовки к работе на ассемблере рекомендуется вывод с помощью рассмотренной в Л1 функции $printf()$ (библиотека libc доступна в C/C++ и GNU Assembler).

Штраф за одно пропущенное обязательное задание -1 балл.

Задание на лабораторную работу

Задание Л2.з1. Разработайте функцию void $viewPointer(\text{void } *p)$, которая принимает нетипизированный указатель p, преобразует его в типизированные:

а) `char *p1 = reinterpret_cast<char *>(p);`
б) `unsigned short *p2 = reinterpret_cast<unsigned short *>(p);`
в) `double *p3 = reinterpret_cast<double *>(p);`

и печатает $p, p1, p2, p3$ (не значения по этим адресам, а сами адреса). Убедитесь, что $p, p1, p2, p3$ — один и тот же адрес, то есть что оператор `reinterpret_cast` не меняет преобразуемого указателя и, следовательно, может быть использован для интерпретации одной и той же области памяти как значений различных типов.

Дополните $viewPointer()$ печатью смежных с p адресов: $p1 + 1, p2 + 1, p3 + 1$. Сопоставьте разницу между p_i и $p_i + 1$ в байтах для типизированного указателя $T\ *p_i$ с размером типа T. Проверьте, позволяют ли текущие настройки компилятора рассчитать $p + 1$. Если да — какова разница между p и $p + 1$ в байтах?

При выводе *в поток* указателя $p1$ (на однобайтовый целый тип) результат отличается от $p, p2, p3$ — так как в C/C++ не определён строковый тип, вместо строк используются массивы однобайтовых целых и основанные на них классы. Соответственно, оператор << для указателей на типы $char/unsigned\,char/int8\_t/uint8\_t$ перегружен и печатает не адрес, а значения байтов в символьной форме, начиная с указанного адреса и до ближайшего нулевого байта. Для вывода такого указателя как адреса его надо преобразовать `reinterpret_cast` к нетипизированному void $*$. Так как в Л2.з1 `reinterpret_cast<void *>(p1)` — это p, в поток имеет смысл выводить: $p, p2, p3$ и `reinterpret_cast<void *>(p1+1)`, $p2 + 1, p3 + 1$.

При выводе с помощью $printf()$ формат вывода определяется не типом аргумента, а форматной строкой; в формате p (вывод целого числа как адреса) можно вывести все указатели: $p, p1, p2, p3$ и $p1 + 1, p2 + 1, p3 + 1$.

Задание Л2.з2. Разработайте функцию void $printPointer(\text{void } *p)$, которая принимает нетипизированный указатель p, преобразует его в типизированные $p1, p2, p3$ аналогично $viewPointer()$ и печатает значения соответствующих типов по адресу p: $*p1, *p2, *p3$. Можно ли рассчитать (и, соответственно, напечатать) $*p$? Дополните $printPointer()$ печатью значений по смежным с p адресам: $*(p1+1), *(p2+1), *(p3+1)$.

Все целые числа выводите в шестнадцатеричном виде. Проверьте работу функции $printPointer()$ на значениях `0x1122334455667788` ($long\ long$), `"0123456789abcdef"` ($char[]$).

При выводе *в поток* режим вывода целых чисел переключается манипуляторами $hex/dec/oct$ (или методом $setf()$ с одноимёнными флагами, или методом $setbase()$, принимающим аргументы 16, 10, 8); режим вывода действует на все целые числа до его смены. Так, для вывода всех в шестнадцатеричном виде — в начале $main()$ напечатайте манипулятор hex. На вывод чисел с плавающей запятой манипуляторы hex, oct, dec никакого влияния не оказывают.

При выводе с помощью $printf()$ используйте формат вывода X с соответствующим модификатором размера перед X.

Задание Л2.з3. Разработайте функцию void $printDump(\text{void } *p, \text{size\_t } N)$, которая принимает нетипизированный указатель p, преобразует его в типизированный указатель на байт $unsigned\ char * p1$ и печатает шестнадцатеричные значения N байтов, начиная с этого адреса: $*p1, *(p1+1), \ldots *\Big(p1+(N-1)\Big)$ — шестнадцатеричный дамп памяти. Каждый байт должен выводиться в виде двух шестнадцатеричных цифр; байты разделяются пробелом.

С помощью $printDump()$ определите и выпишите в отчёт, как хранятся в памяти компьютера в программе на C/C++:

- целое число x (типа int; таблица Л2.1); по результату исследования определите порядок следования байтов в словах для вашего процессора:
  а) прямой (младший байт по младшему адресу, порядок Intel, Little-Endian, от младшего к старшему);
  б) обратный (младший байт по старшему адресу, порядок Motorola, Big-Endian, от старшего к младшему);
- массив из трёх целых чисел (статический или динамический, но не высокоуровневый контейнер) с элементами x, y, z;
- число с плавающей запятой y (типа $double$; таблица Л2.1).

При выводе *в поток*: однобайтовые целочисленные переменные (не только $char$ / $unsigned\ char$, но часто и $int8\_t$ / $uint8\_t$) выводятся в поток *в виде символа,* код которого равен значению переменной (независимо от манипуляторов $hex/oct/dec$). Для вывода в поток значения однобайтовой переменной в виде шестнадцатеричного, десятичного или восьмеричного числа необходимо расширить это

значение до двух- или более байтового типа. Для корректного шестнадцатеричного вывода байта необходимо дополнить его нулями (беззнаковое расширение), то есть преобразовать $unsigned\ char$ в $unsigned\ short$ или $unsigned$ и т. п. Для преобразования *значения в значение* в C++ используется оператор `static_cast`, то есть для печати i-го байта `*(p1+i)` типа $unsigned\ char$ следует выводить в поток: `static_cast<unsigned>( *(p1+i) )`. Вместо `static_cast` можно использовать универсальное приведение в стиле C, но это не рекомендуется.

При выводе с помощью $printf()$ используйте формат $02hhX$; в этом случае никакое преобразование не нужно.

Бонус +2 балла за платформу. При подготовке к работе выполните измерения на платформе, где архитектура процессора отлична от x86/x86-64.

Задание Л2.з4. Изучите, как интерпретируется одна и та же область памяти, если она рассматривается как знаковое или беззнаковое целое число, а также — как одно и то же число записывается в различных системах счисления.

Для этого на языке C/C++ разработайте функцию $\mathrm{void}\ print16(\mathrm{void}\ *\ p)$, которая печатает для области памяти по заданному адресу p:

а) целочисленную беззнаковую 16-битную интерпретацию ($unsigned\ short$) в шестнадцатеричном представлении;
б) целочисленную беззнаковую 16-битную интерпретацию ($unsigned\ short$) в двоичном представлении;
в) целочисленную беззнаковую 16-битную интерпретацию ($unsigned\ short$) в десятичном представлении (для $printf()$ используйте формат u: она умеет выводить любые целые в любом представлении, и требуется явное указание);
г) целочисленную знаковую 16-битную интерпретацию ($short$) в шестнадцатеричном представлении;
д) целочисленную знаковую 16-битную интерпретацию ($short$) в двоичном представлении;
е) целочисленную знаковую 16-битную интерпретацию ($short$) в десятичном представлении (для $printf()$ используйте формат d).

Штраф -2 балла, если количество выводимых цифр двоичного представления отлично от количества бит в числе (16 для $print16()$) либо если количество выводимых цифр шестнадцатеричного представления отлично от количества тетрад в числе ($\frac{16}{4} = 4$ для $print16()$).

Бонус $+1$ балл, если вывод $print16()$ занимает одну строку (так на экран поместится больше чисел). **Бонус $+2$ балла,** если при этом младшая цифра находится под младшей цифрой предыдущей строки (чего можно добиться заданием ширины поля вывода).

Для получения различных интерпретаций участка памяти по адресу p в C++ можно использовать преобразование *указателя p в указатель на другой тип* опе-

ратором `reinterpret_cast` с последующим разыменованием. Обратите внимание, что разыменованный указатель является lvalue (может стоять слева от оператора присваивания), то есть различные интерпретации можно использовать не только для просмотра, но и для изменения участка памяти по адресу p.

Так, целочисленная беззнаковая интерпретация 16 бит памяти по адресу p для (а) и (в) — `*(reinterpret_cast<unsigned short *>(p))`, знаковая для (г) и (е) — `*(reinterpret_cast<short *>(p))` (см. разделы 7.2 и 7.3).

Вместо `reinterpret_cast` можно использовать универсальное приведение в стиле C, но его использование в коде на C++ не рекомендуется.

Обратите внимание, что преобразование *значения в значение* оператором `static_cast` или приведением в стиле C не обеспечивает необходимого эффекта; хотя для целых типов одного размера $signed \leftrightarrow unsigned$ преобразование значения в значение чаще всего приводит к тому же результату, что `reinterpret_cast` + разыменование, но уже для плавающей запятой это не так.

При выводе *в поток* двоичное (битовое) представление чисел можно получить, используя шаблон `std::bitset<N>`, где N — количество бит в представлении — необходимо задать вручную.

При выводе с помощью $printf()$ в новейших версиях GCC можно использовать форматы b и B с соответствующим модификатором размера; в более старых, где b и B не поддерживаются, необходимо вручную выделять и выводить биты числа.

Отсутствие двоичного представления (б)/(д) не штрафуется в том случае, если для студента не составляет труда прочитать шестнадцатеричное представление (а)/(г) и записать по нему двоичное для любого выбранного числа.

Проверьте работу функции $print16()$ на 16-битных целочисленных переменных, принимающих следующие значения:

- минимальное целое 16-битное значение без знака;
- максимальное целое 16-битное значение без знака;
- минимальное целое 16-битное значение со знаком;
- максимальное целое 16-битное значение со знаком;
- значение x, соответствующее варианту (таблица Л2.1);
- значение y, соответствующее варианту (таблица Л2.1);

(запишите каждое из значений в 16-битную целочисленную переменную и передайте её адрес функции).

Убедитесь, что (б) и (д) — одно и то же двоичное представление.

Убедитесь, что (а) и (г) — одно и то же шестнадцатеричное представление. Шестнадцатеричный формат вывода для целочисленных переменных используется как *компактная запись двоичного кода,* а не альтернативное представление значения, поэтому результат совпадает для беззнаковой и знаковой целочисленных интерпретаций p (и равен беззнаковой интерпретации в шестнадцатеричной системе счисления).

Варианты значений

Таблица Л2.1

$(№ - 1)\%2 + 1$	**Вариант**
1	$x = 9$, $y = -9$, $z =$ `0x88776155`
2	$x = 5$, $y = -5$, $z =$ `0xFF007100`

Измените функцию $print16()$ так, чтобы убрать дублирование (сохраните полный вариант как комментарий), и в дальнейшем пользуйтесь вариантом без дублей.

Задание Л2.з5. Разработайте на языке C/C++ функцию void $print32(\text{void } *p)$, аналогичную $print16()$ для размера 32 (каждое из дублирующихся представлений — шестнадцатеричное (а) и (г), двоичное (б) и (д) — выводить один раз).

Кроме целочисленных интерпретаций, $print32()$ должна рассматривать память по адресу p как 32-битное число с плавающей запятой («вещественное») одинарной точности ($float$) и печатать:

ж) 32-битную интерпретацию с плавающей запятой ($float$) в представлении с фиксированным количеством цифр после запятой;

з) 32-битную интерпретацию с плавающей запятой ($float$) в экспоненциальном представлении.

При выводе *в поток* режим вывода чисел с плавающей запятой переключается манипуляторами $fixed/scientific$. Количество цифр после запятой задаётся манипулятором $setprecision()$.

При выводе с помощью $printf()$ используйте форматы вывода f (так, $5.2f$ — 5 цифр всего, 2 после запятой) и e с соответствующим модификатором размера.

Проверьте работу $print32()$ на 32-битных целочисленных переменных, принимающих следующие значения:

- минимальное целое 32-битное значение без знака;
- максимальное целое 32-битное значение без знака;
- минимальное целое 32-битное значение со знаком;
- максимальное целое 32-битное значение со знаком;
- целочисленное значение x, соответствующее варианту (таблица Л2.1);
- целочисленное значение y, соответствующее варианту (таблица Л2.1);
- целочисленное значение z, соответствующее варианту (таблица Л2.1);

аналогично $print16()$, а также 32-битных переменных с плавающей запятой ($float$):

- $float$-значение x, соответствующее варианту (таблица Л2.1);
- $float$-значение y, соответствующее варианту (таблица Л2.1);
- $float$-значение z, соответствующее варианту (таблица Л2.1).

Сравните структуру целой переменной и $float$-переменной, имеющих равные значения (в частности, x). Сравните $float$-значения x и $y = -x$.

Задание Л2.з6. Бонус +2 балла. Разработайте на языке C/C++ функцию $print64()$, аналогичную $print32()$ для размера 64 бита и, соответственно, числа с плавающей запятой двойной точности, $double$.

Аналогично Л2.з5, проверьте $print64()$ на граничных целочисленных 64-битных значениях, целочисленных значениях x, y, z и $double$-значениях x, y, z.

Штраф -2 балла, если для $print32()$ либо $print64()$ количество выводимых цифр двоичного представления отлично от количества бит в числе либо количество выводимых цифр шестнадцатеричного — от количества тетрад.

Бонус $+1$ балл, если вывод $print32()$ (и $print64()$, если она реализована) занимает одну строку. **Бонус $+2$ балла,** если при этом младшая цифра находится под младшей цифрой предыдущей строки.

Задание Л2.з7. Бонус +2 балла для пар, обязательное для троек. С помощью функции $printDump()$ задания Л2.з3 определите и выпишите в отчёт, как хранятся в памяти на платформах из таблицы Л1.1:

- строки `"jzyx"` и `"ёяюэ"` из $char$; при выборе количества отображаемых байтов N учитывайте всю длину строки (включая завершающий нулевой символ), а не только видимые буквы;
- «широкие» строки `L"jzyx"` и `L"ёяюэ"` из $wchar\_t$; при выборе N учитывайте всю длину строки.

Результаты оформите в отчёте в виде таблицы. На MS Windows возможна (если файл исходного кода сохранён в однобайтовой кодировке `windows-1251`) ситуация, когда литерал `L"ёяюэ"` не воспринимается компилятором как корректная широкая строка. Поставьте в соответствующих ячейках отчёта прочерки.

Длину строки *в элементах* $char/wchar\_t$ без завершающего нуля можно получить при помощи функций $strlen()/wcslen()$; после чего, зная размер элемента и то, что завершающий ноль занимает один элемент, можно вычислить размер строки в байтах.

Если строки хранятся в статическом массиве без явного указания размера, инициализированном строкой при создании — размер массива равен размеру строки, а полный размер массива в байтах можно определить оператором sizeof.

Л2.1. Дополнительные бонусные и штрафные баллы

-3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л2.2. Ссылки на теоретические сведения

1.2.1. Единицы измерения

1.2.2. Порядок следования байтов
2.4. Двоичное представление беззнаковых целых чисел
2.5. Представление отрицательных чисел
2.8. Представление вещественных чисел
7.2. Типы данных
7.3. Приведение типов
7.4. Литералы C++
7.5. Средства автоматизации C++
4.2. Препроцессор
7.6. Ввод-вывод
7.7. Отладочная печать

Л2.3. Вопросы

1. Как представляются целые числа со знаком и без знака?
2. Как перевести число в дополнительный код?
3. Для чего нужно знать порядок следования байтов на вашем компьютере?
4. Всякая ли последовательность из N битов $\Big(N \in \{16, 32, 64\}\Big)$ может быть рассмотрена как N-битное *беззнаковое целое* число в натуральном двоичном коде (беззнаковом коде ЭВМ)? Единственное ли беззнаковое значение можно сопоставить этой последовательности?
5. Каждое ли целочисленное значение $x \in [0, 2^N)$ имеет своё представление в натуральном двоичном коде? Единственная ли последовательность из N битов соответствует каждому значению x?
6. Всякая ли последовательность из N битов может быть рассмотрена как N-битное *знаковое целое* число в дополнительном коде (знаковом коде ЭВМ)? Единственное ли знаковое значение можно сопоставить этой последовательности?
7. Каждое ли целочисленное значение $x \in [-2^{N-1}, 2^{N-1})$ имеет своё представление в дополнительном коде? Единственная ли последовательность из N битов соответствует каждому значению x?
8. Всякая ли последовательность из N битов $\Big(N \in \{32, 64\}\Big)$ может быть рассмотрена как N-битное *значение с плавающей запятой*? Всегда ли это значение — *число?*
9. Каждое ли вещественное значение $x \in [\min, \max]$ имеет своё представление в коде с плавающей запятой стандарта IEEE 754 ($float/double$ ЭВМ)?
10. Как располагаются в памяти элементы массива?
11. Как найти размер массива, зная размер элемента и их количество?
12. Как представляется символьная информация в компьютере в кодах ASCII, расширениях ASCII и различных кодировках Unicode?

13. Как хранятся русские буквы в «классических» и «широких» строках?
14. Как строковые функции libc (stdlib) определяют конец строки?
15. Сколько символов (для узких строк — узких символов $char$, для широких — $wchar\_t$) необходимо для представления строки из пяти латинских букв? Цифр? Русских букв? Зависит ли ответ от платформы?

Лабораторная работа 3 (0011 = 3)

Арифметика в ЭВМ и представление данных (целочисленные операции)

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: изучить особенности целочисленной арифметики и арифметики с плавающей запятой.

Все задания данной лабораторной работы выполняются на чистом C/C++, без использования ассемблера. Для вывода данных до и после выполнения операции необходимо использовать функции $print16()$ и $print32()$, то есть *каждое* значение должно быть представлено в формах (а)–(з).

Штраф за одно пропущенное обязательное задание -1 балл.

Задание на лабораторную работу

Задание Л3.з1. Разработайте программу на языке C++, которая расширяет значение целочисленной переменной из 16 бит до 32 бит, рассматривая числа как:

- знаковые (signed);
- беззнаковые (unsigned).

Проверьте её работу на значениях m и n (таблица Л3.1). Каждое из двух значений — как m, так и n — должно расширяться двумя способами — как знаковым, так и беззнаковым (итого четыре операции).

Варианты целочисленных значений

Таблица Л3.1

$(№ - 1)\%3 + 1$	**Вариант**
1	$m = 231, n = -33$
2	$m = 33, n = -101$
3	$m = 201, n = -59$

Расширение числа происходит, в частности, при присваивании — если размер приёмника больше размера источника. Для явного расширения в C++ можно использовать оператор `static_cast`. Источник и приёмник должны быть либо оба знаковыми, либо оба беззнаковыми, иначе — неопределённое поведение C/C++.

К знаковой/беззнаковой интерпретации m и n можно обратиться при помощи `reinterpret_cast` адресов, как и в $print16()/print32()$.

Штраф -2 балла, если исходное число и результат расширения выводятся не $print16()$ и $print32()$ соответственно, а только в одной-двух формах.

Штраф -2 балла, если для $print16()$ либо $print32()$ количество выводимых цифр двоичной/шестнадцатеричной формы отлично от количества битов/тетрад.

Штраф -1 балл, если здесь или ниже вывод хотя бы одной функции — $print16()$ или $print32()$ — занимает более одной строки.

Бонус $+1$ балл, если младшая цифра каждого представления $print32()$ находится под младшей цифрой соответствующего представления $print16()$.

Задание Л3.з2. Разработайте программу на языке C/C++, которая выполняет над 16-битным целочисленным значением x:

- знаковое умножение на 2;
- беззнаковое умножение на 2;
- знаковое деление на 2;
- беззнаковое деление на 2;
- расчёт остатка от беззнакового деления на 16;
- округление вниз до числа, кратного 16 (беззнаковое).

а также:

- знаковый сдвиг влево на 1 бит;
- беззнаковый сдвиг влево на 1 бит;
- знаковый сдвиг вправо на 1 бит;
- беззнаковый сдвиг вправо на 1 бит;
- рассчитывает $x \ \& \ 15$;
- рассчитывает $x \ \& \ -16$.

Сопоставьте результаты — вначале на значении m, затем n (таблица Л3.1).

Перед каждой операцией переменная имеет одно и то же начальное значение (соответственно, лучше для каждой операции создавать свою копию x); и это значение должно быть легко изменяемо.

Знаковое целочисленное умножение/деление выполняется C/C++ в том случае, если оба операнда — знаковые целые числа; беззнаковое — если оба беззнаковые. Знаковые (арифметические) сдвиги выполняются C/C++, если первый операнд (сдвигаемое число) — знаковое целое, беззнаковые (логические) сдвиги — если оно беззнаковое. Соответственно, необходимо обращаться к знаковой/беззнаковой интерпретации x при помощи `reinterpret_cast` адреса $\&x$, как и в $print16()$.

Задание Л3.з3. Разработайте программу на языке C/C++, которая, используя только сложение, вычитание и побитовые операции, округляет целочисленное беззнаковое значение x до кратного значению D (таблица Л3.2) двумя способами:

а) вниз;
б) вверх.

Варианты значений

Таблица Л3.2

$(№ - 1)\%5 + 1$	**Вариант**
1	$D = 16$
2	$D = 32$
3	$D = 64$
4	$D = 128$
5	$D = 256$

Задание Л3.з4. Разработайте программу на языке C/C++, которая выполняет для 32-битной переменной x целочисленный инкремент (то есть целочисленная интерпретация x должна увеличиться на 1).

Проверьте её работу на 32-битных целочисленных значениях m и n (таблица Л3.1), 32-битных значениях с плавающей запятой a, b, c, d из таблицы Л3.3, а также на целочисленных значениях:

– 0;
– максимальное целое 32-битное значение без знака;
– минимальное целое 32-битное значение со знаком;
– максимальное целое 32-битное значение со знаком.

Исходное значение и результат напечатайте рядом, чтобы их можно было сравнить.

Варианты значений с плавающей запятой

Таблица Л3.3

$(№ - 1)\%2 + 1$	**Вариант**
1	$a = 0, b = 1, c = 12345678, d = 123456789$
2	$a = 0, b = 1, c = 12345689, d = 123456891$

Целочисленный инкремент/декремент выполняется C/C++ в том случае, если операнд — целое число (знаковое или беззнаковое). Соответственно, необходимо обращаться к целочисленной интерпретации x при помощи `reinterpret_cast` адреса $\&x$, как и в $print32()$.

В зависимости от компилятора и его настроек при попытке инкремента максимально возможного значения типа и декремента минимального значения можно

получить предупреждение о неопределённом поведении C/C++. Занесите его в отчёт. Если дополнительных проверок не производится, и операторы инкремента ++ и декремента -- в C/C++ компилируются в команды x86 inc/dec — их поведение вполне определено для любого целочисленного операнда, а также одинаково для знаковых и беззнаковых целых чисел.

Задание Л3.з5. Рассчитайте для заданного 32-битного значения с плавающей запятой x его модуль $|x|$, используя только битовые (целочисленные) операции и преобразование указателей.

Задание Л3.з6. Разработайте программу на языке C/C++, выполняющую вычисления над числами с плавающей запятой одинарной точности ($float$). Проверьте, что программа действительно работает с операндами одинарной точности, а не приводит к типу $float$ окончательный результат.

Для частичной суммы гармонического ряда $S(N) = \sum_{i=1}^{N} \frac{1}{i} \in \mathbb{R}$ найдите две её оценки: $S_d(N)$ — последовательно складывая члены, начиная от $i = 1$ и заканчивая $i = N$ («наивный» порядок), и $S_a(N)$ — от $i = N$ к $i = 1$. Сравните $S_d(N)$ и $S_a(N)$ для различных значений N: $10^3, 10^6, 10^9$. Объясните результат.

Измените тип операндов на $double$. Для вывода результата используйте $print64()$ (если она не реализована — обязательно выведите, кроме $double$- интерпретации, также и $long\ long$-интерпретацию результата в шестнадцатеричном представлении). Объясните результат.

Л3.1. Дополнительные бонусные и штрафные баллы

−3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л3.2. Ссылки на теоретические сведения

2. Представление данных

Л3.3. Вопросы

1. Что такое расширение чисел со знаком и без знака? Для чего нужны операции расширения?
2. Как выполняются логические операции, побитовые операции и сдвиги над строкой битов?
3. Как представляются в памяти компьютера числа с плавающей запятой?

Лабораторная работа 4 (0100 = 4)

Использование ассемблерных вставок в программах на C++. Команды пересылки

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: научиться вставлять в программы на языке высокого уровня ассемблерные фрагменты. Ознакомиться с командами пересылки данных.

Данная лабораторная работа, как и все предыдущие и последующие, должна собираться **компилятором из коллекции GCC** (для C++ — компилятор `g++`, для чистого C — `gcc`). Среда Microsoft Visual Studio не поддерживает других компиляторов, кроме Microsoft, и не может быть использована. Задания выполняются в виде ассемблерных вставок в программу на C/C++.

Штрафы: -1 балл за одно пропущенное обязательное задание, $-\frac{1}{2}$ балла за каждую некорректную секцию перезаписываемых элементов (clobbers).

Задание на лабораторную работу

Задание Л4.з1. Как в задании Л1.з4, создайте массивы Ms из 16-битных целых чисел, Ml из 32-битных целых чисел, Mq из 64-битных целых чисел (длина и начальные значения аналогичны Л1.з4).

Реализуйте для каждого массива M вставку, записывающую непосредственное значение 16 в $M[i]$ для заданного $i \in [0, N)$ с использованием команды mov, где выражение $M[i]$ является выходным параметром вставки *в памяти.* Так как оба операнда mov здесь не имеют определённого размера (непосредственное значение и память), необходимо указывать для mov суффикс размера: $movw$, $movl$, $movq$.

Здесь и далее все целочисленные массивы до и после изменения выводите в шестнадцатеричном представлении.

Задание Л4.з2. Реализуйте для одного из массивов M (по варианту согласно таблице Л4.1) вставку, записывающую непосредственное (-1) в $M[i]$, где адрес начала массива M и индекс i передаются как входные параметры *в регистрах.*

Варианты целочисленного массива M

Таблица Л4.1

$(№ - 1)\%3 + 1$	**Вариант**
1	Ms
2	Ml
3	Mq

Используйте компоненты эффективного адреса $(Base, Index, 2^{Scale})$. Разрядность компонент $Base$ и $Index$ должна быть одинаковой, поэтому для переносимости вставки необходимо объявить переменную i не как int (4 байта как для 32-, так и для 64-битного режимов), а как $size\_t$ (размер равен размеру указателя).

Задание Л4.з3. Реализуйте вставку, записывающую непосредственное значение `0xBB` в заданный байт $Mq[i]$ (по варианту согласно таблице Л4.2; младший байт считайте нулевым) с использованием одной команды mov ($movb$) и всех компонент эффективного адреса $Disp(Base, Index, 2^{Scale})$; адрес начала массива Mq и индекс i передаются как входные параметры *в регистрах.*

Варианты перезаписываемого байта $Mq[i]$ для Л4.з3

Таблица Л4.2

$(№ - 1)\%5 + 1$	**Вариант**
1	Первый байт после младшего
2	Третий байт
3	Четвёртый байт
4	Шестой байт
5	Седьмой байт (старший байт 64-битного $Mq[i]$)

Задание Л4.з4. Реализуйте вставку, записывающую в $M[i]$ значение x (M по варианту согласно таблице Л4.1; размер переменной x равен размеру элемента M), где значение x передаётся как входной параметр *в памяти,* M и i — как входные параметры *в регистрах.*

Так как команда x86 не может адресовать два операнда в памяти, прямая пересылка $x \to M[i]$ невозможна; используйте промежуточный регистр (таблица Л4.3).

Задание Л4.з5. Реализуйте вставку, записывающую в $M[i]$ значение x аналогично Л4.з4, но во вставку передаётся адрес $\&x$.

Задание Л4.з6. Реализуйте вставку, рассчитывающую для целочисленных x и y значения $z = x + y$ и $w = x - y$ при помощи команд add и sub. Разрядность указана в таблице Л4.4; переменные x, y, z, w передаются во вставку как параметры (z и w — выходные, x и y — входные).

Задание Л4.з7. Определите, доступны ли на выбранной платформе расширения AVX и SSE, используя команду $cpuid$ или документацию на процессор.

Как в задании Л1.з4, создайте массивы Mfl из 64-битных чисел с плавающей запятой и Mfs из 32-битных чисел с плавающей запятой.

Реализуйте вставку, записывающую в $M[i]$ значение x с плавающей запятой аналогично Л4.з4 (M по варианту согласно таблице Л4.5; размер переменной x равен

Варианты временного РОН

Таблица Л4.3

$(№-1)\%7+1$	**Вариант**
1	Регистр A ($al/ax/eax/rax$)
2	Регистр C ($cl/cx/ecx/rcx$)
3	Регистр D ($dl/dx/edx/rdx$)
4	Регистр si ($sil/si/esi/rsi$)
5	Регистр di ($dil/di/edi/rdi$)
6	Регистр $r8$ ($r8b/r8w/r8d/r8$) на 64-битной платформе, A на 32
7	Регистр $r9$ ($r9b/r9w/r9d/r9$) на 64-битной платформе, C на 32

Варианты разрядности x, y, z, w

Таблица Л4.4

$(№-1)\%2+1$	**Вариант**
1	64 бита
2	16 бит

размеру элемента M; x, M и i — параметры вставки), используя команды AVX $vmovsd/vmovss$ или их SSE-аналоги $movsd/movss$. Используйте промежуточ-

Варианты массива M из значений с плавающей запятой

Таблица Л4.5

$(№-1)\%2+1$	**Вариант**
1	Mfl
2	Mfs

ный регистр xmmi, где номер регистра $i \in [0,5]$ рассчитывается как $(№-1)\%6$ (по варианту).

Задание Л4.з8. Реализуйте вставку, записывающую в $M[i]$ значение с плавающей запятой, равное целочисленному значению x. Преобразование целочисленного x к нужному виду выполните при помощи команд AVX $vcvtsi2sd/vcvtsi2ss$ или их SSE-аналогов $cvtsi2sd/cvtsi2ss$.

Л4.1. Дополнительные бонусные и штрафные баллы

−3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л4.2. Ссылки на теоретические сведения

4.3. Ассемблерные вставки в код C++
5.2. Основные команды

Л4.3. Вопросы

1. Какие вы знаете регистры общего назначения x86 и x86-64?
2. Какие вы знаете xmm-регистры x86 и x86-64?
3. Каким ключевым словом открывается ассемблерная вставка?
4. Где описываются выходные параметры ассемблерных вставок расширенного синтаксиса GCC? Что означают символы `=`, `=&`, `+` в начале строки ограничений выходного параметра?
5. Где описываются входные параметры?
6. Где указывается список перезаписываемых [clobbers] во вставке регистров (кроме параметров)? Какая строка соответствуют изменению флагов $flags$? Какая строка соответствуют изменению памяти (кроме параметров)?
7. Где описываются метки ЯВУ, на которые может быть передано управление из вставки?
8. Какое ключевое слово нужно указать после `asm`, чтобы запретить компилятору оптимизировать вставку?
9. Какое ключевое слово нужно указать после `asm`, чтобы показать, что управление из вставки может передаваться на ту или иную метку C/C++ (зато у этой вставки нет выходных параметров)?
10. Для чего используется команда mov и команды AVX/SSE $*mov*$?

Лабораторная работа 5 (0101 = 5)

Модули и функции. Вызов функций стандартной библиотеки C (libc и libm)

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: изучить стандартные соглашения о вызовах и их соответствие платформам, научиться вызывать из программы на ассемблере функции стандартной библиотеки C.

Для всех заданий данной лабораторной работы программа целиком реализуется на ассемблере. Для каждого из заданий указывайте ОС, разрядность программы и соответствующее им соглашение.

Штраф за одно пропущенное обязательное задание -2 балла.

Задание на лабораторную работу

Задание Л5.з1. Разработайте программу, выводящую на стандартный вывод группу, номер и состав команды при помощи функции $puts()$ библиотеки libc (аналогично заданию Л1.з1).

Задание Л5.з2. Выделите в стеке $main()$ место под переменные нескольких типов (по значению на каждый тип):
- 16-битное целое;
- 32-битное целое;
- 64-битное целое;
- 32-битное число с плавающей запятой;
- 64-битное число с плавающей запятой.

с учётом выравнивания — адрес переменной должен быть кратен как минимум её размеру. Введите в каждую из выделенных областей памяти по значению соответствующего типа при помощи $scanf()$. Напечатайте значения из памяти при помощи $printf()$. Обратите внимание, что $printf()$ и $scanf()$ имеют *переменное число аргументов,* что во многих соглашениях требует дополнительных действий.

Задание Л5.з3. Разработайте программу, вычисляющую по введённым значениям x и y с плавающей запятой двойной точности значение z (таблица Л5.1), вызывая функции libm $pow()/atan2()$.

Если программа не собирается из-за отсутствия ссылок на $pow()/atan2()$, добавьте к команде сборки ключ `-lm` (указание компоновщику использовать libm).

Задание Л5.з4. Бонус +2 балла для пар, обязательное для троек. Реализуйте задания Л5.з2–Л5.з3 для платформы с иным соглашением о вызовах (то есть если задания Л5.з2–Л5.з3 выполнялись под 64-битной GNU/Linux — реализуйте их дополнительно и для 64-битной MS Windows, или для любой 32-битной системы).

Варианты выражений для расчёта

Таблица Л5.1

$(№ - 1)\%2 + 1$	**Вариант**
1	$z = \mathrm{pow}(x, y)$, x^y
2	$z = \mathrm{atan2}(x, y)$, угол между вектором (x, y) и осью абсцисс

Л5.1. Дополнительные бонусные и штрафные баллы

—2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

—3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

Л5.2. Ссылки на теоретические сведения

4.1. Компиляция
7.2. Типы данных
6.2. Подпрограммы и функции
6.1. Структура программы на ассемблере
5.2. Основные команды

Л5.3. Подключение к проекту модулей на ассемблере

Qt Creator Файл проекта Qt Creator для добавления ассемблерного модуля необходимо отредактировать вручную, так как мастер добавления файлов не воспринимает расширения `.S` и `.s` как допустимые для исходного кода. В частности, для файла `main.S` необходимо добавить строку `SOURCES += main.S`.

Листинг Л.1. Файл проекта, содержащего `main.S` и `sqr.S`

```
1  TEMPLATE = app
2  CONFIG += console
3  CONFIG -= app_bundle
4  CONFIG -= qt
5
6  SOURCES += main.cpp
7  SOURCES += sqr.S
8
9  include(deployment.pri)
10 qtcAddDeployment()
```

Файлы `main.S` и `sqr.S` здесь должны находиться в той же папке, что и проект, иначе в строке после `SOURCES +=` необходимо указать имя файла с относительным путём. Других настроек, кроме редактирования файла проекта, делать не нужно.

Code::Blocks Создать ассемблерный модуль в Code::Blocks можно, используя меню $File \to New \to Empty\ file$. Имя файла обязательно должно иметь расширение `.S` (заглавное; расширение `.s` не воспринимается Code::Blocks как допустимое).

После создания в проекте файла с таким расширением он во время сборки проекта обрабатывается препроцессором и компилируется gcc; полученный объектный файл в дальнейшем используется компоновщиком. Дополнительных настроек делать не нужно.

Л5.4. Вопросы

1. Какие вы знаете соглашения о вызове?
2. Какое соглашение соответствует используемой вами платформе?
3. Какая команда передаёт управление подпрограмме?
4. Какая команда возвращает управление вызывающей программе?
5. Что такое адрес возврата?

Лабораторная работа 6 (0110 = 6)

Модули и функции. Описание функций на ассемблере

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: научиться совмещать в проекте язык C++ и ассемблер.

Для всех заданий данной лабораторной работы программа состоит из нескольких модулей, часть которых реализуется на чистом C/C++ (без ассемблерных вставок), часть на чистом ассемблере. Для каждого из заданий указывайте ОС, разрядность программы и соответствующее им соглашение.

При описании функции на ассемблере в комментарии приведите её прототип (объявление, заголовок) на C/C++. При описании на ассемблере подпрограммы, не являющейся C-функцией — в комментариях подробно опишите способ передачи параметров, возвращения результата и другие особенности вызова.

Штраф за одно пропущенное обязательное задание -3 балла.

Задание на лабораторную работу

Задание Л6.з1. Разработайте ассемблерную функцию, вычисляющую целое выражение от двух целых аргументов (таблица Л6.1), а также головную программу на языке C/C++, использующую разработанную функцию.

Варианты целочисленных выражений для расчёта

Таблица Л6.1

$(№ - 1)\%2 + 1$	**Вариант**
1	$z(x, y) = -113 + x + 2y$
2	$z(x, y) = 67 + 4x + y$

Бонус $+1$ балл, если вычисление производится одной командой lea.
Для проверки реализуйте вычисление того же выражения на C/C++.

Задание Л6.з2. Разработайте ассемблерную функцию, вычисляющую выражение от двух чисел с плавающей запятой двойной точности x и y (таблица Л6.2), используя команды AVX $vsubsd$ и $vdivsd$ или их SSE-аналоги $subsd$ и $divsd$, а также головную программу на языке C/C++.

Задание Л6.з3. Опишите на произвольном языке высокого уровня (включая C/C++) функцию с семью целочисленными параметрами, которая выводит свои параметры на экран и возвращает результат, равный второму параметру.

Разработайте головную программу на ассемблере, вызывающую эту функцию.

Варианты выражений с плавающей запятой для расчёта

Таблица Л6.2

$(№ - 1)\%2 + 1$	**Вариант**
1	$z(x, y) = x - y$
2	$z(x, y) = x / y$

Л6.1. Дополнительные бонусные и штрафные баллы

−2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

−3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

−1 балл за отсутствие в комментарии к ассемблерной функции её C/C++-прототипа.

Л6.2. Ссылки на теоретические сведения

4.1. Компиляция
7.2. Типы данных
6.2. Подпрограммы и функции
6.1. Структура программы на ассемблере
5.2. Основные команды

Л6.3. Вопросы

1. Какие вы знаете соглашения о вызове?
2. Какое соглашение соответствует используемой вами платформе?
3. Какая команда передаёт управление подпрограмме?
4. Какая команда возвращает управление вызывающей программе?
5. Что такое адрес возврата?

Лабораторная работа 7 (0111 = 7)
Флаги и условные команды. Ветвления и циклы

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: ознакомиться с набором флагов состояния регистра $flags$, командами условной установки байта, командами сравнения (выставления флагов).

Все задания данной лабораторной работы выполняются на ассемблере: либо в виде программы, целиком реализованной на ассемблере (возможно для всех заданий), либо в виде ассемблерной вставки в программу на C/C++ (если это не приводит к неопределённому поведению).

Штрафы: -1 балл за одно пропущенное обязательное задание, -1 балл за каждую вставку с неопределённым поведением, в том числе за некорректную секцию перезаписываемых элементов (clobbers).

Задание на лабораторную работу

Задание Л7.з1. Вычислите сумму двух целых чисел $z = x + y$, используя команду add. Сформируйте w (таблица Л7.1), используя семейство команд $setCC$ и анализируя флаги состояния CF, OF, SF, ZF, AF, PF после вычисления z.

Варианты w

Таблица Л7.1

$(№ - 1)\%3 + 1$	**Вариант**
1	$w = \begin{cases} 0, & \text{если не было беззнакового переполнения,} \\ 1, & \text{если было беззнаковое переполнение} \end{cases}$
2	$w = \begin{cases} 0, & \text{если не было знакового переполнения,} \\ 1, & \text{если было знаковое переполнение} \end{cases}$
3	$w = \begin{cases} 0, & \text{если } z \neq 0, \\ 1, & \text{если } z = 0 \end{cases}$

Задание Л7.з2. Вычислите z для заданного целого беззнакового x (таблица Л7.2); z принимает значение 1 либо 0, аналогично операторам сравнения C/C++.

Задание Л7.з3. Реализуйте Л7.з2 для целого знакового x.

Задание Л7.з4. Реализуйте Л7.з2 для x с плавающей запятой (таблица Л7.3), используя AVX-команды сравнения $vcomisd/vcomiss$ (или их SSE-аналоги).

Варианты z для заданий на $setCC$

Таблица Л7.2

$(№ - 1)\%2 + 1$	**Вариант**
1	$z = (x < 11)$
2	$z = (x \geqslant -2)$

Варианты типов с плавающей запятой для AVX/SSE

Таблица Л7.3

$(№ - 1)\%2 + 1$	**Вариант**
1	Двойной точности ($double$)
2	Одинарной точности ($float$)

Задание Л7.з5. Вычислите z для заданного целого беззнакового x (таблица Л7.4), используя семейство условных команд $cmovCC$ и выставляя флаги

Варианты выражений для $cmovCC$

Таблица Л7.4

$(№ - 1)\%3 + 1$	**Вариант**
1	$z = \begin{cases} 23 + 5x, & 23 + 5x > 5, \\ -1, & 23 + 5x \leqslant 5 \end{cases}$
2	$z = \begin{cases} -1 + x, & -1 + x \geqslant 0, \\ 10, & -1 + x < 0 \end{cases}$
3	$z = \begin{cases} 155, & 3x > 1, \\ 3x, & 3x \leqslant 1 \end{cases}$

состояния при помощи команды cmp.

Бонус $+1$ балл, если вычисление линейной комбинации производится одной командой lea.

Задание Л7.з6. Заполните массив из N целочисленных элементов первыми N членами последовательности (таблица Л7.5).

Выделение памяти под массив может быть выполнено на языке C/C++, в этом случае в ассемблерную функцию передаётся адрес начала массива и длина N.

Варианты последовательности

Таблица Л7.5

$(№ - 1)\%3 + 1$	**Вариант**
1	Чётные неотрицательные: $0, 2, 4, 6, 8...$
2	Кратные 4 неотрицательные: $0, 4, 8, 12...$
3	Кратные 8 неотрицательные: $0, 8, 16, 24...$

Задание Л7.з7. Бонус +2 балла для пар, обязательное для троек. Напечатайте первые N членов последовательности (таблица Л7.5), не сохраняя их в массиве.

Так как вызов функций из ассемблерной вставки является неопределённым поведением, это задание может быть выполнено только как функция, целиком выполненная на ассемблере (или фрагмент программы, целиком выполненной на ассемблере).

Л7.1. Дополнительные бонусные и штрафные баллы

—1 балл за каждую некорректную секцию перезаписываемых элементов (clobbers) во вставках — и с неуказанием нужного, и с указанием лишнего.

—2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

—3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

—3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

—3 балла за команды `loop*`, `jcx*` или `jecx*` (`dec` + `jz`/`jnz` вдвое быстрее).

Л7.2. Ссылки на теоретические сведения

4.3. Ассемблерные вставки в код C++
5.2. Основные команды

Л7.3. Вопросы

1. Какие вы знаете флаги?
2. Какие вы знаете условные команды?

Лабораторная работа 8 (1000 = 8)

Команды, применяемые для целочисленных вычислений. Скалярные команды AVX/SSE

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: научиться использовать базовые команды x86 и команды расширений AVX/SSE. Научиться использовать для вычислений lea и битовые операции.

Все задания данной лабораторной работы выполняются на ассемблере.

Штраф за одно пропущенное обязательное задание -2 балла.

Задание на лабораторную работу

Задание Л8.з1. Вычислите целочисленное выражение (таблица Л8.1) для заданных целых x и y. Разрядность x, y, z совпадает.

Варианты целочисленных выражений

Таблица Л8.1

$(№ - 1)\%2 + 1$	**Вариант**
1	$z = x + x \cdot y - 7$
2	$z = 12 - x - y^2$

Задание Л8.з2. Вычислите беззнаковое целочисленное выражение (таблица Л8.2) для заданных целых x и y.

Варианты беззнакового/знакового деления

Таблица Л8.2

$(№ - 1)\%3 + 1$	**Вариант**
1	$\begin{cases} z = x/(y-7) \\ w = x\%(y-7) \end{cases}$
2	$\begin{cases} z = (x+3)/y \\ w = (x+3)\%y \end{cases}$
3	$\begin{cases} z = x/(y-2) \\ w = x\%(y-2) \end{cases}$

Вычислите знаковое целочисленное выражение (таблица Л8.2) для тех же x и y.

Сравните результаты беззнакового и знакового деления в случае, когда делимое равно -3, а делитель $+2$.

Задание Л8.з3. Вычислите целочисленное выражение (таблица Л8.3) для заданного целого x, используя *одну* команду. Разрядность x и z совпадает.

Варианты целочисленных выражений для lea и битовых операций

Таблица Л8.3

$(№ - 1)\%9 + 1$	**Вариант**
1	$z = x + 68$
2	$z = 2x - 34$
3	$z = 3x + 8$
4	$z = 4x - 132$
5	$z = 5x + 237$
6	$z = 8x - 9$
7	$z = 9x + 23$
8	$z = 16x$
9	$z = 32x$

Штраф -2 балла, если умножение выполняется командами $mul/imul$.

Задание Л8.з4. Вычислите для заданных x и y с плавающей запятой двойной точности выражение из таблицы Л8.4, используя скалярные AVX-команды либо их SSE-аналоги.

Варианты выражений с плавающей запятой

Таблица Л8.4

$(№ - 1)\%2 + 1$	**Вариант**
1	$z = x/3 + 2/y - xy$
2	$z = 1 - 5/x - y^2/7$

Л8.1. Дополнительные бонусные и штрафные баллы

—1 балл за каждую некорректную секцию перезаписываемых элементов (clobbers) во вставках — и с неуказанием нужного, и с указанием лишнего.

—2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

—3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

—2 балла за включение в отчёт заведомо недостоверных цифр.

—3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л8.2. Вопросы

1. Какие вы знаете команды ассемблера x86?
2. Знаковой или беззнаковой является операция сложения?
3. Какие наборы команд используются для выполнения арифметических операций над числами с плавающей запятой?
4. Какие регистры используются расширениями AVX/SSE для хранения операндов?

Лабораторная работа 9 (1001 = 9)
Векторные команды AVX/SSE

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: научиться использовать векторные команды расширений AVX/SSE.

Все задания данной лабораторной работы выполняются на ассемблере.

Штраф за одно пропущенное обязательное задание -3 балла.

Задание на лабораторную работу

Задание Л9.з1. Вычислите для массивов $(x_0, ...x_3)$ и $(y_0, ...y_3)$ из четырёх чисел с плавающей запятой двойной точности значения $(z_0, ...z_3)$ согласно таблице Л9.1, используя векторные команды AVX $vmovupd$, $vaddpd$, $vsubpd$, $vmulpd$, $vdivpd$, $vpbroadcastd$ и ymm-регистры (если они недоступны — SSE-аналоги и xmm).

Варианты действий с массивами

Таблица Л9.1

$(№ - 1)\%3 + 1$	**Вариант**
1	$z_i = x_i - y_i + 1$
2	$z_i = x_i / y_i + 2$
3	$z_i = x_i y_i - 5$

Выделение памяти под x, y, z и заполнение массивов x, y может быть выполнено на C/C++. Проверьте расчёт, реализовав то же самое на C/C++.

Задание Л9.з2. Разработайте ассемблерную функцию $\text{int } L92(\text{void } *px, \text{void } *py, \text{void } *pz, \text{size\_t } N)$, рассчитывающую z согласно таблице Л9.1 для длины N, кратной четырём.

Возвращаемое значение должно быть равно -1 при N, не кратном 4, и количеству успешно рассчитанных элементов z при корректном N.

Задание Л9.з3. Разработайте ассемблерную функцию $\text{int } L93(\text{void } *px, \text{void } *py, \text{void } *pz, \text{size\_t } N)$, аналогичную Л9.з2 для произвольной длины N.

Проверьте, что массив z корректно заполняется (то есть ячейки от $pz[0]$ до $pz[N-1]$ перезаписываются верными значениями, а $pz[N]$ и далее не изменяются) при $N \in \{4k, 4k+1, 4k+2, 4k+3\}$ для выбранного k.

Л9.1. Дополнительные бонусные и штрафные баллы

−1 балл за каждую некорректную секцию перезаписываемых элементов (clobbers) во вставках — и с неуказанием нужного, и с указанием лишнего.

−3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

−2 балла за включение в отчёт заведомо недостоверных цифр.

−2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

−3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

Л9.2. Вопросы

1. Какие вы знаете команды ассемблера x86?
2. Знаковой или беззнаковой является операция сложения?
3. Какие наборы команд используются для выполнения арифметических операций над числами с плавающей запятой?
4. Какие регистры используются расширениями AVX/SSE для хранения операндов?

Лабораторная работа 10 (1010 = A)
Команды FPU

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: научиться использовать FPU.

Все задания данной лабораторной работы выполняются на ассемблере.

Штраф за одно пропущенное обязательное задание -2 балла.

Задание на лабораторную работу

Задание ЛА.з1. Вычислите для заданных x и y с плавающей запятой двойной точности выражение из таблицы Л8.4, используя FPU.

Выведите результаты заданий Л8.з4 и ЛА.з1 при помощи $print64()$. Совпадают ли результаты побитово? Если значения различаются — какое из них точнее? Достаточно ли они близки друг к другу, чтобы можно было считать их совпадающими в пределах допустимой погрешности?

Задание ЛА.з2. Вычислите для заданных x и y с плавающей запятой двойной точности выражение из таблицы Л5.1, используя FPU и не используя функций libm.

Сравните результаты заданий Л5.з3 и ЛА.з2 аналогично ЛА.з1.

Задание ЛА.з3. Вычислите для заданных x и y с плавающей запятой двойной точности выражение из таблицы ЛА.1, используя FPU.

Варианты выражений для расчёта

Таблица ЛА.1

$(№-1)\%2+1$	**Вариант**
1	$(100{,}69 \mod x) \cdot ((-47{,}46) \mod y)$
2	$y \cdot \log_2(x+1)$

Задание ЛА.з4. Реализуйте Л7.з2 для x с плавающей запятой (таблица ЛА.2), используя FPU-команды сравнения $f[u]comi[p]$.

Варианты типов с плавающей запятой для FPU

Таблица ЛА.2

$(№ - 1)\%3 + 1$	**Вариант**
1	Двойной расширенной точности ($long\ double$)
2	Двойной точности ($double$)
3	Одинарной точности ($float$)

ЛА.1. Дополнительные бонусные и штрафные баллы

—1 балл за каждую некорректную секцию перезаписываемых элементов (clobbers) во вставках — и с неуказанием нужного, и с указанием лишнего.

—3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

—2 балла за включение в отчёт заведомо недостоверных цифр.

—2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

—3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

ЛА.2. Вопросы

1. Какие регистры используются в FPU для хранения операндов?
2. Какие команды используются для выполнения тригонометрических операций?
3. Какие команды используются для сравнения чисел с плавающей запятой?

Лабораторная работа 11 (1011 = B)

Использование многомерных массивов и структур

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Цель работы: ознакомиться с расположением элементов структуры в памяти компьютера, с понятием выравнивания; научиться обрабатывать многомерные массивы и массивы структур.

Все задания данной лабораторной работы, где явно не указан язык C/C++, выполняются на ассемблере.

Штраф за одно пропущенное обязательное задание -2 балла.

Задание на лабораторную работу

Задание ЛВ.з1. Создайте, используя язык C/C++, матрицу (двумерный статический массив) $M[i,j]$ из целых знаковых чисел (int).

Изучите расположение элементов матрицы (используя возможности языка высокого уровня или IDE).

1. Каков размер элемента (в байтах)?
2. Насколько отличаются адреса соседних элементов строки (в байтах)?
3. Насколько отличаются адреса соседних элементов столбца (в байтах)?
4. Каков общий размер матрицы (в байтах)?
5. Как получить адрес элемента матрицы, зная номера строки и столбца, а также адрес начала матрицы?

Задание ЛВ.з2. Рассчитайте для массива $\alpha[\,]$ из целых знаковых чисел (int) значение согласно таблице ЛВ.1. Выделение памяти и заполнение массива может быть выполнено на языке C/C++.

Варианты обработки массива

Таблица ЛВ.1

$(№ - 1)\%2 + 1$	**Вариант**
1	Найти ближайший к -7 чётный элемент массива
2	Найти ближайший к $+120$ нечётный элемент массива

Бонус +2 балла. Выполните задание для заданной (с номером i) строки матрицы M. Выполните задание для заданного (с номером j) столбца матрицы M. Что отличается в коде?

Задание ЛВ.з3. Реализуйте задание ЛВ.з2 для массива $\beta[\,]$ из чисел с плавающей запятой ($double$). Выделение памяти и заполнение массива может быть выполнено на языке C/C++.

Задание ЛВ.з4. Опишите на C/C++ структуру, состоящую из двух полей:
- целочисленное поле $\mathrm{int}\ key$ — ключ;
- поле с плавающей запятой $\mathrm{double}\ val$ — значение.

Каков размер структуры (в байтах)? Каков суммарный размер её полей (в байтах)?

Пересоберите программу, указав максимальную кратность выравнивания 4, для чего либо укажите в командной строке ключ компилятора `-fpack-struct=4`, либо добавьте в начало файла директиву препроцессора `#pragma pack(4)`. Что изменилось?

Пересоберите программу, указав максимальную кратность выравнивания 8.

Какие поля надо добавить в структуру, чтобы её размер не зависел от максимальной кратности выравнивания, а key и val были выравнены кратно своему размеру? Как получить адрес поля полученной структуры, зная адрес начала структуры и её состав?

Задание ЛВ.з5. Создайте, используя язык высокого уровня, массив $\gamma[\,]$ из структур задания ЛВ.з4 (размер не должен зависеть от настроек выравнивания). Реализуйте задание ЛВ.з2 для значений тех элементов массива $\gamma[\,]$, ключ которых равен заданному числу κ.

Если таких нет, выведите корректное сообщение об этом.

Задание ЛВ.з6. Бонус +2 балла для пар, обязательное для троек. Разработайте функцию $\mathrm{size\_t}\ snorm(\mathrm{void}\ *M, \mathrm{size\_t}\ N, \mathrm{int}\ E)$, нормирующую элементы с ключом E массива $M = \gamma$ длины N (таблица ЛВ.2).

Варианты нормировки

Таблица ЛВ.2

$(№ - 1)\%2 + 1$	**Вариант**
1	Сумма элементов должна быть равна 64
2	Произведение элементов должно быть равно 125

После обработки $snorm()$ элементы массива с $key \neq E$ должны сохранить своё значение; элементы массива с $key = E$ должны измениться пропорционально; возвращаемое значение $snorm()$ должно быть равно количеству элементов с ключом E.

ЛВ.1. Дополнительные бонусные и штрафные баллы

—1 балл за каждую некорректную секцию перезаписываемых элементов (clobbers) во вставках — и с неуказанием нужного, и с указанием лишнего.

—2 балла за хранение локальных переменных в сегменте данных (использование статических/глобальных констант допускается).

—3 балла за нарушение соглашения о вызовах (даже если в данной конкретной программе это не имеет видимых проявлений).

—3 балла за утечку памяти (выделенные, но не освобождённые блоки динамической памяти).

—3 балла за команды `loop*`, `jcx*` или `jecx*` (`dec` + `jz`/`jnz` вдвое быстрее).

ЛВ.2. Ссылки на теоретические сведения

5.1.4. Адресация операндов
6.3. Программирование нелинейных алгоритмов

ЛВ.3. Вопросы

1. Что такое выравнивание полей структуры?
2. Зачем нужно выравнивание данных?

Лабораторная работа 12 (1100 = C)

Просмотр и редактирование файлов в шестнадцатеричном представлении. Работа с файлами в C/C++

Версия 2024 г. — засчитывается только в 2024 г. Актуальная версия — в `https://gitlab.com/illinc/gnu-asm`

Лабораторная работа предназначена для групп НБ-31, ПМ-3* и ПИН-41Д; Группы ПИН-2* выполнят её задания через полгода, осенью — сейчас не нужно.

Цель работы: 1) изучить двоичное и шестнадцатеричное представление информации, научиться работать с шестнадцатеричным редактором; 2) изучить структуру простейших форматов файлов; 3) изучить кодировки и кодовые таблицы русского языка.

Штраф за одно пропущенное обязательное задание -2 балла.

Так как задания данной лабораторной работы являются также частью курса ОТИК групп ПИН-, файлы лежат в репозитории ОТИК* `gitlab.com/illinc/otik/`*, в подпапках папки* `/labs-files/`.

Задание на лабораторную работу

Задание ЛС.з1. С помощью hexdump/xxd или шестнадцатеричного просмотровщика/редактора исследуйте файлы различных форматов (некоторые файлы представлены в папке «labs-files/Файлы в разных форматах»). Выделите сигнатуры или иные признаки формата там, где это возможно.

Описания части форматов находятся в папке «labs-files/Описание некоторых форматов», для прочих можно найти в Сети.

Задание ЛС.з2. Определите тип файла, соответствующего номеру варианта $((№ - 1)\%10)$, из папки «labs-files/Варианты 1 — *». Откройте его корректным приложением. Поместите в отчёт тип и описание содержимого файла, а также признаки формата, по которым удалось определить тип.

Задание ЛС.з3. В соответствии с номером варианта отредактируйте (таблица ЛС.1) изображение colorchess16x16x2.bmp, используя шестнадцатеричный редактор. Откройте изменённый файл и убедитесь, что изменения корректны.

Файл colorchess16x16x2.bmp представляет собой изображение 16×16 пикселей, сиренево-болотное (две сиреневые и две болотные клетки по 8×8 пикселей), глубина цвета — 1 бит на пиксель. Убедитесь, что просмотровщик отображает его как цветное (некоторые игнорируют палитру файлов с глубиной 1 бит на пиксель).

Задание ЛС.з4. С помощью hexdump/xxd или шестнадцатеричного просмотровщика/редактора исследуйте файлы формата «простой текст» (plain text), представленные в различных кодировках (папка `labs-files/Файлы в формате простого текста - кодировки разные`, раздел ЛС.1).

Варианты действий для редактирования

Таблица ЛС.1

$(№ - 1)\%3 + 1$	**Вариант**
1	Поставить зелёную точку в правом нижнем углу изображения
2	Поставить сиреневую точку в правом верхнем углу изображения
3	Поставить зелёную точку в левом верхнем углу изображения

Есть ли у простого текста заголовок?

Сравните один и тот же текст, представленный в различных кодировках: размер и шестнадцатеричное представление. Одинаково ли количество байтов для представления одного печатного символа в различных кодировках? Одинаково ли шестнадцатеричное представление пробела в различных кодировках? Цифр? Латинских букв? Русских букв?

Задание ЛС.з5. Бонус +1 или +10 баллов. Для файла $(№ - 1)\%9$ из папки `labs-files/Варианты 2 - определение кодировки простого текста` (далее — файл Z):

- определите, является ли Z простым текстом на русском языке в одной из стандартных кодировок (один из вариантов представляет собой нерусскоязычный текст);
- если да — определите кодировку и декодируйте в UTF-8.

Если для определения кодировки используется существующая программа определения кодировок, задание засчитывается на $+1$ балл. Для получения $+10$ баллов необходимо провести частотный анализ самостоятельно.

Для проведения частотного анализа выполните следующие шаги.

1. Разработайте программу для определения частот октетов (байтов x86) в заданном файле (это может быть как скрипт-однострочник, использующий стандартные утилиты GNU/Linux, так и проект на любом языке программирования в любой среде).

   Хотя в этом задании далее анализироваться будут файлы в формате простого текста — программа, анализирующая распределение октетов, *должна корректно обрабатывать любые файлы.*

2. Рассчитайте частоты появления октетов в файлах, являющихся осмысленным русскоязычным текстом достаточного объёма в различных кодировках (папка `labs-files/Файлы в формате простого текста - кодировки разные`).

Определите:
- четыре наиболее частых октета среди всех используемых;
- четыре наиболее частых октета, не являющихся кодами печатных символов ASCII; для однобайтовых кодировок сопоставьте соотношение их частот с частотами символов русского языка.

Обратите внимание на распределение октетов многобайтовых кодировок Unicode (UTF-8, UTF-16, UTF-32).

3. Рассчитайте частоты появления октетов в файле Z. Определите, аналогично п. 2, четыре наиболее частых октета среди всех и четыре — среди не являющихся кодами печатных символов ASCII.
   Сопоставьте их с результатами п. 2 и с частотами символов русского языка. Определите наиболее вероятную кодировку или нерусскоязычность текста.

4. Если по результатам п. 3 файл Z является русскоязычным текстом в кодировке X — декодируйте Z из X в UTF-8 любой утилитой перекодировки. Проверьте корректность результата.

ЛС.1. Кодировки и кодовые таблицы русского языка

Кодировки и кодовые таблицы

Строго говоря, необходимо различать понятия:
- *кодовая таблица* или таблица кодов — соответствие символов кодам в каком-то диапазоне;
- *кодировка* — представление кода символа в памяти или на диске.

Но обычно их смешивают и называют для краткости «кодировкой» совокупность кодовой таблицы и собственно кодировки.

Это в большинстве случаев не приводит к недопониманию, так как:
- кодировкам UTF-8, UTF-16, UTF-32 всегда соответствует одна и та же универсальная кодовая таблица Unicode, содержащая *все* национальные алфавиты;
- национальным кодовым таблицам (KOI8-R, IBM CP866, Windows-1251 и т. п.) всегда соответствует одна и та же кодировка: код записывается октетом «как есть».

Таким образом, *однобайтовыми кодировками* на практике называются *кодовые таблицы,* сопоставляющие символы кодам в диапазоне 0–255 (0x00–0xFF); коды символов таких таблиц всегда записывается одним октетом (байтом x86). В настоящее время все такие кодовые таблицы сопоставляют кодам 0–127 те же символы, что и кодовая таблица ASCII (являются расширениями кодовой таблицы ASCII). Коды в диапазоне 128–255 описывают национальные кодовые страницы.

Кодовая таблица ASCII сопоставляет символы кодам в диапазоне 0–127 (0x00–0x7F) (см. раздел В). При этом понятие «однобайтовая кодировка ASCII» *не определено,* и в зависимости от контекста может описывать как исторические способы

записи семибитных ASCII-кодов восемью битами (старший бит мог использоваться для контроля чётности, дублировать один из семи младших или всегда быть нулевым), так и Latin-1 (ISO 8859-1), и, чаще, ту однобайтовую кодировку, которая используется на компьютере говорящего.

Кодовая таблица Unicode сопоставляет символы кодам `0`–`0x10 FFFF` (кодам 0–127 соответствуют символы ASCII) то есть не может быть представлена однобайтовой кодировкой. Не всем Unicode-кодам соответствуют символы; так, коды `0xD800`–`0xDFFF` зарезервированы для представления суррогатных пар в UTF-16.

Для кодирования символов Unicode используются три основные кодировки.

1. UTF-8, кодировка переменной длины (изначально от 1 до 6 октетов, позже ограничили до 4) для узких строк:
   - `0xxx xxxx` — ASCII-символы (коды от 0 до $127 =$ `0x7F`) представляются одним байтом, равным ASCII-коду (старший бит — 0).

   Прочие, включая 128–255, представляются не менее чем двумя байтами. Старшие биты первого из k байтов содержат k единиц, затем следует разделитель 0, затем — старшие биты Unicode-кода. Старшие биты последующих байтов — 10, так что представление символа в UTF-8 не равно его коду Unicode:
   - `110x xxxx 10xx xxxx` — символы с Unicode-кодами от $128 =$ `0x80` до `0x7FF`, в том числе греческие, русские и арабские буквы, представляются двумя байтами;
   - `1110 xxxx 10xx xxxx 10xx xxxx` — далее символы до `0xFFFF`, в том числе основные китайские и японские иероглифы — тремя;
   - `1111 0xxx 10xx xxxx 10xx xxxx 10xx xxxx` — прочие символы (с запасом — до `0x1F FFFF`) могут быть представлены четырьмя байтами.

   UTF-8 — наиболее распространённая в настоящее время кодировка Unicode.
2. UTF-16, кодировка переменной длины (от 1 до 2 элементов) для широких строк из двухоктетных (16-битных) элементов:
   - символы с Unicode-кодами `0x0000`–`0xFFFF` записываются одним 16-битным элементом «как есть»; символов с кодами `0xD800`–`0xDFFF` не существует;
   - символы `0x1 0000`–`0x10 FFFF` — двумя элементами: первый лежит в диапазоне `0xD800`–`0xDBFF`, второй — `0xDC00`–`0xDFFF` (суррогатной парой);

   UTF-16 — старейшая кодировка Unicode (первые версии Unicode умещались в один 16-битный элемент). UTF-16, в отличие от UTF-8 и UTF-32, не позволяет записать коды свыше `0x10 FFFF`.
3. UTF-32, кодировка постоянной длины (один 32-битный элемент с запасом вмещает все Unicode-коды) для широких строк из четырёхоктетных (32-битных) элементов.

Кодировки UTF-16 и UTF-32 имеют варианты, соответствующие разному порядку байтов в двух- или четырёхоктетном элементе (LE/BE); по умолчанию подразумевается порядок байтов платформы (LE для x86).

В MS Windows «Unicode» обозначает устаревшую версию кодировки UTF-16 (включающую только 16-битные символы, но не суррогатные пары), что неверно. Однобайтовая кодировка в MS Windows (для русского языка используется кодовая страница Windows-1251) обозначается «ANSI».

Представление русского языка

В папке `labs-files/Файлы в формате простого текста - кодировки разные` представлены основные кодировки/таблицы для русского языка:

1. Многобайтовые кодировки универсальной кодовой таблицы Unicode:
   - UTF-8 — суффикс имени файла utf8;
   - UTF-16 — суффикс utf16;
   - UTF-32 — суффикс utf32.
2. Однобайтовые расширения ASCII:
   - КОИ-8 (код обмена информацией 8-битный) для русского алфавита (KOI8-R), использовавшаяся в России до широкого распространения MS DOS/MS Windows — суффикс koi8r;
   - ISO 8859-5, разработанная ISO и IEC и одно время считавшаяся стандартной, но не использовавшаяся — суффикс iso;
   - IBM CP866 (альтернативная кодировка ГОСТ), использовавшаяся в русифицированной MS DOS — суффикс dos;
   - Windows-1251 (CP1251), использующаяся в русифицированной MS Windows — суффикс windows;
   - MacCyrillic, использующаяся в Mac OS X — суффикс maccyrillic.

   Из-за совпадения кодов наиболее частотных русских букв утилиты распознавания кодировок регулярно путают Windows-1251 и MacCyrillic; для различения этих кодировок необходим дополнительный анализ.

ЛС.2. Вопросы

1. Для чего нужен шестнадцатеричный редактор?
2. Какие функции libc используются для чтения/записи бинарных файлов?
3. Известно, что файл содержит осмысленный русскоязычный текст в одной из представленных в данной работе кодировок. Можно ли, используя только шестнадцатеричный редактор, без частотного анализа, отличить UTF-8, UTF-16, UTF-32: а) друг от друга, б) от однобайтовой кодировки? По каким признакам?

Приложение B. Коды ASCII

ASCII CONTROL CODE CHART

b7 b6 b5 / BITS b4 b3 b2 b1	0 0 0	0 0 1	0 1 0	0 1 1	1 0 0	1 0 1	1 1 0	1 1 1
	CONTROL		SYMBOLS NUMBERS		UPPER CASE		LOWER CASE	
0 0 0 0	0 NUL 0 0	16 DLE 10 20	32 SP 20 40	48 0 30 60	64 @ 40 100	80 P 50 120	96 ‘ 60 140	112 p 70 160
0 0 0 1	1 SOH 1 1	17 DC1 11 21	33 ! 21 41	49 1 31 61	65 A 41 101	81 Q 51 121	97 a 61 141	113 q 71 161
0 0 1 0	2 STX 2 2	18 DC2 12 22	34 ” 22 42	50 2 32 62	66 B 42 102	82 R 52 122	98 b 62 142	114 r 72 162
0 0 1 1	3 ETX 3 3	19 DC3 13 23	35 # 23 43	51 3 33 63	67 C 43 103	83 S 53 123	99 c 63 143	115 s 73 163
0 1 0 0	4 EOT 4 4	20 DC4 14 24	36 $ 24 44	52 4 34 64	68 D 44 104	84 T 54 124	100 d 64 144	116 t 74 164
0 1 0 1	5 ENQ 5 5	21 NAK 15 25	37 % 25 45	53 5 35 65	69 E 45 105	85 U 55 125	101 e 65 145	117 u 75 165
0 1 1 0	6 ACK 6 6	22 SYN 16 26	38 & 26 46	54 6 36 66	70 F 46 106	86 V 56 126	102 f 66 146	118 v 76 166
0 1 1 1	7 BEL 7 7	23 ETB 17 27	39 ’ 27 47	55 7 37 67	71 G 47 107	87 W 57 127	103 g 67 147	119 w 77 167
1 0 0 0	8 BS 8 10	24 CAN 18 30	40 (28 50	56 8 38 70	72 H 48 110	88 X 58 130	104 h 68 150	120 x 78 170
1 0 0 1	9 HT 9 11	25 EM 19 31	41) 29 51	57 9 39 71	73 I 49 111	89 Y 59 131	105 i 69 151	121 y 79 171
1 0 1 0	10 LF A 12	26 SUB 1A 32	42 * 2A 52	58 : 3A 72	74 J 4A 112	90 Z 5A 132	106 j 6A 152	122 z 7A 172
1 0 1 1	11 VT B 13	27 ESC 1B 33	43 + 2B 53	59 ; 3B 73	75 K 4B 113	91 [5B 133	107 k 6B 153	123 { 7B 173
1 1 0 0	12 FF C 14	28 FS 1C 34	44 , 2C 54	60 < 3C 74	76 L 4C 114	92 \ 5C 134	108 l 6C 154	124 | 7C 174
1 1 0 1	13 CR D 15	29 GS 1D 35	45 – 2D 55	61 = 3D 75	77 M 4D 115	93] 5D 135	109 m 6D 155	125 } 7D 175
1 1 1 0	14 SO E 16	30 RS 1E 36	46 . 2E 56	62 > 3E 76	78 N 4E 116	94 ^ 5E 136	110 n 6E 156	126 ~ 7E 176
1 1 1 1	15 SI F 17	31 US 1F 37	47 / 2F 57	63 ? 3F 77	79 O 4F 117	95 ¨ 5F 137	111 o 6F 157	127 DEL 7F 177

LEGEND: dec / CHAR / hex oct

Victor Eijkhout
Dept. of Comp. Sci.
University of Tennessee
Knoxville TN 37996, USA

Литература

1. AMD64 Architecture Programmer's Manual Volume 1: Application Programming. USA, Sunnyvale: Advanced Micro Devices Inc., 2013. Т. 1. 390 с.
2. AMD64 Architecture Programmer's Manual Volume 2: System Programming. USA, Sunnyvale: Advanced Micro Devices Inc., 2013. Т. 2. 690 с.
3. AMD64 Architecture Programmer's Manual Volume 3: General-Purpose and System Instructions. USA, Sunnyvale: Advanced Micro Devices Inc., 2017. Т. 3. 681 с.
4. AMD64 Architecture Programmer's Manual Volume 4: 128-Bit and 256-Bit Media Instructions. USA, Sunnyvale: Advanced Micro Devices Inc., 2017. Т. 4. 1045 с.
5. AMD64 Architecture Programmer's Manual Volume 5: 64-Bit Media and x87 Floating-Point Instructions. USA, Sunnyvale: Advanced Micro Devices Inc., 2016. Т. 5. 372 с.
6. Bartlett J. Programming from the Ground Up. USA: Bartlett Publishing, 2003. 326 с.
7. Coleman C. L. Using Inline Assembly With gcc. USA, Boston: Free Software Foundation, Inc, 2000. 25 с.
8. Elsner D., Fenlason J. Using as. USA, Boston: Free Software Foundation, Inc, 2009. 318 с.
9. Fog A. Calling conventions for different C++ compilers and operating systems. Denmark, Copenhagen: Technical University of Denmark, 2014. 57 с.
10. Fog A. Optimizing subroutines in assembly language. An optimization guide for x86 platforms. Denmark, Copenhagen: Technical University of Denmark, 2017. 170 с.
11. Glaser A. History of binary and other nondecimal numeration. USA: Tomash publishers, 1981. 231 с.
12. IBM 7090 Data Processing System. USA, New York: International Business Machines Corporation, 1959. 16 с.
13. IEEE Standard for Binary Floating-Point Arithmetic. USA, New York: IEEE, 1985. 23 с.
14. IEEE Std 754™-2008 (Revision of IEEE Std 754-1985). IEEE Standard for Floating-Point Arithmetic. USA, New York: IEEE, 2008. 70 с.
15. Intel® 64 and IA-32 Architectures Optimization Reference Manual. USA, Santa Clara: Intel Corporation, 2016. 672 с.
16. Intel® 64 and IA-32 Architectures Software Developer's Manual. Basic Architecture. USA, Santa Clara: Intel Corporation, 2017. Т. 1. 482 с.
17. Intel® 64 and IA-32 Architectures Software Developer's Manual. Instruction Set Reference, A-Z. USA, Santa Clara: Intel Corporation, 2017. Т. 2. 2234 с.

18. Intel® 64 and IA-32 Architectures Software Developer's Manual. System Programming Guide. USA, Santa Clara: Intel Corporation, 2017. Т. 3. 1660 с.
19. Intel® 64 and IA-32 Architectures Software Developer's Manual. Model-Specific Registers. USA, Santa Clara: Intel Corporation, 2017. Т. 4. 420 с.
20. ISO/IEC 9899:201x. Programming languages — C. Committee Draft — April 12, 2011. ISO/IEC, 2011. 701 с.
21. Juan Caramuel Lobkowitz: The Last Scholastic Polymath / Под ред. P. Dvořák, J. Schmutz. Czech Republic, Prague: Filosofia, 2008. 408 с.
22. Neumann J. v. First Draft of a Report on the EDVAC: Tech. rep.: 1945.
23. Rojas R. Konrad Zuse's Legacy: The Architecture of the Z1 and Z3 // Annals of the History of Computing, IEEE. 1997. — apr-jun. Vol. 19, no. 2. P. 5–16.
24. Stallman R. M., the GCC Developer Community. Using the GNU Compiler Collection For GCC version 5.4.0. USA, Boston: GNU Press, 2015. 810 с.
25. Working Draft, Standard for Programming Language C++. ISO/IEC, 2014. 1368 с.
26. Абель П. Язык Ассемблера для IBM PC и программирования. М.: Высшая школа, 1992. 447 с.
27. Александров Е. К., Грушвицкий Р. И., Купрянов М. С., Мартынов О. Е. Микропроцессорные системы. СПб: Политехника, 2002. 935 с.
28. Бурдаев О. В., Иванов М. А., Тетерин И. И. Ассемблер в задачах защиты информации. М.: Кудиц-образ, 2004. 538 с.
29. Вандевурд Д., Джосаттис Н. М. Шаблоны C++: справочник разработчика. М: Вильямс, 2008. 544 с.
30. Воройский Ф. С. Информатика. Новый систематизированный толковый словарь. М: Физматлит, 2003. 760 с.
31. ГОСТ 19.701-90 Схемы алгоритмов, программ, данных и систем. Обозначения условные и правила выполнения. М: Стандартинформ, 2010. 158 с.
32. ГОСТ 34.003-90 Информационная технология. Комплекс стандартов на автоматизированные системы. Автоматизированные системы. Термины и определения. М: Стандартинформ, 2009. 16 с.
33. Ершов А. П., Шура-Бура М. Р. Становление программирования в СССР. Новосибирск: Сибирское отделение РАН Институт систем информатики им. А. П. Ершова, 2016. 79 с.
34. Зубков С. В. Assembler для DOS, Windows и UNIX. М: ДМК-Пресс, 2017. 638 с.
35. Касперски К. Техника оптимизации программ. Эффективное использование памяти. СПб: БХВ-Петербург, 2003. 464 с.
36. Касперски К., Рокко Е. Искусство дизассемблирования. СПб: БХВ-Петербург, 2009. 896 с.
37. Кушнерев Н. Т., Неменман М. Е., Цагельский В. И. Программирование для ЭВМ «Минск-32». М: Статистика, 1973. 248 с.

38. Малашевич Б. М. Неизвестные модулярные супер-ЭВМ // PCWeek Russian Edition. 2005. № 9. С. 44–45.
39. Малашевич Б. М. Модулярная арифметика и модулярные компьютеры // История информационных технологий в СССР. Знаменитые проекты: компьютеры, связь, микроэлектроника. М.: Книма, 2016. С. 228–257.
40. Орлов С. А., Цилькер Б. Я. Организация ЭВМ и систем. Фундаментальный курс по архитектуре и структуре современных компьютерных средств. 3-е издание. СПб: Питер, 2014. 688 с.
41. Пухальский Г. И., Новосельцева Т. Я. Цифровые устройства: Учебное пособие для втузов. СПб: Политехника, 1996. 885 с.
42. Ревич Ю. В., Малиновский Б. Н. Информационные технологии в СССР. Создатели советской вычислительной техники. СПб: BHV, 2014. 336 с.
43. Садыхов Р. Х., Поденок Л. П., Отвагин А. В. и др. Средства параллельного программирования в ОС Linux. Мн.: ЕГУ, 2004. 475 с.
44. Смоленцев М. Программирование на языке Ассемблера для 32/64-разрядных микропроцессоров семейства 80x86. Иркутск: ИрГУПС, 2009. 192 с.
45. Таненбаум Э., Остин Т. Архитектура компьютера. СПб: Питер, 2014. 816 с.
46. Федотов А. М. Современные проблемы информатики и вычислительной техники. Новосибирск: Новосибирский государственный университет, 2010. 43 с.
47. Фомин С. В. Системы счисления. М: Наука, 1987. 48 с.
48. Фролов А., Фролов Г. Аппаратное обеспечение персонального компьютера. М: Диалог-МИФИ, 1997. 304 с.
49. Шелихов А. А., Селиванов Ю. П. Вычислительные машины. Справочник. М: Энергия, 1973. 216 с.
50. Юричев Д. Reverse Engineering для начинающих. China: PTPress publisher, 2017. 1063 с.
51. Юров В. И. Архитектура компьютера. СПб: Питер, 2010. 637 с.
52. A Brief Tutorial on GCC inline asm (x86 biased) [Электронный ресурс]. URL: `http://www.osdever.net/tutorials/view/a-brief-tutorial-on-gcc-inline-asm` (дата обращения: 07.07.2017).
53. Asmworld. Программирование на ассемблере для начинающих и не только [Электронный ресурс]. URL: `http://asmworld.ru/` (дата обращения: 07.07.2017).
54. AT&T Syntax bugs [Электронный ресурс]. URL: `http://sourceware.org/binutils/docs/as/i386_002dBugs.html` (дата обращения: 07.07.2017).
55. CSCI 241 Intermediate Programming in C++ Spring 2015 (The C++ compilation process) [Электронный ресурс]. URL: `http://faculty.cs.niu.edu/~mcmahon/CS241/Notes/compile.html` (дата обращения: 07.07.2017).
56. David John Wheeler [Электронный ресурс]. URL: `http://www.thocp.net/biographies/wheeler_david.htm` (дата обращения: 07.07.2017).

57. Eijkhout V. ASCII control code chart [Электронный ресурс]. URL: http://mirror.macomnet.net/pub/CTAN/help/Catalogue/entries/ascii-chart.html (дата обращения: 07.07.2017). 2009.
58. GCC and File Extensions [Электронный ресурс]. URL: http://labor-liber.org/en/gnu-linux/development/extensions (дата обращения: 07.07.2017).
59. Guyver M. The Trouble With FSUB [Электронный ресурс]. URL: http://www.mindfruit.co.uk/2012/03/trouble-with-fsub.html (дата обращения: 07.07.2017). 2012.
60. History of operating systems [Электронный ресурс]. URL: http://www.osdata.com/kind/history.htm (дата обращения: 07.07.2017).
61. How to use RIP Relative Addressing in a 64-bit assembly program? [Электронный ресурс]. URL: https://stackoverflow.com/questions/3250277/how-to-use-rip-relative-addressing-in-a-64-bit-assembly-program (дата обращения: 07.07.2017).
62. Linux Syscall Reference [Электронный ресурс]. URL: http://syscalls.kernelgrok.com/ (дата обращения: 07.07.2017).
63. Lonesome TSH/Digital Daemons. Inline Assembler в GCC [Электронный ресурс]. URL: http://sysbin.com/files/lowlevel/gcc_inline_assembly.htm (дата обращения: 07.07.2017).
64. Microsoft. x64 calling convention [Электронный ресурс]. URL: https://docs.microsoft.com/en-us/cpp/build/x64-calling-convention?view=msvc-160 (дата обращения: 11.11.2020).
65. Padua S. The Marvellous Analytical Engine — How It Works [Электронный ресурс]. URL: http://sydneypadua.com/2dgoggles/the-marvellous-analytical-engine-how-it-works/ (дата обращения: 07.07.2017). 2015.
66. Rojas R. Наследие Конрада Цузе: Архитектура Z1 и Z3 [Электронный ресурс]. URL: https://geektimes.ru/post/210412/ (дата обращения: 07.07.2017).
67. Sandeep.S. GCC-Inline-Assembly-HOWTO [Электронный ресурс]. URL: http://ibiblio.org/gferg/ldp/GCC-Inline-Assembly-HOWTO.html (дата обращения: 07.07.2017).
68. Valsorda F. Searchable Linux Syscall Table for x86 and x86_64 [Электронный ресурс]. URL: https://filippo.io/linux-syscall-table/ (дата обращения: 07.07.2017).
69. Алексеев А. Написание и отладка кода на ассемблере x86/x64 в Linux [Электронный ресурс]. URL: https://eax.me/linux-assembler/ (дата обращения: 07.07.2017). 2016.
70. Алексеев А. Шпаргалка по основным инструкциям ассемблера x86/x64 [Электронный ресурс]. URL: https://eax.me/assembler-basics/ (дата обращения: 07.07.2017). 2016.

71. Архитектура системы [Электронный ресурс]. URL: http://infosys2006.narod.ru/struct/architec.htm (дата обращения: 07.07.2017).
72. Гончаров В. Управление памятью в сетевой подсистеме и ядре FreeBSD в целом [Электронный ресурс]. URL: https://nuclight.livejournal.com/129544.html?nojs=1 (дата обращения: 07.07.2017).
73. Ильин Е. История UNIX-систем [Электронный ресурс]. URL: http://jenyay.net/blog/2012/02/04/history-unix-systems/ (дата обращения: 07.07.2017). 2012.
74. Караваев Д. Ю. Об исключенных командах или за что «списали» инструкцию INTO? [Электронный ресурс]. URL: http://rsdn.org/article/pl1/pl1ex12/pl1ex12.xml (дата обращения: 07.07.2017).
75. Клуб 155. Архитектура и система команд микропроцессоров x86 [Электронный ресурс]. URL: http://www.club155.ru/programming (дата обращения: 07.07.2017).
76. Михайличенко А. Приведение типов [Электронный ресурс]. URL: https://habrahabr.ru/post/106294/ (дата обращения: 07.07.2017).
77. Поляков А. В. Нормализованная запись числа [Электронный ресурс]. URL: http://av-assembler.ru/asm/afd/asm-real-normalization.htm (дата обращения: 07.07.2017).
78. Потёмкин А. Основы компьютера для маньяков [Электронный ресурс]. URL: http://phg.su/basis2/base.htm (дата обращения: 07.07.2017).
79. Ревич Ю. В. ЕС ЭВМ. Крупнейший промах или всеобщее счастье? [Электронный ресурс]. URL: http://nnm.me/blogs/2bytes/es_evm_krupneyshiy_promah_ili_vseobshee_schaste/ (дата обращения: 07.07.2017).
80. Сагалаева Е. Приведение типов в C++ [Электронный ресурс]. URL: http://alenacpp.blogspot.ru/2005/08/c.html (дата обращения: 07.07.2017).
81. Семенко А. Smart ASM [Электронный ресурс]. URL: http://sasm.narod.ru (дата обращения: 07.07.2017).
82. Холодилов С. А. Код Грея [Электронный ресурс]. URL: http://rsdn.org/article/alg/gray.xml (дата обращения: 07.07.2017).
83. Яшкардин В. IEEE 754 — стандарт двоичной арифметики с плавающей точкой [Электронный ресурс]. URL: http://www.softelectro.ru/ieee754.html (дата обращения: 07.07.2017). 2012.

Предметный указатель

Список таблиц

Список иллюстраций

Оглавление